



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه هوش مصنوعی

گزارش پروژه کارشناسی

رشته مهندسی کامپیوتر گرایش هوش مصنوعی

عنوان پروژه:

توسعه يك عامل يادگيري تقويتي براي تصميم گيري در بازارهاي مالي
با بهره گيري از مدل هاي زباني بزرگ

استاد راهنما:

دکتر حسین کارشناس

پژوهشگر:

متین اعظمی

شهریور ۱۴۰۴



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه هوش مصنوعی

پروژه کارشناسی رشته مهندسی کامپیوتر گرایش هوش مصنوعی

آقای متین اعظمی

تحت عنوان:

توسعه يك عامل يادگيري تقويتي براي تصميم گيري در بازارهاي مالي
با بهره گيري از مدل هاي زباني بزرگ

در تاريخ _____ / _____ / _____ توسط هیأت داوران زیر بررسی و با نمره
_____ به تصویب نهایی رسید.

۱ - استاد راهنمای پروژه: دکتر _____ امضا _____

۲ - استاد داور: دکتر _____ امضا _____

امضای مدیر گروه _____

تشر و قدردانی

با تشکر،
متین اعظمی
شهریور ۱۴۰۴

تقديم به

چکیده

کلمات کلیدی:

فهرست مطالب

۹	۱ فهرست مخفف‌ها
۱۰	۲ مقدمه
۱۰	۲-۱- اهداف و دامنه پژوهش
۱۱	۲-۲- کاربردها و اهمیت عملی
۱۲	۲-۳- پرسش‌های پژوهش و فرضیه‌ها
۱۳	۲-۴- ساختار گزارش
۱۵	۳ مفاهیم نظری
۱۵	۳-۱- مقدمه
۱۶	۳-۲- مبانی یادگیری تقویتی
۱۶	۳-۲-۱- اجزای اصلی
۱۷	۳-۲-۲- اکتشاف ^۱ در برابر بهره‌برداری ^۲
۱۷	۳-۲-۳- وظایف رویدادمحور ^۳ در برابر وظایف پیوسته ^۴
۱۸	۳-۲-۴- یادگیری درون‌سیاستی ^۵ در برابر برون‌سیاستی ^۶
۱۹	۳-۲-۵- روش‌های مدل‌مبنا ^۷ در برابر مدل‌نامبنا ^۸
۲۰	۳-۳- الگوریتم‌های یادگیری تقویتی
۲۰	۳-۳-۱- Q-Learning و شبکه‌های Q عمیق ^۹
۲۱	۳-۳-۲- روش‌های گرادیان سیاست ^{۱۰}
۲۲	۳-۳-۳- روش‌های بازیگر-منتقد ^{۱۱}
۲۳	۳-۳-۴- Proximal Policy Optimization (PPO)
۲۴	۳-۳-۵- PPO بازگشتی ^{۱۲}
۲۴	۳-۴- مبانی مدل‌های زبانی بزرگ
۲۴	۳-۴-۱- معماری Transformer

Exploration^۱

Exploitation^۲

Episodic Tasks^۳

Continuous Tasks^۴

On-Policy Learning^۵

Off-Policy Learning^۶

Model-Based Methods^۷

Model-Free Methods^۸

۲۶	۳-۴-۲ جاسازی واژه‌ها و جاسازی‌های متنی
۲۶	۳-۴-۳ پیش‌آموزش در برابر ریزتنظیم و تنظیم مبتنی بر دستور
۲۷	۳-۴-۴ تحلیل احساسات در زمینه مالی ^{۱۳}
۲۹	۳-۵-۵ داده‌های بازار و شاخص‌های مالی
۲۹	۳-۵-۱ مبانی داده‌های OHLCV ^{۱۴}
۳۰	۳-۵-۲ شاخص‌های فنی پرکاربرد
۳۲	۳-۵-۳ چالش‌های موجود در بازارهای مالی
۳۳	۳-۵-۴ شاخص‌ها و دارایی‌های مالی اصلی ^{۱۵}
۳۴	۳-۶-۶ مدیریت سبد دارایی‌ها و محدودیت‌های معامله‌گری
۳۴	۳-۶-۱ معامله تک‌سهم در برابر معامله سبد دارایی‌ها
۳۵	۳-۶-۲ فضای حالت ^{۱۶}
۳۷	۳-۶-۳ شکل‌دهی پاداش ^{۱۷}
۳۸	۳-۶-۴ هزینه‌های تراکنش، لغزش قیمتی و محدودیت‌های نقدشوندگی ^{۱۸}
۳۹	۳-۶-۵ معیارهای ریسک ^{۱۹}
۴۱	۳-۶-۶ معیارهای ارزیابی ^{۲۰}
۴۳	۳-۷-۷ جمع‌بندی

۴۴	۴ مرور ادبیات
۴۴	۴-۱-۱ مقدمه
۴۵	۴-۲-۲ مدل‌های زبانی بزرگ و پردازش زبان طبیعی مالی
	Applications: Financial for Models Language Large of Survey A- ۱-۲-۴
۴۵	[۱] Challenges and Prospects Progress, Lan- Pre-trained with Analysis Sentiment Financial FinBERT:- ۲-۲-۴
۴۶	[۲] Models guage
۴۸	[۳] Models Language Large Financial Open-Source FinGPT:- ۳-۲-۴
۴۹	۴-۳-۳ کتابخانه‌ها و مرورهای RL در مالی
	Trad- Algorithmic Quantitative in Learning Reinforcement Deep- ۱-۳-۴
۴۹	[۴] Review A ing: Imple- Learning Reinforcement Reliable Stable-Baselines۳:- ۲-۳-۴
۵۰	[۵] mentations Automated for Library Learning Reinforcement Deep A FinRL:- ۳-۳-۴
۵۲	[۶] Finance Quantitative in Trading Stock Trading: Stock Automated for Learning Reinforcement Deep- ۴-۳-۴
۵۳	[۷] Strategy Ensemble An Stock Automated Learning-Based Reinforcement Deep Novel A- ۵-۳-۴
۵۵	[۸] Networks LSTM Cascaded Using System Trading Reinforced Hierarchical A Enough: not is Fee Commission- ۶-۳-۴
۵۶	[۹] Management Portfolio for Framework

	Reinforce- Deep on Based Framework Fusion Data Multi-Type ۷-۳-۴
۵۷	[۱۰] Trading Algorithmic for Learning ment
	Ap- Learning Reinforcement Deep Sentiment-Aware Market ۸-۳-۴
۵۹	[۱۱] Allocation Portfolio Stock for proach
	Opti- for Framework Learning Reinforcement Multi-Agent A ۹-۳-۴
۶۰	[۱۲] TimesNet on Based Strategies Trading Financial mizing
۶۱	۴-۴-۴- رویکردهای ترکیبی: ادغام مدل‌های زبانی بزرگ با یادگیری تقویتی در مالی
	Con- with System Multi-Agent LLM Synthesized A FINCON ۱-۴-۴
	Deci- Financial Enhanced for Reinforcement Verbal ceptual
۶۱	[۱۳] Making sion
۶۳	۴-۵- جمع‌بندی

فهرست تصاویر

- (۳-۱) پچارچوب کلی یادگیری تقویتی [۱۴]. ۱۶
- (۳-۲) نمایی از موازنه اکتشاف - بهره‌برداری [۱۵]. ۱۸

فهرست جداول

۴۵	 (۱-۴) حوزه‌های کاربرد مدل‌های زبانی بزرگ در مالی (اقتباس شده از [۱])
۴۷	 FinBERT شناسی کلیمای کلی روش شناسی
۴۸	 FinGPT شناسی کلیمای روش شناسی
۵۰	 (۴-۴) بسته‌بندی رویکردهای DRL در معامله‌گری (اقتباس شده از [۴])
۵۲	 framework FinRL the of components Key (۵-۴)
۵۴	 (۶-۴) مروری بر راهبرد تجمیعی (Li et al., ۲۰۲۰)

فصل ۱

فهرست مخفف‌ها

فصل ۲

مقدمه

۲-۱ - اهداف و دامنه پژوهش

هدف اصلی این پژوهش آن است که بررسی شود آیا عامل‌های یادگیری تقویتی^۱ که با اطلاعات احساسی استخراج شده از مدل‌های زبانی بزرگ^۲ تقویت شده‌اند، قادر به بهبود عملکرد معاملاتی در بازارهای مالی هستند یا خیر. روش‌های یادگیری تقویتی در سال‌های اخیر به‌طور فزاینده‌ای در حوزه‌های معاملات الگوریتمی و مدیریت سبد سهام^۳ به کار گرفته شده‌اند [۴] و از این رو بستری مناسب برای این پژوهش فراهم می‌آورند. برای تحقق این هدف، پژوهش حاضر اهداف زیر را دنبال می‌کند:

- توسعه و ارزیابی عامل‌های یادگیری تقویتی برای معامله‌گری در بازارهای مالی.
- یکپارچه‌سازی ویژگی‌های احساسی استخراج شده از اخبار مرتبط (با بهره‌گیری از مدل‌های زبانی بزرگ) همراه با داده‌های بازار و شاخص‌های فنی.
- مقایسه عملکرد مدل‌های پیشنهادی با مدل‌های سنتی، راهبردهای مبتنا^۴ و یافته‌های پژوهش‌های دانشگاهی اخیر.
- بررسی تأثیر طراحی فضای حالت^۵ و فضای عمل^۶، شکل‌دهی پاداش^۷ و انتخاب ابرپارامترها^۸ بر کارایی مدل.
- ارزیابی الگوریتم‌های پیشرفته و بررسی ادغام معماری‌هایی مانند LSTM در این الگوریتم‌ها به منظور بهبود عملکرد معاملاتی.

دامنه پژوهش به صورت زیر تعریف می‌شود:

Learning Reinforcement^۱

Models Language Large^۲

Portfolio^۳

Baseline^۴

Space State^۵

Space Action^۶

Shaping Reward^۷

Hyperparameters^۸

- تحلیل صرفاً محدود به اجزای شاخص Dow Jones Industrial Average (Dow30) است و به سایر طبقات دارایی یا بازارهای جهانی تعمیم داده نمی‌شود.
- داده‌های بازار شامل داده‌های OHLCV^۹ و سیگنال‌های احساسی مبتنی بر FinBERT [۲]، FinGPT [۳] و اخبار گوگل است. منابع جایگزین مانند شبکه‌های اجتماعی یا داده دفتر سفارش^{۱۰} در این پژوهش مدنظر قرار نمی‌گیرند.
- تمرکز پژوهش بر افق‌های معاملاتی روزانه است و معاملات با فرکانس بسیار بالا^{۱۱} خارج از دامنه بررسی قرار دارند.
- مدل‌ها صرفاً در محیط پژوهشی طراحی و ارزیابی می‌شوند و هدف، توسعه سامانه‌های معاملاتی آماده بهره‌برداری نیست.
- ارزیابی‌ها بر اساس شاخص‌های رایج عملکرد و ریسک انجام می‌شود. بهینه‌سازی سبد سرمایه‌گذاری بلندمدت و راهبردهای تخصیص سرمایه در این پژوهش بررسی نمی‌شوند.

۲-۲- کاربردها و اهمیت عملی

توسعه **عامل‌های یادگیری تقویتی** تقویت‌شده با **مدل‌های زبانی بزرگ** دارای پتانسیل کاربردی چشمگیری در حوزه‌های معامله‌گری الگوریتمی و مدیریت سبد سرمایه‌گذاری است. با ترکیب داده‌های ساختاریافته بازار با اطلاعات احساسی غیرساختاریافته، این سامانه‌ها قادر خواهند بود تصمیم‌گیری **انطباقی و بسترآگاه**^{۱۲} را پشتیبانی کرده و در نتیجه عملکرد تعدیل‌شده بر اساس ریسک را بهبود دهند. چارچوب پیشنهادی این پژوهش صرفاً به آزمایش‌های نظری محدود نیست، بلکه قابلیت به‌کارگیری مستقیم در خطوط لوله معاملاتی خودکار، سامانه‌های پشتیبان تصمیم‌گیری سرمایه‌گذاری و بسترهای پایش ریسک مالی را نیز دارد.

با وجود آنکه معامله مستقیم در بازارهای سهام بین‌المللی از ایران به دلیل محدودیت‌های نظارتی و ژئوپلیتیکی در حال حاضر امکان‌پذیر نیست، پیاده‌سازی عملی همچنان از طریق کارگزاران واسطه و پلتفرم‌های معاملاتی برخط (مانند RoboForex و ارائه‌دهندگان مشابه) میسر است. این واسطه‌ها دسترسی به شاخص‌های جهانی سهام، بازار ارز و سایر طبقات دارایی را فراهم می‌کنند و در نتیجه ادغام عامل‌های مبتنی بر یادگیری تقویتی در سناریوهای معاملاتی واقعی را امکان‌پذیر می‌سازند. بنابراین، هرچند مدل‌های ارائه‌شده در این پژوهش رویکردی پژوهشی دارند، می‌توان آن‌ها را برای اجرای نیمه‌خودکار یا تمام‌خودکار از طریق اتصال به **رابط‌های برنامه‌نویسی کارگزاری**^{۱۳} تطبیق و پیاده‌سازی کرد.

زمان‌بندی این پژوهش نیز اهمیت ویژه‌ای دارد. با پیشرفت سریع فناوری‌های یادگیری تقویتی و مدل‌های زبانی بزرگ، بازارهای مالی وارد مرحله‌ای تازه از تصمیم‌گیری مبتنی بر هوش مصنوعی شده‌اند. توانایی یادگیری تقویتی در بهینه‌سازی راهبردهای دنباله‌دار و قابلیت مدل‌های زبانی بزرگ در تفسیر حجم انبوه داده‌های متنی و احساسی، مزیتی هم‌افزا برای سرمایه‌گذاران ایجاد می‌کند. در عصری که با نوسان‌پذیری، جهانی‌شدن و اهمیت

^۹ (OHLCV) Volume Close, Low, High, Open

^{۱۰} Book Order

^{۱۱} Trading High-Frequency

^{۱۲} Context-Aware

^{۱۳} APIs Brokerage

روزافزون معامله‌گری مبتنی بر اطلاعات تعریف می‌شود، سامانه‌های یکپارچه مبتنی بر یادگیری تقویتی و مدل‌های زبانی بزرگ می‌توانند منافع مالی قابل‌توجهی همچون بازدهی بالاتر و مدیریت ریسک مقاوم‌تر را فراهم آورند.

۲-۳- پرسش‌های پژوهش و فرضیه‌ها

این پژوهش بر اساس پرسش‌های زیر و فرضیه‌های متناظر با آن‌ها سازمان‌دهی شده است:

کارایی یادگیری تقویتی در مقایسه با رویکردهای سنتی

- پرسش پژوهش ۱: (RQ1) آیا عامل‌های یادگیری تقویتی^{۱۴} در مقایسه با مدل‌های سنتی، راهبردهای مینا و رویکردهای گزارش‌شده در پژوهش‌های دیگر در معاملات شاخص Dow30 و سایر وظایف معاملاتی بازار عملکرد بهتری دارند؟
- فرضیه ۱: (H1) انتظار می‌رود عامل‌های یادگیری تقویتی بازدهی تعدیل‌شده بر اساس ریسک بالاتری نسبت به مدل‌های سنتی و راهبردهای مینا ارائه دهند؛ هرچند ممکن است در مقایسه با پیشرفته‌ترین رویکردهای روز همواره برتری نداشته باشند.

تأثیر داده‌های احساسی و داده‌های بازار

- پرسش پژوهش ۲: (RQ2) آیا افزودن ویژگی‌های احساسی استخراج‌شده از اخبار مرتبط موجب بهبود عملکرد معاملاتی نسبت به مدل‌های صرفاً مبتنی بر قیمت می‌شود؟
- فرضیه ۲: (H2) انتظار می‌رود ویژگی‌های احساسی استخراج‌شده از اخبار مرتبط عملکرد معاملاتی را نسبت به مدل‌های صرفاً مبتنی بر داده‌های قیمتی بهبود دهند.
- پرسش پژوهش ۳: (RQ3) آیا روند قیمت سهام اعتبار ویژگی‌های احساسی استخراج‌شده از اخبار را تأیید می‌کند؟
- فرضیه ۳: (H3) انتظار می‌رود ویژگی‌های احساسی دارای ارتباط با حرکات قیمتی باشند و بتوانند اطلاعات تکمیلی ارزشمندی برای بهبود عملکرد مدل فراهم کنند.
- پرسش پژوهش ۴: (RQ4) شکل‌دهی پاداش و طراحی فضای عمل و فضای حالت چه تأثیری بر عملکرد مدل‌های معاملاتی مبتنی بر یادگیری تقویتی دارند؟
- فرضیه ۴: (H4) انتظار می‌رود شکل‌دهی پاداش و طراحی دقیق فضای عمل و فضای حالت تأثیر مثبتی بر عملکرد عامل‌های معاملاتی مبتنی بر یادگیری تقویتی داشته باشند.

معماری مدل‌ها و ابرپارامترها

- پرسش پژوهش ۵: (RQ5) آیا ترکیب LSTM^{۱۵} با الگوریتم‌های یادگیری تقویتی مانند Recur-rent PPO (RPPO) به بهبود پایدار عملکرد منجر می‌شود؟

^{۱۴} (RL) Learning Reinforcement

^{۱۵} (LSTM) Memory Short-Term Long

فرضیه ۵: (H5) ترکیب معماری‌های LSTM با الگوریتم‌های یادگیری تقویتی مانند RPPO با افزایش توانایی مدل در تشخیص الگوهای دنباله‌ای، عملکرد آن را بهبود خواهد داد.

• **پرسش پژوهش ۶: (RQ6)** کدام رویکرد استخراج و بازنمایی ویژگی‌های احساسی برای معامله‌گری مالی کارآمدتر است؟

فرضیه ۶: (H6) انتظار می‌رود رویکردهای ترکیبی در استخراج احساسات، بازنمایی مؤثرتری نسبت به استفاده منفرد از یک روش ارائه دهند.

• **پرسش پژوهش ۷: (RQ7)** ابرپارامترهای الگوریتمی^{۱۶} تا چه اندازه بر عملکرد و پایداری راهبردهای معاملاتی مبتنی بر یادگیری تقویتی اثرگذارند؟

فرضیه ۷: (H7) انتظار می‌رود ابرپارامترهای الگوریتمی نقش مهم و تعیین‌کننده‌ای در بهبود یا تضعیف عملکرد و پایداری مدل‌های معاملاتی مبتنی بر یادگیری تقویتی داشته باشند.

۲-۴- ساختار گزارش

این گزارش در نه فصل تنظیم شده است:

فصل اول مقدمه است و به اهداف پژوهش، پرسش‌ها و فرضیه‌ها، اهمیت عملی و دامنه مطالعه می‌پردازد.

فصل دوم مبانی نظری پژوهش را معرفی می‌کند. این فصل به مرور اصول یادگیری تقویتی، مدل‌های زبانی بزرگ، داده‌ها و اطلاعات مرتبط به بازارهای مالی و محدودیت‌های عملی معامله‌گری می‌پردازد.

فصل سوم مروری بر ادبیات مرتبط ارائه می‌دهد. این فصل به بررسی پژوهش‌های مربوط به کاربرد مدل‌های زبانی بزرگ و یادگیری تقویتی در حوزه مالی و رویکردهای ترکیبی آن‌ها در معامله‌گری می‌پردازد.

فصل چهارم روش‌شناسی پژوهش و طراحی کلی سامانه را توضیح می‌دهد و به تعریف رسمی مسئله و معماری چارچوب پیشنهادی می‌پردازد.

فصل پنجم به «توصیف پروژه» اختصاص دارد و شامل زیربخش‌های زیر است:

• مقدمه

• توصیف بازار انتخاب‌شده

• گردآوری داده‌ها

• پیش‌پردازش داده‌ها

• تحلیل داده‌ها

• استخراج احساسات از اخبار

• محیط معامله‌گری

• عامل یادگیری تقویتی

• پایش

^{۱۶} Hyperparameters

• ارائه و استقرار

فصل ششم به پیاده‌سازی اختصاص دارد و جزئیات فرآیند اجرا، ابزارها و چارچوب‌های مورد استفاده، ملاحظات مربوط به بازتولیدپذیری و منابع محاسباتی را بیان می‌کند.

فصل هفتم طراحی آزمایش‌ها و نتایج تجربی حاصل از ارزیابی سامانه پیشنهادی را تشریح می‌کند.

فصل هشتم شامل بحث و تحلیل انتقادی یافته‌ها است و بر نقاط قوت، دستاوردها و محدودیت‌های پژوهش تأکید دارد.

در نهایت، **فصل نهم** به جمع‌بندی مطالعه، بررسی پیامدهای آن برای حوزه **هوش مصنوعی مالی** و پیشنهاد مسیرهای بالقوه برای تحقیقات آینده اختصاص دارد.

فصل ۳

مفاهیم نظری

۳-۱ - مقدمه

این فصل به مبانی نظری مورد نیاز برای درک توسعه یک **عامل یادگیری تقویتی** در بستر بازارهای مالی، با تأکید بر ادغام آن با **مدل‌های زبانی بزرگ**، می‌پردازد.

ابتدا اصول پایه‌ای یادگیری تقویتی معرفی می‌شوند؛ از جمله اجزای اصلی آن، موازنه اکتشاف - بهره‌برداری^۱، و تمایز میان رویکردهای درون‌سیاستی^۲ و برون‌سیاستی^۳، همچنین مدل‌مبنا^۴ در برابر مدل‌نامبنا^۵. بر این اساس، الگوریتم‌های کلیدی یادگیری تقویتی از Q-learning و روش‌های **گرادیان سیاست**^۶ تا چارچوب‌های **بازیگر-منتقد**^۷ و الگوریتم‌های پیشرفته‌ای مانند Proximal Policy Optimization (PPO) و نسخه بازگشتی آن Recurrent PPO مرور خواهند شد.

در ادامه، مبانی **مدل‌های زبانی بزرگ** بررسی می‌شوند. این بخش شامل توضیح معماری ترنسفورمر^۸، روش‌های تعبیه^۹ و پارادایم‌های مختلف آموزش است. همچنین نقش تحلیل احساسات در حوزه مالی برجسته می‌شود تا نشان دهد چگونه داده‌های متنی می‌توانند مکمل شاخص‌های عددی بازار باشند.

در نهایت، ساختار و چالش‌های داده‌های بازار مالی، اصول مدیریت سبد سهام و محدودیت‌های عملی مانند هزینه‌های تراکنش، معیارهای ریسک و شاخص‌های ارزیابی تشریح می‌شوند. به‌طور کلی، این مفاهیم بنیان نظری لازم برای طراحی و ارزیابی یک عامل معاملاتی مبتنی بر یادگیری تقویتی را که با بینش‌های استخراج‌شده از مدل‌های زبانی بزرگ تقویت شده است، فراهم می‌آورند.

^۱ Balance Exploration-Exploitation

^۲ Learning On - Policy

^۳ Learning Off - Policy

^۴ Model - Based

^۵ Model - Free

^۶ Methods Gradient Policy

^۷ Frameworks Actor-Critic


^۸ Architecture Transformer

^۹ Techniques Embedding

۳-۲- مبانی یادگیری تقویتی

۳-۲-۱- اجزای اصلی

یادگیری تقویتی [۲۰] محاسباتی برای تصمیم‌گیری دنباله‌ای است که در آن عامل با تعامل مستقیم با محیط می‌آموزد چگونه عمل‌های مناسب را انتخاب کند. هدف اصلی این رویکرد، بیشینه‌سازی پاداش تجمعی در طول زمان است. اجزای اصلی یادگیری تقویتی در شکل (۳-۱) نمایش داده شده‌اند.



شکل (۳-۱) چارچوب کلی یادگیری تقویتی [۱۴].

- **عامل:** یادگیرنده یا تصمیم‌گیرنده. در معامله‌گری الگوریتمی، عامل همان راهبرد معاملاتی است که عمل‌های خرید، فروش یا نگهداشتن را انتخاب می‌کند.
- **محیط:** سامانه خارجی که عامل با آن تعامل دارد. در کاربردهای مالی، محیط معمولاً بازار است که شامل پویایی قیمت، دفتر سفارش و داده‌های احساسی می‌شود.
- **حالت (s_t):** بازنمایی وضعیت محیط در زمان t . در معامله‌گری، حالت‌ها می‌توانند شامل شاخص‌های فنی و امتیازهای احساسی استخراج‌شده از اخبار و داده‌های تاریخی باشند.
- **عمل (a_t):** مجموعه تصمیم‌های در دسترس عامل در زمان t . در ساده‌ترین حالت، این مجموعه شامل {خرید، فروش، نگهداشتن} است، اما می‌تواند به بازتخصیص سبد سهام یا تعیین اندازه موقعیت به‌صورت پیوسته نیز گسترش یابد.
- **پاداش (r_t):** سیگنال بازخورد عددی که سود یا زیان فوری ناشی از اجرای عمل a_t در حالت s_t را نشان می‌دهد. در زمینه مالی، این معمولاً به‌صورت **سود و زیان**، بازدهی تعدیل‌شده بر اساس ریسک یا تابعی سفارشی تعریف می‌شود که اهداف مدیریت ریسک را نیز در نظر می‌گیرد.

• **سیاست (π):** راهبرد عامل برای نگاشت حالت‌ها به عمل‌ها. سیاست‌ها می‌توانند **قطعی** باشند ($a = \pi(s)$) یا **تصادفی** باشند ($a \sim \pi(\cdot|s)$).

• **تابع ارزش:** برآورد پاداش تجمعی مورد انتظار هنگام شروع از یک حالت یا جفت حالت - عمل مشخص. این تابع معیاری از مطلوبیت بلندمدت حالت‌ها، فراتر از پاداش‌های فوری ارائه می‌دهد.

• **مدل محیط:** یک مؤلفه اختیاری که انتقال حالت‌ها را بر اساس عمل‌ها پیش‌بینی می‌کند. رویکردهای **مدل‌نامبنا**^{۱۰} مانند Proximal Policy Optimization, PPO محیط را به‌طور صریح مدل‌سازی نمی‌کنند، در حالی که روش‌های **مدل‌مبنا**^{۱۱} چنین مدل‌های پیش‌بینی را در نظر می‌گیرند.

این اجزا شالوده الگوریتم‌های یادگیری تقویتی را تشکیل می‌دهند. در معامله‌گری مالی، طراحی دقیق فضای حالت، مجموعه عمل و تابع پاداش اهمیت حیاتی دارد؛ زیرا تعریف‌های ضعیف یا نادرست می‌توانند به پویایی‌های یادگیری ناپایدار یا راهبردهای معاملاتی زیان‌ده منجر شوند.

۳-۲-۲- اکتشاف^{۱۲} در برابر بهره‌برداری^{۱۳}

یکی از چالش‌های اصلی در یادگیری تقویتی موازنه میان **اکتشاف** و **بهره‌برداری** است.

• **اکتشاف:** فرآیند انتخاب عمل‌هایی با قطعیت کمتر برای کسب دانش جدید و احتمالاً کشف راهبردهایی که بازدهی بلندمدت بیشتری ایجاد می‌کنند. در معامله‌گری، اکتشاف می‌تواند شامل آزمون شاخص‌ها یا سیگنال‌های جدید بازار باشد، حتی اگر سودآوری فوری آن‌ها نامشخص باشد.

• **بهره‌برداری:** فرآیند استفاده از دانش موجود برای بیشینه‌سازی پاداش مورد انتظار از طریق انتخاب مداوم عمل‌هایی که بهترین عملکرد برآوردشده را دارند. در کاربردهای مالی، این به معنای انجام معاملاتی است که در گذشته بازدهی قوی نشان داده‌اند.

تعادل میان اکتشاف و بهره‌برداری حیاتی است. بهره‌برداری بیش از حد می‌تواند به همگرایی زودهنگام بر سیاست‌های زیربینه منجر شود و عملکرد بلندمدت را محدود کند. در مقابل، اکتشاف بیش از حد ممکن است به رفتار ناپایدار و افزایش مواجهه با ریسک بیانجامد - موضوعی که در بازارهای مالی اهمیت ویژه‌ای دارد.

۳-۲-۳- وظایف رویدادمحور^{۱۴} در برابر وظایف پیوسته^{۱۵}

مسائل یادگیری تقویتی را می‌توان به‌طور کلی به **وظایف رویدادمحور** و **وظایف پیوسته** تقسیم کرد که بر اساس نحوه تعامل عامل با محیط تعریف می‌شوند.

• **وظایف رویدادمحور:** تعامل به دوره‌های گسسته تقسیم می‌شود که هرکدام حالت آغازین و پایانی مشخص دارند. در پایان هر اپیزود، محیط بازنشانی می‌شود و فرآیند یادگیری دوباره آغاز می‌گردد.

^{۱۰} Model-Free


^{۱۱} Model-Based

^{۱۲} Exploration

^{۱۳} Exploitation

^{۱۴} Episodic Tasks

^{۱۵} Continuous Tasks



شکل (۲-۳) نمایی از موازنه اکتشاف - بهره‌برداری [۱۵].

نمونه‌های کلاسیک شامل بازی‌های تخته‌ای مانند شطرنج و Go هستند که هر مسابقه یک اپیزود محسوب می‌شود. در معامله‌گری مالی، یک افق سرمایه‌گذاری ثابت (مثلاً شبیه‌سازی ۳۰ روز معاملاتی) را می‌توان به‌عنوان یک وظیفه اپیزودیک مدل کرد.

• **وظایف پیوسته:** تعامل به‌طور نامحدود ادامه دارد، بدون اینکه حالت پایانی طبیعی داشته باشد. عامل باید رفتار خود را در یک جریان بی‌پایان از حالت‌ها و پاداش‌ها بهینه کند. بازارهای مالی ذاتاً پیوسته‌اند، زیرا فرصت‌های معاملاتی و حرکت‌های قیمتی بدون نقطه پایان از پیش تعیین‌شده در جریان هستند.

این تمایز به‌طور مستقیم بر نحوه محاسبه توابع ارزش اثر می‌گذارد. در وظایف رویدادمحور معمولاً پاداش‌ها تا یک نقطه پایان مشخص جمع می‌شوند (بازدهی با افق محدود). اما در وظایف پیوسته از بازدهی تنزیل‌شده با افق نامحدود استفاده می‌شود تا مجموع پاداش‌ها همواره مقدار محدودی داشته باشد:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}, \quad 0 \leq \gamma < 1,$$

که در آن γ **ضریب تنزیل**^{۱۶} است و موازنه میان پاداش‌های فوری و بلندمدت را کنترل می‌کند. در معامله‌گری الگوریتمی، محیط‌ها غالباً به‌صورت پیوسته مدل می‌شوند تا ماهیت همیشگی بازار بازتاب یابد. با این حال، فرآیند آموزش معمولاً در قالب اپیزودها (مانند دوره‌های سالانه یا فصلی) سازمان‌دهی می‌شود تا یادگیری پایدارتر گردد، ارزیابی تسهیل شود و مقایسه میان راهبردها امکان‌پذیر باشد.

۳-۲-۴ - یادگیری درون‌سیاستی^{۱۷} در برابر برون‌سیاستی^{۱۸}

الگوریتم‌های یادگیری تقویتی را می‌توان به روش‌های درون‌سیاستی و روش‌های برون‌سیاستی تقسیم کرد. این دسته‌بندی بر اساس نحوه بهبود سیاست عامل تعریف می‌شود.

^{۱۶} Discount Factor

^{۱۷} On-Policy Learning

^{۱۸} Off-Policy Learning

• **یادگیری درون‌سیاستی:** عامل ارزش سیاستی را می‌آموزد که هم‌اکنون در حال اجراست. داده‌ها با پیروی از همین سیاست جمع‌آوری می‌شوند و بهبودها بر همان اساس صورت می‌گیرد. نمونه‌ها شامل SARSA و روش‌های **گرا دیان سیاست**^{۱۹} مانند Proximal Policy Optimization, PPO هستند. در معامله‌گری الگوریتمی، این به عاملی اشاره دارد که بر اساس معاملاتی که تحت راهبرد جاری خود انجام می‌دهد، تطبیق پیدا می‌کند.

• **یادگیری برون‌سیاستی:** عامل ارزش یک سیاست بهینه را می‌آموزد، حتی اگر از یک سیاست رفتاری متفاوت پیروی کند. این رویکرد امکان یادگیری از داده‌های تاریخی، نمایش‌ها یا رفتارهای اکتشافی را فراهم می‌آورد. نمونه‌های بارز شامل Q-learning و DQN, Deep Q-Networks هستند. در معامله‌گری، این روش به عامل اجازه می‌دهد از داده‌های تاریخی گسترده بازار بیاموزد، بدون آنکه معاملات را در زمان واقعی اجرا کند.

روش‌های درون‌سیاستی معمولاً پایدارتر و ایمن‌تر در حوزه‌های پرریسک مانند معامله‌گری هستند، در حالی که روش‌های برون‌سیاستی داده‌محورتر بوده و می‌توانند از تجربیات گذشته و شبیه‌سازی‌های برون‌خط استفاده کنند [۲۰].

۳-۲-۵ - روش‌های مدل‌مبنا^{۲۰} در برابر مدل‌نامبنا^{۲۱}

تمایز مهم دیگر در یادگیری تقویتی میان روش‌های مدل‌نامبنا و روش‌های مدل‌مبنا است. این تمایز بر اساس صریح بودن یا نبودن مدل‌سازی محیط تعریف می‌شود.

• **روش‌های بدون مدل:** این الگوریتم‌ها تلاشی برای یادگیری ساختار انتقال محیط نمی‌کنند، بلکه مستقیماً توابع ارزش یا سیاست‌ها را از طریق تعامل تخمین می‌زنند. نمونه‌هایی از این دسته شامل Q-learning, DQN و PPO هستند. در معامله‌گری، یک عامل بدون مدل مستقیماً از داده‌های بازار مانند سری‌های قیمتی، شاخص‌ها و سیگنال‌های احساسی یاد می‌گیرد، بدون آنکه مسیر آینده بازار را پیش‌بینی کند.

• **روش‌های مبتنی بر مدل:** این رویکردها بر یادگیری یا استفاده از یک مدل پیش‌بینی‌کننده رفتار محیط (مانند احتمال‌های گذار بین حالت‌ها و تابع پاداش) تکیه دارند. چنین مدل‌هایی امکان به کارگیری تکنیک‌های برنامه‌ریزی مانند برنامه‌ریزی پویا^{۲۲} یا جستجوی درختی مونت کارلو^{۲۳} را فراهم می‌کنند. در حوزه مالی، این می‌تواند شامل ساخت مدل‌های پیش‌بینی تغییرات قیمت دارایی‌ها یا شبیه‌سازی رفتار دفتر سفارش برای هدایت تصمیم‌گیری باشد.

به طور کلی، روش‌های بدون مدل ساده‌تر بوده و با یادگیری عمیق بهتر مقیاس‌پذیر هستند، هرچند به داده و فرآیند اکتشاف بیشتری نیاز دارند. در مقابل، روش‌های مبتنی بر مدل از نظر استفاده از داده کاراترند، اما نسبت به خطاهای مدل حساسیت بیشتری دارند. موضوعی که در بازارهای مالی پرتلاطم و ناپایدار اهمیت ویژه‌ای پیدا می‌کند.

^{۱۹} Methods Gradient Policy

^{۲۰} Model-Based Methods

^{۲۱} Model-Free Methods

^{۲۲} Programming Dynamic

^{۲۳} MCTS Search. Tree Carlo Monte

۳-۳- الگوریتم‌های یادگیری تقویتی

۳-۳-۱- Q-Learning و شبکه‌های Q عمیق^{۲۴}

Q-Learning که نخستین بار توسط Watkins در سال ۱۹۸۹ معرفی شد [۲۱]، یکی از الگوریتم‌های بنیادی در یادگیری تقویتی است. این روش برون‌سیاستی و مدل‌نامبنا است و هدف آن یادگیری تابع ارزش عمل بهینه $Q^*(s, a)$ می‌باشد. این تابع بیانگر پاداش تجمعی تنزیل‌شده مورد انتظار از انتخاب عمل a در حالت s و سپس پیروی از سیاست بهینه است. قاعده به‌روزرسانی Q-learning به‌صورت زیر تعریف می‌شود:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right]$$

که در آن α نرخ یادگیری^{۲۵}، γ ضریب تنزیل^{۲۶} و r_{t+1} پاداش دریافتی پس از اجرای عمل a_t در حالت s_t است.

شبکه‌های Q عمیق^{۲۷} بسط Q-learning هستند که در آن تابع Q با استفاده از یک شبکه عصبی عمیق تقریب زده می‌شود. این رویکرد امکان مقیاس‌پذیری به فضاهای ورودی با ابعاد بالا مانند تصاویر یا سری‌های زمانی مالی را فراهم می‌کند. پژوهش برجسته (2015) Mnih et al. [۲۲] موفقیت DQN را در یادگیری مستقیم از ورودی‌های خام پیکسلی در بازی‌های آتاری نشان داد. نوآوری‌های کلیدی DQN شامل موارد زیر است:

- **بازپخش تجربه^{۲۸}**: انتقال‌ها (s, a, r, s') در یک حافظه بازپخش ذخیره می‌شوند و آموزش شبکه با استفاده از **بسته‌های کوچک داده** که به‌طور تصادفی از این حافظه نمونه‌برداری می‌شوند انجام می‌شود. این فرآیند همبستگی میان به‌روزرسانی‌های متوالی را کاهش داده و پایداری آموزش را افزایش می‌دهد.
- **شبکه‌های هدف**: یک شبکه هدف جداگانه برای محاسبه مقادیر هدف در Q-learning به کار گرفته می‌شود که به‌صورت دوره‌ای به‌روزرسانی می‌گردد. این رویکرد از نوسانات مخرب و واگرایی در طول آموزش جلوگیری می‌کند.

در کاربردهای معاملاتی، Q-learning و DQN می‌توانند برای یادگیری سیاست‌هایی مورد استفاده قرار گیرند که مشخص می‌کنند آیا عامل باید دارایی را بخرد، بفروشد یا نگه دارد؛ بر اساس حالتی که توسط شاخص‌های بازار، امتیازهای احساسی و داده‌های قیمتی تعریف می‌شود. با این حال، بازارهای مالی چالش‌های خاصی برای DQN ایجاد می‌کنند، زیرا حالت‌ها پیوسته، غیرایستا و پاداش‌ها تصادفی هستند؛ بنابراین تصمیم‌گیری حساس به ریسک ضرورت می‌یابد. با وجود این محدودیت‌ها، DQN همچنان به‌عنوان یک معیار مرجع ارزشمند در مقایسه با روش‌های پیشرفته‌تر مانند **گرا دیان سیاست** و رویکردهای **بازیگر-منتقد** به کار می‌رود.

^{۲۴} Deep Q-Networks, DQN

^{۲۵} Rate Learning

^{۲۶} Factor Discount

^{۲۷} DQN Q-Networks, Deep

^{۲۸} Replay Experience

۳-۲-۲ - روش‌های گرادیان سیاست^{۲۹}

در حالی که روش‌های مبتنی بر ارزش مانند Q-learning به تخمین تابع ارزش عمل می‌پردازند، روش‌های گرادیان سیاست^{۳۰} مستقیماً سیاست $\pi_\theta(a|s)$ را که با پارامترهای θ (مانند وزن‌های یک شبکه عصبی) مشخص می‌شود، بهینه می‌کنند. هدف اصلی، بیشینه‌سازی بازدهی مورد انتظار است:

$$J(\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right],$$

که گرادیان‌ها بر اساس قضیه گرادیان سیاست^{۳۱} به دست می‌آیند [۲۳]:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a_t|s_t) G_t],$$

که در آن G_t بازدهی پس از گام زمانی t را نشان می‌دهد.

مزایای روش‌های گرادیان سیاست:

- قابلیت طبیعی در مدیریت فضا‌های عمل پیوسته و با ابعاد بالا، در حالی که روش‌های مبتنی بر ارزش معمولاً به عمل‌های گسسته محدودند.
- پشتیبانی از سیاست‌های تصادفی که فرآیند اکتشاف را تسهیل می‌کنند.
- امکان ادغام مستقیم محدودیت‌ها، معیارهای ریسک یا هزینه‌های تراکنش در طراحی پاداش.

چالش‌ها:

- برآورد گرادیان در این روش‌ها معمولاً نوسان زیادی دارد (واریانس بالا^{۳۲})، به همین دلیل لازم است از روش‌های کاهش واریانس^{۳۳} مانند استفاده از مبنای^{۳۴} یا توابع برتری^{۳۵} کمک گرفته شود تا پایداری آموزش افزایش یابد.
- این الگوریتم‌ها در مقایسه با روش‌های برون‌سیاستی مانند DQN، به داده‌های بیشتری برای یادگیری نیاز دارند و از نظر کارایی استفاده از نمونه‌ها ضعیف‌تر عمل می‌کنند.

در معامله‌گری مالی، روش‌های گرادیان سیاست به‌ویژه اهمیت دارند زیرا عمل‌ها (مانند وزن‌های سبد سهام یا اندازه موقعیت‌ها) ذاتاً پیوسته‌اند. برای نمونه، یک عامل یادگیری تقویتی می‌تواند به‌طور مستقیم کسری از سرمایه را که باید میان دارایی‌های مختلف تخصیص یابد، خروجی دهد. الگوریتم‌های اولیه‌ای مانند REINFORCE [۲۴] بنیان این حوزه را شکل دادند، در حالی که بسط‌های مدرن مانند روش‌های بازیگر-منتقد پایداری و کارایی بیشتری به همراه داشته‌اند.

^{۲۹} Policy Gradient Methods

^{۳۰} Methods Gradient Policy

^{۳۱} Theorem Gradient Policy

^{۳۲} Variance High

^{۳۳} Techniques Reduction Variance

^{۳۴} Baselines

^{۳۵} Functions Advantage

۳-۳-۳- روش‌های بازیگر-منتقد^{۳۶}

روش‌های بازیگر-منتقد مزایای رویکردهای مبتنی بر ارزش و مبتنی بر سیاست را در یادگیری تقویتی ترکیب می‌کنند. این روش‌ها از دو مؤلفه اصلی تشکیل شده‌اند [۲۵]:

• **بازیگر (Actor):** تابع سیاست $\pi_\theta(a|s)$ با پارامترهای θ که عمل‌ها را بر اساس حالت‌ها انتخاب می‌کند.

• **منتقد (Critic):** تابع ارزش $V^\pi(s)$ یا تابع ارزش عمل $Q^\pi(s, a)$ با پارامترهای ϕ که کیفیت سیاست را از طریق برآورد بازدهی مورد انتظار ارزیابی می‌کند.

منتقد در این چارچوب نقشی مانند یک **مبنا**^{۳۷} دارد و کمک می‌کند تا نوسان زیاد (واریانس) در برآورد گرادیان سیاست کاهش یابد. بازیگر وظیفه دارد پارامترهای سیاست را در جهتی که **قضیه گرادیان سیاست**^{۳۸} مشخص کرده به‌روزرسانی کند. در مقابل، منتقد با استفاده از **یادگیری تفاضل زمانی**^{۳۹} مقدارهای ارزش را بهبود می‌دهد و بازخورد دقیق‌تری به بازیگر می‌دهد. به‌طور خلاصه، به‌روزرسانی رایج بازیگر به صورت زیر نوشته می‌شود:

$$\nabla_\theta J(\theta) \approx \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a_t|s_t) A^\pi(s_t, a_t)],$$

که در آن $A^\pi(s_t, a_t)$ **تابع برتری**^{۴۰} است. این تابع نشان می‌دهد که یک عمل در وضعیت خاص، نسبت به میانگین انتظاری (مبنا) تا چه حد بهتر یا بدتر است. به این ترتیب، بازیگر به سمت اعمالی متمایل می‌شود که ارزش بیشتری نسبت به مبنا دارند.

مزایای روش‌های بازیگر-منتقد

- کارایی نمونه‌ای بیشتر نسبت به روش‌های صرفاً گرادیان سیاست مانند REINFORCE، به دلیل کاهش واریانس توسط منتقد.
- مقیاس‌پذیری به فضاهاى عمل پیوسته و با ابعاد بزرگ.
- ایجاد بنیان برای الگوریتم‌های پیشرفته‌ای مانند Advantage Actor-Critic, A2C, Asynchronous Advantage Actor-Critic, A3C و Proximal Policy Optimization, PPO.

روش‌های Actor-Critic به‌ویژه در معامله‌گری مالی کارآمد هستند؛ زیرا منتقد با ارائه برآوردهای دقیق‌تر از بازدهی، یادگیری را در بازارهای پرنوسان و غیرایستا پایدارتر می‌سازد. برای نمونه، بازیگر می‌تواند معاملاتی مانند تنظیم اندازه موقعیت‌ها را پیشنهاد دهد، در حالی که منتقد سودآوری بلندمدت آن‌ها را ارزیابی می‌کند. بسط‌هایی مانند A3C نیز امکان آموزش موازی در چندین بازار شبیه‌سازی‌شده را فراهم کرده و کارایی و پایداری فرآیند یادگیری را افزایش می‌دهند.

^{۳۶} Actor-Critic Methods

^{۳۷} Baseline

^{۳۸} Theorem Gradient Policy

^{۳۹} Learning TD Temporal-Difference

^{۴۰} Function Advantage

۳-۴-۳ Proximal Policy Optimization (PPO)

الگوریتم Proximal Policy Optimization (PPO) [۱۹] یکی از پرکاربردترین روش‌های **گرا دیان سیاست** است که به دلیل پایداری، سادگی و عملکرد تجربی قوی شناخته می‌شود. این الگوریتم در خانواده روش‌های **بازیگر-منتقد** قرار می‌گیرد، اما سازوکاری برای محدود کردن به‌روزرسانی‌های بیش از حد سیاست معرفی می‌کند؛ زیرا چنین به‌روزرسانی‌هایی می‌توانند آموزش را ناپایدار سازند. ایده اصلی، بهینه‌سازی یک **تابع هدف جانشین** با استفاده از نسبت احتمالات **برش‌خورده**^{۴۱} است:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) A_t \right) \right],$$

که در آن:

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)} \quad \bullet$$

$$A_t \text{ تابع برتری برآوردشده است,} \quad \bullet$$

$$\epsilon \text{ پارامتر برش است (معمولاً در بازه 0.1 تا 0.2).} \quad \bullet$$

برش‌زدن مانع می‌شود که سیاست جدید در یک به‌روزرسانی بیش از حد از سیاست قدیم منحرف شود و به این ترتیب یادگیری پایداری می‌گردد. افزون بر این، PPO اغلب از **منظم‌سازی آنتروپی**^{۴۲} برای تقویت اکتشاف بهره می‌گیرد.

تابع زیان کلی: در عمل، PPO چندین مؤلفه را در یک تابع زیان ترکیب می‌کند:

$$L^{\text{PPO}}(\theta) = \mathbb{E}_t \left[L^{\text{CLIP}}(\theta) - c_1 (V_{\theta}(s_t) - V_t^{\text{target}})^2 + c_2 H(\pi_{\theta}(\cdot|s_t)) \right],$$

که در آن:

$$L^{\text{CLIP}}(\theta) \text{ زیان سیاست برش‌خورده است,} \quad \bullet$$

$$(V_{\theta}(s_t) - V_t^{\text{target}})^2 \text{ خطای مربعی میان برآورد منتقد و بازدهی هدف است,} \quad \bullet$$

$$H(\pi_{\theta}(\cdot|s_t)) \text{ آنتروپی سیاست است که اکتشاف را تشویق می‌کند,} \quad \bullet$$

$$c_1 \text{ و } c_2 \text{ ضرایب کنترل‌کننده اهمیت مؤلفه‌های ارزش و آنتروپی هستند.} \quad \bullet$$

مزایای PPO:

- موازنه مؤثر میان اکتشاف و بهره‌برداری،
- ساده‌تر و مقاوم‌تر نسبت به روش‌های پیشین مبتنی بر ناحیه اعتماد مانند **TRPO**^{۴۳}،
- مقیاس‌پذیری مناسب در ترکیب با شبکه‌های عصبی عمیق و مسائل با ابعاد بالا.

^{۴۱} Ratio Probability Clipped

^{۴۲} Regularization Entropy

^{۴۳} TRPO Optimization, Policy Region Trust

PPO به‌ویژه برای محیط‌های معاملاتی مالی مناسب است؛ جایی که پایداری و مقاومت بودن اهمیت بالایی دارند زیرا داده‌ها پرنویز و غیرایستا هستند. با کنترل دقیق به‌روزرسانی‌های سیاست و ترکیب مؤلفه‌های سیاست، ارزش و آنتروپی، PPO امکان سازگاری تدریجی راهبردهای معاملاتی را فراهم می‌کند و میان بیشینه‌سازی سود، مدیریت ریسک و اکتشاف فرصت‌های جدید تعادل برقرار می‌سازد.

۳-۵- PPO بازگشتی^{۴۴}

بسیاری از محیط‌های دنیای واقعی - از جمله بازارهای مالی - دارای **قابلیت مشاهده ناقص**^{۴۵} هستند؛ به این معنا که عامل مستقیماً حالت زیربنایی را مشاهده نمی‌کند، بلکه تنها سیگنال‌های نویزی یا ناقصی مانند قیمت‌ها، شاخص‌های احساسی یا ویژگی‌های فنی دریافت می‌کند. برای رفع این چالش، الگوریتم **PPO** را می‌توان با **شبکه‌های عصبی بازگشتی**^{۴۶} بسط داد که منجر به **PPO بازگشتی**^{۴۷} می‌شود [۹].

در **RPPO**، شبکه‌های سیاست و ارزش با مؤلفه‌های حافظه‌ای مانند LSTM یا GRU تقویت می‌شوند. این ساختار به عامل امکان می‌دهد **وابستگی‌های زمانی**^{۴۸} را ثبت کرده و یک **حالت پنهان**^{۴۹} را در طول گام‌های زمانی حفظ کند. حالت پنهان اطلاعات گذشته مرتبط را خلاصه می‌کند و در نتیجه تصمیم‌گیری مؤثرتری را در شرایط مشاهده ناقص ممکن می‌سازد.

مزایای PPO بازگشتی:

- توانایی مدیریت مشاهده ناقص از طریق حفظ حافظه شرایط گذشته بازار.
- بهبود عملکرد در وظایف دنباله‌ای با وابستگی‌های بلندمدت.
- ارائه چارچوبی واقع‌بینانه‌تر برای معامله‌گری مالی، جایی که تصمیم‌ها هم به بستر تاریخی و هم به سیگنال‌های جاری وابسته‌اند.

الگوریتم **Recurrent PPO (RPPO)** توانایی عامل معاملاتی مبتنی بر یادگیری تقویتی را در تشخیص الگوهای زمانی موجود در داده‌های مالی افزایش می‌دهد. برای نمونه، گاهی قیمت‌ها تمایل دارند مدتی در همان جهت قبلی حرکت کنند (اثر تداوم روند)، یا دوره‌های پرنوسان و کم‌نوسان بازار معمولاً پشت سر هم رخ می‌دهند. با ترکیب شاخص‌های فنی و ویژگی‌های احساسی در یک ساختار بازگشتی، **RPPO** می‌تواند این الگوهای زمانی را بهتر از نسخه استاندارد **PPO** (بدون حافظه بازگشتی) ثبت کرده و راهبردهای معاملاتی سازگارتر ارائه دهد.

۳-۴- مبانی مدل‌های زبانی بزرگ

۳-۴-۱- معماری Transformer

Transformer [۱۸] یک معماری یادگیری عمیق است که بنیان مدل‌های زبانی بزرگ مدرن را تشکیل می‌دهد. برخلاف شبکه‌های عصبی بازگشتی یا مدل‌های کانولوشنی^{۵۰}، **Transformer** کاملاً

^{۴۴} Recurrent PPO

^{۴۵} Observability Partial

^{۴۶} RNNs Networks: Neural Recurrent

^{۴۷} RPPO PPO, Recurrent

^{۴۸} Dependencies Temporal

^{۴۹} State Hidden

^{۵۰} Convolutional Models

بر سازوکار خودتوجهی^{۵۱} متکی است تا وابستگی میان واحدهای زبانی در متن را ثبت کند. این ویژگی امکان موازی سازی کارآمد و مقیاس پذیری تا مجموعه داده های بسیار بزرگ را فراهم می سازد.

اجزای کلیدی معماری Transformer:

- **تعبیه ورودی^{۵۲}:** هر Token (واحد زبانی) در دنباله به یک بردار متراکم نگاشت می شود. از آنجا که Transformer فاقد بازگشت یا کانولوشن هستند، **کدگذاری های مکانی^{۵۳}** به این بردارها افزوده می شوند تا ترتیب Token ها حفظ شود.

- **سازوکار خودتوجهی:** عملیات اصلی روابط میان همه جفت Token ها در یک دنباله را محاسبه می کند. برای هر Token، بردارهای پرسش (Q)، کلید (K) و مقدار (V) از نگاشت خطی تعبیه های ورودی به دست می آیند. توجه به صورت زیر محاسبه می شود:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V,$$

که در آن d_k بُعد بردارهای کلید است. این سازوکار به هر Token اجازه می دهد بر اساس ارتباط معنایی به سایر Token ها توجه کند.

- **توجه چندسری^{۵۴}:** به جای یک عملیات توجه منفرد، چندین توجه به طور موازی محاسبه می شوند که امکان ثبت انواع مختلفی از روابط را فراهم می کند. خروجی ها سپس به هم متصل شده و به فضای تعبیه بازافکنی می شوند.

- **شبکه های پیشخور^{۵۵}:** بازنمایی هر موقعیت از یک شبکه عصبی تمام متصل با فعال ساز غیرخطی (مانند ReLU یا GELU) عبور می کند.

- **اتصالات باقیمانده و نرمال سازی لایه^{۵۶}:** برای پایدارسازی آموزش و بهبود جریان گرادیان، اتصالات باقیمانده پیرامون لایه های توجه و پیشخور اعمال می شوند و سپس نرمال سازی لایه انجام می شود.

- **ساختار رمزگذار - رمزگشا^{۵۷}:** Transformer اصلی شامل یک رمزگذار (مفید برای بازنمایی ورودی ها مانند ترجمه) و یک رمزگشا (مسئول تولید دنباله) است. مدل های زبانی بزرگی مانند GPT از **گونه فقط رمزگشا^{۵۸}** با سازوکار Masked Self-Attention استفاده می کنند تا اطمینان یابند پیش بینی در گام t تنها به Token های مشاهده شده تا آن لحظه وابسته باشد.

^{۵۱} Self-Attention Mechanism

^{۵۲} Input Embeddings

^{۵۳} Positional Encodings

^{۵۴} Multi-Head Attention

^{۵۵} Feed-Forward Networks

^{۵۶} Residual Connections & Layer Normalization

^{۵۷} Encoder-Decoder Structure

^{۵۸} Decoder-Only

۳-۴-۲- جاسازی واژه‌ها و جاسازی‌های متنی

مدل‌های پردازش زبان طبیعی^{۵۹} برای عملکرد مناسب نیازمند بازنمایی عددی از واژه‌ها هستند تا معنای واژگانی در آن‌ها منعکس شود. این هدف با استفاده از **جاسازی‌ها**^{۶۰} محقق می‌شود؛ یعنی نگاشت توکن‌های گسسته به فضا‌های برداری پیوسته که در آن‌ها روابط معنایی قابل اندازه‌گیری هستند.

جاسازی‌های ایستا^{۶۱}: روش‌های اولیه مانند Word2Vec [۲۶] و GloVe [۲۷] به هر واژه یک بردار ثابت اختصاص می‌دهند، مستقل از بافت آن. این جاسازی‌ها شباهت معنایی را از طریق حساب برداری ثبت می‌کنند (برای نمونه: king - man + woman ≈ queen). با این حال، جاسازی‌های ایستا قادر به ثبت **چندمعنایی**^{۶۲} نیستند؛ یعنی واژه‌هایی با معانی متعدد (مانند «bank» صرف‌نظر از بافت تنها با یک بردار نمایش داده می‌شوند).

جاسازی‌های متنی^{۶۳}: مدل‌های مدرن مبتنی بر ترنسفورمر مانند BERT [۲۸] و GPT [۲۹] جاسازی‌هایی تولید می‌کنند که **بافت‌محور** هستند. بازنمایی یک واژه بر اساس توکن‌های پیرامونی تغییر می‌کند و مدل را قادر می‌سازد میان معانی مختلف یک واژه تمایز قائل شود. این نوع جاسازی‌ها از سازوکار **خودتوجهی**^{۶۴} برای ادغام اطلاعات معنایی در سراسر دنباله ورودی استفاده می‌کنند. به‌صورت رسمی، اگر x_t جاسازی اولیه توکن t باشد، جاسازی متنی h_t به شکل زیر تعریف می‌شود:

$$h_t = f_{\theta}(x_t | x_1, x_2, \dots, x_T),$$

که در آن f_{θ} تابع ترنسفورمر است که بازنمایی هر توکن را بر اساس کل دنباله شرطی می‌کند.

کاربرد در تحلیل احساسات مالی:

- جاسازی‌های ایستا می‌توانند شباهت‌های معنایی کلی در اصطلاحات مالی را ثبت کنند (برای نمونه، رابطه میان «stock»، «equity» و «share»).
- جاسازی‌های متنی امکان رفع ابهام از اصطلاحات خاص مالی را فراهم می‌کنند (برای نمونه، تمایز میان «bear» به معنای حیوان و «bear» به معنای احساس منفی بازار).
- با بهره‌گیری از جاسازی‌های متنی، عامل‌های معاملاتی می‌توانند سیگنال‌های احساسی دقیق‌تری را از اخبار، تحلیل‌های کارشناسان و پست‌های شبکه‌های اجتماعی استخراج کنند و آن‌ها را در مدل‌های یادگیری تقویتی برای بهبود تصمیم‌های معاملاتی ادغام نمایند.

۳-۴-۳- پیش‌آموزش در برابر ریزتنظیم و تنظیم مبتنی بر دستور

مدل‌های زبانی بزرگ^{۶۵} در چندین مرحله آموزش داده می‌شوند تا به‌تدریج از درک عمومی زبان به رفتار ویژه‌وظیفه‌ای یا همسو با کاربر سازگار شوند. سه پارادایم اصلی عبارت‌اند از:

^{۵۹} Natural Language Processing, NLP

^{۶۰} Embeddings

^{۶۱} Static Embeddings

^{۶۲} Polysemy

^{۶۳} Contextual Embeddings

^{۶۴} Self-Attention Mechanism

^{۶۵} Large Language Models, LLMs

پیش‌آموزش^{۶۶}: در نخستین مرحله، مدل بر روی متون عظیم به‌صورت خودنظارتی آموزش می‌بیند. اهداف رایج شامل **پیش‌بینی توکن بعدی^{۶۷}** (مانند GPT [۲۹]) یا **پیش‌بینی توکن‌های ماسک‌شده^{۶۸}** (مانند BERT [۲۸]) هستند. پیش‌آموزش، مدل را به دانش زبانی گسترده، دستور زبان و درک معنایی مجهز می‌سازد:

$$\min_{\theta} \mathbb{E}_{x \sim D} \left[-\log p_{\theta}(x) \right],$$

که در آن D مجموعه داده عظیم و p_{θ} توزیع مدل بر دنباله‌هاست.

ریزتنظیم^{۶۹}: پس از پیش‌آموزش، مدل می‌تواند با ادامه آموزش روی یک مجموعه داده برچسب‌خورده کوچک‌تر، به وظیفه‌ای خاص تطبیق یابد. برای نمونه، ریزتنظیم BERT روی مجموعه داده‌ای با برچسب احساسات، تخصص در طبقه‌بندی احساسات را ممکن می‌سازد. در حوزه مالی، ریزتنظیم می‌تواند بر روی متون تخصصی مانند گزارش‌های تحلیلی، اخبار مالی یا داده‌های شبکه‌های اجتماعی انجام شود.

تنظیم مبتنی بر دستور^{۷۰}: این رویکرد [۳۰] پارادایمی جدیدتر است که در آن مدل‌ها بر روی مجموعه داده‌هایی شامل دستورهای زبان طبیعی همراه با پاسخ‌های مورد انتظار آموزش می‌بینند. این فرآیند مدل‌ها را به نیت انسانی نزدیک‌تر کرده و توانایی تعمیم در حالت **بدون نمونه^{۷۱}** و **کم‌نمونه^{۷۲}** را بهبود می‌بخشد. مدل‌های تنظیم‌شده با دستور (مانند InstructGPT و ChatGPT) می‌توانند بدون نیاز به ریزتنظیم گسترده ویژه وظیفه، مستقیماً از طریق توصیف وظیفه عمل کنند.

مراحل مختلف آموزش LLMها به‌طور مکمل در کاربردهای مالی نقش دارند:

- **پیش‌آموزش** دانش زبانی گسترده‌ای فراهم می‌کند که شناسایی احساسات عمومی و مفاهیم مالی در منابع متنی متنوع را ممکن می‌سازد.
- **ریزتنظیم** روی متون مالی موجب تخصص مدل در واژگان حوزه‌ای (مانند «hawkish»، «bearish» «guidance» شده و دقت طبقه‌بندی احساسات را افزایش می‌دهد.
- **تنظیم مبتنی بر دستور** تعامل زبان طبیعی با اسناد مالی را تسهیل کرده و به عامل‌های یادگیری تقویتی یا تحلیل‌گران اجازه می‌دهد مدل‌ها را مستقیماً برای استخراج سیگنال‌های احساسی، نشانه‌های ریسک یا خلاصه‌های بازار به کار گیرند.

۳-۴-۴ - تحلیل احساسات در زمینه مالی^{۷۳}

تحلیل احساسات^{۷۴} فرآیند استخراج اطلاعات ذهنی - مانند نظرات، نگرش‌ها یا هیجانات - از داده‌های متنی است. در حوزه مالی، تحلیل احساسات به دنبال کمی‌سازی لحن عاطفی مقالات خبری، گزارش‌های تحلیلی،

Pre-training^{۶۶}
 Causal Language Modeling^{۶۷}
 Masked Language Modeling^{۶۸}
 Fine-tuning^{۶۹}
 Instruction Tuning^{۷۰}
 Zero-shot^{۷۱}
 Few-shot^{۷۲}
 Sentiment Analysis in Finance^{۷۳}
 Sentiment Analysis^{۷۴}

تماس‌های اعلام درآمد یا بحث‌های شبکه‌های اجتماعی است؛ زیرا این منابع اغلب بر رفتار سرمایه‌گذاران و پویایی بازار اثرگذارند.

چرا احساسات اهمیت دارند: بازارهای مالی صرفاً بر مبنای عوامل بنیادین هدایت نمی‌شوند، بلکه روان‌شناسی سرمایه‌گذاران و احساسات جمعی نیز نقشی تعیین‌کننده دارند [۹]. اخبار یا دیدگاه‌های مثبت می‌توانند حرکت‌های صعودی (Bullish) را تقویت کنند، در حالی که احساسات منفی ممکن است به فروش گسترده منجر شود. با تبدیل متن‌های غیرساختاریافته به امتیازهای ساختاریافته احساسات، عامل‌های معاملاتی قادر خواهند بود سیگنال‌های روان‌شناختی را در فرآیند تصمیم‌گیری سیستماتیک وارد کنند.

روش‌های تحلیل احساسات:

- **رویکردهای واژگانی^{۷۵}:** مبتنی بر فرهنگ‌های لغت از پیش تعریف‌شده برای واژه‌های مثبت و منفی هستند. واژه‌نامه Loughran-McDonald [۳۱] در کاربردهای مالی بسیار رایج است زیرا واژگان ویژه این حوزه را پوشش می‌دهد.
- **یادگیری ماشین کلاسیک^{۷۶}:** با استفاده از ویژگی‌های مهندسی‌شده مانند **کیسه واژگان^{۷۷}** یا بازنمایی‌های TF-IDF و ترکیب آن‌ها با دسته‌بندی‌هایی مانند **رگرسیون لجستیک^{۷۸}** یا **ماشین‌های بردار پشتیبان^{۷۹}**.
- **یادگیری عمیق و جاسازی‌های متنی^{۸۰}:** مدل‌های مبتنی بر ترنسفورمر مانند BERT و FinBERT [۲] بازنمایی‌های بافت‌محور از احساسات تولید می‌کنند که نسبت به روش‌های واژگانی و یادگیری سطحی عملکرد بسیار بهتری دارند.
- **مدل‌های زبانی بزرگ^{۸۱}:** مدل‌های تنظیم‌شده بر اساس دستور (مانند InstructGPT و ChatGPT) می‌توانند طبقه‌بندی احساسات را در حالت **بدون نمونه^{۸۲}** یا **کم‌نمونه^{۸۳}** انجام دهند و بدون نیاز به ریزتنظیم گسترده به بافت‌های مالی تطبیق یابند.

ادغام سیگنال‌های احساسی در عامل‌های RL: سیگنال‌های احساسی می‌توانند بخشی از بازنمایی حالت عامل‌های معاملاتی مبتنی بر یادگیری تقویتی^{۸۴} باشند:

- احساسات مثبت احتمال اتخاذ موقعیت‌های خرید (Long) را افزایش می‌دهد.
- احساسات منفی عامل را به سمت موقعیت‌های فروش (Short) یا کاهش ریسک هدایت می‌کند.
- احساسات خنثی یا نامطمئن می‌تواند راهبردهای محافظه‌کارانه یا پوششی (Hedging) را تقویت کند.

^{۷۵} Lexicon-based Methods

^{۷۶} Classical Machine Learning

^{۷۷} Bag-of-Words

^{۷۸} Logistic Regression

^{۷۹} Support Vector Machines, SVMs

^{۸۰} Deep Learning & Contextual Embeddings

^{۸۱} Large Language Models, LLMs

^{۸۲} Zero-shot

^{۸۳} Few-shot

^{۸۴} Reinforcement Learning, RL

چالش‌ها:

- زبان مالی دارای واژگان حوزه‌ای خاص است (برای نمونه: «beat»، «expectations»، «hawkish» «guidance» که ممکن است مدل‌های عمومی را گمراه کند).
- طعنه، ابهام و ظرافت‌های زبانی هنوز به‌سختی توسط مدل‌ها شناسایی می‌شوند.
- منابع خبری می‌توانند پرنویز، جانبدارانه یا دارای تأخیر باشند که قابلیت اطمینان سیگنال‌ها را کاهش می‌دهد.

با وجود این چالش‌ها، تحلیل احساسات همچنان ابزاری قدرتمند برای تقویت راهبردهای معامله‌گری الگوریتمی باقی می‌ماند؛ به‌ویژه زمانی که در چارچوب‌های یادگیری تقویتی همراه با شاخص‌های فنی و داده‌های بازار به‌کار گرفته شود.

۳-۵ - داده‌های بازار و شاخص‌های مالی

۳-۵-۱ - مبانی داده‌های OHLCV^{۸۵}

داده‌های OHLCV نمایش استاندارد بازار مالی هستند که شامل قیمت باز، بیشینه، کمینه، بسته و حجم معاملات می‌شوند. این قالب، اساس تحلیل تکنیکال را تشکیل داده و به‌طور گسترده در معامله‌گری اختیاری و الگوریتمی به‌کار گرفته می‌شود.

- **Open: (O)** نخستین قیمت معامله‌شده یک دارایی در ابتدای بازه زمانی مشخص (مانند یک دقیقه، یک ساعت یا یک روز).
- **High: (H)** بیشترین قیمتی که در طول بازه زمانی ثبت شده است.
- **Low: (L)** کمترین قیمتی که در طول بازه زمانی ثبت شده است.
- **Close: (C)** آخرین قیمت معامله‌شده دارایی در پایان بازه زمانی.
- **Volume: (V)** مجموع حجم معامله‌شده دارایی در طول بازه زمانی، که بیانگر میزان فعالیت و نقدشوندگی بازار است.

نمایش داده‌ها: داده‌های OHLCV معمولاً با استفاده از **نمودار شمعی**^{۸۶} نمایش داده می‌شوند. در این نمودار، هر شمع قیمت‌های باز، بسته، بیشینه و کمینه را در یک بازه زمانی خلاصه می‌کند. ضخامت و رنگ بدنه شمع نشان‌دهنده صعودی بودن (Bullish) یا نزولی بودن (Bearish) قیمت در آن بازه است.

کاربردها:

^{۸۵} Open, High, Low, Close, Volume
^{۸۶} Candlestick Chart

- داده‌های OHLCV ورودی خام برای شاخص‌های فنی متداول مانند میانگین‌های متحرک^{۸۷}، شاخص قدرت نسبی^{۸۸} و واگرایی/همگرایی میانگین متحرک^{۸۹} محسوب می‌شوند.
- این داده‌ها هم پویایی‌های قیمت (از طریق O، H، L، C) و هم میزان مشارکت بازار (از طریق V) را منتقل می‌کنند.
- بسته به افق معاملاتی و راهبرد، می‌توان از دقت‌های زمانی مختلف (داده تیک، درون‌روزی، روزانه یا هفتگی) استفاده کرد.
- در چارچوب‌های یادگیری تقویتی، مقادیر OHLCV اغلب بخشی از فضای حالت هستند تا عامل بتواند از زمینه تاریخی ساختاریافته برای تصمیم‌گیری بهره‌برد.

محدودیت‌ها: اگرچه OHLCV پویایی‌های اساسی قیمت و حجم را ثبت می‌کند، اما جزئیاتی مانند عمق دفتر سفارش^{۹۰}، شکاف خرید-فروش^{۹۱} و نقدشوندگی پنهان را در بر نمی‌گیرد. از این رو، داده‌های OHLCV اغلب با منابع تکمیلی – مانند شاخص‌های احساسی یا داده‌های بنیادین – ترکیب می‌شوند تا قدرت پیش‌بینی و پایداری راهبردهای معامله‌گری الگوریتمی افزایش یابد.

۳-۵-۲ - شاخص‌های فنی پرکاربرد

شاخص‌های فنی^{۹۲} مقیاس‌های کمی مشتق‌شده از داده‌های OHLCV هستند که معامله‌گران برای شناسایی روندها^{۹۳}، مومنتوم^{۹۴}، نوسان‌پذیری^{۹۵} و نقاط احتمالی بازگشت به کار می‌گیرند. این شاخص‌ها هم در معامله‌گری اختیاری و هم در معامله‌گری الگوریتمی پرکاربردند و اغلب بخشی جدایی‌ناپذیر از فضای حالت برای عامل‌های یادگیری تقویتی محسوب می‌شوند.

شاخص‌های پیرو روند^{۹۶}:

- میانگین‌های متحرک^{۹۷}: میانگین قیمت‌های بسته‌شدن در یک پنجره زمانی ثابت. میانگین متحرک ساده^{۹۸} میانگینی بدون وزن است، در حالی که میانگین متحرک نمایی^{۹۹} وزن بیشتری به قیمت‌های اخیر می‌دهد. تلاقی میانگین‌های کوتاه‌مدت و بلندمدت اغلب برای شناسایی تغییر روند استفاده می‌شود.

^{۸۷} Moving Averages

^{۸۸} Relative Strength Index, RSI

^{۸۹} Moving Average Convergence Divergence, MACD

^{۹۰} Order Book Depth

^{۹۱} Bid-Ask Spread

^{۹۲} Technical Indicators

^{۹۳} Trends

^{۹۴} Momentum

^{۹۵} Volatility

^{۹۶} Trend-following Indicators

^{۹۷} Moving Averages, MA

^{۹۸} Simple Moving Average, SMA

^{۹۹} Exponential Moving Average, EMA

- **واگرایی - همگرایی میانگین متحرک^{۱۰۰}**: اختلاف میان دو EMA (معمولاً ۱۲ و ۲۶ دوره‌ای) تعریف می‌شود و یک خط سیگنال (EMA) نه‌دوره‌ای) برای برجسته‌سازی تغییرات مومنتوم به آن افزوده می‌شود.

شاخص‌های تکانه^{۱۰۱}:

- **شاخص قدرت نسبی^{۱۰۲}**: یک نوسان‌نما در بازه ۰ تا ۱۰۰ است که بزرگی نسبی سودها در برابر زیان‌های اخیر را اندازه‌گیری می‌کند. مقادیر بالاتر از ۷۰ معمولاً شرایط اشباع خرید و مقادیر پایین‌تر از ۳۰ شرایط اشباع فروش را نشان می‌دهند.
- **نوسان‌نمای تصادفی^{۱۰۳}**: قیمت بسته‌شدن را با دامنه قیمت‌ها در یک دوره بازگشت مشخص مقایسه می‌کند و بازتاب‌دهنده مومنتوم نسبت به بیشینه‌ها و کمینه‌های اخیر است.

شاخص‌های نوسان‌پذیری^{۱۰۴}:

- **باندهای بولینگر^{۱۰۵}**: با قرار دادن باندهای بالا و پایین در چند انحراف معیار از یک میانگین متحرک ساخته می‌شوند. این باندها در دوره‌های پرنوسان گسترش یافته و در دوره‌های کم‌نوسان منقبض می‌شوند.
- **میانگین دامنه واقعی^{۱۰۶}**: نوسان‌پذیری را با میانگین‌گیری از دامنه واقعی (بیشینه اختلاف‌های High-Low، High-Close Low و Low-Close) در یک دوره اندازه‌گیری می‌کند.

شاخص‌های مبتنی بر حجم^{۱۰۷}:

- **حجم تعادلی^{۱۰۸}**: یک معیار تجمعی است که در روزهای صعودی حجم معاملات را اضافه و در روزهای نزولی کم می‌کند تا فشار خرید و فروش را بازتاب دهد.
- **میانگین موزون حجمی قیمت^{۱۰۹}**: میانگین قیمت معامله‌شده یک دارایی است که بر اساس حجم وزن‌دهی می‌شود و اغلب به عنوان معیار کیفیت اجرا توسط معامله‌گران نهادی استفاده می‌گردد.

برای عامل‌های یادگیری تقویتی، شاخص‌های فنی بازنمایی‌های سطح بالاتری از داده‌های OHLCV فراهم می‌کنند و به عامل کمک می‌کنند الگوهایی مانند روندها، بازگشت‌ها یا رژیم‌های نوسان‌پذیری را که ممکن است در دنباله‌های خام قیمتی پنهان باشند شناسایی کند. ادغام این شاخص‌ها در فضای حالت می‌تواند کارایی یادگیری را از طریق تزریق دانش حوزه‌ای به مشاهدات عامل بهبود دهد.

^{۱۰۰}Moving Average Convergence Divergence, MACD

^{۱۰۱}Momentum Indicators

^{۱۰۲}Relative Strength Index, RSI

^{۱۰۳}Stochastic Oscillator

^{۱۰۴}Volatility Indicators

^{۱۰۵}Bollinger Bands

^{۱۰۶}Average True Range, ATR

^{۱۰۷}Volume-based Indicators

^{۱۰۸}On-Balance Volume, OBV

^{۱۰۹}Volume-Weighted Average Price, VWAP

محدودیت‌ها: اگرچه شاخص‌های فنی می‌توانند بازنمایی حالت را غنی‌تر کنند، اما اتکای بیش از حد به آن‌ها می‌تواند منجر به فضاهای ویژگی با ابعاد بالا، نویز بیشتر و خطر **بیش‌برازش**^{۱۱۰} شود. در عمل، انتخاب ویژگی محتاطانه، کاهش ابعاد یا استفاده از روش‌های یادگیری بازنمایی برای تضمین پایداری و مقاومت راهبردهای معاملاتی ضروری است.

۳-۵-۳ - چالش‌های موجود در بازارهای مالی

به کارگیری **یادگیری تقویتی**^{۱۱۱} در بازارهای مالی ذاتاً دشوار است؛ زیرا این محیط پیچیده، پویا و پراز نویز است. برخلاف وظایف معیار کنترل‌شده، بازارها موانع متعددی ایجاد می‌کنند که طراحی عامل‌های معاملاتی مقاوم را با چالش روبه‌رو می‌سازد.

ناایستایی^{۱۱۲}: ویژگی‌های آماری سری‌های زمانی مالی به‌مرور تغییر می‌کنند؛ به دلیل تغییر رژیم‌های بازار، چرخه‌های اقتصادی، تحولات مقرراتی و شوک‌های پیش‌بینی‌نشده. راهبردی که در یک رژیم (مانند بازار صعودی) موفق عمل می‌کند، ممکن است در شرایط متفاوت (مانند رکود یا بحران‌ها) ناکام بماند.

نسبت بالای نویز به سیگنال^{۱۱۳}: قیمت دارایی‌ها تحت تأثیر عوامل متنوع و غیرقابل‌پیش‌بینی - از جمله اعلامیه‌های کلان اقتصادی، رویدادهای ژئوپولیتیکی و روان‌شناسی سرمایه‌گذاران - قرار دارند. تشخیص الگوهای معنادار از نوسانات تصادفی کاری بسیار دشوار است.

مشاهده ناقص^{۱۱۴}: معامله‌گران به‌ندرت به وضعیت کامل بازار دسترسی دارند. متغیرهای پنهان مانند جریان سفارش‌های نهادی، اطلاعات خصوصی و محرک‌های نهفته بازار تأثیر چشمگیری بر پویایی‌ها دارند، اما برای عامل قابل مشاهده نیستند.

پاداش‌های پراکنده و با تأخیر^{۱۱۵}: فرصت‌های سودآور نسبت به تعداد کنش‌های معاملاتی ممکن، به‌ندرت رخ می‌دهند. بنابراین سیگنال‌های پاداش هم پراکنده و هم با تأخیر هستند و مسئله تخصیص اعتبار در آموزش RL را پیچیده می‌سازند.

هزینه‌های تراکنش و لغزش قیمتی^{۱۱۶}: اجرای واقعی معاملات مستلزم هزینه‌هایی مانند کمیسیون، **شکاف خرید-فروش**^{۱۱۷} و تأثیر بازار است. راهبردهایی که در شبیه‌سازی سودآور به نظر می‌رسند، ممکن است پس از در نظر گرفتن این اصطکاک‌ها دیگر کارایی نداشته باشند.

ریسک و رویدادهای دنباله‌ای^{۱۱۸}: بازده‌های مالی دارای دنباله‌های سنگین، خوشه‌بندی نوسان‌پذیری و رویدادهای شدید (مانند سقوط‌ها) هستند که بیش از آنچه مدل‌های گاوسی پیش‌بینی می‌کنند رخ می‌دهند. عامل‌های RL باید اهداف حساس به ریسک را لحاظ کنند تا از افت سرمایه‌های فاجعه‌بار جلوگیری شود.

^{۱۱۰} Overfitting

^{۱۱۱} Reinforcement Learning, RL

^{۱۱۲} Non-stationarity

^{۱۱۳} High Noise-to-Signal Ratio

^{۱۱۴} Partial Observability

^{۱۱۵} Sparse and Delayed Rewards

^{۱۱۶} Transaction Costs and Slippage

^{۱۱۷} Bid-Ask Spread

^{۱۱۸} Risk and Tail Events

محدودیت‌های داده^{۱۱۹}: مجموعه داده‌های فرکانس بالا اغلب گران یا انحصاری هستند و دسترسی به آن‌ها محدود است. داده‌های عمومی (مانند داده‌های روزانه OHLCV) ممکن است برای راهبردهای کوتاه‌مدت یا درون‌روزی دقت کافی نداشته باشند.

سختی‌های ارزیابی^{۱۲۰}: بک‌تست^{۱۲۱} می‌تواند دچار سوگیری نگاه به آینده^{۱۲۲}، سوگیری بقا^{۱۲۳} و بیش‌برازش^{۱۲۴} نسبت به داده‌های تاریخی شود. اگرچه آزمون خارج از نمونه^{۱۲۵} ضروری است، اما ماهیت نایستای بازارها تعمیم واقعی را به‌ویژه دشوار می‌سازد.

این چالش‌ها نشان می‌دهند که طراحی دقیق سامانه‌های RL در مالی ضروری است. عامل‌های معاملاتی کارآمد باید سودآوری را با مدیریت ریسک متعادل سازند، هزینه‌های تراکنش را در نظر بگیرند، با رژیم‌های متغیر بازار تطبیق پیدا کنند و تحت چارچوب‌های ارزیابی سخت‌گیرانه و بدون سوگیری آزموده شوند. تنها در این صورت است که راهبردهای مبتنی بر RL می‌توانند به مقاومت و پایداری بلندمدت در بازارهای واقعی دست یابند.

۳-۵-۴ - شاخص‌ها و دارایی‌های مالی اصلی^{۱۲۶}

عامل‌های یادگیری تقویتی^{۱۲۷} اغلب بر اساس شاخص‌های شناخته‌شده بازار و طبقات دارایی پرمعامله ارزیابی می‌شوند. این ابزارها نقدشوندگی بالایی دارند، به‌صورت جهانی شناخته‌شده‌اند و شرایط متنوعی از بازار را برای آزمون راهبردهای معامله‌گری الگوریتمی فراهم می‌کنند.

(DJIA) Average Industrial Jones Dow

شاخص (DJIA) Dow Jones Industrial Average یکی از قدیمی‌ترین و پرپیگیری‌ترین شاخص‌های سهام است که شامل ۳۰ شرکت بزرگ و عمومی ایالات متحده در صنایع مختلف می‌شود. اگرچه تنها بخش نسبتاً کوچکی از شرکت‌ها را پوشش می‌دهد، اما اغلب به‌عنوان معیاری برای عملکرد اقتصادی ایالات متحده در نظر گرفته می‌شود. برای عامل‌های معاملاتی، DJIA دسترسی به سهام بلوچیپ با نوسان‌پذیری^{۱۲۸} نسبتاً کمتر در مقایسه با شاخص‌های کوچک‌تر فراهم می‌آورد.

S&P 500 Index

شاخص S&P 500 شامل ۵۰۰ شرکت بزرگ ایالات متحده است و به‌طور گسترده به‌عنوان بهترین معیار کلی بازار سهام آمریکا شناخته می‌شود. این شاخص حدود ۸۰٪ از ارزش بازار ایالات متحده را پوشش می‌دهد.

^{۱۱۹}Data Limitations

^{۱۲۰}Evaluation Difficulties

^{۱۲۱}Backtesting

^{۱۲۲}Look-ahead Bias

^{۱۲۳}Survivorship Bias

^{۱۲۴}Overfitting

^{۱۲۵}Out-of-sample Testing

^{۱۲۶}Major Financial Indices and Assets

^{۱۲۷}Reinforcement Learning, RL

^{۱۲۸}Volatility

به دلیل نقدشوندگی بالا و پوشش گسترده، S&P ۵۰۰ یک معیار متداول برای ارزیابی عملکرد راهبردهای معامله‌گری الگوریتمی، از جمله عامل‌های RL، محسوب می‌شود.

XAU/USD

XAU/USD نشان‌دهنده قیمت طلا (XAU) بر حسب دلار آمریکا است. طلا هم یک کالا و هم یک دارایی پناهگاه امن محسوب می‌شود که در زمان عدم قطعیت اقتصادی یا تورم ارزش می‌یابد. برای عامل‌های معاملاتی، طلا چالشی منحصر به فرد ایجاد می‌کند زیرا دینامیک قیمتی آن تحت تأثیر شرایط کلان اقتصادی جهانی، سیاست‌های پولی و احساسات ریسکی قرار دارد.

رمزارزها^{۱۲۹}

رمزارزهایی مانند Bitcoin (BTC) و Ethereum (ETH) دارایی‌هایی بسیار پرنوسان و سفته‌بازانه هستند. برخلاف بازارهای سنتی، بازار رمزارزها به صورت ۲۴/۷ و در صرافی‌های غیرمتمرکز معامله می‌شوند و مجموعه داده‌های غنی‌ای برای آموزش RL فراهم می‌کنند. نوسان‌پذیری بالای آن‌ها هم فرصت و هم ریسک ایجاد می‌کند و آن‌ها را به بستر مناسبی برای آزمون عامل‌های RL با هدف شناسایی الگوهای کوتاه‌مدت قیمتی تبدیل می‌سازد.

بازار تبادل ارز خارجی^{۱۳۰}

بازار تبادل ارز خارجی یا فارکس بزرگ‌ترین و نقدشونده‌ترین بازار مالی در جهان است، با حجم معاملات روزانه بیش از ۶ تریلیون دلار. جفت‌ارزهای اصلی (مانند EUR/USD، USD/JPY و GBP/USD) بیشترین حجم معاملات را به خود اختصاص می‌دهند. بازار فارکس تحت تأثیر نرخ بهره، رویدادهای ژئوپلیتیکی و شاخص‌های کلان اقتصادی قرار دارد و بسیار پویاست. عامل‌های RL در فارکس باید با نوسانات سریع سازگار شوند و در عین حال هزینه‌های تراکنش و ریسک اهرم را نیز در نظر بگیرند.

این شاخص‌ها و دارایی‌ها محیط‌های متنوعی را نمایندگی می‌کنند — از سهام (DJIA و S&P ۵۰۰) گرفته تا کالاها، (XAU/USD) دارایی‌های دیجیتال (رمزارزها) و ارزهای جهانی (فارکس). آزمون الگوریتم‌های RL در چنین ابزارهای گوناگونی موجب تعمیم وسیع‌تر، مقاومت در برابر تغییر رژیم‌ها و ارزیابی واقع‌بینانه‌تر در برابر معیارهای استاندارد مالی می‌شود.

۳-۶ - مدیریت سبد دارایی‌ها و محدودیت‌های معامله‌گری

۳-۶-۱ - معامله تک‌سهام در برابر معامله سبد دارایی‌ها

رویکردهای یادگیری تقویتی^{۱۳۱} در معامله‌گری الگوریتمی می‌توانند یا برای یک دارایی منفرد یا برای یک سبد دارایی^{۱۳۲} به کار گرفته شوند. این انتخاب پیامدهای مهمی برای بازنمایی حالت، فضای عمل^{۱۳۳} و

^{۱۲۹} Cryptocurrencies

^{۱۳۰} Foreign Exchange Market, Forex

^{۱۳۱} Reinforcement Learning, RL

^{۱۳۲} Portfolio

^{۱۳۳} Action Space

طراحی پاداش^{۱۳۴} دارد.

معامله تک سهم^{۱۳۵}: در این حالت، عامل RL تنها بر یک دارایی (مانند سهام Apple، بیت کوین یا طلا) تمرکز می کند. فضای عمل می تواند گسسته (خرید، فروش، نگاه داری) یا پیوسته (مانند تعیین اندازه موقعیت) باشد.

• **مزایا:** فضای حالت و عمل ساده تر، آموزش سریع تر و نیاز کمتر به داده.

• **محدودیت ها:** نبود تنوع بخشی و تمرکز ریسک بر یک دارایی منفرد.

معامله سبد دارایی ها^{۱۳۶}: در این حالت، عامل RL سرمایه را هم زمان میان چندین دارایی (مانند سهام، کالاها یا رمزارزها) تخصیص می دهد. فضای عمل چند بعدی است، زیرا عامل باید وزن های تخصیص برای هر دارایی را تعیین کند، مشروط به محدودیت های بودجه و ریسک.

• **مزایا:** امکان تنوع بخشی، واقع گرایی بیشتر برای سرمایه گذاری نهادی، و بهینه سازی بازدهی تعدیل شده بر اساس ریسک.

• **محدودیت ها:** فضای حالت و عمل بزرگ تر، پیچیدگی آموزشی بالاتر و نیاز بیشتر به داده.

به طور کلی، معامله تک سهم برای مطالعات **اثبات مفهوم^{۱۳۷}** و مقایسه الگوریتم های RL ارزشمند است، در حالی که رویکردهای سبد دارایی بازتاب واقعی تری از مدیریت سرمایه دارند؛ جایی که تنوع بخشی و کنترل ریسک حیاتی است. به همین دلیل، پژوهش های نوین RL در مالی به طور فزاینده ای بر **بهینه سازی سبد دارایی ها^{۱۳۸}** تمرکز می کنند تا راهبردهای معاملاتی مقاوم تر و واقع گرایانه تر ایجاد شود.

۳-۶-۲- فضای حالت^{۱۳۹}

در **یادگیری تقویتی^{۱۴۰}**، فضای حالت اطلاعاتی را تعریف می کند که در هر گام تصمیم گیری در دسترس عامل قرار دارد. در معامله گری، حالت بازنمایی محیط بازار، وضعیت **سبد دارایی ها^{۱۴۱}** و گاه سیگنال های بیرونی را رمزگذاری می کند. طراحی فضای حالت مناسب یکی از حیاتی ترین جنبه های ساخت عامل معاملاتی RL است، زیرا تعیین می کند که عامل چه اطلاعاتی را می تواند مورد استفاده قرار دهد.

۱. **تاریخچه قیمت و بازده:** ساده ترین بازنمایی حالت شامل مقادیر خام OHLCV یا بازده های لگاریتمی در یک پنجره بازگشت است.

• **مزایا:** مستقیم، قابل تفسیر، و نیازمند کمترین پیش پردازش.

^{۱۳۴} Reward Design

^{۱۳۵} Single-stock Trading

^{۱۳۶} Portfolio Trading

^{۱۳۷} Proof-of-Concept

^{۱۳۸} Portfolio Optimization

^{۱۳۹} State Space

^{۱۴۰} Reinforcement Learning, RL

^{۱۴۱} Portfolio

• **محدودیت‌ها:** ناتوانی در ثبت وابستگی‌های زمانی پیچیده یا الگوهای مرتبه‌بالا.

۲. **شاخص‌های فنی^{۱۴۲}:** شاخص‌هایی مانند میانگین‌های متحرک، RSI، MACD و باندهای بولینگر اغلب به‌عنوان ویژگی‌های مهندسی‌شده از OHLCV به حالت افزوده می‌شوند.

• **مزایا:** خلاصه‌سازی فشرده از پویایی قیمت، پرکاربرد در عمل.

• **محدودیت‌ها:** استفاده بیش‌ازحد می‌تواند منجر به افزونگی و ریسک بیش‌برازش^{۱۴۳} شود.

۳. **اطلاعات سبد دارایی‌ها:** در وظایف مدیریت سبد دارایی‌ها^{۱۴۴}، حالت معمولاً شامل تخصیص فعلی سرمایه میان دارایی‌ها، وجه نقد موجود و میزان استفاده از اهرم است.

• **مزایا:** تضمین می‌کند که تصمیم‌های معاملاتی بر اساس وضعیت واقعی سبد اتخاذ شوند.

• **محدودیت‌ها:** در محیط‌های چنددارایی، ابعاد حالت افزایش می‌یابد.

۴. **سیگنال‌های احساسی و بنیادی:** اخبار، گزارش‌های درآمد و رسانه‌های اجتماعی می‌توانند به امتیازهای احساسی تبدیل شوند و در حالت ادغام گردند.

• **مزایا:** ثبت محرک‌های حرکت قیمت فراتر از داده‌های فنی و کمک به توضیح تغییرات ناگهانی.

• **محدودیت‌ها:** سیگنال‌های متنی پرنویز هستند و اغلب با تأخیر نسبت به حرکت قیمت همراه می‌شوند.

۵. **داده‌های ریزساختار بازار^{۱۴۵}:** در معامله‌گری با فرکانس بالا، حالت می‌تواند شامل عمق دفتر سفارش، شکاف خرید-فروش^{۱۴۶} و آمار عدم تعادل سفارش‌ها باشد.

• **مزایا:** ارائه بینش دقیق درباره نقدشوندگی درون‌روزی و پویایی کوتاه‌مدت بازار.

• **محدودیت‌ها:** نیازمند داده‌های حجیم با فرکانس بالا و خطوط پردازش پیچیده.

به‌طور کلی، فضای حالت بنیان اطلاعاتی عامل RL را تشکیل می‌دهد. بازنمایی‌های حداقلی ممکن است سیگنال‌های کلیدی را نادیده بگیرند، در حالی که بازنمایی‌های بیش‌ازحد پیچیده می‌توانند ریسک بیش‌برازش و ضعف تعمیم‌پذیری ایجاد کنند. در عمل، عامل‌های معاملاتی مقاوم اغلب از طراحی متوازن بهره می‌برند — ترکیبی از قیمت‌ها، شاخص‌های فنی، وضعیت سبد دارایی و سیگنال‌های احساسی — تا سازگاری در شرایط متنوع بازار تضمین شود.

^{۱۴۲} Technical Indicators

^{۱۴۳} Overfitting

^{۱۴۴} Portfolio Management

^{۱۴۵} Market Microstructure Data

^{۱۴۶} Bid-Ask Spread

۳-۶-۳- شکل دهی پاداش^{۱۴۷}

در یادگیری تقویتی^{۱۴۸}، تابع پاداش^{۱۴۹} رفتار عامل را هدایت می‌کند و تعیین می‌نماید که چه چیزی موفقیت تلقی می‌شود. در معامله‌گری، شکل دهی پاداش اهمیت ویژه‌ای دارد زیرا بازده‌های خام به‌تنهایی نمی‌توانند اهداف گسترده‌تری مانند کنترل ریسک، هزینه‌های تراکنش یا پایداری راهبرد را بازتاب دهند.

۱. پاداش‌های مبتنی بر سود^{۱۵۰}: مستقیم‌ترین رویکرد استفاده از بازده سبد دارایی به‌عنوان پاداش است:

$$r_t = \frac{V_{t+1} - V_t}{V_t},$$

که در آن V_t ارزش سبد دارایی در زمان t است.

- مزایا: هم‌راستایی مستقیم با بیشینه‌سازی سود.
- محدودیت‌ها: نادیده گرفتن ریسک، که می‌تواند به راهبردهای پرنوسان منجر شود.

۲. پاداش‌های تعدیل‌شده بر اساس ریسک^{۱۵۱}: پاداش‌ها می‌توانند با معیارهای ریسک (مانند نوسان‌پذیری، انحراف معیار نزولی یا افت سرمایه) نرمال شوند:

$$r_t = \frac{R_t - R_f}{\sigma_t},$$

که در آن R_t بازده سبد دارایی، R_f نرخ بدون ریسک و σ_t برآورد نوسان‌پذیری است.

- مزایا: تشویق به راهبردهای روان‌تر و بازده‌های تعدیل‌شده بر اساس ریسک بالاتر.
- محدودیت‌ها: نیازمند برآورد دقیق نوسان‌پذیری یا معیارهای ریسک.

۳. پاداش‌های مبتنی بر مطلوبیت^{۱۵۲}: گنجاندن توابع مطلوبیت (مانند لگاریتمی یا نمایی) امکان مدل‌سازی صریح ترجیحات ریسک را فراهم می‌کند:

$$r_t = U(R_t) = \log(1 + R_t).$$

- مزایا: بازتاب‌دهنده ریسک‌گریزی سرمایه‌گذار و سازگار با نظریه اقتصادی.
- محدودیت‌ها: انتخاب تابع مطلوبیت ذهنی و وابسته به بستر است.

^{۱۴۷} Reward Shaping

^{۱۴۸} Reinforcement Learning, RL

^{۱۴۹} Reward Function

^{۱۵۰} Profit-based Rewards

^{۱۵۱} Risk-adjusted Rewards

^{۱۵۲} Utility-based Rewards

۴. پاداش‌های چندهدفه^{۱۵۳}: توابع پاداش می‌توانند بازده، هزینه‌های تراکنش و معیارهای ریسک را ترکیب کنند:

$$r_t = R_t - \lambda_1 \cdot \text{Cost}_t - \lambda_2 \cdot \text{Risk}_t,$$

که در آن λ_1, λ_2 تعادل میان سودآوری، اصطکاک‌های معاملاتی و ریسک را تعیین می‌کنند.

شکل‌دهی پاداش مستقیماً رفتار معاملاتی را تعیین می‌کند:

- پاداش‌های صرفاً مبتنی بر سود می‌توانند راهبردهای ناپایدار و پرریسک را تشویق کنند.
 - پاداش‌های تعدیل‌شده بر اساس ریسک یا مبتنی بر مطلوبیت، به پایداری و حفظ سرمایه کمک می‌کنند.
 - پاداش‌های چندهدفه امکان تعادل واقع‌گرایانه میان سود، ریسک و هزینه‌های اجرا را فراهم می‌سازند.
- بنابراین طراحی دقیق تابع پاداش برای عامل‌های RL که هدف آن‌ها استقرار در دنیای واقعی است، حیاتی محسوب می‌شود.

۳-۶-۴ - هزینه‌های تراکنش، لغزش قیمتی و محدودیت‌های نقدشوندگی^{۱۵۴}

در عمل، راهبردهای معاملاتی با اصطکاک‌هایی مواجه‌اند که به‌شدت بر عملکرد اثر می‌گذارند. عامل‌های یادگیری تقویتی^{۱۵۵} که بدون در نظر گرفتن این عوامل آموزش می‌بینند، در معرض یادگیری سیاست‌های غیرواقعی قرار دارند که در بازارهای واقعی شکست می‌خورند.

هزینه‌های تراکنش^{۱۵۶}: هر معامله شامل هزینه‌های صریحی مانند کارمزد کارگزار، هزینه‌های بورس و شکاف خرید - فروش^{۱۵۷} است. در محیط‌های RL، این هزینه‌ها معمولاً به‌صورت کارمزدی متناسب با حجم معامله مدل می‌شوند:

$$\text{Cost}_t = c \cdot |q_t|,$$

که در آن c نرخ هزینه و q_t اندازه معامله است. نادیده گرفتن هزینه‌های تراکنش اغلب منجر به بیش‌معامله‌گری می‌شود.

لغزش قیمتی^{۱۵۸}: لغزش به اختلاف میان قیمت مورد انتظار اجرا و قیمت واقعی پرشده اشاره دارد که معمولاً ناشی از بازارهای پرسرعت یا عمق محدود دفتر سفارش است. لغزش معمولاً با افزایش اندازه سفارش و نوسان‌پذیری بیشتر می‌شود. در شبیه‌سازی‌ها، لغزش اغلب به‌صورت یک هزینه اضافی متناسب با حجم معامله و نوسان‌پذیری مدل می‌شود.

محدودیت‌های نقدشوندگی^{۱۵۹}: نقدشوندگی تعیین می‌کند که یک دارایی تا چه حد می‌تواند بدون اثرگذاری چشمگیر بر قیمت معامله شود. دارایی‌های بسیار نقدشونده (مانند سهام شاخص S&P 500 یا

^{۱۵۳} Multi-objective Rewards

^{۱۵۴} Transaction Costs, Slippage, Liquidity Constraints

^{۱۵۵} Reinforcement Learning, RL

^{۱۵۶} Transaction Costs

^{۱۵۷} Bid-Ask Spread

^{۱۵۸} Slippage

^{۱۵۹} Liquidity Constraints

جفت‌های اصلی (Forex) می‌توانند سفارش‌های بزرگ را با لغزش حداقلی جذب کنند، در حالی که دارایی‌های کم‌نقدشونده (مانند سهام شرکت‌های کوچک یا برخی رمزارزها) بیشتر در معرض اثرگذاری بازار هستند. در محیط‌های RL، نقدشوندگی می‌تواند به‌صورت‌های زیر مدل شود:

- سقف‌گذاری بر اندازه موقعیت یا حجم معامله نسبت به حجم بازار،
- افزودن تأخیر در اجرا برای معاملات بزرگ،
- جریمه کردن گردش بیش‌ازحد از طریق تابع پاداش.
- بدون مدل‌سازی هزینه‌ها و لغزش، عامل‌های RL ممکن است به بسامدهای معاملاتی غیرواقعی (مانند صدها معامله در روز) تکیه کنند.
- محدودیت‌های آگاه به نقدشوندگی تضمین می‌کنند که عامل‌ها راهبردهایی مقیاس‌پذیر و مناسب برای استفاده نهادی بیاموزند.
- یکپارچه‌سازی این اصطکاک‌ها در تابع پاداش یا در پویایی محیط به نتایجی مقاوم‌تر و واقع‌گرایانه‌تر در معامله‌گری منجر می‌شود.

۳-۶-۵ - معیارهای ریسک^{۱۶۰}

در معامله‌گری، سودآوری همواره باید در بستر ریسک ارزیابی شود. عامل‌های یادگیری تقویتی^{۱۶۱} که ریسک را نادیده می‌گیرند، ممکن است به سیاست‌های ناپایدار یا غیرعملی همگرا شوند. معیارهای ریسک^{۱۶۲} ابزارهای کمی برای ارزیابی و محدود کردن مواجهه نزولی یک راهبرد معاملاتی فراهم می‌کنند.

۱. نوسان‌پذیری^{۱۶۳}: رایج‌ترین معیار ریسک است و پراکندگی بازده‌ها را ثبت می‌کند:

$$\sigma = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (R_t - \bar{R})^2},$$

که در آن R_t بازده در زمان t است.

- مزایا: محاسبه ساده و استفاده گسترده در نسبت‌های عملکردی مانند نسبت شارپ.
- محدودیت‌ها: انحراف‌های مثبت و منفی را یکسان جریمه می‌کند، در حالی که سرمایه‌گذاران معمولاً بیشتر به ریسک نزولی اهمیت می‌دهند.

^{۱۶۰} Risk Measures

^{۱۶۱} Reinforcement Learning, RL

^{۱۶۲} Risk Measures

^{۱۶۳} Volatility, Standard Deviation

۲. ارزش در معرض ریسک^{۱۶۴}: معیاری که حداکثر زیان بالقوه در یک افق زمانی مشخص با سطح اطمینان α را برآورد می‌کند:

$$\text{VaR}_\alpha(T) = \inf\{x \in \mathbb{R} : P(L_T > x) \leq 1 - \alpha\},$$

که در آن L_T زیان سبد دارایی است.

• مزایا: استفاده گسترده در مدیریت ریسک نهادی و مقرراتی.

• محدودیت‌ها: شدت زیان‌های فراتر از آستانه VaR را ثبت نمی‌کند.

۳. ارزش شرطی در معرض ریسک^{۱۶۵}: زیان مورد انتظار را مشروط به فراتر رفتن از VaR اندازه‌گیری می‌کند:

$$\text{CVaR}_\alpha = \mathbb{E}[L_T \mid L_T > \text{VaR}_\alpha].$$

• مزایا: معیار ریسک همدوس و پوشش‌دهنده ریسک‌های دنباله‌ای و زیان‌های شدید.

• محدودیت‌ها: برآورد محاسباتی سنگین‌تر، به‌ویژه در محیط‌های با فرکانس بالا.

۴. بیشینه افت سرمایه^{۱۶۶}: بزرگ‌ترین افت اوج تا حضيض در ارزش سبد طی یک افق زمانی.

• مزایا: شهودی و پرکاربرد در عمل برای ارزیابی بدترین زیان‌ها.

• محدودیت‌ها: فرکانس یا مدت افت‌ها را نادیده می‌گیرد و تفسیر احتمالاتی ندارد.

۵. معیارهای ریسک نزولی^{۱۶۷}: مانند انحراف نزولی (استفاده‌شده در نسبت Sortino) تنها بر بازده‌های منفی نسبت به بازده هدف یا حداقل قابل قبول تمرکز دارند.

• مزایا: هم‌راستا با ریسک‌گریزی سرمایه‌گذار؛ جریمه کردن صرفاً نوسان‌های مضر.

• محدودیت‌ها: نیازمند تعیین بازده هدف است که ممکن است ذهنی باشد.

• معیارهای ریسک می‌توانند در تابع پاداش ادغام شوند (مانند پاداش‌های مبتنی بر نسبت شارپ یا نسبت Sortino).

• آن‌ها می‌توانند به‌عنوان قیود صریح در بهینه‌سازی سبد دارایی استفاده شوند (مثلاً محدود کردن CVaR یا MDD).

• پایش معیارهای ریسک در طول آموزش تضمین می‌کند که عامل‌های RL راهبردهایی بیاموزند که نه تنها سودآور بلکه مقاوم و قابل‌استقرار در محیط واقعی باشند.

^{۱۶۴} Value at Risk, VaR

^{۱۶۵} Conditional VaR, CVaR / Expected Shortfall

^{۱۶۶} Maximum Drawdown, MDD

^{۱۶۷} Downside Risk Measures

۳-۶-۶- معیارهای ارزیابی^{۱۶۸}

ارزیابی عامل‌های یادگیری تقویتی^{۱۶۹} در معامله‌گری نیازمند معیارهایی است که سودآوری را همراه با ریسک و پایداری در نظر بگیرند. اتکا به بازده خام می‌تواند منجر به راهبردهای ناپایدار یا غیرعملی شود؛ ازاین‌رو معمولاً ترکیبی از معیارهای تعدیل‌شده بر اساس ریسک، سنج‌های رشد و معیارهای تشخیصی به کار می‌روند.

Ratio Sortino و Ratio Sharpe

سودآوری به‌تنهایی برای ارزیابی یک راهبرد در بازارهای پرنوسان کافی نیست. معیارهای تعدیل‌شده بر اساس ریسک مانند **Ratio Sharpe**^{۱۷۰} و **Ratio Sortino**^{۱۷۱} به‌طور گسترده برای سنجش عملکرد نسبت به ریسک استفاده می‌شوند.

Ratio: Sharpe این نسبت بازده مازاد کسب‌شده به ازای هر واحد ریسک کل (انحراف معیار بازده‌ها) را اندازه‌گیری می‌کند:

$$\text{Ratio Sharpe} = \frac{R_p - R_f}{\sigma_p},$$

که در آن R_p میانگین بازده سبد دارایی، R_f نرخ بدون ریسک و σ_p انحراف معیار بازده‌ها است.

• **تفسیر:** مقادیر بالاتر **Ratio Sharpe** نشان‌دهنده عملکرد بهتر تعدیل‌شده بر اساس ریسک هستند، هرچند این معیار نوسان‌های مثبت و منفی را یکسان جریمه می‌کند.

Ratio: Sortino این نسبت اصلاحی بر **Ratio Sharpe** است که تنها بر نوسان نزولی تمرکز دارد:

$$\text{Ratio Sortino} = \frac{R_p - R_f}{\sigma_d},$$

که در آن σ_d انحراف نزولی نسبت به بازده حداقلی قابل قبول (Minimum Acceptable Return, MAR) است.

• **تفسیر:** میان نوسان‌های مضر (زیان‌ها) و مفید (سودها) تمایز قائل می‌شود و اغلب در بستر معامله‌گری مناسب‌تر است.

برای عامل‌های **Ratio Sharpe** و **Ratio Sortino** معیارهای کلیدی برای متوازن‌سازی سود و ریسک محسوب می‌شوند و معمولاً هم به‌عنوان ابزار ارزیابی و هم به‌عنوان بخشی از طراحی پاداش برای تشویق سیاست‌های پایدار به کار می‌روند.

^{۱۶۸} Evaluation Metrics
^{۱۶۹} Reinforcement Learning, RL
^{۱۷۰} Ratio Sharpe
^{۱۷۱} Ratio Sortino

^{۱۷۲} (CAGR) Rate Growth Annual Compound

CAGR رشد میانگین سالانه یک سرمایه‌گذاری را با فرض بازسرمایه‌گذاری سودها اندازه‌گیری می‌کند:

$$CAGR = \left(\frac{V_f}{V_i} \right)^{\frac{1}{T}} - 1,$$

که در آن V_f ارزش نهایی سبد، V_i ارزش اولیه و T تعداد سال‌ها است.

- **تفسیر:** CAGR شاخصی هموار از رشد بلندمدت ارائه می‌دهد و اثر نوسان‌پذیری بر میانگین بازده را حذف می‌کند.

برای عامل‌های CAGR RL، پایداری یک راهبرد را در افق‌های بلندمدت برجسته می‌کند؛ حتی رشدهای متوسط ولی پایدار می‌توانند بر راهبردهای پرنوسان با بازده‌های کوتاه‌مدت بیشتر برتری داشته باشند.

^{۱۷۳} (MDD) Drawdown Maximum

MDD بزرگ‌ترین افت اوج تا حضيض ارزش سبد را پیش از رسیدن به یک اوج جدید اندازه‌گیری می‌کند:

$$MDD = \max_{t \in [0, T]} \left(\frac{V_{\text{to up peak } t} - V_t}{V_{\text{to up peak } t}} \right).$$

- **تفسیر:** مقادیر کوچک‌تر MDD نشان‌دهنده راهبردهای باثبات‌تر هستند؛ افت‌های بزرگ مشکل‌سازند زیرا جبران آن‌ها نیازمند سودهای نامتناسب است.

MDD برای ارزیابی عامل‌های RL حیاتی است، چراکه افت‌های شدید می‌توانند راهبردی سودآور را در عمل غیرقابل قبول سازند. این معیار اغلب همراه با Ratio Sharpe و CAGR برای یک ارزیابی متوازن استفاده می‌شود.

نرخ برد^{۱۷۴} و دقت معاملات^{۱۷۵}

Rate Win نسبت معاملات سودآور به کل معاملات است:

$$\text{Rate Win} = \frac{\text{تعداد معاملات سودآور}}{\text{کل معاملات}} \times 100\%.$$

Accuracy Trade میزان درستی عامل در پیش‌بینی جهت حرکت قیمت را اندازه‌گیری می‌کند:

$$\text{Accuracy} = \frac{\text{تعداد پیش‌بینی‌های صحیح جهت قیمت}}{\text{کل پیش‌بینی‌ها}} \times 100\%.$$

Compound Annual Growth Rate, CAGR^{۱۷۲}

Maximum Drawdown, MDD^{۱۷۳}

Win Rate^{۱۷۵}

Trade Accuracy^{۱۷۵}

• **تفسیر:** نرخ برد یا دقت بالا لزوماً تضمین‌کننده سودآوری نیست، زیرا زیان‌های بزرگ می‌توانند سود معاملات موفق را خنثی کنند. برعکس، حتی یک راهبرد با Rate Win پایین ممکن است سودآور باشد اگر میانگین سود معاملات برد از زیان‌ها بیشتر باشد.

برای عامل‌های Rate Win RL و Accuracy Trade بیشتر نقش تشخیصی دارند و کیفیت پیش‌بینی یا تصمیم‌گیری را نشان می‌دهند. با این حال، بیشترین ارزش آن‌ها زمانی است که در کنار معیارهای تعدیل‌شده بر اساس ریسک (مانند Sharpe و Sortino) سنجه‌های رشد (CAGR) و معیارهای ریسک نزولی (MDD) به کار روند تا یک چارچوب ارزیابی جامع حاصل شود.

۳-۷- جمع‌بندی

این فصل به مرور مفاهیم نظری کلیدی زیربنای پژوهش پرداخت. در ابتدا مبانی یادگیری تقویتی، الگوریتم‌های اصلی آن و کاربردهای مرتبط در معامله‌گری معرفی شدند. سپس نقش مدل‌های زبانی بزرگ، به‌ویژه در استخراج احساسات و اطلاعات متنی، مورد بررسی قرار گرفت. همچنین ساختار داده‌های مالی بازار، شاخص‌های فنی پرکاربرد و محدودیت‌های عملی در مدیریت دارایی مرور شدند. این مباحث، چارچوب نظری لازم برای طراحی روش‌شناسی و انجام آزمایش‌های ارائه‌شده در فصل‌های بعدی را فراهم می‌سازند.

فصل ۴

مرور ادبیات

۴-۱ - مقدمه

هدف این فصل مرور پژوهش‌ها و ابزارهای پیشین است که بنیان این مطالعه را تشکیل می‌دهند. ادبیات مربوط به یادگیری تقویتی^۱ و مدل‌های زبانی بزرگ^۲ در بازارهای مالی به سرعت در حال تکامل است و بازتاب‌دهنده علاقه روزافزون به سامانه‌های معاملاتی داده‌محور و انطباق‌پذیر می‌باشد. برای قرار دادن این پژوهش در بستر علمی موجود، این فصل مشارکت‌های پیشین را در چهار حوزه اصلی بررسی می‌کند.

نخست، به بررسی پیشرفت‌ها در پردازش زبان طبیعی^۳ مالی با استفاده از مدل‌های زبانی بزرگ پرداخته می‌شود، شامل سازگاری‌های خاص دامنه مانند FinBERT و FinGPT، و همچنین مرورهای کلی که فرصت‌ها و چالش‌ها را ترسیم می‌کنند. دوم، کتابخانه‌ها و چارچوب‌های یادگیری تقویتی مرور می‌شوند که پیاده‌سازی‌های استاندارد برای توسعه و ارزیابی عامل‌های معاملاتی فراهم می‌کنند، با تمرکز ویژه بر Stable-Baselines3 و FinRL. سوم، مطالعاتی تحلیل می‌شوند که یادگیری تقویتی عمیق^۴ را در تصمیم‌گیری‌های مالی به کار گرفته‌اند، شامل رویکردهایی از راهبردهای تجمیعی تا تخصیص سبد دارایی مبتنی بر احساسات و معماری‌های چندعاملی. در نهایت، رویکردهای هیبریدی نوظهوری برجسته می‌شوند که به‌طور صریح مدل‌های زبانی بزرگ و یادگیری تقویتی را برای کاربردهای مالی با هم ادغام می‌کنند.

هر مقاله بر اساس تمرکز پژوهشی، روش‌شناسی، نتایج، محدودیت‌ها و سهم بالقوه آن در این پروژه تحلیل خواهد شد. این رویکرد ساختاریافته به ما امکان می‌دهد تا الگوهای تکرارشونده، نقاط قوت روش‌شناختی و خلأهای پژوهشی را شناسایی کرده و طراحی چارچوب پیشنهادی مبتنی بر یادگیری تقویتی و تقویت‌شده با مدل‌های زبانی بزرگ را شکل دهیم.

^۱ RL Learning, Reinforcement

^۲ LLMs Models, Language Large

^۳ NLP Processing, Language Natural

^۴ DRL Learning, Reinforcement Deep

۴-۲- مدل‌های زبانی بزرگ و پردازش زبان طبیعی مالی

۴-۲-۱- Appli- Financial for Models Language Large of Survey A

[۱] Challenges and Prospects Progress، cations:

تمرکز پژوهش

این مرور به بررسی به کارگیری مدل‌های زبانی بزرگ^۵ در کاربردهای مالی می‌پردازد و به‌طور ویژه نقش آن‌ها را در زمینه‌های زیر برجسته می‌کند:

- تحلیل احساسات^۶
- پیش‌بینی سری‌های زمانی^۷
- استدلال و پشتیبانی تصمیم مالی^۸
- مدل‌سازی مبتنی بر عامل^۹ برای معامله‌گری و شبیه‌سازی

این مطالعه هم‌پتانسیل تحول‌آفرین‌ها LLM در پردازش زبان طبیعی مالی^{۱۰} و هم چالش‌های مربوط به پیاده‌سازی عملی آن‌ها را مورد توجه قرار می‌دهد.

روش‌شناسی

نویسندگان یک مرور نظام‌مند از پژوهش‌های موجود ارائه کرده و آن‌ها را در پنج دسته اصلی طبقه‌بندی کرده‌اند: وظایف زبانی، تحلیل احساسات، مدل‌سازی سری‌های زمانی مالی، استدلال مالی و مدل‌سازی مبتنی بر عامل. همچنین نمایی کلی از مجموعه داده‌ها و بنچمارک‌های پرکاربرد ارائه شده و یک چارچوب طبقه‌بندی برای پژوهش‌های LLM در مالی پیشنهاد گردیده است (جدول (۱-۴)).

جدول (۱-۴) حوزه‌های کاربرد مدل‌های زبانی بزرگ در مالی (اقتباس شده از [۱])

دسته	نمونه‌ها
وظایف زبانی	خلاصه‌سازی تماس‌های درآمدی، استخراج اطلاعات از گزارش‌ها
تحلیل احساسات	طبقه‌بندی اخبار مالی، گزارش‌ها و میکرو بلاگ‌ها
سری‌های زمانی مالی	پیش‌بینی مبتنی بر متن، تشخیص ناهنجاری
استدلال مالی	پرسش و پاسخ، پشتیبانی تصمیم، استدلال عددی
مدل‌سازی مبتنی بر عامل	عامل‌های معاملاتی مبتنی بر LLM، شبیه‌سازی بازار

^۵ LLMs Models، Language Large

^۶ Analysis Sentiment

^۷ Forecasting Time-series

^۸ Support Decision and Reasoning Financial

^۹ Modeling Agent-based

^{۱۰} NLP Financial Processing، Language Natural Financial

یافته‌ها

یافته‌های کلیدی این مرور عبارتند از:

- ها LLM به‌طور مداوم عملکردی بهتر از مدل‌های سنتی پردازش زبان طبیعی در وظایف مالی ارائه می‌دهند.
- پیش‌تمرین حوزه‌محور (مانند FinBERT و FinGPT) دقت و پایداری مدل‌ها را به‌طور قابل‌توجهی افزایش می‌دهد.
- بنچمارک‌هایی مانند FiQA FPB و FinQA بهبود چشمگیری در طبقه‌بندی احساسات، پرسش و پاسخ مالی و وظایف استدلالی نشان داده‌اند.

محدودیت‌ها

با وجود مزایا، چالش‌های زیر همچنان باقی است:

- **کمبود داده و انطباق حوزه‌ای:** مجموعه داده‌های مالی با کیفیت محدود و برجسب‌گذاری آن‌ها پرهزینه است.
- **سوگیری نگاه به آینده^{۱۱}:** خطر وارد شدن اطلاعات آینده در مدل‌های پیش‌بینی وجود دارد.
- **هزینه محاسباتی و تأخیر:** های LLM بزرگ نیازمند منابع محاسباتی قابل‌توجهی هستند که استفاده آن‌ها را در کاربردهای زمان‌واقعی محدود می‌کند.
- **تفسیرپذیری:** شفافیت محدود تصمیمات، اعتماد کاربران به مدل‌ها را کاهش می‌دهد.
- **ریسک‌های نظارتی:** مسائل حقوقی، انطباقی و اخلاقی مانع به‌کارگیری گسترده در مؤسسات مالی می‌شوند.

سهم در پروژه من

Pre-trained with Analysis Sentiment Financial FinBERT: ۴-۲-۲ - [۲] Models Language

تمرکز پژوهش

مدل FinBERT به چالش تحلیل احساسات^{۱۲} در متون مالی می‌پردازد، جایی که مدل‌های عمومی تحلیل احساسات به دلیل اصطلاحات تخصصی و بافت حوزه‌ای عملکرد ضعیفی دارند. هدف، سازگار کردن BERT برای طبقه‌بندی دقیق اخبار مالی، گزارش‌ها و بیانیه‌ها است.

^{۱۱} Bias Look-ahead
^{۱۲} Analysis Sentiment

روش‌شناسی

- پیش‌تمرین^{۱۳} BERT بر روی یک پیکره متنی بزرگ مالی (مانند اخبار، پرونده‌های شرکتی، گزارش‌های تحلیلی).
- ریزتنظیم^{۱۴} بر روی مجموعه داده‌های بنچمارک تحلیل احساسات مالی برای طبقه‌بندی سه کلاسه (مثبت، منفی، خنثی).
- مقایسه عملکرد با روش‌های سنتی یادگیری ماشین^{۱۵} و مدل‌های عمومی تحلیل احساسات مبتنی بر BERT.

جدول (۲-۴) نمای کلی روش‌شناسی FinBERT

گام	توضیح
پیش‌تمرین	آموزش حوزه‌محور بر روی پیکره‌های بزرگ متون مالی
ریزتنظیم	طبقه‌بندی احساسات (مثبت/منفی/خنثی) با استفاده از-Financial PhraseBank و مجموعه داده‌های مشابه
مقایسه مبنا	مقایسه با روش‌های مبتنی بر واژگان و رویکردهای سنتی یادگیری ماشین

یافته‌ها

- دقت و امتیاز F1 به‌طور قابل‌توجهی بالاتر از مدل‌های عمومی تحلیل احساسات است.
- توانمند در شناسایی ظرافت‌های بیانی مالی (مانند «کاهش جزئی»، «چشم‌انداز قوی»).
- پایداری بالا در مجموعه داده‌های مختلف (مانند Financial PhraseBank و FiQA).

محدودیت‌ها

- نیازمند دسترسی به متون مالی بزرگ و باکیفیت برای پیش‌تمرین.
- همچنان محدودیت‌های معماری BERT را دارد (مانند محدودیت طول ورودی).
- مانند سایر مدل‌های ترنسفورمر^{۱۶} فاقد تفسیرپذیری و قابلیت توضیح است.
- عملکرد ممکن است در زمینه‌هایی که نیازمند استدلال اقتصادی عمیق‌تر هستند افت کند.

^{۱۳} Pre-training

^{۱۴} Fine-tuning

^{۱۵} ML Learning, Machine

^{۱۶} Transformers

سهم در پروژه من

Mod - Language Large Financial Open - Source FinGPT: ۳-۲-۴ [۳] els

تمرکز پژوهش

FinGPT به دنبال دموکراتیک سازی دسترسی به مدل های زبانی بزرگ مالی^{۱۷} است و یک جایگزین متن باز، مقرون به صرفه و قابل سفارشی سازی برای سامانه های اختصاصی هوش مالی فراهم می کند. تمرکز این پروژه بر امکان پذیر کردن تحلیل احساسات مالی^{۱۸}، خلاصه سازی گزارش ها و پرسش و پاسخ است، در حالی که موانع پذیرش در دانشگاه و صنعت را کاهش می دهد.

روش شناسی

FinGPT از مدل های زبانی بزرگ متن باز استفاده کرده و آن ها را با بهره گیری از ریزتنظیم^{۱۹} کارآمد و تکنیک های هم تراز^{۲۰}ی به حوزه مالی سازگار می کند:

- **ستون فقرات مدل^{۲۰}:** ساخته شده بر پایه معماری های متن باز خانواده GPT.
- **انطباق حوزه ای:** استفاده از تنظیم مبتنی بر دستورالعمل^{۲۱} و ریزتنظیم بر پیکره مالی برای سازگاری با وظایف خاص حوزه.
- **کارایی:** به کارگیری روش های سازگار کم رتبه (LoRA) و رویکردهای سبک و بهینه سازی پارامترها برای کاهش هزینه محاسباتی.
- **هم تراز^{۲۲}:** بهره گیری از یادگیری تقویتی با بازخورد انسانی^{۲۲} برای اطمینان از پاسخ های قابل اعتماد و متناسب با وظایف مالی.

جدول (۳-۴) نکات کلیدی روش شناسی FinGPT

مؤلفه	توضیح
ستون فقرات مدل	مدل های زبانی بزرگ متن باز خانواده GPT
انطباق حوزه ای	تنظیم مبتنی بر دستورالعمل همراه با ریزتنظیم داده های مالی
روش های کارایی	LoRA و خطوط آموزشی بهینه سازی شده برای پارامترها
هم تراز	RLHF برای افزایش قابلیت اعتماد و عملکرد وظیفه ای

^{۱۷} LLMs Models, Language Large

^{۱۸} Analysis Sentiment Financial

^{۱۹} Fine-tuning

^{۲۰} Backbone Model

^{۲۱} Tuning Instruction

^{۲۲} RLHF Feedback, Human with Learning Reinforcement

یافته‌ها

- عملکرد رقابتی روی بنچمارک‌های پردازش زبان طبیعی مالی در مقایسه با نمونه‌های اختصاصی نشان می‌دهد.
- قابلیت سازگاری در طیف متنوعی از وظایف شامل طبقه‌بندی احساسات، پرسش و پاسخ و خلاصه‌سازی.
- چارچوب متن‌باز شفافیت، قابلیت سفارشی‌سازی و پژوهش مشارکتی را ترویج می‌دهد.
- جایگزینی مقرون‌به‌صرفه در برابر مدل‌های مالی اختصاصی و غیرمتن‌باز فراهم می‌آورد.

محدودیت‌ها

- عملکرد وابسته به پوشش و کیفیت داده‌های آموزشی مالی است.
- ممکن است از مدل‌های اختصاصی بزرگ که بر روی پیکره‌های عظیم آموزش دیده‌اند عقب بماند.
- مقاومت در کاربردهای حساس یا دارای الزامات سخت‌گیرانه انطباقی همچنان چالش‌برانگیز است.
- خطر توهم‌زایی (Hallucination) مسائل اخلاقی، حقوقی و نظارتی را در حوزه مالی مطرح می‌کند.

سهم در پروژه من

۴ - ۳ - کتابخانه‌ها و مرورهای RL در مالی

Algorithm - Quantitative in Learning Reinforcement Deep - ۱ - ۳ - ۴

[۴] Review A Trading: mic

تمرکز پژوهش

این مرور به بررسی به کارگیری یادگیری تقویتی عمیق^{۲۳} در معامله‌گری الگوریتمی کم‌فرکانس^{۲۴} کمی می‌پردازد. بازار سهام به عنوان محیطی با مشاهده جزئی و اطلاعات ناقص در نظر گرفته می‌شود — مشابه بازی‌هایی مانند Go یا شطرنج — که در آن عامل‌ها راهبردهایی برای بیشینه‌سازی بازده تجمیعی در عین مدیریت ریسک می‌آموزند.

روش‌شناسی

دامنه مرور محدود به عامل‌های معاملاتی DRL خودکار و انتها-به-انتها است که در بازه‌های دقیقه‌ای تا روزانه فعالیت می‌کنند. مدل‌های پیش‌بینی، رویکردهای ترکیبی/فراابتکاری^{۲۵}، روش‌های بهینه‌سازی سبب‌دارایی و معامله‌گری با فرکانس بالا در نظر گرفته نشده‌اند. رویکردهای بررسی‌شده به سه خانواده اصلی دسته‌بندی شده‌اند (جدول (۴-۴)).

^{۲۳} DRL Learning, Reinforcement Deep

^{۲۴} Trading Algorithmic Low-frequency

^{۲۵} Approaches Hybrid/Metaheuristic

جدول (۴-۴) دسته‌بندی رویکردهای DRL در معامله‌گری (اقتباس شده از [۴])

دسته	نمونه‌ها
فقط منتقد (مبتنی بر شبکه‌های Q عمیق ^{۲۷} ، DQN دوگانه ^{۲۸} ارزش) ^{۲۶}	
فقط بازیگر (مبتنی بر REINFORCE، روش‌های گرادیان سیاست ^{۳۰} سیاست) ^{۲۹}	
ترکیبی بازیگر-منتقد	بازیگر-منتقد مزیت ^{۳۱} ، گرادیان سیاست قطعی عمیق ^{۳۲} ، بهینه‌سازی سیاست مجانبی ^{۳۳}

یافته‌ها

- عامل‌های معاملاتی مبتنی بر DRL عموماً در مطالعات شبیه‌سازی عملکردی بهتر از مبنای سنتی دارند.
- دستاوردهای گزارش شده عمدتاً ماهیتی آماری دارند و همیشه به سودآوری واقعی منجر نمی‌شوند.
- بیشتر پژوهش‌ها در حد اثبات مفهوم باقی مانده‌اند و نتایجی متوسط اما امیدوارکننده ارائه داده‌اند.

محدودیت‌ها

- اکثر مطالعات به شبیه‌سازی بک‌تست ساده متکی‌اند و نه محیط‌های معاملاتی واقعی.
- تحلیل مقایسه‌ای محدودی میان الگوریتم‌های مختلف DRL وجود دارد و بنچمارک‌های اندکی در برابر معامله‌گران انسانی انجام شده است.
- موانع عملی مانند تأخیر، هزینه‌های تراکنش و اصطکاک‌های ریزساختار بازار اغلب نادیده گرفته می‌شوند.
- سودآوری پایدار در شرایط واقعی همچنان اثبات نشده است.

سهم در پروژه من

Im - Learning Reinforcement Reliable Stable - Baselines^۳: - ۲ - ۳ - ۴ [۵] plementations

تمرکز پژوهش

Stable-Baselines3 (SB3) یک کتابخانه متن‌باز است که پیاده‌سازی‌های قابل‌اعتماد و آزموده‌شده از الگوریتم‌های یادگیری تقویتی عمیق^{۳۴} در پایتون ارائه می‌دهد. این کتابخانه که بر پایه PyTorch و به‌عنوان جانشین Stable-Baselines (مبتنی بر TensorFlow) ساخته شده است، هدف اصلی‌اش تضمین بازتولیدپذیری، سهولت استفاده و قابلیت توسعه پژوهشی در یادگیری تقویتی است. این کتابخانه با ارائه پیاده‌سازی‌های استاندارد الگوریتم‌ها برای بنچمارک‌گیری^{۳۵}، آزمایش و توسعه روش‌های جدید، هم از پژوهشگران و هم از متخصصان کاربردی پشتیبانی می‌کند.

^{۳۴}DRL Learning, Reinforcement Deep
^{۳۵}Benchmarking

روش‌شناسی

SB3 بر قابلیت اعتماد، بازتولیدپذیری و دسترس‌پذیری از طریق اصول طراحی زیر تأکید می‌کند:

- **قابلیت اعتماد و بازتولیدپذیری:** اجرای پروتکل‌های تست سخت‌گیرانه (واحد، یکپارچه‌سازی، بازگشتی) و تضمین نتایج قطعی در صورت امکان.
- **سهولت استفاده:** ارائه یک رابط سطح بالا و کاربرپسند (مانند `.learn()`) با حلقه‌های آموزشی و ارزیابی سازگار در تمام الگوریتم‌ها. سازگاری کامل با OpenAI Gym، PyTorch و NumPy.
- **قابلیت توسعه:** معماری ماژولار که اجازه می‌دهد سیاست‌ها، شبکه‌ها، حافظه‌های بازپخش^{۳۶} و توابع زیان به راحتی سفارشی شوند، و این امکان را فراهم می‌کند که نمونه‌سازی سریع روش‌های جدید RL صورت گیرد.

یافته‌ها

- SB3 شامل الگوریتم‌های پرکاربرد یادگیری تقویتی است، هم مبتنی بر سیاست جاری^{۳۷} (مانند PPO، A2C، TRPO) و هم خارج از سیاست^{۳۸} (مانند DQN، DDPG، TD3، SAC).
- بنچمارک‌گیری در محیط‌های استاندارد (مانند MuJoCo و Atari) نتایجی هم‌تراز یا بهتر از آنچه در مقالات اصلی الگوریتم‌ها و نسخه قبلی Stable-Baselines گزارش شده بود ارائه داد.
- ابرپارامترها^{۳۹} و پیکربندی‌های پیش‌فرض با دقت بر اساس مقالات اصلی تنظیم شده‌اند تا نتایج قابل اعتماد حاصل شود.

محدودیت‌ها

- تمرکز بر پیاده‌سازی‌های تک‌ماشینه و غیرتوزیعی؛ فاقد مقیاس‌پذیری مشابه چارچوب‌هایی مانند RLlib یا Tianshou.
- الگوریتم‌های آزمایشی به صورت جداگانه در SB3-Contrib ارائه می‌شوند که ممکن است همان سطح پایداری و آزمون‌پذیری را نداشته باشند.
- با وجود اولویت‌دهی به بازتولیدپذیری، نتایج همچنان ممکن است بسته به تصادفی بودن محیط یا تفاوت سخت‌افزار تغییر کنند.

^{۳۶} Buffers Replay

^{۳۷} On-policy

^{۳۸} Off-policy

^{۳۹} Hyperparameters

Au- for Library Learning Reinforcement Deep A FinRL: -۳-۳-۴ [۶] Finance Quantitative in Trading Stock tomated

تمرکز پژوهش

FinRL یکی از نخستین کتابخانه‌های متن‌باز یادگیری تقویتی عمیق^{۴۰} است که به‌طور خاص برای حوزه مالی کمی طراحی شده است. هدف اصلی آن فراهم کردن یک چارچوب بازتولیدپذیر، قابل گسترش و کاربرپسند است که سد ورود برای پژوهشگران و متخصصان علاقه‌مند به توسعه راهبردهای معامله‌گری خودکار را کاهش دهد.

روش‌شناسی

این کتابخانه یک معماری سه‌لایه ماژولار اتخاذ می‌کند که انعطاف‌پذیری و قابلیت توسعه را در کاربردهای مختلف ممکن می‌سازد:

- **لایه محیط:** شبیه‌سازی بازار با استفاده از داده‌های تاریخی یا بلادرنگ، شامل هزینه‌های معاملاتی، محدودیت‌های نقدشوندگی و ترجیحات ریسک سرمایه‌گذار.

- **لایه عامل:** پیاده‌سازی الگوریتم‌های پیشرفته DRL (مانند DQN, DDPG, PPO, SAC, A2C, TD3) با توابع پاداش قابل سفارشی‌سازی.

- **لایه کاربرد:** ماژول‌های آماده برای معامله سهام، تخصیص دارایی و معامله رمزارز، همراه با ابزارهای یکپارچه برای بک‌تست^{۴۱}.

این چارچوب در PyTorch پیاده‌سازی شده، با API OpenAI Gym - سازگار است و مستندات و آموزش‌های گسترده‌ای برای پشتیبانی از آموزش و بازتولیدپذیری ارائه می‌دهد.

جدول (۵-۴) Key components of the FinRL framework

ویژگی‌های کلیدی	مؤلفه
داده‌های تاریخی/بلادرنگ، هزینه‌های تراکنش، محدودیت‌های نقدشوندگی	لایه محیط
الگوریتم‌های (DQN, DRL), TD3, A2C, SAC, PPO, توابع پاداش قابل سفارشی‌سازی	لایه عامل
ماژول‌های معامله سهام و رمزارز، راهبردهای پرتفوی ^{۴۲} ، ابزارهای بک‌تست	لایه کاربرد

^{۴۰} DRL Learning, Reinforcement Deep
^{۴۱} Backtesting

یافته‌ها

- نشان می‌دهد که عامل‌های DRL می‌توانند در وظایف متنوع معامله‌گری مالی به‌طور موفق عمل کنند.
- بنچمارک‌های بازتولیدپذیر و محیط‌های استاندارد فراهم می‌کند که مقایسه منصفانه الگوریتم‌ها را ممکن می‌سازد.
- به‌طور گسترده در پژوهش‌های دانشگاهی و آموزش مورد استفاده قرار گرفته و پلی میان یادگیری ماشین و مالی کمی ایجاد کرده است.

محدودیت‌ها

- راهبردهای سودآور آماده ارائه نمی‌دهد؛ بیشتر به‌عنوان یک جعبه‌ابزار زیرساختی عمل می‌کند تا یک راه‌حل معاملاتی کامل.
- برخی انتخاب‌های طراحی محیط (مانند نمایش فضای عمل) ممکن است سوگیری‌های مدل‌سازی ظریفی ایجاد کنند.
- استقرار در دنیای واقعی نیازمند تخصص بالای حوزه، مهندسی داده و مدیریت ریسک فراتر از خود ابزار است.

سهم در پروژه من

Trad - Stock Automated for Learning Reinforcement Deep ۴ - ۳ - ۴ [۷] Strategy Ensemble An ing:

تمرکز پژوهش

این مطالعه یک راهبرد تجمیعی^{۴۳} مبتنی بر یادگیری تقویتی عمیق^{۴۴} را برای معامله‌گری خودکار سهام پیشنهاد می‌دهد. هدف اصلی، ترکیب نقاط قوت چند الگوریتم DRL برای ساخت یک عامل معاملاتی مقاوم‌تر و سازگارتر است که بتواند با رژیم‌های پویا و پرنوسان بازار مقابله کند.

روش‌شناسی

چارچوب تجمیعی چند الگوریتم بازیگر-منتقد^{۴۵} را با یک فرآیند انتخاب سیستماتیک ادغام می‌کند:

- **الگوریتم‌های استفاده‌شده:** Proximal Policy Optimization (PPO)، Advan-، Actor-Critic (A2C) و Deep Deterministic Policy Gradient (DDPG).

^{۴۳}Strategy Ensemble
^{۴۴}Deep Reinforcement Learning
^{۴۵}Actor-Critic

- **تکنیک بارگذاری در صورت نیاز^{۴۶}:** روشی کارآمد برای مدیریت داده با هدف کاهش سربار حافظه در فضای عمل پیوسته.

• سازوکار تجمیع:

- عامل‌ها با استفاده از پنجره‌های متحرک داده‌های تاریخی آموزش داده می‌شوند.
- یک پنجره اعتبارسنجی برای ارزیابی عامل‌ها بر اساس نسبت شارپ^{۴۷} (بازده تعدیل‌شده بر اساس ریسک) و شاخص آشفتگی^{۴۸} (کنترل ریسک) استفاده می‌شود.
- بهترین عامل برای اجرای معاملات در دوره معاملاتی بعدی انتخاب می‌شود.
- **مجموعه داده:** سی سهم از شاخص Dow Jones Industrial Average (DJIA).
- **مقایسه با مبنا:** شاخص DJIA و پرتفوی حداقل واریانس^{۴۹}.

جدول (۴-۶) مروری بر راهبرد تجمیعی (Li, et al., ۲۰۲۰)

مؤلفه	توضیحات
الگوریتم‌ها	DDPG A2C، PPO، (مدل‌های DRL بازیگر-منتقد)
معیار انتخاب	نسبت شارپ (تعدیل‌شده با ریسک)، شاخص آشفتگی (کنترل ریسک)
فرآیند	آموزش → اعتبارسنجی → انتخاب بهترین عامل → معامله
مقایسه با مبنا	شاخص DJIA، پرتفوی حداقل واریانس

یافته‌ها

- راهبرد تجمیعی به‌طور مداوم عملکردی بهتر از خط‌مبناهای تک‌عاملی (DDPG و A2C، PPO، DRL) دارد.
- نسبت‌های شارپ بالاتر و بازده‌های تعدیل‌شده با ریسک پایدارتر تولید می‌کند.
- با انتخاب عامل مناسب تحت رژیم‌های مختلف بازار، سازگاری بالایی نشان می‌دهد.

محدودیت‌ها

- از نظر محاسباتی پرهزینه است، زیرا نیازمند آموزش و نگهداری چندین عامل به‌طور همزمان است.
- عملکرد به اندازه پنجره متحرک، ابرپارامترها و شرایط غالب بازار حساس است.

^{۴۶} technique Load-on-demand

^{۴۷} Ratio Sharpe

^{۴۸} Index Turbulence

^{۴۹} Portfolio Minimum-variance

- محدود به سه الگوریتم است؛ گسترش به روش‌های جدیدتر (مانند SAC یا TD^۳) می‌تواند مقاومت را افزایش دهد.
- ارزیابی تنها به یک تست محدود است؛ استقرار در دنیای واقعی همچنان تأیید نشده است.

سهم در پروژه من

Automated Learning - Based Reinforcement Deep Novel A - ۵ - ۳ - ۴ Networks LSTM Cascaded Using System Trading Stock

[۸]

تمرکز پژوهش

این مقاله به چالش‌های به کارگیری یادگیری تقویتی عمیق^{۵۰} در سری‌های زمانی مالی می‌پردازد؛ سری‌هایی که با نسبت پایین سیگنال به نویز و الگوهای نامنظم و نایستای مشخص می‌شوند. نویسندگان یک معماری Cascaded LSTM پیشنهاد می‌کنند تا توانایی عامل‌های DRL در ثبت وابستگی‌های زمانی و ساختارهای پنهان در داده‌های روزانه قیمت سهام افزایش یابد.

روش‌شناسی

این چارچوب با یک طراحی دو مرحله‌ای Cascaded LSTM، استخراج ویژگی و یادگیری تقویتی را ترکیب می‌کند:

- **مرحله استخراج ویژگی:** نخستین شبکه LSTM الگوهای زمانی را از داده‌های خام روزانه سهام مدل‌سازی می‌کند.

- **مرحله عامل:** ویژگی‌های استخراج‌شده به یک عامل DRL مبتنی بر Proximal Policy Op-timization (PPO) داده می‌شوند، جایی که یک LSTM دیگر درون شبکه‌های بازیگر-منتقد^{۵۱} تعبیه شده تا تصمیم‌گیری دنباله‌ای بهبود یابد.

این سیستم بر روی چهار شاخص عمده سهام ارزیابی شده است: Dow Jones Industrial Average (US)، SSE50 (China)، SENSEX (India) و FTSE100 (UK). عملکرد آن در برابر مبناهایی مانند Buy-and-Hold، PPO-MLP، مدل‌های Standalone LSTM/MLP، Gradient Boosting، LightGBM و راهبردهای DRL تجمیعی مقایسه شده است.

یافته‌ها

- سیستم Cascaded LSTM-PPO بهبودهایی در حدود ۵ تا ۵۲ درصد در شاخص‌های مالی کلیدی، از جمله بازده تجمعی، بیشینه نرخ سود، و میانگین سود هر معامله نشان داد.

^{۵۰}DRL Learning, Reinforcement Deep
^{۵۱}Actor-Critic

- عملکردی بهتر از مبناهای یادگیری ماشین سنتی و مدل‌های DRL بدون ادغام Cascaded LSTM داشت.
- در بازار SSE50 عملکرد به‌ویژه قوی بود که نشان‌دهنده سازگاری در زمینه بازارهای نوظهور است.

محدودیت‌ها

- پیچیدگی و هزینه آموزشی بیشتر به دلیل معماری دومرحله‌ای.
- حساسیت به ابرپارامترها، رژیم‌های بازار و فرکانس داده که ممکن است مقاومت را کاهش دهد.
- ارزیابی محدود به آزمایش‌های بک‌تست، بدون اعتبارسنجی در معاملات زنده.

سهم در پروژه من

Reinforced Hierarchical A Enough: not is Fee Commission - ۴ - ۳ - ۶ [۹] Management Portfolio for Framework

تمرکز پژوهش

این مطالعه به یک محدودیت رایج در مدیریت پرتفوی مبتنی بر یادگیری تقویتی عمیق^{۵۲} اشاره می‌کند: اغلب مدل‌های موجود تنها کارمزد کمیسیون را به‌عنوان هزینه معاملاتی در نظر می‌گیرند و تأثیر قابل‌توجه لغزش قیمتی^{۵۳} را نادیده می‌گیرند. از آنجا که لغزش می‌تواند نتایج اجرا را به‌طور چشمگیری تغییر دهد، نویسندگان HRPM را پیشنهاد می‌کنند؛ یک چارچوب تقویتی سلسله‌مراتبی که تخصیص پرتفوی را از اجرای معاملات به‌طور صریح جدا می‌کند.

روش‌شناسی

- چارچوب HRPM از طراحی سلسله‌مراتبی دوسطحی استفاده می‌کند:
- **سیاست سطح بالا:** وزن‌های پرتفوی را در فرکانس پایین‌تر تعیین می‌کند با هدف بیشینه‌سازی بازده بلندمدت.
 - **سیاست سطح پایین:** معاملات را در بازه‌های کوتاه‌تر اجرا می‌کند و به‌طور راهبردی هزینه‌های معاملاتی از جمله لغزش را به حداقل می‌رساند.
- راهبرد آموزشی شامل موارد زیر است:
- پیش‌آموزش هر دو سطح به‌صورت جداگانه برای ایجاد رفتارهای پایه.
 - آموزش مشترک تکرارشونده برای دستیابی به کارایی هماهنگ بین راهبرد و اجرا.
- این چارچوب بر روی بازار سهام ایالات متحده و چین ارزیابی شده و با خط‌مبناهای DRL و روش‌های سنتی مدیریت پرتفوی مقایسه شده است.

^{۵۲}DRL Learning, Reinforcement Deep
^{۵۳}Slippage Price

یافته‌ها

- **هزینه‌های معاملاتی:** تحلیل نشان می‌دهد که کارمزد کمیسیون تنها بخش کوچکی از هزینه‌ها را تشکیل می‌دهد، در حالی که لغزش در اجراهای واقعی (به‌ویژه برای معاملات با حجم بالا) غالب است.
- **تنظیم آنتروپی^{۵۴}:** افزودن پاداش آنتروپی باعث بهبود تنوع‌سازی می‌شود:
 - $\eta = 0.05$ بالاترین بازده سالانه^{۵۵} را به دست می‌آورد.
 - $\eta = 0.1$ کمترین افت سرمایه بیشینه^{۵۶} را حاصل می‌کند.
- **رفتار اجرا:** سیاست سطح پایین معاملات را به‌صورت راهبردی پخش می‌کند، مانند فروش جزئی زودهنگام و هم‌تراز کردن خرید/فروش با پویایی کوتاه‌مدت قیمت، که هزینه‌های لغزش را کاهش می‌دهد.
- **عملکرد کلی:** HRPم در هر دو بازار ایالات متحده و چین بهتر از خط‌مبناهای DRL و راهبردهای کلاسیک پرتفوی عمل می‌کند.

محدودیت‌ها

- معماری دوسطحی پیچیدگی و هزینه آموزشی مدل را افزایش می‌دهد.
- حساسیت به ابرپارامترها (مانند وزن آنتروپی η) بر تعادل میان ریسک و بازده تأثیر می‌گذارد.
- صرفاً از طریق بک‌تست ارزیابی شده است؛ هیچ آزمایش معاملات زنده انجام نشده است.
- پویایی اجرا ممکن است تحت شرایط بازاری که در مطالعه ثبت نشده‌اند، متفاوت باشد.

سهام در پروژه من

۴-۳-۷ Re-Deep on Based Framework Fusion Data Multi-Type [۱۰] Trading Algorithmic for Learning inforcement

تمرکز پژوهش

این مقاله به محدودیت‌های سامانه‌های معامله‌گری مبتنی بر DRL^{۵۷} که فقط از یک منبع داده استفاده می‌کنند می‌پردازد. چنین سامانه‌هایی اغلب نمی‌توانند ماهیت چندبُعدی بازارهای مالی را به‌طور کامل ثبت کنند. برای رفع این مشکل، نویسندگان MSF-DRL را پیشنهاد می‌دهند؛ چارچوبی برای ادغام چندمنوع داده که داده‌های خام سهام، شاخص‌های فنی^{۵۸} و تصاویر نمودار شمعی^{۵۹} را با هم ترکیب می‌کند تا بازنمایی جامع‌تری از بازار ساخته شود.

Regularization Entropy^{۵۴}

ARR Return, Annualized^{۵۵}

MDD Drawdown, Maximum^{۵۶}

Learning Reinforcement Deep^{۵۷}

Indicators Technical^{۵۸}

Charts Candlestick^{۵۹}

روش‌شناسی

چارچوب MSF-DRL از یک فرآیند استخراج ویژگی دوشاخه و سپس ادغام استفاده می‌کند:

- **شاخه عددی:** قیمت‌های سهام و شاخص‌های فنی با یک شبکه LSTM^{۶۰} پردازش می‌شوند تا وابستگی‌های زمانی استخراج و نویز کاهش یابد.
 - **شاخه دیداری:** نمودارهای شمعی با یک شبکه CNN^{۶۱} همراه با BiLSTM^{۶۲} کدگذاری می‌شوند تا الگوهای دیداری فضایی و توالی‌محور هر دو ثبت شوند.
 - **ادغام:** ویژگی‌های هر دو شاخه ترکیب شده و یک بازنمایی حالت جامع ساخته می‌شود.
- بازنمایی حالت ادغام‌شده سپس به یک عامل DRL داده می‌شود که خروجی آن تصمیمات گسسته خرید، فروش یا نگهداری است.

یافته‌ها

- MSF-DRL عملکرد بهتری نسبت به خط‌مبناهای سنتی و مدل‌های DRL تک‌منبعی دارد.
- سودآوری بالاتر و نسبت‌های شارپ^{۶۳} بهتری ارائه می‌دهد که نشان‌دهنده بازده‌های تعدیل‌شده با ریسک قوی‌تر است.
- پایداری میان‌بازاری نشان می‌دهد و هم در داده‌های سهام چین و هم در برخی سهام S&P ۵۰۰ عملکرد مؤثری دارد.

محدودیت‌ها

- معماری دوشاخه پیچیدگی محاسباتی و هزینه آموزش را افزایش می‌دهد.
- عملکرد به کیفیت تولید نمودارهای شمعی و انتخاب‌های پیش‌پردازش حساس است.
- ارزیابی تنها به بک‌تست تاریخی محدود است و هیچ اعتبارسنجی در معاملات زنده انجام نشده است.
- ادغام داده به سه نوع محدود می‌شود و منابع اطلاعاتی دیگر مانند احساسات یا اخبار در نظر گرفته نشده‌اند.

Memory Short-Term Long^{۶۰}
 Network Neural Convolutional^{۶۱}
 LSTM Bidirectional^{۶۲}
 Ratio Sharpe^{۶۳}

۴-۳-۸ - Learning Reinforcement Deep Sentiment-Aware Market Allocation Portfolio Stock for Approach [۱۱]

تمرکز پژوهش

این مقاله به یکی از محدودیت‌های کلیدی راهبردهای تخصیص پرتفوی مبتنی بر DRL^{۶۴} می‌پردازد؛ این مدل‌ها معمولاً فقط به اطلاعات قیمتی تاریخی متکی هستند. نویسندگان یک چارچوب DRL آگاه از احساسات^{۶۵} پیشنهاد می‌دهند که قیمت‌های بازار را با احساسات سرمایه‌گذاران ادغام می‌کند و بدین ترتیب پویایی‌های روانشناختی بازار را که نقش مهمی در بازده سهام دارند، ثبت می‌نماید.

روش‌شناسی

این چارچوب بازنمایی حالت را با ترکیب سیگنال‌های کمی و احساسی غنی‌تر می‌سازد:

- **ورودی‌های یکپارچه:** ترکیب داده‌های تاریخی سهام با ویژگی‌های احساسی استخراج شده از اخبار مالی و رسانه‌های اجتماعی.
- **استخراج احساسات:** اگرچه جزئیات خط لوله پردازش زبان طبیعی مشخص نشده، امتیازهای احساسی به ویژگی‌های کمی مناسب برای ورودی مدل تبدیل شده‌اند.
- **چارچوب: DRL** بازنمایی حالت غنی شده به یک عامل DRL داده می‌شود (الگوریتم دقیق مشخص نیست، اما رویکردهایی مانند DQN یا PPO کاربردپذیر هستند).
- **دامنه پرتفوی:** ارزیابی روی شرکت‌های شاخص Dow Jones Industrial Average (DJIA) انجام شده است.

یافته‌ها

- مدل‌های DRL آگاه از احساسات عملکرد بهتری نسبت به رویکردهای DRL متکی صرف به داده‌های قیمتی دارند.
- نسبت‌های شارپ^{۶۶} و بازده‌های سالانه بالاتری به دست می‌آورند.
- با ادغام سیگنال‌های احساسی، مقاومت بیشتری در تخصیص پرتفوی نشان می‌دهند.

محدودیت‌ها

- فرآیند استخراج احساسات شفافیت ندارد، زیرا جزئیات خط لوله NLP مشخص نشده است.

^{۶۴} Learning Reinforcement Deep
^{۶۵} DRL Sentiment-aware
^{۶۶} Ratio Sharpe

- عملکرد مدل به کیفیت و قابلیت اعتماد داده‌های احساسی وابسته است که ممکن است پرنویز یا جانبدارانه باشند.
- مطالعه فقط به سهام Jones Dow محدود شده و تعمیم به سایر بازارها بررسی نشده است.
- ارزیابی به بک‌تست تاریخی محدود شده و هیچ آزمایش زنده یا بلادرنگ انجام نشده است.

سهم در پروژه من

۴-۳-۹ - for Framework Learning Reinforcement Multi-Agent A Times - on Based Strategies Trading Financial Optimizing [۱۲] Net

تمرکز پژوهش

این مقاله به محدودیت‌های مقاومت مدل‌های DRL تک‌عاملی^{۶۷} در معامله‌گری مالی می‌پردازد. نویسندگان MADDQN را معرفی می‌کنند، یک چارچوب یادگیری تقویتی عمیق چندعاملی^{۶۸} که استخراج‌کننده‌های ویژگی متنوعی — TimesNet و Multi-Scale CNN — را ادغام می‌کند تا راهبردهای معاملاتی با هدف متعادل‌سازی بیشینه‌سازی بازده و کنترل ریسک توسعه دهد.

روش‌شناسی

چارچوب پیشنهادی یک طراحی دوعاملی را به کار می‌گیرد که هرکدام در استخراج ویژگی متفاوتی تخصص دارند:

- **عامل ۱:** از TimesNet استفاده می‌کند که سری‌های زمانی یک‌بعدی را به نمایش‌های دوبعدی تبدیل می‌کند تا وابستگی‌های زمانی دوره‌ای و چندمقیاسی را ثبت کند.
- **عامل ۲:** از Multi-Scale CNN برای استخراج ویژگی‌های زمانی در چندین وضوح بهره می‌برد. هر دو عامل با استفاده از Double DQN (DDQN) آموزش داده می‌شوند تا سوگیری بیش‌برآورد در یادگیری مقادیر Q کاهش یابد. این چارچوب یک فرآیند آموزشی دو مرحله‌ای را دنبال می‌کند:
- **پیش‌آموزش:** روی یک مجموعه داده ترکیبی از شاخص‌های اصلی ایالات متحده برای افزایش قابلیت تعمیم انجام می‌شود.
- **ریزتنظیم:** روی دارایی‌های منفرد برای انطباق راهبردها با سناریوهای خاص بازار صورت می‌گیرد.

^{۶۷}DRL Learning, Reinforcement Deep
^{۶۸}DRL Multi-Agent

یافته‌ها

- بازده تجمعی میانگین ۰.۲۳٪ را در پنج شاخص سهامی به دست آورد.
- به طور مداوم از خط‌مبناهای تک‌عاملی در سودآوری و مقاومت عملکردی بهتر داشت.
- توانایی **تعمیم‌پذیری** قوی نشان داد؛ پیش‌آموزش قابلیت انتقال را پشتیبانی کرد و ریزتنظیم عملکرد ویژه‌دارایی را تثبیت کرد.
- طراحی چندعاملی پروفایل‌های بازده-ریسک پایدارتر نسبت به سیستم‌های DRL تک‌عاملی ایجاد کرد.

محدودیت‌ها

- از نظر محاسباتی پرهزینه است به دلیل سربار آموزش و هماهنگ‌سازی چندین عامل.
- اتکا شدید به TimesNet و استخراج‌کننده‌های مبتنی بر CNN ممکن است انطباق‌پذیری را در رژیم‌های بازار کاملاً متفاوت یا پیش‌بینی‌نشده کاهش دهد.
- ارزیابی به بک‌تست‌های تاریخی محدود بود؛ هیچ آزمایش معاملاتی زنده انجام نشد.
- تمرکز عمدتاً بر شاخص‌های سهام ایالات متحده بوده و تعمیم فرامرزی بررسی نشده است.

سهم در پروژه من

۴-۴ - رویکردهای ترکیبی: ادغام مدل‌های زبانی بزرگ با یادگیری تقویتی در مالی

۴-۴-۱ - with System Multi-Agent LLM Synthesized A FINCON: Finan - Enhanced for Reinforcement Verbal Conceptual [۱۳] Making Decision cial

تمرکز پژوهش

این پژوهش به پیچیدگی تصمیم‌گیری‌های متوالی مالی با ادغام مدل‌های زبانی بزرگ^{۶۹} و یادگیری تقویتی^{۷۰} در یک چارچوب چندعاملی^{۷۱} می‌پردازد. FINCON یک سلسله‌مراتب مدیر-تحلیلگر، تقویت کلامی مفهومی^{۷۲} و کنترل ریسک دوسطحی معرفی می‌کند تا مقاومت، تفسیرپذیری و آگاهی از ریسک در راهبردهای مالی خودکار ارتقا یابد.

^{۶۹}LLMs Models, Language Large

^{۷۰}RL Learning, Reinforcement

^{۷۱}Framework Multi-Agent

^{۷۲}CVRF Reinforcement, Verbal Conceptual

روش‌شناسی

چارچوب FINCON به صورت زیر طراحی شده است:

• معماری چندعاملی:

- **عوامل تحلیلگر بازار:** استخراج و خلاصه‌سازی داده‌های کمی بازار (مانند قیمت سهام و بنیادها).
- **عوامل خبر و احساسات:** پردازش اخبار مالی، گزارش‌های تحلیلی و شبکه‌های اجتماعی برای تولید بینش‌های احساسی.
- **عوامل راهبردی:** تدوین اقدامات معاملاتی و پرتفوی پیشنهادی با ادغام ورودی‌های تحلیلگر و احساسات.
- **عوامل مدیریت ریسک:** اعمال محدودیت‌های ریسک در سطح پرتفوی، پایش مواجهه و تضمین ایمنی.
- **عامل مدیر:** تجمیع همه ورودی‌ها، قضاوت میان راهبردها و نهایی‌سازی تصمیمات معاملاتی.

• کنترل ریسک:

- **درون‌اپیزودی:** پایش Conditional Value-at-Risk (CVaR) برای محدود کردن ریسک کوتاه‌مدت.
- **میان‌اپیزودی:** به‌روزرسانی باورها و تنظیم راهبردی برای بهبود سازگاری بلندمدت.
- **CVRF:** عامل‌ها به خودانتقادی پرداخته و «باورهای مفهومی» را به زبان طبیعی بیان می‌کنند تا تصمیم‌گیری‌های آینده هدایت شود.
- **فرمول‌بندی POMDP^{۷۳}:** معامله و تخصیص پرتفوی به‌عنوان POMDP مدل‌سازی می‌شوند تا عدم قطعیت‌های کلان اقتصادی و بازار ثبت شوند.
- **بهینه‌سازی پرامپت:** گرادیان نزولی متنی پرامپت‌ها را میان اپیزودها اصلاح می‌کند تا استدلال و هماهنگی عامل‌ها پایدارتر شود.

یافته‌ها

- عملکردی بهتر از عامل‌های DRL خط‌مبنا و سایر سیستم‌های محور-LLM در تصمیم‌گیری مالی دارد.
- بهبود در بازده تجمعی (CR)، نسبت شارپ (SR) و کاهش بیشینه افت سرمایه (MDD) را نشان می‌دهد.
- سلسله‌مراتب مدیر-تحلیلگر کارایی را با کاهش سربار ارتباط میان‌عاملی افزایش می‌دهد.
- CVRF تفسیرپذیری و تعمیم‌پذیری را در وظایف تک‌سهمی و مدیریت پرتفوی تقویت می‌کند.

^{۷۳} Process Decision Markov Observable Partially

محدودیت‌ها

- به دلیل پیچیدگی هماهنگی چندعاملی و پردازش چندوجهی ورودی‌ها، محاسبات سنگین و پرهزینه است.
- عملکرد به شدت وابسته به مهندسی پرامپت و دسترسی به داده‌های مالی باکیفیت است.
- ارزیابی به بک‌تست تاریخی محدود است؛ عملکرد در معاملات زنده بررسی نشده است.
- مقیاس‌پذیری به شبکه‌های بزرگ‌تر عاملی ممکن است چالش‌های هماهنگی را تشدید کند.

سهم در پروژه من

۴-۵ - جمع‌بندی

این فصل پژوهش‌های مربوط به مدل‌های زبانی بزرگ^{۷۴} و یادگیری تقویتی^{۷۵} در حوزه مالی را مرور کرد که شامل مدل‌های حوزه‌محور پردازش زبان طبیعی مالی^{۷۶}، کتابخانه‌های استاندارد RL و راهبردهای متنوع مبتنی بر یادگیری تقویتی عمیق^{۷۷} در معامله‌گری بود. همچنین به رویکردهای ترکیبی نوظهوری اشاره شد که سیگنال‌های متنی و عددی را با یکدیگر ادغام می‌کنند. اگرچه این مطالعات پتانسیل ترکیب LLM و RL را نشان می‌دهند، کاربرد آن‌ها در حوزه مالی همچنان محدود است و فضای قابل‌توجهی برای کاوش بیشتر باقی مانده است. این بینش‌ها مستقیماً انگیزه و جهت‌گیری این پروژه را شکل می‌دهند.

^{۷۴}LLMs Models, Language Large

^{۷۵}RL Learning, Reinforcement

^{۷۶}NLP Financial

^{۷۷}DRL Learning, Reinforcement Deep

کتابنامه

- [۱] “A Zohren, S. and Wen, Q. Poor, V. H. Mulvey, M. J. Dong, X. Kong, Y. Nie, Y. [۱] prospects Progress, applications: financial for models language large of survey .۲۰۲۴, *arXiv: ۲۴۰۶. ۱۱۹۰۳ preprint arXiv challenges*,” and
- language pre-trained with analysis sentiment Financial “Finbert: Araci, T. D. [۲] .۲۰۱۹, *arXiv: ۱۹۰۸. ۱۰۰۶۳ preprint arXiv models*,”
- large financial Open-source “Fingpt: Wang, D. C. and Liu, X.-Y. Yang, H. [۳] .۲۰۲۳, *arXiv: ۲۳۰۶. ۰۶۰۳۱ preprint arXiv models*,” language
- trad- algorithmic quantitative in learning reinforcement “Deep Pricope, T.-V. [۴] .۲۰۲۱, *arXiv: ۲۱۰۶. ۰۰۱۲۳ preprint arXiv review*,” A ing:
- Dormann, N. and Ernestus, M. Kanervisto, A. Gleave, A. Hill, A. Raffin, A. [۵] *Jour- implementations*,” learning reinforcement Reliable “Stable-baselines۳: .۲۰۲۱, *Research Learning Machine of nal*
- Wang, D. C. and Xiao, B. Yang, L. Zhang, R. Chen, Q. Yang, H. Liu, X.-Y. [۶] in trading stock automated for library learning reinforcement deep A “Finrl: .۲۰۲۰, *arXiv: ۲۰۱۱. ۰۹۶۰۷ preprint arXiv finance*,” quantitative
- learning reinforcement “Deep Walid, A. and Zhong, S. Liu, X.-Y. Yang, H. [۷] *ACM the of Proceedings strategy*,” ensemble An trading: stock automated for .۲۰۲۰, *(ICAIF) Finance in AI on Conference International*
- learning reinforcement deep novel “A Liu, S. and Wang, B. Lou, J. Zou, J. [۸] *arXiv networks*,” lstm cascaded using system trading stock automated based .۲۰۲۲, *arXiv: ۲۲۱۲. ۰۲۷۲۱ preprint*
- enough: not is fee “Commission Yao, J. and Feng, Z. An, B. Wei, H. Wang, R. [۹] *Proceedings management*,” portfolio for framework reinforced hierarchical A *(Track) Technical (AAAI-۲۱ Intelligence Artificial on Conference AAAI the of* .۲۰۲۱

frame- fusion data “Multi-type Zhang, C. and Yao, X. Bao, F. Zhang, Y. Liu, P. [١٠]
Applied trading,” algorithmic for learning reinforcement deep on based work
 .٢٠٢٢ ,*Intelligence*

“Market Sanjeevi, G. S. and Gupta, M. Wadhwani, K. Koratamaddi, P. [١١]
 portfolio stock for approach learning reinforcement deep sentiment-aware
Journal International an Technology, and Science Engineering allocation,
 .٢٠٢١

learn- reinforcement multi-agent “A Lu, X. and Cui, K. Zhou, C. Huang, Y. [١٢]
 timesnet,” on based strategies trading financial optimizing for framework ing
 .٢٠٢٣ ,*Applications with Systems Expert*

Cui, Z. Liu, R. Suchow, W. J. Chen, Z. Cao, Y. Deng, Z. Li, H. Yao, Z. Yu, Y. [١٣]
 Xie, Q. and Li, D. Huang, J. He, Y. Xiong, G. Subbalakshmi, K. Zhang, D. Xu, Z.
 rein- verbal conceptual with system multi-agent llm synthesized A “Fincon:
Confer- ٢٠٢٤ NeurIPS making,” decision financial enhanced for forcement
 .٢٠٢٤ ,*Proceedings ence*

https: from Retrieved diagram.” learning “Reinforcement MathWorks, T. [١٤]
 //www.mathworks.com/help/reinforcement-learning/ug/reinforcement_
 .٢٠٢٥ ,learning_diagram.png

reinforce- deep from schematic rl ٢ “Experiment Face, H. [١٥]
 https://huggingface.co/datasets/ course.” learning ment
 huggingface-deep-rl-course/course-images/resolve/main/en/unit1/
 .٢٠٢٥ ,exp_2.jpg

.١٩٥٢ ,*Finance of Journal The selection,*” “Portfolio Markowitz, H. [١٦]

Com - Neural memory,” short-term “Long Schmidhuber, J. and Hochreiter S. [١٧]
 .١٩٩٧ ,*putation*

Gomez, N. A. Jones, L. Uszkoreit, J. Parmar, N. Shazeer, N. Vaswani, A. [١٨]
Neural in Advances in need,” you all is “Attention Polosukhin, I. and Kaiser, .[٩]
 .٢٠١٧ ,(٣٠ (NeurIPS Systems Processing Information

“Proximal Klimov, O. and Radford, A. Dhariwal, P. Wolski, F. Schulman, J. [١٩]
 .٢٠١٧ ,arXiv: ١٧٠٧. ٠٩٣٤٧ preprint arXiv algorithms,” optimization policy

MIT .*Introduction An Learning: Reinforcement* Barto, G. A. and Sutton S. R. [٢٠]
 .٢٠١٨ Press,

- Col- King's thesis, PhD .*Rewards Delayed from Learning* Watkins, H. C. J. C. [୨୧]
. ୧୯୮୯ Cambridge. of University lege.
- Bellemare, G. M. Veness, J. Rusu, A. A. Silver, D. Kavukcuoglu, K. Mnih, V. [୨୨]
Beat- C. Petersen, S. Ostrovski, G. Fidjeland, K. A. Riedmiller, M. Graves, A.
and Legg, S. Wierstra, D. Kumaran, D. King, H. Antonoglou, I. Sadik, A. tie,
learning," reinforcement deep through control "Human-level Hassabis, D.
. ୨୦୧୫ ,*Nature*
- meth- gradient "Policy Mansour, Y. and Singh, S. McAllester, D. Sutton, S. R. [୨୩]
in Advances in approximation," function with learning reinforcement for ods
. ୧୯୯୯ Press, MIT ,(୧୨ (*NeurIPS Systems Processing Information Neural*
- connec- for algorithms gradient-following statistical "Simple Williams, J. R. [୨୪]
. ୧୯୯୨ ,*Learning Machine* learning," reinforcement tionist
in Advances in algorithms," "Actor-critic Tsitsiklis, N. J. and Konda R. V. [୨୫]
. ୨୦୦୦ Press, MIT ,(୧୩ (*NeurIPS Systems Processing Information Neural*
- word of estimation "Efficient Dean, J. and Corrado, G. Chen, K. Mikolov, T. [୨୬]
. ୨୦୧୩ ,*arXiv: ୧୩. ୧. ୩୪୮୧ preprint arXiv* space," vector in representations
- word for vectors Global "Glove: Manning, D. C. and Socher, R. Pennington, J. [୨୭]
Methods Empirical on Conference ୨୦୧୪ the of Proceedings in representation,"
. ୨୦୧୪ ,(EMNLP) *Processing Language Natural in*
- of Pre-training "Bert: Toutanova, K. and Lee, K. Chang, M.-W. Devlin, J. [୨୮]
Proceedings in understanding," language for transformers bidirectional deep
for Association the of Chapter American North the of Conference ୨୦୧୯ the of
.(NAACL-HLT) Technologies Language Human Linguistics: Computational
. ୨୦୧୯
- "Lan- Sutskever, I. and Amodei, D. Luan, D. Child, R. Wu, J. Radford, A. [୨୯]
Report Technical OpenAI learners," multitask unsupervised are models guage
. ୨୦୧୯
- Zhang, C. Mishkin, P. Wainwright, C. Almeida, D. Jiang, X. Wu, J. Ouyang, L. [୩୦]
Miller, L. Kelton, F. Hilton, J. Schulman, J. Ray, A. Slama, K. Agarwal, S.
Lowe, R. and Leike, J. Christiano, P. Welinder, P. Askell, A. Simens, M.
arXiv feedback," human with instructions follow to models language "Training
. ୨୦୨୨ ,*arXiv: ୨୨. ୩. ୦୨୧୫୫ preprint*
- textual liability? a not liability a is "When McDonald, B. and Loughran T. [୩୧]
. ୨୦୧୧ ,*Finance of Journal The ୧୦-ks*," and dictionaries, analysis.