



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه هوش مصنوعی

گزارش پروژه کارشناسی

رشته مهندسی کامپیوتر گرایش هوش مصنوعی

عنوان پروژه:

توسعه یک عامل یادگیری تقویتی برای تصمیم‌گیری در بازارهای مالی با
بهره‌گیری از مدل‌های زبانی بزرگ

استاد راهنما:

دکتر حسین کارشناس

پژوهشگر:

متین اعظمی

شهریور ۱۴۰۴



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه هوش مصنوعی

پروژه کارشناسی رشته مهندسی کامپیوتر گرایش هوش مصنوعی

آقای متین اعظمی

تحت عنوان:

توسعه یک عامل یادگیری تقویتی برای تصمیم‌گیری در بازارهای مالی با
بهره‌گیری از مدل‌های زبانی بزرگ

در تاریخ _____ / _____ / _____ توسط هیأت داوران زیر بررسی و با نمره
_____ به تصویب نهایی رسید.

۱- استاد راهنمای پروژه: دکتر _____ امضا _____

۲- استاد داور: دکتر _____ امضا _____

امضای مدیر گروه _____

تشکر و قدردانی

از پدر و مادرم که همیشه پشتیبان و دلگرمی من بوده‌اند، صمیمانه سپاسگزارم.

از استاد راهنمایم، جناب آقای دکتر حسین کارشناس، بابت راهنمایی‌ها و حمایت‌های ارزشمندشان قدردانی می‌کنم.

همچنین از دوستان خوبم، تمامی اساتید و جامعه دانشکده مهندسی کامپیوتر دانشگاه اصفهان، و همه کسانی که در این مسیر کنارم بودند و باعث شدند تجربه‌ام شیرین‌تر و پربارتر شود، صمیمانه قدردانی می‌کنم.

با تشکر،

متین اعظمی

شهریور ۱۴۰۴

چکیده

این پژوهش با هدف بررسی نقش مدل‌های زبانی بزرگ در طراحی و بهبود عامل‌های یادگیری تقویتی برای معامله‌گری در بازارهای مالی انجام شد. به‌طور مشخص، تلاش شد تا علاوه بر داده‌های عددی بازار (مانند OHLCV و شاخص‌های فنی)، از سیگنال‌های متنی استخراج‌شده از اخبار مالی نیز برای غنی‌سازی فضای حالت استفاده شود. در این راستا، دو مدل زبانی تخصصی FinBERT و FinGPT برای تحلیل احساسات به‌کار گرفته شدند و نتایج آن‌ها با داده‌های قیمتی و فنی ادغام گردید.

محیط معاملاتی سفارشی‌سازی‌شده بر اساس FinRL طراحی شد که در آن مکانیزم‌های کنترل ریسک، تصادفی‌سازی دوره‌ها و سازوکار اجرای عمل مبتنی بر وزن‌های سبد سهام پیاده‌سازی گردید. برای آموزش عامل‌ها، الگوریتم‌های PPO و RecurrentPPO در چارچوب Stable-Baselines3 به‌کار گرفته شدند و تنظیم ابرپارامترها با کمک Optuna صورت گرفت. ارزیابی مدل‌ها بر اساس معیارهایی همچون بازدهی سالانه، نسبت شارپ و حداکثر افت سرمایه انجام شد.

نتایج نشان داد که ترکیب داده‌های متنی با داده‌های عددی می‌تواند بازدهی کلی را بهبود بخشد. به‌ویژه، FinGPT نسبت به FinBERT عملکرد بهتری در استخراج سیگنال‌های احساسی داشت. با این حال، در برخی معیارهای ریسک، روش‌های مرجع عملکرد بهتری ارائه دادند. از محدودیت‌های اصلی پژوهش، اتکا به بک‌تست در یک بازه ثابت بود که ضرورت استفاده از روش‌های ارزیابی پویا و چندبازه‌ای را برجسته می‌سازد.

به‌طور کلی، این تحقیق نشان می‌دهد که ادغام یادگیری تقویتی با مدل‌های زبانی بزرگ ظرفیت بالایی برای توسعه سامانه‌های معاملاتی هوشمند دارد و مسیرهای آینده می‌تواند بر افزایش پایداری، تعمیم‌پذیری و استفاده از معماری‌های پیشرفته‌تر (مانند شبکه‌های بازگشتی و Transformerها) متمرکز شود.

کلمات کلیدی: دانشگاه اصفهان - گزارش هوش مصنوعی - یادگیری تقویتی - مدل‌های زبانی بزرگ - شبکه‌های بازگشتی

فهرست مطالب

مخفف‌ها	۱۱
۱ مقدمه	۱۲
۱-۱ اهداف و دامنه پژوهش	۱۲
۲-۱ کاربردها و اهمیت عملی	۱۳
۳-۱ پرسش‌های پژوهش و فرضیه‌ها	۱۳
۴-۱ ساختار گزارش	۱۵
۲ مفاهیم نظری	۱۶
۱-۲ مقدمه	۱۶
۲-۲ مبانی یادگیری تقویتی	۱۷
۱-۲-۲ اجزای اصلی	۱۷
۲-۲-۲ اکتشاف ^۱ در برابر بهره‌برداری ^۲	۱۸
۳-۲-۲ وظایف رویدادمحور ^۳ در برابر وظایف پیوسته ^۴	۱۸
۴-۲-۲ یادگیری درون‌سیاستی ^۵ در برابر برون‌سیاستی ^۶	۱۹
۵-۲-۲ روش‌های مدل‌مینا ^۷ در برابر مدل‌نامینا ^۸	۲۰
۳-۲ الگوریتم‌های یادگیری تقویتی	۲۰
۱-۳-۲ Q-Learning و شبکه‌های Q عمیق ^۹	۲۰
۲-۳-۲ روش‌های گرادیان سیاست ^{۱۰}	۲۱
۳-۳-۲ روش‌های بازیگر - منتقد ^{۱۱}	۲۲
۴-۳-۲ Proximal Policy Optimization (PPO)	۲۳
۵-۳-۲ PPO بازگشتی	۲۴
۴-۲ مبنای مدل‌های زبانی بزرگ	۲۵
۱-۴-۲ Transformer معماری	۲۵

^۱Exploration

^۲Exploitation

^۳Episodic Tasks

^۴Continuous Tasks

^۵On-Policy Learning

^۶Off-Policy Learning

^۷Model-Based Methods

^۸Model-Free Methods

۲۶	جاسازی واژه‌ها ^{۱۲} و جاسازی‌های متنی ^{۱۳}	۲-۴-۲
۲۶	راهکارهای سازگارسازی مدل‌های زبانی بزرگ	۳-۴-۲
۲۷	تحلیل احساسات در زمینه مالی ^{۱۴}	۴-۴-۲
۲۸	داده‌های بازار و شاخص‌های مالی	۵-۲
۲۸	مبانی داده‌های OHLCV ^{۱۵}	۱-۵-۲
۲۹	شاخص‌های فنی ^{۱۶} پرکاربرد	۲-۵-۲
۳۱	چالش‌های موجود در بازارهای مالی	۳-۵-۲
۳۲	شاخص‌های مالی ^{۱۷} و دارایی‌های اصلی ^{۱۸}	۴-۵-۲
۳۳	مدیریت سبد دارایی‌ها و محدودیت‌های معامله‌گری	۶-۲
۳۳	معامله تک‌سهم ^{۱۹} در برابر معامله سبد دارایی‌ها ^{۲۰}	۱-۶-۲
۳۴	فضای حالت ^{۲۱}	۲-۶-۲
۳۵	شکل‌دهی پاداش ^{۲۲}	۳-۶-۲
۳۶	هزینه‌های تراکنش ^{۲۳} ، لغزش قیمتی ^{۲۴} و محدودیت‌های نقدشوندگی ^{۲۵}	۴-۶-۲
۳۷	معیارهای ریسک ^{۲۶}	۵-۶-۲
۳۸	معیارهای ارزیابی	۶-۶-۲
۴۰	جمع‌بندی	۷-۲

۴۱	مرور ادبیات	۳
۴۱	مقدمه	۱-۳
۴۱	مدل‌های زبانی بزرگ و پردازش زبان طبیعی در حوزه مالی	۲-۳
	A Survey of Large Language Models for Finan-	۱-۲-۳
	cial Applications: Progress, Prospects and	
۴۱	Challenges [۱]	
	FinBERT: Financial Sentiment Analysis with Pre-	۲-۲-۳
۴۳	trained Language Models [۲]	
	FinGPT: Open-Source Financial Large Language	۳-۲-۳
۴۴	Models [۳]	
۴۶	کتابخانه‌ها و چارچوب‌های یادگیری تقویتی در حوزه مالی	۳-۳
	Deep Reinforcement Learning in Quantitative	۱-۳-۳
۴۶	Algorithmic Trading: A Review [۴]	

¹²Word Embeddings

¹³Text Embeddings

¹⁶Technical Indicators

¹⁷Financial Indices

¹⁸Major Assets

¹⁹Single-Asset Trading

²⁰Portfolio Trading

²³Transaction Costs

²⁴Slippage

²⁵Liquidity Constraints

	Stable-Baselines3: Reliable Reinforcement Learn-	-۲-۳-۳
۴۷	 [۵]ing Implementations	
	FinRL: A Deep Reinforcement Learning Library	-۳-۳-۳
	for Automated Stock Trading in Quantitative	
۴۸	 [۶] Finance	
	Deep Reinforcement Learning for Automated Stock	-۴-۳-۳
۵۰	 [۷] Trading: An Ensemble Strategy	
	A Novel Deep Reinforcement Learning-Based Au-	-۵-۳-۳
	tomated Stock Trading System Using Cascaded	
۵۱	 [۸] LSTM Networks	
	Commission Fee is not Enough: A Hierarchical	-۶-۳-۳
۵۲	[۹] Reinforced Framework for Portfolio Management	
	Multi-Type Data Fusion Framework Based on Deep	-۷-۳-۳
	Reinforcement Learning for Algorithmic Trading	
۵۴	 [۱۰]	
	Market Sentiment-Aware Deep Reinforcement Learn-	-۸-۳-۳
۵۵	[۱۱]ing Approach for Stock Portfolio Allocation	
	A Multi-Agent Reinforcement Learning Framework	-۹-۳-۳
	for Optimizing Financial Trading Strategies	
۵۶	 [۱۲] Based on TimesNet	
۵۸	 رویکردهای ترکیبی: ادغام مدل‌های زبانی بزرگ با یادگیری تقویتی در زمینه مالی	-۴-۳
	FINCON: A Synthesized LLM Multi-Agent System	-۱-۴-۳
	with Conceptual Verbal Reinforcement for En-	
۵۸	 [۱۳]hanced Financial Decision Making	
۵۹	 جمع‌بندی	-۵-۳

۶۰	شرح پروژه	۴
۶۰	 مقدمه	-۱-۴
۶۰	 معماری کلی سیستم	-۲-۴
۶۲	 توصیف بازار انتخاب‌شده	-۳-۴
۶۳	 جمع‌آوری داده	-۴-۴
۶۴	 تحلیل داده	-۵-۴
۶۴	 استخراج احساس از اخبار	-۶-۴
۶۴	 FinBERT	-۱-۶-۴
۶۵	 FinGPT (Llama 3 + LoRA adapters)	-۲-۶-۴
۶۵	 امتیازدهی عددی احساسات	-۳-۶-۴
۶۵	 محیط معاملاتی	-۷-۴
۶۵	 محیط معاملاتی سفارشی‌سازی‌شده	-۱-۷-۴
۶۶	 فضای حالت	-۲-۷-۴

۶۶	۳-۷-۴	تابع پاداش
۶۷	۴-۷-۴	کنترل ریسک با استفاده از آشفستگی
۶۷	۵-۷-۴	تصادفی سازی دوره
۶۸	۶-۷-۴	سازوکار اجرای عمل
۶۹	۷-۷-۴	جمع بندی
۶۹	۸-۴	عامل یادگیری تقویتی
۶۹	۱-۸-۴	چارچوب پیاده سازی
۶۹	۲-۸-۴	الگوریتم های ارزیابی شده
۷۰	۳-۸-۴	بهینه سازی ابرپارامترها
۷۰	۹-۴	پایش
۷۰	۱-۹-۴	رویکرد
۷۰	۲-۹-۴	مزایا
۷۱	۱۰-۴	ارائه و استقرار
۷۱	۱-۱۰-۴	بخش Backend
۷۱	۲-۱۰-۴	بخش Frontend
۷۱	۳-۱۰-۴	جمع بندی
۷۱	۱۱-۴	جمع بندی

۵ پیاده سازی

۷۲	۱-۵	مقدمه
۷۲	۲-۵	ابزارها و چارچوب ها
۷۴	۳-۵	بازتولیدپذیری و محیط
۷۴	۴-۵	سخت افزار و منابع محاسباتی
۷۵	۵-۵	جمع بندی

۶ آزمایش ها و نتایج

۷۶	۱-۶	تحلیل ایستایی: قیمت های پایانی در مقابل بازدهی ها
۷۶	۱-۱-۶	روش شناسی
۷۶	۲-۱-۶	نتایج
۷۷	۳-۱-۶	بحث
۷۷	۲-۶	تحلیل علیت: مدل های احساسی و بازدهی های بازار
۷۷	۱-۲-۶	روش شناسی
۷۷	۲-۲-۶	نتایج
۷۸	۳-۲-۶	بحث
۷۸	۳-۶	ارزیابی عامل معاملات: الگوریتم ها، محیط ها و پیکربندی ها
۷۸	۱-۳-۶	مروری بر ابعاد آزمایش
۷۹	۲-۳-۶	نتایج آزمایش
۸۵	۴-۶	جمع بندی

۸۷	۷ بحث و تحلیل
۸۷	۷-۱- مقدمه
۸۷	۷-۲- تحلیل نقش منبع احساسات
۸۷	۷-۳- مقایسه با مدل‌های سنتی
۸۸	۷-۴- مقایسه روش پیشنهادی با سایر پژوهش‌ها
۸۹	۷-۵- تحلیل پیکربندی‌ها
۹۰	۷-۶- روش‌های ارزیابی
۹۱	۷-۷- جمع‌بندی
۹۲	۸ نتیجه‌گیری و کارهای آینده

فهرست تصاویر

۱۷	 (۱-۲) چارچوب کلی یادگیری تقویتی [۱۴].
۱۹	 (۲-۲) نمایی از موازنه اکتشاف - بهره‌برداری [۱۵].
۶۱	 (۱-۴) معماری کلی سیستم

فهرست جداول

۱۱	فهرست مخفف‌ها و معادل آن‌ها
۴۲	(۱-۳) حوزه‌های کاربرد مدل‌های زبانی بزرگ در مالی (اقتباس شده از [۱])
۴۴	(۲-۳) نمای کلی روش‌شناسی FinBERT
۴۵	(۳-۳) نکات کلیدی روش‌شناسی FinGPT
۴۶	(۴-۳) دسته‌بندی رویکردهای DRL در معامله‌گری (اقتباس شده از [۴])
۴۹	(۵-۳) احزای کلیدی در FinRL
۵۱	(۶-۳) مروری بر راهبرد تجمیعی (Li et al., 2020)
۷۳	(۱-۵) خلاصه ابزارها و چارچوب‌های مورد استفاده در پیاده‌سازی.
۷۷	(۱-۶) نتایج آزمون ADF برای قیمت‌های پایانی و بازدهی‌های لگاریتمی (2010-2025).
	(۲-۶) آزمون‌های Granger Causality برای اثر امتیازهای احساسی FinBERT و FinGPT
۷۸	بر بازدهی سهام.
۷۹	(۳-۶) نتایج PPO □ پاداش بازدهی خام نرمال شده □ محیط تک‌گانه □ دوره‌های عادی
۸۰	(۴-۶) نتایج PPO □ پاداش بازدهی خام نرمال شده □ محیط تک‌گانه □ دوره‌های تصادفی
۸۰	(۵-۶) نتایج PPO □ پاداش بازدهی خام نرمال شده □ محیط‌های برداری (۳-محیط) □ دوره‌های عادی
۸۱	(۶-۶) نتایج PPO □ پاداش بازدهی خام نرمال شده □ محیط‌های برداری (۳-محیط) □ دوره‌های تصادفی
۸۱	(۷-۶) نتایج PPO □ پاداش پاداش لگاریتمی تعدیل شده □ محیط تک‌گانه □ دوره‌های عادی
۸۲	(۸-۶) نتایج PPO □ پاداش پاداش لگاریتمی تعدیل شده □ محیط‌های برداری (۳-محیط) □ دوره‌های عادی
۸۲	(۹-۶) نتایج RPPO □ پاداش بازدهی خام نرمال شده □ محیط تک‌گانه □ دوره‌های عادی
۸۳	(۱۰-۶) نتایج RPPO □ پاداش بازدهی خام نرمال شده □ محیط تک‌گانه □ دوره‌های تصادفی
۸۳	(۱۱-۶) نتایج RPPO □ پاداش بازدهی خام نرمال شده □ محیط‌های برداری (۳-محیط) □ دوره‌های عادی
۸۴	(۱۲-۶) نتایج RPPO □ پاداش بازدهی خام نرمال شده □ محیط‌های برداری (۳-محیط) □ دوره‌های تصادفی
۸۴	(۱۳-۶) نتایج RPPO □ پاداش پاداش لگاریتمی تعدیل شده □ محیط تک‌گانه □ دوره‌های عادی
۸۵	(۱۴-۶) نتایج RPPO □ پاداش پاداش لگاریتمی تعدیل شده □ محیط‌های برداری (۳-محیط) □ دوره‌های عادی
۸۵	(۱۵-۶) مقایسه کلی عملکرد PPO و RPPO در سناریوهای مختلف
۸۵	(۱۶-۶) مقایسه میانگین عملکرد PPO و RPPO
۸۵	(۱۷-۶) مقایسه میانگین عملکرد Raw در برابر پاداش لگاریتمی تعدیل شده
۸۶	(۱۸-۶) مقایسه میانگین عملکرد محیط تک‌گانه در برابر محیط‌های برداری (۳-محیط)
۸۶	(۱۹-۶) مقایسه میانگین عملکرد دوره‌های عادی در برابر دوره‌های تصادفی

- ۸۸ (۱-۷) مقایسه عملکرد مدل پیشنهادی با روش‌های سنتی
- ۸۹ (۲-۷) مقایسه نتایج روش پیشنهادی و پژوهش مرجع بر اساس بازده سالانه و نسبت شارپ
- ۸۹ (۳-۷) مقایسه روش پیشنهادی با پژوهش مبتنی بر xLSTM

مخفف‌ها

مخفف	توضیح
AI	هوش مصنوعی (Artificial Intelligence)
RL	یادگیری تقویتی (Reinforcement Learning)
DRL	یادگیری تقویتی عمیق (Deep Reinforcement Learning)
MDP	فرایند تصمیم‌گیری مارکوف (Markov Decision Process)
PPO	بهینه‌سازی سیاست مجاورتی (Proximal Policy Optimization)
RPPO	نسخه بازگشتی PPO (Recurrent PPO)
LSTM	حافظه طولانی‌مدت کوتاه (Long Short-Term Memory)
LLM	مدل زبانی بزرگ (Large Language Model)
FinBERT	مدل زبانی مبتنی بر BERT برای تحلیل مالی
FinGPT	مدل زبانی بازمتن برای امور مالی
OHLCV	داده‌های روزانه شامل: Open, High, Low, Close, Volume
VIX	شاخص نوسان بازار (Volatility Index)
ATR	میانگین دامنه واقعی (Average True Range)
MACD	میانگین متحرک همگرایی-واگرایی (Moving Average Convergence Divergence)
EMA	میانگین متحرک نمایی (Exponential Moving Average)
RSI	شاخص قدرت نسبی (Relative Strength Index)
OBV	حجم تعادلی (On-Balance Volume)
ADF	آزمون دیکی-فولر تعمیم‌یافته (Augmented Dickey-Fuller Test)
API	رابط برنامه‌نویسی کاربردی (Application Programming Interface)
GPU	واحد پردازش گرافیکی (Graphics Processing Unit)
W&B	پلتفرم پایش آزمایش‌ها (Weights & Biases)

جدول (۱-۰) فهرست مخفف‌ها و معادل آن‌ها

فصل ۱

مقدمه

۱-۱- اهداف و دامنه پژوهش

هدف اصلی این پژوهش آن است که بررسی شود آیا عامل‌های یادگیری تقویتی^۱ که با اطلاعات احساسی استخراج شده از مدل‌های زبانی بزرگ^۲ تقویت شده‌اند، قادر به بهبود عملکرد معاملاتی در بازارهای مالی هستند یا خیر. روش‌های یادگیری تقویتی در سال‌های اخیر به‌طور فزاینده‌ای در حوزه‌های معاملات الگوریتمی و مدیریت سبد سهام^۳ به‌کار گرفته شده‌اند [۴] و از این رو بستری مناسب برای این پژوهش فراهم می‌آورند. برای تحقق این هدف، پژوهش حاضر اهداف زیر را دنبال می‌کند:

- توسعه و ارزیابی عامل‌های یادگیری تقویتی برای معامله‌گری در بازارهای مالی.
- یکپارچه‌سازی ویژگی‌های احساسی استخراج شده از اخبار مرتبط (با بهره‌گیری از مدل‌های زبانی بزرگ) همراه با داده‌های بازار و شاخص‌های فنی.
- مقایسه عملکرد مدل‌های پیشنهادی با مدل‌های سنتی، راهبردهای مبنای^۴ و یافته‌های پژوهش‌های دانشگاهی اخیر.
- بررسی تأثیر طراحی فضای حالت^۵ و فضای عمل^۶، شکل‌دهی پاداش^۷ و انتخاب ابرپارامترها^۸ بر کارایی مدل.
- ارزیابی الگوریتم‌های پیشرفته و بررسی ادغام معماری‌هایی مانند LSTM در این الگوریتم‌ها به‌منظور بهبود عملکرد معاملاتی.

دامنه پژوهش به‌صورت زیر تعریف می‌شود:

- تحلیل صرفاً محدود به اجزای شاخص Dow Jones Industrial Average (Dow30) است و به سایر طبقات دارایی یا بازارهای جهانی تعمیم داده نمی‌شود.

¹Reinforcement Learning

²Large Language Models

³Portfolio

⁴Baseline

⁵State Space

⁶Action Space

⁷Reward Shaping

⁸Hyperparameters

□ داده‌های بازار شامل داده‌های OHLCV^۹ و سیگنال‌های احساسی مبتنی بر FinBERT [۲]، FinGPT [۳] و اخبار گوگل است. منابع جایگزین مانند شبکه‌های اجتماعی یا داده دفتر سفارش^{۱۰} در این پژوهش مدنظر قرار نمی‌گیرند.

□ تمرکز پژوهش بر افق‌های معاملاتی روزانه است و معاملات با فرکانس بسیار بالا^{۱۱} خارج از دامنه بررسی قرار دارند.

□ مدل‌ها صرفاً در محیط پژوهشی طراحی و ارزیابی می‌شوند و هدف، توسعه سامانه‌های معاملاتی آماده بهره‌برداری نیست.

□ ارزیابی‌ها بر اساس شاخص‌های رایج عملکرد و ریسک انجام می‌شود. بهینه‌سازی سبد سرمایه‌گذاری بلندمدت و راهبردهای تخصیص سرمایه در این پژوهش بررسی نمی‌شوند.

۱-۲- کاربردها و اهمیت عملی

توسعه عامل‌های یادگیری تقویتی تقویت‌شده با مدل‌های زبانی بزرگ دارای پتانسیل کاربردی چشمگیری در حوزه‌های معامله‌گری الگوریتمی و مدیریت سبد سرمایه‌گذاری است. با ترکیب داده‌های ساختاریافته بازار با اطلاعات احساسی غیرساختاریافته، این سامانه‌ها قادر خواهند بود تصمیم‌گیری انطباقی و بسترآگاه^{۱۲} را پشتیبانی کرده و در نتیجه عملکرد تعدیل‌شده بر اساس ریسک را بهبود دهند. چارچوب پیشنهادی این پژوهش صرفاً به آزمایش‌های نظری محدود نیست، بلکه قابلیت به‌کارگیری مستقیم در خطوط لوله معاملاتی خودکار، سامانه‌های پشتیبان تصمیم‌گیری سرمایه‌گذاری و بسترهای پایش ریسک مالی را نیز دارد.

با وجود آنکه معامله مستقیم در بازارهای سهام بین‌المللی از ایران به دلیل محدودیت‌های نظارتی و ژئوپلیتیکی در حال حاضر امکان‌پذیر نیست، پیاده‌سازی عملی همچنان از طریق کارگزاران واسطه و پلتفرم‌های معاملاتی برخط (مانند RoboForex و ارائه‌دهندگان مشابه) میسر است. این واسطه‌ها دسترسی به شاخص‌های جهانی سهام، بازار ارز و سایر طبقات دارایی را فراهم می‌کنند و در نتیجه ادغام عامل‌های مبتنی بر یادگیری تقویتی در سناریوهای معاملاتی واقعی را امکان‌پذیر می‌سازند. بنابراین، هرچند مدل‌های ارائه‌شده در این پژوهش رویکردی پژوهشی دارند، می‌توان آن‌ها را برای اجرای نیمه‌خودکار یا تمام‌خودکار از طریق اتصال به رابط‌های برنامه‌نویسی کارگزاری^{۱۳} تطبیق و پیاده‌سازی کرد.

زمان‌بندی این پژوهش نیز اهمیت ویژه‌ای دارد. با پیشرفت سریع فناوری‌های یادگیری تقویتی و مدل‌های زبانی بزرگ، بازارهای مالی وارد مرحله‌ای تازه از تصمیم‌گیری مبتنی بر هوش مصنوعی شده‌اند. توانایی یادگیری تقویتی در بهینه‌سازی راهبردهای دنباله‌دار و قابلیت مدل‌های زبانی بزرگ در تفسیر حجم انبوه داده‌های متنی و احساسی، مزیتی هم‌افزا برای سرمایه‌گذاران ایجاد می‌کند. در عصری که با نوسان‌پذیری، جهانی‌شدن و اهمیت روزافزون معامله‌گری مبتنی بر اطلاعات تعریف می‌شود، سامانه‌های یکپارچه مبتنی بر یادگیری تقویتی و مدل‌های زبانی بزرگ می‌توانند منافع مالی قابل توجهی همچون بازدهی بالاتر و مدیریت ریسک مقاوم‌تر را فراهم آورند.

۱-۳- پرسش‌های پژوهش و فرضیه‌ها

این پژوهش بر اساس پرسش‌های زیر و فرضیه‌های متناظر با آن‌ها سازمان‌دهی شده است:

^۹Open, High, Low, Close, Volume (OHLCV)

^{۱۰}Order Book

^{۱۱}High-Frequency Trading

^{۱۲}Context-Aware

^{۱۳}Brokerage APIs

کارایی یادگیری تقویتی در مقایسه با رویکردهای سنتی

- پرسش پژوهش ۱ (RQ1): آیا عامل‌های یادگیری تقویتی^{۱۴} در مقایسه با مدل‌های سنتی، راهبردهای مبنا و رویکردهای گزارش‌شده در پژوهش‌های دیگر در معاملات شاخص Dow30 و سایر وظایف معاملاتی بازار عملکرد بهتری دارند؟
- فرضیه ۱ (H1): انتظار می‌رود عامل‌های یادگیری تقویتی بازدهی تعدیل‌شده بر اساس ریسک بالاتری نسبت به مدل‌های سنتی و راهبردهای مبنا ارائه دهند؛ هرچند ممکن است در مقایسه با پیشرفته‌ترین رویکردهای روز همواره برتری نداشته باشند.

تأثیر داده‌های احساسی و داده‌های بازار

- پرسش پژوهش ۲ (RQ2): آیا افزودن ویژگی‌های احساسی استخراج‌شده از اخبار مرتبط موجب بهبود عملکرد معاملاتی نسبت به مدل‌های صرفاً مبتنی بر قیمت می‌شود؟
- فرضیه ۲ (H2): انتظار می‌رود ویژگی‌های احساسی استخراج‌شده از اخبار مرتبط عملکرد معاملاتی را نسبت به مدل‌های صرفاً مبتنی بر داده‌های قیمتی بهبود دهند. دوره
- پرسش پژوهش ۳ (RQ3): آیا روند قیمت سهام اعتبار ویژگی‌های احساسی استخراج‌شده از اخبار را تأیید می‌کند؟
- فرضیه ۳ (H3): انتظار می‌رود ویژگی‌های احساسی دارای ارتباط با حرکات قیمتی باشند و بتوانند اطلاعات تکمیلی ارزشمندی برای بهبود عملکرد مدل فراهم کنند.
- پرسش پژوهش ۴ (RQ4): شکل‌دهی پاداش و طراحی فضای عمل و فضای حالت چه تأثیری بر عملکرد مدل‌های معاملاتی مبتنی بر یادگیری تقویتی دارند؟
- فرضیه ۴ (H4): انتظار می‌رود شکل‌دهی پاداش و طراحی دقیق فضای عمل و فضای حالت تأثیر مثبتی بر عملکرد عامل‌های معاملاتی مبتنی بر یادگیری تقویتی داشته باشند.

معماری مدل‌ها و ابرپارامترها

- پرسش پژوهش ۵ (RQ5): آیا ترکیب LSTM^{۱۵} با الگوریتم‌های یادگیری تقویتی مانند Recurrent PPO (RPPO) به بهبود پایدار عملکرد منجر می‌شود؟
- فرضیه ۵ (H5): ترکیب معماری‌های LSTM با الگوریتم‌های یادگیری تقویتی مانند RPPO با افزایش توانایی مدل در تشخیص الگوهای دنباله‌ای، عملکرد آن را بهبود خواهد داد.
- پرسش پژوهش ۶ (RQ6): کدام رویکرد استخراج و بازنمایی ویژگی‌های احساسی برای معامله‌گری مالی کارآمدتر است؟
- فرضیه ۶ (H6): انتظار می‌رود رویکردهای ترکیبی در استخراج احساسات، بازنمایی مؤثرتری نسبت به استفاده منفرد از یک روش ارائه دهند.
- پرسش پژوهش ۷ (RQ7): ابرپارامترهای الگوریتمی^{۱۶} تا چه اندازه بر عملکرد و پایداری راهبردهای معاملاتی مبتنی بر یادگیری تقویتی اثرگذارند؟
- فرضیه ۷ (H7): انتظار می‌رود ابرپارامترهای الگوریتمی نقش مهم و تعیین‌کننده‌ای در بهبود یا تضعیف عملکرد و پایداری مدل‌های معاملاتی مبتنی بر یادگیری تقویتی داشته باشند.

¹⁴Reinforcement Learning (RL)

¹⁵Long Short-Term Memory (LSTM)

¹⁶Hyperparameters

۱-۴- ساختار گزارش

این گزارش در هشت فصل تنظیم شده است:

فصل اول مقدمه است و به اهداف پژوهش، پرسش‌ها و فرضیه‌ها، اهمیت عملی و دامنه مطالعه می‌پردازد.

فصل دوم مبانی نظری پژوهش را معرفی می‌کند. این فصل به مرور اصول یادگیری تقویتی، مدل‌های زبانی بزرگ، داده‌ها و اطلاعات مرتبط با بازارهای مالی و محدودیت‌های عملی معامله‌گری می‌پردازد.

فصل سوم مروری بر ادبیات مرتبط ارائه می‌دهد. این فصل به بررسی پژوهش‌های مربوط به کاربرد مدل‌های زبانی بزرگ و یادگیری تقویتی در حوزه مالی و رویکردهای ترکیبی آن‌ها در معامله‌گری می‌پردازد.

فصل چهارم به «توصیف پروژه» اختصاص دارد و شامل زیربخش‌های زیر است:

□ معماری کلی سیستم

□ مقدمه

□ توصیف بازار انتخاب‌شده

□ گردآوری داده‌ها

□ تحلیل داده‌ها

□ استخراج احساسات از اخبار

□ محیط معامله‌گری

□ عامل یادگیری تقویتی

□ پایش

□ ارائه و استقرار

فصل پنجم به پیاده‌سازی اختصاص دارد و جزئیات فرآیند اجرا، ابزارها و چارچوب‌های مورد استفاده، ملاحظات مربوط به بازتولیدپذیری و منابع محاسباتی را بیان می‌کند.

فصل ششم طراحی آزمایش‌ها و نتایج تجربی حاصل از ارزیابی سیستم پیشنهادی را تشریح می‌کند.

فصل هفتم شامل بحث و تحلیل انتقادی یافته‌ها است و بر نقاط قوت، دستاوردها و محدودیت‌های پژوهش تأکید دارد.

در نهایت، **فصل هشتم** به جمع‌بندی مطالعه، بررسی پیامدهای آن برای حوزه **هوش مصنوعی مالی** و پیشنهاد مسیرهای بالقوه برای تحقیقات آینده اختصاص دارد.

فصل ۲

مفاهیم نظری

۲-۱- مقدمه

این فصل به مبانی نظری مورد نیاز برای درک توسعه یک عامل یادگیری تقویتی در بستر بازارهای مالی، با تأکید بر ادغام آن با مدل‌های زبانی بزرگ، می‌پردازد.

ابتدا اصول پایه‌ای یادگیری تقویتی معرفی می‌شوند؛ از جمله اجزای اصلی آن، موازنه اکتشاف - بهره‌برداری^۱، و تمایز میان رویکردهای درون‌سیاستی^۲ و برون‌سیاستی^۳، همچنین مدل‌مبنا^۴ در برابر مدل‌نامبنا^۵. بر این اساس، الگوریتم‌های کلیدی یادگیری تقویتی از Q-learning و روش‌های گرادینان سیاست^۶ تا چارچوب‌های بازیگر - منتقد^۷ و الگوریتم‌های پیشرفته‌ای مانند Proximal Policy Optimization (PPO) و نسخه بازگشتی آن Recurrent PPO مرور خواهند شد.

در ادامه، مبانی مدل‌های زبانی بزرگ بررسی می‌شوند. این بخش شامل توضیح معماری Transformer^۸، روش‌های تعبیه^۹ و پارادایم‌های مختلف آموزش است. همچنین نقش تحلیل احساسات در حوزه مالی برجسته می‌شود تا نشان دهد چگونه داده‌های متنی می‌توانند مکمل شاخص‌های عددی بازار باشند.

در نهایت، ساختار و چالش‌های داده‌های بازار مالی، اصول مدیریت سبد سهام و محدودیت‌های عملی مانند هزینه‌های تراکنش، معیارهای ریسک و شاخص‌های ارزیابی تشریح می‌شوند. به‌طور کلی، این مفاهیم بنیان نظری لازم برای طراحی و ارزیابی یک عامل معاملاتی مبتنی بر یادگیری تقویتی را که با بینش‌های استخراج‌شده از مدل‌های زبانی بزرگ تقویت شده است، فراهم می‌آورند.

^۱Exploration-Exploitation Balance

^۲On-Policy Learning

^۳Off-Policy Learning

^۴Model-Based

^۵Model-Free

^۶Policy Gradient Methods

^۷Actor-Critic Frameworks


^۸Transformer Architecture

^۹Embedding Techniques

۲-۲- مبانی یادگیری تقویتی

۲-۲-۱- اجزای اصلی

یادگیری تقویتی [۱۶] محاسباتی برای تصمیم‌گیری دنباله‌ای است که در آن عامل با تعامل مستقیم با محیط می‌آموزد چگونه عمل‌های مناسب را انتخاب کند. هدف اصلی این رویکرد، بیشینه‌سازی پاداش تجمعی در طول زمان است. اجزای اصلی یادگیری تقویتی در شکل (۱-۲) نمایش داده شده‌اند.



شکل (۱-۲) چارچوب کلی یادگیری تقویتی [۱۴].

□ **عامل:** یادگیرنده یا تصمیم‌گیرنده. در معامله‌گری الگوریتمی، عامل همان راهبرد معاملاتی است که عمل‌های خرید، فروش یا نگهداشتن را انتخاب می‌کند.

□ **محیط:** سامانه خارجی که عامل با آن تعامل دارد. در کاربردهای مالی، محیط معمولاً بازار است که شامل پویایی قیمت، دفتر سفارش و داده‌های احساسی می‌شود.

□ **حالت (s_t):** بازنمایی وضعیت محیط در زمان t . در معامله‌گری، حالت‌ها می‌توانند شامل شاخص‌های فنی و امتیازهای احساسی استخراج‌شده از اخبار و داده‌های تاریخی باشند.

□ **عمل (a_t):** مجموعه تصمیم‌های در دسترس عامل در زمان t . در ساده‌ترین حالت، این مجموعه شامل {خرید، فروش، نگهداشتن} است، اما می‌تواند به بازتخصیص سبد سهام یا تعیین اندازه موقعیت به‌صورت پیوسته نیز گسترش یابد.

□ **پاداش (r_t):** سیگنال بازخورد عددی که سود یا زیان فوری ناشی از اجرای عمل a_t در حالت s_t را نشان می‌دهد. در زمینه مالی، این معمولاً به‌صورت **سود و زیان**، بازدهی تعدیل‌شده بر اساس ریسک یا تابعی سفارشی تعریف می‌شود که اهداف مدیریت ریسک را نیز در نظر می‌گیرد.

□ سیاست (π): راهبرد عامل برای نگاشت حالت‌ها به عمل‌ها. سیاست‌ها می‌توانند **قطعی** باشند ($a = \pi(s)$) یا **تصادفی** باشند ($a \sim \pi(\cdot|s)$).

□ **تابع ارزش**: برآورد پاداش تجمعی مورد انتظار هنگام شروع از یک حالت یا جفت حالت - عمل مشخص. این تابع معیاری از مطلوبیت بلندمدت حالت‌ها، فراتر از پاداش‌های فوری ارائه می‌دهد.

□ **مدل محیط**: یک مؤلفه اختیاری که انتقال حالت‌ها را بر اساس عمل‌ها پیش‌بینی می‌کند. رویکردهای **مدل‌نامبنا**^{۱۰} مانند Proximal Policy Optimization, PPO محیط را به‌طور صریح مدل‌سازی نمی‌کنند، در حالی که روش‌های **مدل‌مبنا**^{۱۱} چنین مدل‌های پیش‌بینی را در نظر می‌گیرند.

این اجزا شالوده الگوریتم‌های یادگیری تقویتی را تشکیل می‌دهند. در معامله‌گری مالی، طراحی دقیق فضای حالت، مجموعه عمل و تابع پاداش اهمیت حیاتی دارد؛ زیرا تعریف‌های ضعیف یا نادرست می‌توانند به پویایی‌های یادگیری ناپایدار یا راهبردهای معاملاتی زیان‌ده منجر شوند.

۲-۲-۲ - اکتشاف^{۱۲} در برابر بهره‌برداری^{۱۳}

یکی از چالش‌های اصلی در یادگیری تقویتی موازنه میان **اکتشاف** و **بهره‌برداری** است.

□ **اکتشاف**: فرآیند انتخاب عمل‌هایی با قطعیت کمتر برای کسب دانش جدید و احتمالاً کشف راهبردهایی که بازدهی بلندمدت بیشتری ایجاد می‌کنند. در معامله‌گری، اکتشاف می‌تواند شامل آزمون شاخص‌ها یا سیگنال‌های جدید بازار باشد، حتی اگر سودآوری فوری آن‌ها نامشخص باشد.

□ **بهره‌برداری**: فرآیند استفاده از دانش موجود برای بیشینه‌سازی پاداش مورد انتظار از طریق انتخاب مداوم عمل‌هایی که بهترین عملکرد برآوردشده را دارند. در کاربردهای مالی، این به معنای انجام معاملاتی است که در گذشته بازدهی قوی نشان داده‌اند.

تعادل میان اکتشاف و بهره‌برداری حیاتی است. بهره‌برداری بیش از حد می‌تواند به همگرایی زودهنگام بر سیاست‌های زیربهبینه منجر شود و عملکرد بلندمدت را محدود کند. در مقابل، اکتشاف بیش از حد ممکن است به رفتار ناپایدار و افزایش مواجهه با ریسک بیانجامد - موضوعی که در بازارهای مالی اهمیت ویژه‌ای دارد.

۲-۲-۳ - وظایف رویدادمحور^{۱۴} در برابر وظایف پیوسته^{۱۵}

مسائل یادگیری تقویتی را می‌توان به‌طور کلی به **وظایف رویدادمحور** و **وظایف پیوسته** تقسیم کرد که بر اساس نحوه تعامل عامل با محیط تعریف می‌شوند.

□ **وظایف رویدادمحور**: تعامل به دوره‌های گسسته تقسیم می‌شود که هر کدام حالت آغازین و پایانی مشخص دارند. در پایان هر دوره، محیط بازنشانی می‌شود و فرآیند یادگیری دوباره آغاز می‌گردد. نمونه‌های کلاسیک شامل بازی‌های تخته‌ای مانند شطرنج و Go هستند که هر مسابقه یک دوره محسوب می‌شود. در معامله‌گری مالی، یک افق سرمایه‌گذاری ثابت (مثلاً شبیه‌سازی ۳۰ روز معاملاتی) را می‌توان به‌عنوان یک وظیفه رویداد محور مدل کرد.

¹⁰Model-Free


¹¹Model-Based

¹²Exploration

¹³Exploitation

¹⁴Episodic Tasks

¹⁵Continuous Tasks



شکل (۲-۲) نمایی از موازنه اکتشاف - بهره‌برداری [۱۵].

□ **وظایف پیوسته:** تعامل به‌طور نامحدود ادامه دارد، بدون اینکه حالت پایانی طبیعی داشته باشد. عامل باید رفتار خود را در یک جریان بی‌پایان از حالت‌ها و پاداش‌ها بهینه کند. بازارهای مالی ذاتاً پیوسته‌اند، زیرا فرصت‌های معاملاتی و حرکت‌های قیمتی بدون نقطه پایان از پیش تعیین‌شده در جریان هستند.

این تمایز به‌طور مستقیم بر نحوه محاسبه توابع ارزش اثر می‌گذارد. در وظایف رویدادمحور معمولاً پاداش‌ها تا یک نقطه پایان مشخص جمع می‌شوند (بازدهی با افق محدود). اما در وظایف پیوسته از بازدهی تنزیل‌شده با افق نامحدود استفاده می‌شود تا مجموع پاداش‌ها همواره مقدار محدودی داشته باشد:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}, \quad 0 \leq \gamma < 1,$$

که در آن γ ضریب تنزیل^{۱۶} است و موازنه میان پاداش‌های فوری و بلندمدت را کنترل می‌کند. در معامله‌گری الگوریتمی، محیط‌ها غالباً به‌صورت پیوسته مدل می‌شوند تا ماهیت همیشگی بازار بازتاب یابد. با این حال، فرآیند آموزش معمولاً در قالب دوره‌ها (مانند دوره‌های سالانه یا فصلی) سازمان‌دهی می‌شود تا یادگیری پایدارتر گردد، ارزیابی تسهیل شود و مقایسه میان راهبردها امکان‌پذیر باشد.

۲-۲-۴ - یادگیری درون‌سیاستی^{۱۷} در برابر برون‌سیاستی^{۱۸}

الگوریتم‌های یادگیری تقویتی را می‌توان به روش‌های درون‌سیاستی و روش‌های برون‌سیاستی تقسیم کرد. این دسته‌بندی بر اساس نحوه بهبود سیاست عامل تعریف می‌شود.

□ **یادگیری درون‌سیاستی:** عامل ارزش سیاستی را می‌آموزد که هم‌اکنون در حال اجراست. داده‌ها با پیروی از همین سیاست جمع‌آوری می‌شوند و بهبودها بر همان اساس صورت می‌گیرد. نمونه‌ها شامل SARSA و روش‌های گرادیان سیاست^{۱۹} مانند Proximal Policy Optimization, PPO هستند. در معامله‌گری

¹⁶Discount Factor

¹⁷On-Policy Learning

¹⁸Off-Policy Learning

¹⁹Policy Gradient Methods

الگوریتمی، این به عاملی اشاره دارد که بر اساس معاملاتی که تحت راهبرد جاری خود انجام می‌دهد، تطبیق پیدا می‌کند.

□ **یادگیری برون‌سیاستی:** عامل ارزش یک سیاست بهینه را می‌آموزد، حتی اگر از یک سیاست رفتاری متفاوت پیروی کند. این رویکرد امکان یادگیری از داده‌های تاریخی، نمایش‌ها یا رفتارهای اکتشافی را فراهم می‌آورد. نمونه‌های بارز شامل Q-learning و DQN، Deep Q-Networks، در معامله‌گری، این روش به عامل اجازه می‌دهد از داده‌های تاریخی گسترده بازار بیاموزد، بدون آنکه معاملات را در زمان واقعی اجرا کند.

روش‌های درون‌سیاستی معمولاً پایدارتر و ایمن‌تر در حوزه‌های پرریسک مانند معامله‌گری هستند، در حالی که روش‌های برون‌سیاستی داده‌محورتر بوده و می‌توانند از تجربیات گذشته و شبیه‌سازی‌های برون‌خط استفاده کنند [۱۶].

۲-۲-۵ - روش‌های مدل‌مبنا^{۲۰} در برابر مدل‌نامبنا^{۲۱}

تمایز مهم دیگر در یادگیری تقویتی میان روش‌های مدل‌نامبنا و روش‌های مدل‌مبنا است. این تمایز بر اساس صریح‌بودن یا نبودن مدل‌سازی محیط تعریف می‌شود.

□ **روش‌های بدون مدل:** این الگوریتم‌ها تلاشی برای یادگیری ساختار انتقال محیط نمی‌کنند، بلکه مستقیماً توابع ارزش یا سیاست‌ها را از طریق تعامل تخمین می‌زنند. نمونه‌هایی از این دسته شامل Q-learning، DQN و PPO هستند. در معامله‌گری، یک عامل بدون مدل مستقیماً از داده‌های بازار مانند سری‌های قیمتی، شاخص‌ها و سیگنال‌های احساسی یاد می‌گیرد، بدون آنکه مسیر آینده بازار را پیش‌بینی کند.

□ **روش‌های مبتنی بر مدل:** این رویکردها بر یادگیری یا استفاده از یک مدل پیش‌بینی‌کننده رفتار محیط (مانند احتمال‌های گذار بین حالت‌ها و تابع پاداش) تکیه دارند. چنین مدل‌هایی امکان به‌کارگیری تکنیک‌های برنامه‌ریزی مانند برنامه‌ریزی پویا^{۲۲} یا جستجوی درختی مونت کارلو^{۲۳} را فراهم می‌کنند. در حوزه مالی، این می‌تواند شامل ساخت مدل‌های پیش‌بینی تغییرات قیمت دارایی‌ها یا شبیه‌سازی رفتار دفتر سفارش برای هدایت تصمیم‌گیری باشد.

به طور کلی، روش‌های بدون مدل ساده‌تر بوده و با یادگیری عمیق بهتر مقیاس‌پذیر هستند، هرچند به داده و فرآیند اکتشاف بیشتری نیاز دارند. در مقابل، روش‌های مبتنی بر مدل از نظر استفاده از داده کاراترند، اما نسبت به خطاهای مدل حساسیت بیشتری دارند - موضوعی که در بازارهای مالی پرتلاطم و ناپایدار اهمیت ویژه‌ای پیدا می‌کند.

۲-۳ - الگوریتم‌های یادگیری تقویتی

۲-۳-۱ - Q-Learning و شبکه‌های Q عمیق^{۲۴}

Q-Learning که نخستین بار توسط Watkins در سال ۱۹۸۹ معرفی شد [۱۷]، یکی از الگوریتم‌های بنیادی در یادگیری تقویتی است. این روش برون‌سیاستی و مدل‌نامبنا است و هدف آن یادگیری تابع ارزش عمل بهینه $Q^*(s, a)$ می‌باشد. این تابع بیانگر پاداش تجمعی تنزیل‌شده مورد انتظار از انتخاب عمل a در حالت s و سپس پیروی از سیاست بهینه است. قاعده به‌روزرسانی Q-learning به صورت زیر تعریف می‌شود:

²⁰Model-Based Methods

²¹Model-Free Methods

²²Dynamic Programming

²³Monte Carlo Tree Search, MCTS

²⁴Deep Q-Networks, DQN

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right]$$

که در آن α نرخ یادگیری^{۲۵}، γ ضریب تنزیل^{۲۶} و r_{t+1} پاداش دریافتی پس از اجرای عمل a_t در حالت s_t است.

شبکه‌های Q عمیق^{۲۷} بسط Q-learning هستند که در آن تابع Q با استفاده از یک شبکه عصبی عمیق تقریب زده می‌شود. این رویکرد امکان مقیاس‌پذیری به فضاهای ورودی با ابعاد بالا مانند تصاویر یا سری‌های زمانی مالی را فراهم می‌کند. پژوهش برجسته (2015) Mnih et al. [۱۸] موفقیت DQN را در یادگیری مستقیم از ورودی‌های خام پیکسلی در بازی‌های آتاری نشان داد. نوآوری‌های کلیدی DQN شامل موارد زیر است:

□ **بازپخش تجربه**^{۲۸}: انتقال‌ها (s, a, r, s') در یک حافظه بازپخش ذخیره می‌شوند و آموزش شبکه با استفاده از بسته‌های کوچک داده که به‌طور تصادفی از این حافظه نمونه‌برداری می‌شوند انجام می‌شود. این فرآیند همبستگی میان به‌روزرسانی‌های متوالی را کاهش داده و پایداری آموزش را افزایش می‌دهد.

□ **شبکه‌های هدف**: یک شبکه هدف جداگانه برای محاسبه مقادیر هدف در Q-learning به‌کار گرفته می‌شود که به‌صورت دوره‌ای به‌روزرسانی می‌گردد. این رویکرد از نوسانات مخرب و واگرایی در طول آموزش جلوگیری می‌کند.

در کاربردهای معاملاتی، Q-learning و DQN می‌توانند برای یادگیری سیاست‌هایی مورد استفاده قرار گیرند که مشخص می‌کنند آیا عامل باید دارایی را بخرد، بفروشد یا نگه دارد؛ بر اساس حالتی که توسط شاخص‌های بازار، امتیازهای احساسی و داده‌های قیمتی تعریف می‌شود. با این حال، بازارهای مالی چالش‌های خاصی برای DQN ایجاد می‌کنند، زیرا حالت‌ها پیوسته، غیرایستا و پاداش‌ها تصادفی هستند؛ بنابراین تصمیم‌گیری حساس به ریسک ضرورت می‌یابد. با وجود این محدودیت‌ها، DQN همچنان به‌عنوان یک معیار مرجع ارزشمند در مقایسه با روش‌های پیشرفته‌تر مانند **گرادین سیاست** و رویکردهای **بازیگر – منتقد** به‌کار می‌رود.

۲-۳-۲ روش‌های گرادین سیاست^{۲۹}

در حالی که روش‌های مبتنی بر ارزش مانند Q-learning به تخمین تابع ارزش عمل می‌پردازند، روش‌های **گرادین سیاست**^{۳۰} مستقیماً سیاست $\pi_\theta(a|s)$ را که با پارامترهای θ (مانند وزن‌های یک شبکه عصبی) مشخص می‌شود، بهینه می‌کنند. هدف اصلی، بیشینه‌سازی بازدهی مورد انتظار است:

$$J(\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right],$$

که گرادین‌ها بر اساس قضیه گرادین سیاست^{۳۱} به‌دست می‌آیند [۱۹]:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a_t|s_t) G_t],$$

²⁵Learning Rate

²⁶Discount Factor

²⁷Deep Q-Networks, DQN

²⁸Experience Replay

²⁹Policy Gradient Methods

³⁰Policy Gradient Methods

³¹Policy Gradient Theorem

که در آن G_t بازدهی پس از گام زمانی t را نشان می‌دهد.

مزایای روش‌های گرادیان سیاست:

- قابلیت طبیعی در مدیریت فضاهای عمل پیوسته و با ابعاد بالا، در حالی که روش‌های مبتنی بر ارزش معمولاً به عمل‌های گسسته محدودند.
- پشتیبانی از سیاست‌های تصادفی که فرآیند اکتشاف را تسهیل می‌کنند.
- امکان ادغام مستقیم محدودیت‌ها، معیارهای ریسک یا هزینه‌های تراکنش در طراحی پاداش.

چالش‌ها:

- برآورد گرادیان در این روش‌ها معمولاً نوسان زیادی دارد (واریانس بالا)^{۳۲}، به همین دلیل لازم است از روش‌های کاهش واریانس^{۳۳} مانند استفاده از مبناها^{۳۴} یا توابع برتری^{۳۵} کمک گرفته شود تا پایداری آموزش افزایش یابد.
- این الگوریتم‌ها در مقایسه با روش‌های برون‌سیاستی مانند DQN، به داده‌های بیشتری برای یادگیری نیاز دارند و از نظر کارایی استفاده از نمونه‌ها ضعیف‌تر عمل می‌کنند.

در معامله‌گری مالی، روش‌های گرادیان سیاست به‌ویژه اهمیت دارند زیرا عمل‌ها (مانند وزن‌های سبد سهام یا اندازه موقعیت‌ها) ذاتاً پیوسته‌اند. برای نمونه، یک عامل یادگیری تقویتی می‌تواند به‌طور مستقیم کسری از سرمایه را که باید میان دارایی‌های مختلف تخصیص یابد، خروجی دهد. الگوریتم‌های اولیه‌ای مانند REINFORCE [۲۰] بنیان این حوزه را شکل دادند، در حالی که بسط‌های مدرن مانند روش‌های بازیگر-منتقد پایداری و کارایی بیشتری به همراه داشته‌اند.

۲-۳-۳ روش‌های بازیگر - منتقد^{۳۶}

روش‌های بازیگر - منتقد مزایای رویکردهای مبتنی بر ارزش و مبتنی بر سیاست را در یادگیری تقویتی ترکیب می‌کنند. این روش‌ها از دو مؤلفه اصلی تشکیل شده‌اند [۲۱]:

- بازیگر (Actor): تابع سیاست $\pi_\theta(a|s)$ با پارامترهای θ که عمل‌ها را بر اساس حالت‌ها انتخاب می‌کند.
- منتقد (Critic): تابع ارزش $V^\pi(s)$ یا تابع ارزش عمل $Q^\pi(s, a)$ با پارامترهای ϕ که کیفیت سیاست را از طریق برآورد بازدهی مورد انتظار ارزیابی می‌کند.

منتقد در این چارچوب نقشی مانند یک مبنا^{۳۷} دارد و کمک می‌کند تا نوسان زیاد (واریانس) در برآورد گرادیان سیاست کاهش یابد. بازیگر وظیفه دارد پارامترهای سیاست را در جهتی که قضیه گرادیان سیاست^{۳۸} مشخص کرده به‌روزرسانی کند. در مقابل، منتقد با استفاده از یادگیری تفاضل زمانی^{۳۹} مقدارهای ارزش را بهبود می‌دهد و بازخورد دقیق‌تری به بازیگر می‌دهد.

³²High Variance

³³Variance Reduction Techniques

³⁴Baselines

³⁵Advantage Functions

³⁶Actor-Critic Methods

³⁷Baseline

³⁸Policy Gradient Theorem

³⁹Temporal-Difference, TD Learning

به‌طور خلاصه، به‌روزرسانی رایج بازیگر به صورت زیر نوشته می‌شود:

$$\nabla_{\theta} J(\theta) \approx \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\pi}(s_t, a_t)],$$

که در آن $A^{\pi}(s_t, a_t)$ **تابع برتری**^{۴۰} است. این تابع نشان می‌دهد که یک عمل در وضعیت خاص، نسبت به میانگین انتظاری (مبنا) تا چه حد بهتر یا بدتر است. به این ترتیب، بازیگر به سمت اعمالی متمایل می‌شود که ارزش بیشتری نسبت به مبنا دارند.

مزایای روش‌های بازیگر-منتقد

□ کارایی نمونه‌ای بیشتر نسبت به روش‌های صرفاً گرادیان سیاست مانند REINFORCE، به دلیل کاهش واریانس توسط منتقد.

□ مقیاس‌پذیری به فضاهای عمل پیوسته و با ابعاد بزرگ.

□ ایجاد بنیان برای الگوریتم‌های پیشرفته‌ای مانند A2C، A3C و PPO.

روش‌های بازیگر-منتقد به‌ویژه در معامله‌گری مالی کارآمد هستند؛ زیرا منتقد با ارائه برآوردهای دقیق‌تر از بازدهی، یادگیری را در بازارهای پرنوسان و غیرایستا پایدارتر می‌سازد. برای نمونه، بازیگر می‌تواند معاملاتی مانند تنظیم اندازه موقعیت‌ها را پیشنهاد دهد، در حالی که منتقد سودآوری بلندمدت آن‌ها را ارزیابی می‌کند. بسط‌هایی مانند A3C نیز امکان آموزش موازی در چندین بازار شبیه‌سازی‌شده را فراهم کرده و کارایی و پایداری فرآیند یادگیری را افزایش می‌دهند.

۲-۳-۴ Proximal Policy Optimization (PPO)

الگوریتم PPO [۲۲] یکی از پرکاربردترین روش‌های گرادیان سیاست است که به دلیل پایداری، سادگی و عملکرد تجربی قوی شناخته می‌شود. این الگوریتم در خانواده روش‌های **بازیگر - منتقد** قرار می‌گیرد، اما سازوکاری برای محدود کردن به‌روزرسانی‌های بیش از حد سیاست معرفی می‌کند؛ زیرا چنین به‌روزرسانی‌هایی می‌توانند آموزش را ناپایدار سازند. ایده اصلی، بهینه‌سازی یک **تابع هدف جانشین** با استفاده از **نسبت احتمالات برش‌خورده**^{۴۱} است:

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) A_t \right) \right],$$

که در آن:

$$r_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{old}}(a_t | s_t)} \quad \square$$

□ A_t **تابع برتری** برآورده شده است،

□ ϵ پارامتر برش است (معمولاً در بازه 0.1 تا 0.2).

برش‌زدن مانع می‌شود که سیاست جدید در یک به‌روزرسانی بیش از حد از سیاست قدیم منحرف شود و به این ترتیب یادگیری پایدارتر می‌گردد. افزون بر این، PPO اغلب از **منظم‌سازی آنتروپی**^{۴۲} برای تقویت اکتشاف بهره می‌گیرد.

^{۴۰}Advantage Function

^{۴۱}Clipped Probability Ratio

^{۴۲}Entropy Regularization

تابع زیان کلی: در عمل، PPO چندین مؤلفه را در یک تابع زیان ترکیب می‌کند:

$$L^{PPO}(\theta) = \mathbb{E}_t \left[L^{CLIP}(\theta) - c_1 (V_\theta(s_t) - V_t^{target})^2 + c_2 H(\pi_\theta(\cdot|s_t)) \right],$$

که در آن:

□ $L^{CLIP}(\theta)$ زیان سیاست برش‌خورده است،

□ $(V_\theta(s_t) - V_t^{target})^2$ خطای مربعی میان برآورد منتقد و بازدهی هدف است،

□ $H(\pi_\theta(\cdot|s_t))$ آنروپی سیاست است که اکتشاف را تشویق می‌کند،

□ c_1 و c_2 ضرایب کنترل‌کننده اهمیت مؤلفه‌های ارزش و آنروپی هستند.

مزایای PPO:

□ موازنه مؤثر میان اکتشاف و بهره‌برداری،

□ ساده‌تر و مقاوم‌تر نسبت به روش‌های پیشین مبتنی بر ناحیه اعتماد مانند TRPO،

□ مقیاس‌پذیری مناسب در ترکیب با شبکه‌های عصبی عمیق و مسائل با ابعاد بالا.

PPO به‌ویژه برای محیط‌های معاملاتی مالی مناسب است؛ جایی که پایداری و مقاوم‌بودن اهمیت بالایی دارند زیرا داده‌ها پرنویز و غیرایستا هستند. با کنترل دقیق به‌روزرسانی‌های سیاست و ترکیب مؤلفه‌های سیاست، ارزش و آنروپی، PPO امکان سازگاری تدریجی راهبردهای معاملاتی را فراهم می‌کند و میان بیشینه‌سازی سود، مدیریت ریسک و اکتشاف فرصت‌های جدید تعادل برقرار می‌سازد.

۲-۳-۵ PPO بازگشتی

۴۳

بسیاری از محیط‌های دنیای واقعی — از جمله بازارهای مالی — دارای قابلیت مشاهده ناقص^{۴۴} هستند؛ به این معنا که عامل مستقیماً حالت زیربنایی را مشاهده نمی‌کند، بلکه تنها سیگنال‌های نویزی یا ناقصی مانند قیمت‌ها، شاخص‌های احساسی یا ویژگی‌های فنی دریافت می‌کند. برای رفع این چالش، الگوریتم PPO را می‌توان با شبکه‌های عصبی بازگشتی بسط داد که منجر به PPO بازگشتی می‌شود [۲۳].

در RPPPO شبکه‌های سیاست و ارزش با مؤلفه‌های حافظه‌ای مانند LSTM یا GRU تقویت می‌شوند. این ساختار به عامل امکان می‌دهد وابستگی‌های زمانی^{۴۵} را ثبت کرده و یک حالت پنهان^{۴۶} را در طول گام‌های زمانی حفظ کند. حالت پنهان اطلاعات گذشته مرتبط را خلاصه می‌کند و در نتیجه تصمیم‌گیری مؤثرتری را در شرایط مشاهده ناقص ممکن می‌سازد.

مزایای PPO بازگشتی:

□ توانایی مدیریت مشاهده ناقص از طریق حفظ حافظه شرایط گذشته بازار.

^{۴۳}Recurrent PPO

^{۴۴}Partial Observability

^{۴۵}Temporal Dependencies

^{۴۶}Hidden State

□ بهبود عملکرد در وظایف دنباله‌ای با وابستگی‌های بلندمدت.

□ ارائه چارچوبی واقع‌بینانه‌تر برای معامله‌گری مالی، جایی که تصمیم‌ها هم به بستر تاریخی و هم به سیگنال‌های جاری وابسته‌اند.

الگوریتم RPPO توانایی عامل معاملاتی مبتنی بر یادگیری تقویتی را در تشخیص الگوهای زمانی موجود در داده‌های مالی افزایش می‌دهد. برای نمونه، گاهی قیمت‌ها تمایل دارند مدتی در همان جهت قبلی حرکت کنند (اثر تداوم روند)، یا دوره‌های پرنوسان و کم‌نوسان بازار معمولاً پشت سر هم رخ می‌دهند. با ترکیب شاخص‌های فنی و ویژگی‌های احساسی در یک ساختار بازگشتی، RPPO می‌تواند این الگوهای زمانی را بهتر از نسخه استاندارد PPO (بدون حافظه بازگشتی) ثبت کرده و راهبردهای معاملاتی سازگارتر ارائه دهد.

۴-۲- مبانی مدل‌های زبانی بزرگ

۴-۲-۱- معماری Transformer

Transformer [۲۴] یک معماری یادگیری عمیق است که بنیان مدل‌های زبانی بزرگ مدرن را تشکیل می‌دهد. برخلاف شبکه‌های عصبی بازگشتی یا مدل‌های کانولوشنی^{۴۷}، Transformer کاملاً بر سازوکار خودتوجهی^{۴۸} متکی است تا وابستگی میان واحدهای زبانی در متن را ثبت کند. این ویژگی امکان موازی‌سازی کارآمد و مقیاس‌پذیری تا مجموعه‌داده‌های بسیار بزرگ را فراهم می‌سازد.

اجزای کلیدی معماری Transformer:

□ **تعبیه ورودی**^{۴۹}: هر واحد زبانی در دنباله به یک بردار متراکم نگاشت می‌شود. از آنجا که Transformer فاقد بازگشت یا کانولوشن هستند، کدگذاری‌های مکانی^{۵۰} به این بردارها افزوده می‌شوند تا ترتیب واحدهای زبانی حفظ شود.

□ **سازوکار خودتوجهی**: عملیات اصلی روابط میان همه جفت واحدهای زبانی در یک دنباله را محاسبه می‌کند. برای هر واحد زبانی، بردارهای پرسش (Q)، کلید (K) و مقدار (V) از نگاشت خطی تعبیه‌های ورودی به دست می‌آیند. توجه به صورت زیر محاسبه می‌شود:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V,$$

که در آن d_k بُعد بردارهای کلید است. این سازوکار به هر واحد زبانی اجازه می‌دهد بر اساس ارتباط معنایی به سایر واحدهای زبانی توجه کند.

□ **توجه چندسری**^{۵۱}: به جای یک عملیات توجه منفرد، چندین توجه به‌طور موازی محاسبه می‌شوند که امکان ثبت انواع مختلفی از روابط را فراهم می‌کند. خروجی‌ها سپس به هم متصل شده و به فضای تعبیه بازافکنی می‌شوند.

^{۴۷}Convolutional Models

^{۴۸}Self-Attention Mechanism

^{۴۹}Input Embeddings

^{۵۰}Positional Encodings

^{۵۱}Multi-Head Attention

- شبکه‌های پیشخور^{۵۲}: بازنمایی هر موقعیت از یک شبکه عصبی تمام‌متصل با فعال‌ساز غیرخطی عبور می‌کند.
- اتصالات باقیمانده و نرمال‌سازی لایه^{۵۳}: برای پایدارسازی آموزش و بهبود جریان گرادیان، اتصالات باقیمانده پیرامون لایه‌های توجه و پیشخور اعمال می‌شوند و سپس نرمال‌سازی لایه انجام می‌شود.
- ساختار رمزگذار – رمزگشا^{۵۴}: Transformer اصلی شامل یک رمزگذار (مفید برای بازنمایی ورودی‌ها مانند ترجمه) و یک رمزگشا (مسئول تولید دنباله) است. مدل‌های زبانی بزرگی مانند GPT از گونه فقط رمزگشا^{۵۵} با سازوکار Masked Self-Attention استفاده می‌کنند تا اطمینان یابند پیش‌بینی در گام t تنها به واحدهای زبانی مشاهده‌شده تا آن لحظه وابسته باشد.

۲-۴-۲ جاسازی واژه‌ها^{۵۶} و جاسازی‌های متنی^{۵۷}

مدل‌های پردازش زبان طبیعی برای عملکرد مناسب نیازمند بازنمایی عددی از واژه‌ها هستند تا معنای واژگانی در آن‌ها منعکس شود. این هدف با استفاده از جاسازی‌ها محقق می‌شود؛ یعنی نگاشت واحدهای گسسته به فضاها برداری پیوسته که در آن‌ها روابط معنایی قابل اندازه‌گیری هستند.

جاسازی‌های ایستا^{۵۸}: روش‌های اولیه مانند Word2Vec [۲۵] و GloVe [۲۶] به هر واژه یک بردار ثابت اختصاص می‌دهند، مستقل از بافت آن. این جاسازی‌ها شباهت معنایی را از طریق حساب برداری ثبت می‌کنند. با این حال، جاسازی‌های ایستا قادر به ثبت چندمعنایی^{۵۹} نیستند؛ یعنی واژه‌هایی با معانی متعدد صرف‌نظر از بافت تنها با یک بردار نمایش داده می‌شوند.

جاسازی‌های متنی^{۶۰}: مدل‌های مدرن مبتنی بر Transformer مانند BERT [۲۷] و GPT [۲۸] جاسازی‌هایی تولید می‌کنند که بافت‌محور هستند. بازنمایی یک واژه بر اساس توکن‌های پیرامونی تغییر می‌کند و مدل را قادر می‌سازد میان معانی مختلف یک واژه تمایز قائل شود. این نوع جاسازی‌ها از سازوکار خودتوجهی^{۶۱} برای ادغام اطلاعات معنایی در سراسر دنباله ورودی استفاده می‌کنند.

۲-۴-۳ راهکارهای سازگارسازی مدل‌های زبانی بزرگ

مدل‌های زبانی بزرگ پس از پیش‌آموزش عمومی، برای کارهای خاص نیاز به سازگارسازی دارند. مهم‌ترین رویکردها عبارت‌اند از:

- ریزتنظیم^{۶۲}: ادامه آموزش روی داده‌های حوزه‌ای (مثلاً متون مالی) برای افزایش دقت در همان زمینه.

⁵²Feed-Forward Networks

⁵³Residual Connections & Layer Normalization

⁵⁴Encoder-Decoder Structure

⁵⁵Decoder-Only

⁵⁶Word Embeddings

⁵⁷Text Embeddings

⁵⁸Static Embeddings

⁵⁹Polysemy

⁶⁰Contextual Embeddings

⁶¹Self-Attention Mechanism

⁶²Fine-tuning

□ **تنظیم مبتنی بر دستور**^{۶۳}: آموزش مدل با داده‌های شامل «دستور + پاسخ» تا رفتار آن به نیت کاربر نزدیک‌تر شود.

□ **مهندسی دستور**^{۶۴}: طراحی ورودی‌های هوشمندانه توسط کاربر برای هدایت بهتر مدل، بدون نیاز به تغییر پارامترهای آن.

۲-۴-۴- تحلیل احساسات در زمینه مالی^{۶۵}

تحلیل احساسات فرآیند استخراج اطلاعات ذهنی — مانند نظرات، نگرش‌ها یا هیجانات — از داده‌های متنی است. در حوزه مالی، تحلیل احساسات به دنبال کمی‌سازی لحن عاطفی مقالات خبری، گزارش‌های تحلیلی یا بحث‌های شبکه‌های اجتماعی است؛ زیرا این منابع اغلب بر رفتار سرمایه‌گذاران و پویایی بازار اثرگذارند.

چرا احساسات اهمیت دارند: بازارهای مالی صرفاً بر مبنای عوامل بنیادین هدایت نمی‌شوند، بلکه روان‌شناسی سرمایه‌گذاران و احساسات جمعی نیز نقشی تعیین‌کننده دارند. اخبار یا دیدگاه‌های مثبت می‌توانند حرکت‌های صعودی^{۶۶} را تقویت کنند، در حالی که احساسات منفی ممکن است به حرکت‌های نزولی^{۶۷} و فروش گسترده منجر شود. با تبدیل متن‌های غیرساختاریافته به امتیازهای ساختاریافته احساسات، عامل‌های معاملاتی قادر خواهند بود سیگنال‌های روان‌شناختی را در فرآیند تصمیم‌گیری سیستماتیک وارد کنند.

روش‌های تحلیل احساسات:

□ **روش‌های واژگانی**^{۶۸}: بر پایه واژه‌نامه‌های از پیش تعریف‌شده برای کلمات مثبت و منفی. برای نمونه، واژه‌نامه Loughran-McDonald [۲۹] به‌طور گسترده در حوزه مالی استفاده می‌شود زیرا واژگان تخصصی این حوزه را پوشش می‌دهد.

□ **روش‌های یادگیری ماشین سنتی**^{۶۹}: استفاده از ویژگی‌های مهندسی‌شده مانند **کیسه واژگان**^{۷۰} یا بازنمایی‌های TF-IDF و ترکیب آن‌ها با دسته‌بندی‌هایی مانند Logistic Regression و Support Vector Machines (SVMs).

□ **روش‌های یادگیری عمیق**^{۷۱}: مدل‌های مبتنی بر Transformer مانند BERT و FinBERT [۲] بازنمایی‌های بافت‌محور از متن تولید می‌کنند و نسبت به روش‌های پیشین عملکرد بهتری دارند. در ادامه، مدل‌های زبانی بزرگ^{۷۲} مانند InstructGPT و ChatGPT معرفی شدند که بدون نیاز به ریزتنظیم گسترده می‌توانند تحلیل احساسات را در حالت Zero-shot یا Few-shot انجام دهند و به‌خوبی به متون مالی تطبیق یابند.

ادغام سیگنال‌های احساسی در عامل‌های یادگیری تقویتی: سیگنال‌های احساسی می‌توانند بخشی از بازنمایی حالت عامل‌های معاملاتی مبتنی بر یادگیری تقویتی باشند:

⁶³Instruction Tuning

⁶⁴Prompt Engineering

⁶⁶Bullish

⁶⁷Bearish

⁶⁸Lexicon-based

⁶⁹Traditional Machine Learning

⁷⁰Bag-of-Words

⁷¹Deep Learning

⁷²Large Language Models, LLMs

- احساسات مثبت احتمال اتخاذ موقعیت‌های خرید^{۷۳} را افزایش می‌دهد.
- احساسات منفی عامل را به سمت موقعیت‌های فروش^{۷۴} یا کاهش ریسک هدایت می‌کند.
- احساسات خنثی یا نامطمئن می‌تواند راهبردهای محافظه‌کارانه یا پوششی^{۷۵} را تقویت کند.

چالش‌ها:

- زبان مالی دارای واژگان حوزه‌ای خاص است که ممکن است مدل‌های عمومی را گمراه کند.
 - طعنه، ابهام و ظرافت‌های زبانی هنوز به‌سختی توسط مدل‌ها شناسایی می‌شوند.
 - منابع خبری می‌توانند پرنویز، جانبدارانه یا دارای تأخیر باشند که قابلیت اطمینان سیگنال‌ها را کاهش می‌دهد.
- با وجود این چالش‌ها، تحلیل احساسات همچنان ابزاری قدرتمند برای تقویت راهبردهای معامله‌گری الگوریتمی باقی می‌ماند؛ به‌ویژه زمانی که در چارچوب‌های یادگیری تقویتی همراه با شاخص‌های فنی و داده‌های بازار به‌کار گرفته شود.

۲-۵- داده‌های بازار و شاخص‌های مالی

۲-۵-۱- مبانی داده‌های OHLCV^{۷۶}

داده‌های OHLCV نمایش استاندارد بازار مالی هستند که شامل قیمت باز، بیشینه، کمینه، بسته و حجم معاملات می‌شوند. این قالب، اساس تحلیل تکنیکال را تشکیل داده و به‌طور گسترده در معامله‌گری به‌کار گرفته می‌شود.

□ **Open (O):** نخستین قیمت معامله‌شده یک دارایی در ابتدای بازه زمانی مشخص (مانند یک دقیقه، یک ساعت یا یک روز).

□ **High (H):** بیشترین قیمتی که در طول بازه زمانی ثبت شده است.

□ **Low (L):** کمترین قیمتی که در طول بازه زمانی ثبت شده است.

□ **Close (C):** آخرین قیمت معامله‌شده دارایی در پایان بازه زمانی.

□ **Volume (V):** مجموع حجم معامله‌شده دارایی در طول بازه زمانی، که بیانگر میزان فعالیت و نقدشوندگی بازار است.

نمایش داده‌ها: داده‌های OHLCV معمولاً با استفاده از **نمودار شمعی**^{۷۷} نمایش داده می‌شوند. در این نمودار، هر شمع قیمت‌های باز، بسته، بیشینه و کمینه را در یک بازه زمانی خلاصه می‌کند. ضخامت و رنگ بدنه شمع نشان‌دهنده صعودی بودن یا نزولی بودن قیمت در آن بازه است.

کاربردها:

^{۷۳}Long

^{۷۴}Short

^{۷۵}Hedging

^{۷۶}Open, High, Low, Close, Volume

^{۷۷}Candlestick Chart

- داده‌های OHLCV ورودی خام برای شاخص‌های فنی متداول مانند محسوب می‌شوند.
- این داده‌ها هم **پویایی‌های قیمت** (از طریق O, H, L, C) و هم **میزان مشارکت بازار** (از طریق V) را منتقل می‌کنند.
- بسته به نوع راهبرد معاملاتی، داده‌ها می‌توانند در بازه‌های زمانی مختلف استفاده شوند؛ برای مثال داده‌های لحظه‌ای (تیک)، داده‌های درون‌روزی (ساعتی یا دقیقه‌ای)، داده‌های روزانه یا حتی هفتگی.
- در چارچوب‌های یادگیری تقویتی، مقادیر OHLCV اغلب بخشی از فضای حالت هستند تا عامل بتواند از زمینه تاریخی ساختاریافته برای تصمیم‌گیری بهره‌برد.

محدودیت‌ها: اگرچه داده‌های OHLCV (قیمت باز، بسته، بالاترین، پایین‌ترین و حجم معاملات) اطلاعات کلی حرکت قیمت و حجم را نشان می‌دهند، اما جزئیات ریز بازار را پوشش نمی‌دهند. برای نمونه: - **عمق دفتر سفارش**^{۷۸}: نشان می‌دهد چه تعداد سفارش خرید و فروش در سطوح مختلف قیمتی وجود دارد. - **شکاف خرید - فروش**^{۷۹}: اختلاف بین بالاترین قیمت پیشنهادی خریداران و پایین‌ترین قیمت پیشنهادی فروشندگان. این اطلاعات می‌توانند نقدشوندگی و فشار عرضه و تقاضا را بهتر نشان دهند. به همین دلیل، داده‌های OHLCV معمولاً همراه با منابع تکمیلی - مانند شاخص‌های احساسی یا داده‌های بنیادین - به کار می‌روند تا قدرت پیش‌بینی و پایداری راهبردهای معامله‌گری الگوریتمی افزایش یابد.

۲-۵-۲ - شاخص‌های فنی^{۸۰} پرکاربرد

شاخص‌های فنی مقیاس‌های کمی مشتق شده از داده‌های OHLCV هستند که معامله‌گران برای شناسایی **روندها**^{۸۱}، **تکانه**^{۸۲}، **نوسان‌پذیری**^{۸۳} و نقاط احتمالی بازگشت به کار می‌گیرند. این شاخص‌ها هم در معامله‌گری اختیاری و هم در معامله‌گری الگوریتمی پرکاربردند و اغلب بخشی جدایی‌ناپذیر از فضای حالت برای عامل‌های یادگیری تقویتی محسوب می‌شوند.

شاخص‌های پیرو روند^{۸۴}:

- **میانگین‌های متحرک**^{۸۵}: میانگین قیمت‌های بسته‌شدن در یک پنجره زمانی ثابت. **میانگین متحرک ساده**^{۸۶} میانگینی بدون وزن است، در حالی که **میانگین متحرک نمایی**^{۸۷} وزن بیشتری به قیمت‌های اخیر می‌دهد. تلاقی میانگین‌های کوتاه‌مدت و بلندمدت اغلب برای شناسایی تغییر روند استفاده می‌شود.

- **واگرایی - همگرایی میانگین متحرک**^{۸۸}: این شاخص تفاوت بین دو میانگین متحرک نمایی (مثلاً ۱۲ و ۲۶ دوره‌ای) را نشان می‌دهد. وقتی این تفاوت محاسبه شد، یک میانگین متحرک کوتاه‌تر (مثلاً ۹ دوره‌ای) روی آن

⁷⁸Order Book Depth

⁷⁹Bid-Ask Spread

⁸⁰Technical Indicators

⁸¹Trends

⁸²Momentum

⁸³Volatility

⁸⁴Trend-following

⁸⁵Moving Averages, MA

⁸⁶Simple Moving Average, SMA

⁸⁷Exponential Moving Average, EMA

⁸⁸Moving Average Convergence Divergence, MACD

اعمال می‌شود که به آن «خط سیگنال» می‌گویند. تقاطع خط MACD و خط سیگنال معمولاً به‌عنوان نشانه‌ای برای خرید یا فروش تفسیر می‌شود.

شاخص‌های تکانه^{۸۹}:

□ **شاخص قدرت نسبی^{۹۰}:** یک نوسان‌نما در بازه ۰ تا ۱۰۰ است که بزرگی نسبی سودها در برابر زیان‌های اخیر را اندازه‌گیری می‌کند. مقادیر بالاتر از ۷۰ معمولاً شرایط اشباع خرید و مقادیر پایین‌تر از ۳۰ شرایط اشباع فروش را نشان می‌دهند.

□ **نوسان‌نمای تصادفی^{۹۱}:** این شاخص نشان می‌دهد قیمت بسته‌شدن یک دارایی در مقایسه با بالاترین و پایین‌ترین قیمت‌های اخیر در چه سطحی قرار دارد. اگر قیمت نزدیک سقف‌های اخیر باشد، نشانه‌ای از فشار خرید (اشباع خرید) است و اگر نزدیک کف‌های اخیر باشد، نشانه‌ای از فشار فروش (اشباع فروش) در نظر گرفته می‌شود.

شاخص‌های نوسان‌پذیری^{۹۲}:

□ **Bollinger Bands:** با قرار دادن باندهای بالا و پایین در چند انحراف معیار از یک میانگین متحرک ساخته می‌شوند. این باندها در دوره‌های پرنوسان گسترش یافته و در دوره‌های کم‌نوسان منقبض می‌شوند.

□ **Average True Range (ATR):** نوسان‌پذیری را با میانگین‌گیری از دامنه واقعی (بیشترین اختلاف‌های High-Low, High-Close و Low-Close) در یک دوره اندازه‌گیری می‌کند.

شاخص‌های مبتنی بر حجم^{۹۳}:

□ **حجم تعادلی^{۹۴}:** یک معیار تجمعی است که در روزهای صعودی حجم معاملات را اضافه و در روزهای نزولی کم می‌کند تا فشار خرید و فروش را بازتاب دهد.

□ **میانگین موزون حجمی قیمت^{۹۵}:** میانگین قیمت معامله‌شده یک دارایی است که بر اساس حجم وزن‌دهی می‌شود و اغلب به‌عنوان معیار کیفیت اجرا توسط معامله‌گران نهادی استفاده می‌گردد.

برای عامل‌های یادگیری تقویتی، شاخص‌های فنی بازنمایی‌های سطح بالاتری از داده‌های OHLCV فراهم می‌کنند و به عامل کمک می‌کنند الگوهایی مانند روندها، بازگشت‌ها یا رژیم‌های نوسان‌پذیری را که ممکن است در دنباله‌های خام قیمتی پنهان باشند شناسایی کند. ادغام این شاخص‌ها در فضای حالت می‌تواند کارایی یادگیری را از طریق تزریق دانش حوزه‌ای به مشاهدات عامل بهبود دهد.

محدودیت‌ها: اگرچه شاخص‌های فنی می‌توانند بازنمایی حالت را غنی‌تر کنند، اما اتکال بیش از حد به آن‌ها می‌تواند منجر به فضاهای ویژگی با ابعاد بالا، نویز بیشتر و خطر بیش‌برازش^{۹۶} شود. در عمل، انتخاب ویژگی محتاطانه، کاهش ابعاد یا استفاده از روش‌های یادگیری بازنمایی برای تضمین پایداری و مقاومت راهبردهای معاملاتی ضروری است.

⁸⁹Momentum

⁹⁰Relative Strength Index, RSI

⁹¹Stochastic Oscillator

⁹²Volatility

⁹³Volume-based

⁹⁴On-Balance Volume, OBV

⁹⁵Volume-Weighted Average Price, VWAP

⁹⁶Overfitting

۲-۵-۳- چالش‌های موجود در بازارهای مالی

به‌کارگیری یادگیری تقویتی در بازارهای مالی ذاتاً دشوار است؛ زیرا این محیط پیچیده، پویا و پراز نویز است. برخلاف وظایف معیار کنترل‌شده، بازارها موانع متعددی ایجاد می‌کنند که طراحی عامل‌های معاملاتی مقاوم را با چالش روبه‌رو می‌سازد.

ناایستایی^{۹۷}: ویژگی‌های آماری سری‌های زمانی مالی به‌مرور تغییر می‌کنند؛ به دلیل تغییر رژیم‌های بازار، چرخه‌های اقتصادی، تحولات مقرراتی و شوک‌های پیش‌بینی‌نشده. راهبردی که در یک رژیم (مانند بازار صعودی) موفق عمل می‌کند، ممکن است در شرایط متفاوت (مانند رکود یا بحران‌ها) ناکام بماند.

نسبت بالای نویز به سیگنال^{۹۸}: قیمت دارایی‌ها تحت تأثیر عوامل متنوع و غیرقابل‌پیش‌بینی — از جمله اعلامیه‌های کلان اقتصادی، رویدادهای ژئوپولیتیکی و روان‌شناسی سرمایه‌گذاران — قرار دارند. تشخیص الگوهای معنادار از نوسانات تصادفی کاری بسیار دشوار است.

مشاهده ناقص^{۹۹}: معامله‌گران به‌ندرت به وضعیت کامل بازار دسترسی دارند. متغیرهای پنهان مانند جریان سفارش‌های نهادی، اطلاعات خصوصی و محرک‌های نهفته بازار تأثیر چشمگیری بر پویایی‌ها دارند، اما برای عامل قابل مشاهده نیستند.

پاداش‌های پراکنده و با تأخیر^{۱۰۰}: فرصت‌های سودآور نسبت به تعداد کنش‌های معاملاتی ممکن، به‌ندرت رخ می‌دهند. بنابراین سیگنال‌های پاداش هم پراکنده و هم با تأخیر هستند و مسئله تخصیص اعتبار در آموزش یادگیری تقویتی را پیچیده می‌سازند.

هزینه‌های تراکنش^{۱۰۱} و **لغزش قیمتی**^{۱۰۲}: اجرای واقعی معاملات مستلزم هزینه‌هایی مانند کمیسیون، شکاف خرید — فروش و تأثیر بازار است. راهبردهایی که در شبیه‌سازی سودآور به نظر می‌رسند، ممکن است پس از در نظر گرفتن این اصطکاک‌ها دیگر کارایی نداشته باشند.

ریسک و رویدادهای دنباله‌ای: بازده‌های مالی دارای دنباله‌های سنگین، خوشه‌بندی نوسان‌پذیری و رویدادهای شدید (مانند سقوط‌ها) هستند که بیش از آنچه مدل‌های گاوسی پیش‌بینی می‌کنند رخ می‌دهند. عامل‌های یادگیری تقویتی باید اهداف حساس به ریسک را لحاظ کنند تا از افت سرمایه‌های فاجعه‌بار جلوگیری شود.

محدودیت‌های داده^{۱۰۳}: مجموعه‌داده‌های فرکانس بالا اغلب گران یا انحصاری هستند و دسترسی به آن‌ها محدود است. داده‌های عمومی (مانند داده‌های روزانه OHLCV) ممکن است برای راهبردهای کوتاه‌مدت یا درون‌روزی دقت کافی نداشته باشند.

سختی‌های ارزیابی^{۱۰۴}: Backtesting یا آزمایش راهبرد روی داده‌های تاریخی می‌تواند با چند مشکل جدی همراه باشد: **Look-ahead Bias**: زمانی رخ می‌دهد که اطلاعاتی از آینده به‌طور ناخواسته وارد داده‌های آموزشی یا آزمایش شوند و باعث نتایج غیرواقعی گردند. **Survivorship Bias**: اگر فقط سهام یا دارایی‌هایی بررسی شوند که هنوز در بازار فعال‌اند (و موارد ورشکسته یا حذف‌شده کنار گذاشته شوند)، نتایج بیش از حد خوش‌بینانه خواهند

⁹⁷Non-stationarity

⁹⁸High Noise-to-Signal Ratio

⁹⁹Partial Observability

¹⁰⁰Sparse and Delayed Rewards

¹⁰¹Transaction Costs

¹⁰²Slippage

¹⁰³Data Limitations

¹⁰⁴Evaluation Difficulties

بود. - **Overfitting**: وقتی مدل بیش از حد با داده‌های تاریخی تطبیق پیدا کند، در داده‌های جدید عملکرد ضعیفی خواهد داشت.

اگرچه Out-of-sample Testing (آزمون روی داده‌هایی خارج از مجموعه آموزش) ضروری است، اما به دلیل نایست بودن بازارها، تعمیم نتایج به شرایط واقعی همیشه دشوار باقی می‌ماند.

این چالش‌ها نشان می‌دهند که طراحی دقیق سامانه‌های یادگیری تقویتی در حوزه مالی ضروری است. عامل‌های معاملاتی کارآمد باید سودآوری را با مدیریت ریسک متعادل سازند، هزینه‌های تراکنش را در نظر بگیرند، با رژیم‌های متغیر بازار تطبیق پیدا کنند و تحت چارچوب‌های ارزیابی سخت‌گیرانه و بدون سوگیری آزموده شوند. تنها در این صورت است که این راهبردهای می‌توانند به مقاومت و پایداری بلندمدت در بازارهای واقعی دست یابند.

۲-۵-۴ - شاخص‌های مالی^{۱۰۵} و دارایی‌های اصلی^{۱۰۶}

عامل‌های یادگیری تقویتی اغلب بر اساس شاخص‌های شناخته‌شده بازار و طبقات دارایی پرمعامله ارزیابی می‌شوند. این ابزارها نقدشوندگی بالایی دارند، به صورت جهانی شناخته‌شده‌اند و شرایط متنوعی از بازار را برای آزمون راهبردهای معامله‌گری الگوریتمی فراهم می‌کنند.

Dow Jones Industrial Average (DJIA)

شاخص یکی از قدیمی‌ترین و پرپیگیری‌ترین شاخص‌های سهام است که شامل ۳۰ شرکت بزرگ و عمومی ایالات متحده در صنایع مختلف می‌شود. اگرچه تنها بخش نسبتاً کوچکی از شرکت‌ها را پوشش می‌دهد، اما اغلب به عنوان معیاری برای عملکرد اقتصادی ایالات متحده در نظر گرفته می‌شود.

برای عامل‌های معاملاتی، شاخص DJIA مجموعه‌ای از سهام شرکت‌های بزرگ و معتبر را فراهم می‌کند که معمولاً نسبت به سهام شرکت‌های کوچک‌تر نوسان‌پذیری کمتری دارند. به همین دلیل، معامله روی این شاخص می‌تواند پایدارتر و ریسک کمتری داشته باشد.

S&P 500 Index

شاخص S&P 500 شامل ۵۰۰ شرکت بزرگ ایالات متحده است و به طور گسترده به عنوان بهترین معیار کلی بازار سهام آمریکا شناخته می‌شود. این شاخص حدود ۸۰٪ از ارزش بازار ایالات متحده را پوشش می‌دهد. به دلیل نقدشوندگی بالا و پوشش گسترده، S&P 500 یک معیار متداول برای ارزیابی عملکرد راهبردهای معامله‌گری الگوریتمی، از جمله عامل‌های یادگیری تقویتی محسوب می‌شود.

XAU/USD

XAU/USD نشان‌دهنده قیمت طلا (XAU) بر حسب دلار آمریکا است. طلا هم یک کالا و هم یک دارایی پناهگاه امن محسوب می‌شود که در زمان عدم قطعیت اقتصادی یا تورم ارزش می‌یابد. برای عامل‌های معاملاتی، طلا چالشی منحصربه‌فرد ایجاد می‌کند زیرا رفتار قیمتی آن تحت تأثیر شرایط کلان اقتصادی جهانی، سیاست‌های پولی و احساسات ریسکی قرار دارد.

رمزارزها^{۱۰۷}

¹⁰⁵Financial Indices

¹⁰⁶Major Assets

¹⁰⁷Cryptocurrencies

رمزارزهایی مانند Bitcoin (BTC) و Ethereum (ETH) دارایی‌هایی بسیار پرنوسان و سفته‌بازانه هستند. برخلاف بازارهای سنتی، بازار رمزارزها به صورت ۲۴/۷ و در صرافی‌های غیرمتمرکز معامله می‌شوند و مجموعه داده‌های غنی‌ای برای آموزش یادگیری تقویتی فراهم می‌کنند. نوسان‌پذیری بالای آن‌ها هم فرصت و هم ریسک ایجاد می‌کند و آن‌ها را به بستر مناسبی برای آزمون عامل‌های یادگیری تقویتی با هدف شناسایی الگوهای کوتاه‌مدت قیمتی تبدیل می‌سازد.

بازار تبادل ارز خارجی^{۱۰۸}

بازار تبادل ارز خارجی یا فارکس بزرگ‌ترین و نقدشونده‌ترین بازار مالی در جهان است، با حجم معاملات روزانه بیش از ۶ تریلیون دلار. جفت‌ارزهای اصلی (مانند EUR/USD، USD/JPY و GBP/USD) بیشترین حجم معاملات را به خود اختصاص می‌دهند. بازار فارکس تحت تأثیر نرخ بهره، رویدادهای ژئوپولیتیکی و شاخص‌های کلان اقتصادی قرار دارد و بسیار پویاست. عامل‌های یادگیری تقویتی در فارکس باید با نوسانات سریع سازگار شوند و در عین حال هزینه‌های تراکنش و ریسک اهرم را نیز در نظر بگیرند.

۲-۶- مدیریت سبد دارایی‌ها و محدودیت‌های معامله‌گری

۲-۶-۱- معامله تک‌سهم^{۱۰۹} در برابر معامله سبد دارایی‌ها^{۱۱۰}

رویکردهای یادگیری تقویتی در معامله‌گری الگوریتمی می‌توانند برای یک دارایی منفرد یا برای یک سبد دارایی به کار گرفته شوند. این انتخاب پیامدهای مهمی برای بازنمایی حالت، فضای عمل و طراحی پاداش دارد.

معامله تک‌سهم: در این حالت، عامل تنها بر یک دارایی (مانند سهام Apple، بیت‌کوین یا طلا) تمرکز می‌کند. فضای عمل می‌تواند گسسته (خرید، فروش، نگهداری) یا پیوسته (مانند تعیین اندازه موقعیت) باشد.

□ **مزایا:** فضای حالت و عمل ساده‌تر، آموزش سریع‌تر و نیاز کمتر به داده.

□ **محدودیت‌ها:** نبود تنوع‌بخشی و تمرکز ریسک بر یک دارایی منفرد.

معامله سبد دارایی‌ها: در این حالت، عامل سرمایه را هم‌زمان میان چندین دارایی (مانند سهام، کالاها یا رمزارزها) تخصیص می‌دهد. فضای عمل چندبعدی است، زیرا عامل باید وزن‌های تخصیص برای هر دارایی را تعیین کند، مشروط به محدودیت‌های بودجه و ریسک.

□ **مزایا:** امکان تنوع‌بخشی، واقع‌گرایی بیشتر برای سرمایه‌گذاری نهادی، و بهینه‌سازی بازدهی تعدیل‌شده بر اساس ریسک.

□ **محدودیت‌ها:** فضای حالت و عمل بزرگ‌تر، پیچیدگی آموزشی بالاتر و نیاز بیشتر به داده.

به‌طور کلی، معامله تک‌سهم بیشتر برای مطالعات آزمایشی و نمایش قابلیت اجرایی یک روش به کار می‌رود، در حالی که رویکردهای سبد دارایی بازتاب واقعی‌تری از مدیریت سرمایه دارند؛ جایی که تنوع‌بخشی و کنترل ریسک حیاتی است. به همین دلیل، پژوهش‌های نوین در زمینه مالی به‌طور فزاینده‌ای بر بهینه‌سازی سبد دارایی‌ها تمرکز می‌کنند تا راهبردهای معاملاتی مقاوم‌تر و واقع‌گرایانه‌تری ایجاد شود.

^{۱۰۸}Foreign Exchange Market, Forex

^{۱۰۹}Single-Asset Trading

^{۱۱۰}Portfolio Trading

۲-۶-۲- فضای حالت^{۱۱۱}

در یادگیری تقویتی، فضای حالت اطلاعاتی را تعریف می‌کند که در هر گام تصمیم‌گیری در دسترس عامل قرار دارد. در معامله‌گری، حالت بازنمایی محیط بازار، وضعیت سبد دارایی‌ها^{۱۱۲} و گاه سیگنال‌های بیرونی را رمزگذاری می‌کند. طراحی فضای حالت مناسب یکی از حیاتی‌ترین جنبه‌های ساخت عامل معاملاتی است، زیرا تعیین می‌کند که عامل چه اطلاعاتی را می‌تواند مورد استفاده قرار دهد.

۱. **تاریخچه قیمت و بازده:** ساده‌ترین بازنمایی حالت شامل مقادیر خام OHLCV یا بازده‌های لگاریتمی در یک پنجره بازگشت است.

□ **مزایا:** مستقیم، قابل تفسیر، و نیازمند کمترین پیش‌پردازش.

□ **محدودیت‌ها:** ناتوانی در ثبت وابستگی‌های زمانی پیچیده یا الگوهای مرتبه‌بالا.

۲. **شاخص‌های فنی:** شاخص‌هایی مانند میانگین‌های متحرک، RSI و MACD اغلب به‌عنوان ویژگی‌های مهندسی‌شده از OHLCV به حالت افزوده می‌شوند.

□ **مزایا:** خلاصه‌سازی فشرده از پویایی قیمت، پرکاربرد در عمل.

□ **محدودیت‌ها:** استفاده بیش‌ازحد می‌تواند منجر به افزونگی و ریسک بیش‌برازش شود.

۳. **اطلاعات سبد دارایی‌ها:** در وظایف مدیریت سبد دارایی‌ها، حالت معمولاً شامل تخصیص فعلی سرمایه میان دارایی‌ها، وجه نقد موجود و میزان استفاده از اهرم است.

□ **مزایا:** تضمین می‌کند که تصمیم‌های معاملاتی بر اساس وضعیت واقعی سبد اتخاذ شوند.

□ **محدودیت‌ها:** در محیط‌های چنددارایی، ابعاد حالت افزایش می‌یابد.

۴. **سیگنال‌های احساسی و بنیادی:** اخبار، گزارش‌های درآمد و رسانه‌های اجتماعی می‌توانند به امتیازهای احساسی تبدیل شوند و در حالت ادغام گردند.

□ **مزایا:** ثبت محرک‌های حرکت قیمت فراتر از داده‌های فنی و کمک به توضیح تغییرات ناگهانی.

□ **محدودیت‌ها:** سیگنال‌های متنی پرنویز هستند و اغلب با تأخیر نسبت به حرکت قیمت همراه می‌شوند.

۵. **داده‌های ریزساختار بازار:** در معامله‌گری با فرکانس بالا، حالت محیط می‌تواند شامل جزئیاتی مثل عمق دفتر سفارش (تعداد و حجم سفارش‌های خرید و فروش در قیمت‌های مختلف)، شکاف خرید - فروش (اختلاف بین بالاترین قیمت خرید و پایین‌ترین قیمت فروش)، و عدم تعادل سفارش‌ها (تفاوت بین حجم سفارش‌های خرید و فروش) باشد.

□ **مزایا:** این داده‌ها دید دقیقی از نقدشوندگی درون‌روزی و رفتار کوتاه‌مدت بازار ارائه می‌دهند.

^{۱۱۱}State Space

^{۱۱۲}Portfolio

□ **محدودیت‌ها:** جمع‌آوری و پردازش آن‌ها نیازمند حجم بسیار بالای داده و زیرساخت محاسباتی پیچیده است.

به‌طور کلی، فضای حالت بنیان اطلاعاتی عامل یادگیری تقویتی را تشکیل می‌دهد. بازنمایی‌های حداقلی ممکن است سیگنال‌های کلیدی را نادیده بگیرند، در حالی که بازنمایی‌های بیش‌ازحد پیچیده می‌توانند ریسک بیش‌برازش و ضعف تعمیم‌پذیری ایجاد کنند. در عمل، عامل‌های معاملاتی مقاوم اغلب از طراحی متوازن بهره می‌برند – ترکیبی از قیمت‌ها، شاخص‌های فنی، وضعیت سبد دارایی و سیگنال‌های احساسی – تا سازگاری در شرایط متنوع بازار تضمین شود.

۲-۶-۳- شکل‌دهی پاداش^{۱۱۳}

در یادگیری تقویتی، تابع پاداش رفتار عامل را هدایت می‌کند و تعیین می‌نماید که چه چیزی موفقیت تلقی می‌شود. در معامله‌گری، شکل‌دهی پاداش اهمیت ویژه‌ای دارد زیرا بازده‌های خام به‌تنهایی نمی‌توانند اهداف گسترده‌تری مانند کنترل ریسک، هزینه‌های تراکنش یا پایداری راهبرد را بازتاب دهند.

۱. **پاداش‌های مبتنی بر سود^{۱۱۴}:** مستقیم‌ترین رویکرد استفاده از بازده سبد دارایی به‌عنوان پاداش است:

$$r_t = \frac{V_{t+1} - V_t}{V_t},$$

که در آن V_t ارزش سبد دارایی در زمان t است.

□ **مزایا:** هم‌راستایی مستقیم با بیشینه‌سازی سود.

□ **محدودیت‌ها:** نادیده‌گرفتن ریسک، که می‌تواند به راهبردهای پرنوسان منجر شود.

۲. **پاداش‌های تعدیل‌شده بر اساس ریسک^{۱۱۵}:** پاداش‌ها می‌توانند با معیارهای ریسک (مانند نوسان‌پذیری، انحراف معیار نزولی یا افت سرمایه) نرمال شوند:

$$r_t = \frac{R_t - R_f}{\sigma_t},$$

که در آن R_t بازده سبد دارایی، R_f نرخ بدون ریسک و σ_t برآورد نوسان‌پذیری است.

□ **مزایا:** تشویق به راهبردهای روان‌تر و بازده‌های تعدیل‌شده بر اساس ریسک بالاتر.

□ **محدودیت‌ها:** نیازمند برآورد دقیق نوسان‌پذیری یا معیارهای ریسک.

۳. **پاداش‌های مبتنی بر مطلوبیت^{۱۱۶}:** گنجاندن توابع مطلوبیت (مانند لگاریتمی یا نمایی) امکان مدل‌سازی صریح ترجیحات ریسک را فراهم می‌کند:

$$r_t = U(R_t) = \log(1 + R_t).$$

□ **مزایا:** بازتاب‌دهنده ریسک‌گریزی سرمایه‌گذار و سازگار با نظریه اقتصادی.

^{۱۱۳}Reward Shaping

^{۱۱۴}Profit-based Rewards

^{۱۱۵}Risk-adjusted Rewards

^{۱۱۶}Utility-based Rewards

□ **محدودیت‌ها:** انتخاب تابع مطلوبیت ذهنی و وابسته به بستر است.

۴. **پاداش‌های چندهدفه^{۱۱۷}:** توابع پاداش می‌توانند بازده، هزینه‌های تراکنش و معیارهای ریسک را ترکیب کنند:

$$r_t = R_t - \lambda_1 \cdot Cost_t - \lambda_2 \cdot Risk_t,$$

که در آن λ_1, λ_2 تعادل میان سودآوری، اصطکاک‌های معاملاتی و ریسک را تعیین می‌کنند.

شکل‌دهی پاداش مستقیماً رفتار معاملاتی را تعیین می‌کند:

□ پاداش‌های صرفاً مبتنی بر سود می‌توانند راهبردهای ناپایدار و پرریسک را تشویق کنند.

□ پاداش‌های تعدیل‌شده بر اساس ریسک یا مبتنی بر مطلوبیت، به پایداری و حفظ سرمایه کمک می‌کنند.

□ پاداش‌های چندهدفه امکان تعادل واقع‌گرایانه میان سود، ریسک و هزینه‌های اجرا را فراهم می‌سازند.

بنابراین طراحی دقیق تابع پاداش برای عامل‌های یادگیری تقویتی که هدف آن‌ها استقرار در دنیای واقعی است، حیاتی محسوب می‌شود.

۲-۶-۴ - هزینه‌های تراکنش^{۱۱۸}، لغزش قیمتی^{۱۱۹} و محدودیت‌های نقدشوندگی^{۱۲۰}

در عمل، راهبردهای معاملاتی با اصطکاک‌هایی مواجه‌اند که به‌شدت بر عملکرد اثر می‌گذارند. عامل‌های یادگیری تقویتی که بدون در نظر گرفتن این عوامل آموزش می‌بینند، در معرض یادگیری سیاست‌های غیرواقعی قرار دارند که در بازارهای واقعی شکست می‌خورند.

هزینه‌های تراکنش: هر معامله شامل هزینه‌های صریحی مانند کارمزد کارگزار، هزینه‌های بورس و شکاف خرید - فروش است. در محیط‌های یادگیری تقویتی، این هزینه‌ها معمولاً به‌صورت کارمزدی متناسب با حجم معامله مدل می‌شوند:

$$Cost_t = c \cdot |q_t|,$$

که در آن c نرخ هزینه و q_t اندازه معامله است. نادیده گرفتن هزینه‌های تراکنش اغلب منجر به بیش‌معامله‌گری می‌شود.

لغزش قیمتی: لغزش به اختلاف میان قیمت مورد انتظار اجرا و قیمت واقعی پرشده اشاره دارد که معمولاً ناشی از بازارهای پرسرعت یا عمق محدود دفتر سفارش است. لغزش معمولاً با افزایش اندازه سفارش و نوسان‌پذیری بیشتر می‌شود. در شبیه‌سازی‌ها، لغزش اغلب به‌صورت یک هزینه اضافی متناسب با حجم معامله و نوسان‌پذیری مدل می‌شود.

محدودیت‌های نقدشوندگی: نقدشوندگی یعنی اینکه یک دارایی تا چه حد می‌تواند سریع و بدون تغییر شدید در قیمت خرید و فروش شود. برای مثال، دارایی‌های بسیار نقدشونده مثل سهام شاخص S&P 500 یا جفت‌ارزهای اصلی در Forex، می‌توانند سفارش‌های بزرگ را تقریباً بدون تغییر قیمت جذب کنند. اما دارایی‌های کم‌نقدشونده مثل سهام شرکت‌های کوچک یا برخی رمزارزها، اگر حجم زیادی معامله شود قیمتشان سریع تغییر می‌کند. در محیط‌های یادگیری تقویتی، برای بازتاب این محدودیت‌ها می‌توان کارهایی انجام داد، مثل:

¹¹⁷Multi-objective Rewards

¹¹⁸Transaction Costs

¹¹⁹Slippage

¹²⁰Liquidity Constraints

□ محدود کردن اندازه معامله یا موقعیت در مقایسه با حجم کلی بازار،

□ افزودن تأخیر در اجرای سفارش‌های بزرگ،

□ قراردادن جریمه در تابع پاداش برای معاملاتی که بیش از حد انجام می‌شوند.

در مجموع، نادیده گرفتن هزینه‌ها، لغزش قیمتی و محدودیت‌های نقدشوندگی می‌تواند به راهبردهایی منجر شود که در عمل غیرقابل اجرا هستند.

۲-۶-۵- معیارهای ریسک^{۱۲۱}

در معامله‌گری، سودآوری همواره باید در بستر ریسک ارزیابی شود. عامل‌های یادگیری تقویتی که ریسک را نادیده می‌گیرند، ممکن است به سیاست‌های ناپایدار یا غیرعملی همگرا شوند. **معیارهای ریسک** ابزارهای کمی برای ارزیابی و محدود کردن مواجهه نزولی یک راهبرد معاملاتی فراهم می‌کنند.

۱. **نوسان‌پذیری^{۱۲۲}**: رایج‌ترین معیار ریسک است و پراکندگی بازده‌ها را ثبت می‌کند:

$$\sigma = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (R_t - \bar{R})^2},$$

که در آن R_t بازده در زمان t است.

□ **مزایا:** محاسبه ساده و استفاده گسترده در نسبت‌های عملکردی مانند Sharpe Ratio.

□ **محدودیت‌ها:** انحراف‌های مثبت و منفی را یکسان جریمه می‌کند، در حالی که سرمایه‌گذاران معمولاً بیشتر به ریسک نزولی اهمیت می‌دهند.

۲. **ارزش در معرض ریسک^{۱۲۳}**: معیاری که حداکثر زیان بالقوه در یک افق زمانی مشخص با سطح اطمینان α را برآورد می‌کند:

$$VaR_{\alpha}(T) = \inf\{x \in \mathbb{R} : P(L_T > x) \leq 1 - \alpha\},$$

که در آن L_T زیان سبد دارایی است.

□ **مزایا:** استفاده گسترده در مدیریت ریسک نهادی و مقرراتی.

□ **محدودیت‌ها:** شدت زیان‌های فراتر از آستانه □□□ را ثبت نمی‌کند.

۳. **ارزش شرطی در معرض ریسک^{۱۲۴}**: زیان مورد انتظار را مشروط به فراتر رفتن از VaR اندازه‌گیری می‌کند:

$$CVaR_{\alpha} = \mathbb{E}[L_T | L_T > VaR_{\alpha}].$$

^{۱۲۱}Risk Measures

^{۱۲۲}Volatility, Standard Deviation

^{۱۲۳}Value at Risk, VaR

^{۱۲۴}Conditional VaR, CVaR / Expected Shortfall

□ **مزایا:** معیار ریسک همدوس و پوشش‌دهنده ریسک‌های دنباله‌ای و زیان‌های شدید.

□ **محدودیت‌ها:** برآورد محاسباتی سنگین‌تر، به‌ویژه در محیط‌های با فرکانس بالا.

۴. **بیشینه افت سرمایه**^{۱۲۵}: بزرگ‌ترین کاهش ارزش سبد از بالاترین نقطه تا پایین‌ترین نقطه در یک دوره زمانی مشخص.

□ **مزایا:** شهودی و پرکاربرد در عمل برای ارزیابی بدترین زیان‌ها.

□ **محدودیت‌ها:** فرکانس یا مدت افت‌ها را نادیده می‌گیرد و تفسیر احتمالاتی ندارد.

۵. **معیارهای ریسک نزولی**^{۱۲۶}: مانند انحراف نزولی (استفاده‌شده در نسبت Sortino) تنها بر بازده‌های منفی نسبت به بازده هدف یا حداقل قابل قبول تمرکز دارند.

□ **مزایا:** هم‌راستا با ریسک‌گریزی سرمایه‌گذار؛ جریمه‌کردن صرفاً نوسان‌های مضر.

□ **محدودیت‌ها:** نیازمند تعیین بازده هدف است که ممکن است ذهنی باشد.

معیارهای ریسک می‌توانند در تابع پاداش یا بهینه‌سازی سبد دارایی ادغام شوند و پایش آن‌ها طی آموزش کمک می‌کند عامل‌های یادگیری تقویتی راهبردهایی سودآور، مقاوم و قابل اجرا در عمل بیاموزند.

۲-۶-۶- معیارهای ارزیابی

ارزیابی عامل‌های یادگیری تقویتی در معامله‌گری باید معیارهایی را شامل شود که علاوه بر سودآوری، ریسک و پایداری را هم در نظر بگیرند. اتکا به بازده خام می‌تواند منجر به راهبردهای ناپایدار یا غیرعملی شود؛ به همین دلیل معمولاً از ترکیبی از معیارهای تعدیل‌شده بر اساس ریسک (مانند Sharpe Ratio یا Sortino Ratio)، معیارهای رشد سرمایه در طول زمان (مانند بازده تجمعی یا نرخ رشد مرکب) و شاخص‌های تشخیصی برای بررسی رفتار زیان‌ها (مانند Maximum Drawdown یا CVaR) استفاده می‌شود.

Sharpe Ratio و Sortino Ratio

سودآوری به‌تنهایی برای ارزیابی یک راهبرد در بازارهای پرنوسان کافی نیست. معیارهای تعدیل‌شده بر اساس ریسک مانند Sharpe Ratio و Sortino Ratio به‌طور گسترده برای سنجش عملکرد نسبت به ریسک استفاده می‌شوند.

Sharpe Ratio: این نسبت بازده مازاد کسب‌شده به ازای هر واحد ریسک کل (انحراف معیار بازده‌ها) را اندازه‌گیری می‌کند:

$$SharpeRatio = \frac{R_p - R_f}{\sigma_p},$$

که در آن R_p میانگین بازده سبد دارایی، R_f نرخ بدون ریسک و σ_p انحراف معیار بازده‌ها است.

¹²⁵Maximum Drawdown, MDD

¹²⁶Downside Risk Measures

□ تفسیر: مقادیر بالاتر Sharpe Ratio نشان‌دهنده عملکرد بهتر تعدیل‌شده بر اساس ریسک هستند، هرچند این معیار نوسان‌های مثبت و منفی را یکسان جریمه می‌کند.

Sortino Ratio: این نسبت اصلاحی بر Sharpe Ratio است که تنها بر نوسان نزولی تمرکز دارد:

$$SortinoRatio = \frac{R_p - R_f}{\sigma_d},$$

که در آن σ_d انحراف نزولی نسبت به بازده حداقلی قابل قبول (Minimum Acceptable Return, MAR) است.

□ تفسیر: میان نوسان‌های مضر (زیان‌ها) و مفید (سودها) تمایز قائل می‌شود و اغلب در بستر معامله‌گری مناسب‌تر است.

Compound Annual Growth Rate (CAGR)

CAGR رشد میانگین سالانه یک سرمایه‌گذاری را با فرض بازسرمایه‌گذاری سودها اندازه‌گیری می‌کند:

$$CAGR = \left(\frac{V_f}{V_i} \right)^{\frac{1}{T}} - 1,$$

که در آن V_f ارزش نهایی سبد، V_i ارزش اولیه و T تعداد سال‌ها است.

□ تفسیر: CAGR شاخصی هموار از رشد بلندمدت ارائه می‌دهد و اثر نوسان‌پذیری بر میانگین بازده را حذف می‌کند.

برای عامل‌های یادگیری تقویتی، CAGR پایداری یک راهبرد را در افق‌های بلندمدت برجسته می‌کند؛ حتی رشدهای متوسط ولی پایدار می‌توانند بر راهبردهای پرنوسان با بازده‌های کوتاه‌مدت بیشتر برتری داشته باشند.

Maximum Drawdown (MDD)

MDD بزرگ‌ترین افت اوج تا حضيض ارزش سبد را پیش از رسیدن به یک اوج جدید اندازه‌گیری می‌کند:

$$MDD = \max_{t \in [0, T]} \left(\frac{V_{peakuptot} - V_t}{V_{peakuptot}} \right).$$

□ تفسیر: مقادیر کوچک‌تر MDD نشان‌دهنده راهبردهای باثبات‌تر هستند؛ افت‌های بزرگ مشکل‌سازند زیرا جبران آن‌ها نیازمند سودهای نامتناسب است.

نرخ برد^{۱۲۷} و دقت معاملات^{۱۲۸}

نرخ برد نسبت معاملات سودآور به کل معاملات است:

$$\text{نرخ برد} = \frac{\text{تعداد معاملات سودآور}}{\text{کل معاملات}} \times 100\%.$$

دقت معاملات میزان درستی عامل در پیش‌بینی جهت حرکت قیمت را اندازه‌گیری می‌کند:

$$\text{دقت معاملات} = \frac{\text{تعداد پیش‌بینی‌های صحیح جهت قیمت}}{\text{کل پیش‌بینی‌ها}} \times 100\%.$$

Win Rate^{۱۲۸}
Trade Accuracy^{۱۲۸}

□ تفسیر: نرخ برد یا دقت بالا لزوماً تضمین‌کننده سودآوری نیست، زیرا زیان‌های بزرگ می‌توانند سود معاملات موفق را خنثی کنند. برعکس، حتی یک راهبرد با نرخ برد پایین ممکن است سودآور باشد اگر میانگین سود معاملات برد از زیان‌ها بیشتر باشد.

۷-۲- جمع‌بندی

این فصل به مرور مفاهیم نظری کلیدی زیربنای پژوهش پرداخت. در ابتدا مبانی یادگیری تقویتی، الگوریتم‌های اصلی آن و کاربردهای مرتبط در معامله‌گری معرفی شدند. سپس نقش مدل‌های زبانی بزرگ، به‌ویژه در استخراج احساسات و اطلاعات متنی، مورد بررسی قرار گرفت. همچنین ساختار داده‌های مالی بازار، شاخص‌های فنی پرکاربرد و محدودیت‌های عملی در مدیریت دارایی مرور شدند. این مباحث، چارچوب نظری لازم برای طراحی روش‌شناسی و انجام آزمایش‌های ارائه‌شده در فصل‌های بعدی را فراهم می‌سازند.

فصل ۳

مرور ادبیات

۳-۱- مقدمه

هدف این فصل مرور پژوهش‌ها و ابزارهای پیشین است که بنیان این مطالعه را تشکیل می‌دهند. ادبیات مربوط به یادگیری تقویتی و مدل‌های زبانی بزرگ در بازارهای مالی به سرعت در حال تکامل است و بازتاب‌دهنده علاقه روزافزون به سامانه‌های معاملاتی داده‌محور و انطباق‌پذیر می‌باشد. برای قرار دادن این پژوهش در بستر علمی موجود، این فصل مشارکت‌های پیشین را در چهار حوزه اصلی بررسی می‌کند.

نخست، به پیشرفت‌های پردازش زبان طبیعی در حوزه مالی با تکیه بر مدل‌های زبانی بزرگ پرداخته می‌شود که فرصت‌ها و چالش‌های این رویکردها را نشان می‌دهند. دوم، کتابخانه‌ها و چارچوب‌های مرتبط با یادگیری تقویتی مرور می‌شوند که امکان توسعه و ارزیابی استاندارد عامل‌های معاملاتی را فراهم می‌کنند. سوم، مطالعاتی بررسی می‌شوند که از یادگیری تقویتی عمیق در تصمیم‌گیری‌های مالی استفاده کرده‌اند، از معامله‌گری تک‌سهم تا مدیریت سبد دارایی. در نهایت، رویکردهای ترکیبی نوظهوری معرفی می‌شوند که مدل‌های زبانی بزرگ و یادگیری تقویتی را برای کاربردهای مالی با یکدیگر ادغام می‌کنند.

هر مقاله بر اساس تمرکز پژوهشی، روش‌شناسی، نتایج، محدودیت‌ها و سهم بالقوه آن در این پروژه تحلیل خواهد شد. این رویکرد ساختاریافته به ما امکان می‌دهد تا الگوهای تکرارشونده، نقاط قوت روش‌شناختی و خلأهای پژوهشی را شناسایی کرده و طراحی چارچوب پیشنهادی مبتنی بر یادگیری تقویتی و تقویت‌شده با مدل‌های زبانی بزرگ را شکل دهیم.

۳-۲- مدل‌های زبانی بزرگ و پردازش زبان طبیعی در حوزه مالی

A Survey of Large Language Models for Financial Applications: Progress, Prospects and Challenges [۱]

تمرکز پژوهش

این مرور به بررسی به کارگیری مدل‌های زبانی بزرگ در کاربردهای مالی می‌پردازد و به طور ویژه نقش آن‌ها را در زمینه‌های زیر برجسته می‌کند:

□ تحلیل احساسات^۱

□ پیش‌بینی سری‌های زمانی^۲

□ استدلال و پشتیبانی تصمیم مالی^۳

□ مدل‌سازی مبتنی بر عامل^۴ برای معامله‌گری و شبیه‌سازی

این مطالعه هم‌پتانسیل مدل‌های زبانی بزرگ در پردازش زبان طبیعی مالی^۵ و هم چالش‌های مربوط به پیاده‌سازی عملی آن‌ها را مورد توجه قرار می‌دهد.

روش‌شناسی

نویسندگان یک مرور نظام‌مند از پژوهش‌های موجود ارائه کرده و آن‌ها را در پنج دسته اصلی طبقه‌بندی کرده‌اند: وظایف زبانی، تحلیل احساسات، مدل‌سازی سری‌های زمانی مالی، استدلال مالی و مدل‌سازی مبتنی بر عامل. همچنین نمایی کلی از مجموعه داده‌ها و بنچمارک‌های پرکاربرد ارائه شده و یک چارچوب طبقه‌بندی برای پژوهش‌های مدل‌های زبانی بزرگ در حوزه مالی پیشنهاد گردیده است (جدول (۱-۳)).

جدول (۱-۳) حوزه‌های کاربرد مدل‌های زبانی بزرگ در مالی (اقتباس شده از [۱])

دسته	نمونه‌ها
وظایف زبانی	خلاصه‌سازی تماس‌های درآمدی، استخراج اطلاعات از گزارش‌ها
تحلیل احساسات	طبقه‌بندی اخبار مالی، گزارش‌ها و میکرو بلاگ‌ها
سری‌های زمانی مالی	پیش‌بینی مبتنی بر متن، تشخیص ناهنجاری
استدلال مالی	پرسش و پاسخ، پشتیبانی تصمیم، استدلال عددی
مدل‌سازی مبتنی بر عامل	عامل‌های معاملاتی مبتنی بر □□□ شبیه‌سازی بازار

یافته‌ها

یافته‌های کلیدی این مرور عبارتند از:

□ مدل‌های زبانی بزرگ به‌طور مداوم عملکردی بهتر از مدل‌های سنتی پردازش زبان طبیعی در وظایف مالی ارائه می‌دهند.

□ آموزش پیش‌زمینه با داده‌های مالی (مانند مدل‌های تخصصی FinBERT و FinGPT) دقت و پایداری نتایج را به‌طور چشمگیری افزایش می‌دهد.

□ معیارهای استاندارد مانند FPB، FiQA، و FinQA پیشرفت محسوسی در وظایفی نظیر تحلیل احساسات، پرسش و پاسخ مالی و استدلال کمی نشان داده‌اند.

¹Sentiment Analysis

²Time-series Forecasting

³Financial Reasoning and Decision Support

⁴Agent-based Modeling

⁵Financial Natural Language Processing, Financial NLP

محدودیت‌ها

با وجود مزایا، چالش‌های زیر همچنان پابرجاست:

- کمبود داده و سازگاری با حوزه: مجموعه داده‌های مالی باکیفیت کم هستند و برچسب‌گذاری آن‌ها هزینه‌بر است.
- سوگیری نگاه به آینده: خطر ورود ناخواسته داده‌های آینده به مدل‌های پیش‌بینی وجود دارد.
- هزینه محاسباتی و تأخیر زمانی: مدل‌های بزرگ نیازمند منابع پردازشی سنگین‌اند و این امر استفاده در زمان واقعی را محدود می‌کند.
- شفافیت و تفسیرپذیری پایین: تصمیمات مدل اغلب مبهم است و این مسئله اعتماد کاربران را کاهش می‌دهد.
- ریسک‌های حقوقی و نظارتی: ملاحظات قانونی و اخلاقی مانع از به‌کارگیری گسترده در نهادهای مالی می‌شود.

سهم در پروژه من

این مرور برای پیشبرد پژوهش من نقش مهمی ایفا کرد. نخست، با معرفی مدل‌ها و روش‌های متن‌باز موجود در حوزه مالی، زمینه‌ای فراهم شد تا بتوانم از آن‌ها در مسئله تحلیل احساسات اخبار مرتبط با بازار بهره‌برداری کنم. دوم، نتایج این مطالعه نشان داد که مدل‌های زبانی بزرگ از دقت مناسبی در وظایف مالی برخوردارند و در مقایسه میان انواع مدل‌ها می‌توان به تفاوت‌های معنادار آن‌ها از نظر عملکرد، پیچیدگی محاسباتی و میزان قابلیت کاربرد در شرایط واقعی پی برد. این بینش‌ها در طراحی و انتخاب چارچوب مناسب برای بخش تحلیل احساسات پروژه‌ام تأثیر مستقیم داشتند.

FinBERT: Financial Sentiment Analysis with ۲-۲-۳ [۲] Pre-trained Language Models

تمرکز پژوهش

مدل FinBERT به چالش تحلیل احساسات در متون مالی می‌پردازد؛ جایی که مدل‌های عمومی تحلیل احساسات (مانند BERT از پیش‌آموزش‌دیده بر روی داده‌های غیرمالی) به دلیل وجود اصطلاحات تخصصی، چندمعنایی بودن واژگان و بافت خاص حوزه مالی عملکرد مناسبی ندارند. هدف اصلی، بومی‌سازی BERT برای طبقه‌بندی دقیق احساسات در اخبار مالی، گزارش‌های شرکتی و بیانیه‌های بازار است.

روش‌شناسی

- آموزش پیش‌زمینه با داده‌های مالی: مدل BERT ابتدا بر روی یک پیکره بزرگ متون مالی (شامل اخبار، پرونده‌های قانونی شرکت‌ها و گزارش‌های تحلیلی) بازآموزی شد تا با واژگان و بافت مالی سازگار شود.
- ریزتنظیم بر روی داده‌های برچسب‌خورده: در مرحله بعد، مدل بر روی مجموعه داده‌های استاندارد تحلیل احساسات مالی مانند Financial PhraseBank و FiQA برای طبقه‌بندی سه‌کلاسه (مثبت، منفی، خنثی) ریزتنظیم شد.
- مقایسه با روش‌های موجود: عملکرد مدل با رویکردهای سنتی (مانند مدل‌های مبتنی بر واژگان و الگوریتم‌های یادگیری ماشین کلاسیک) و همچنین نسخه عمومی BERT مقایسه شد.

جدول (۲-۳) نمای کلی روش‌شناسی FinBERT

گام	توضیح
آموزش پیش‌زمینه	بازآموزی BERT بر روی پیکره‌های بزرگ متون مالی
ریزتنظیم	طبقه‌بندی احساسات (مثبت/منفی/خنثی) با استفاده از Finan-PhraseBank و FiQA
مقایسه مبنا	مقایسه با روش‌های مبتنی بر واژگان، مدل‌های یادگیری ماشین کلاسیک و نسخه عمومی BERT

یافته‌ها

- دقت و امتیاز F1 به‌طور معناداری بهتر از مدل‌های عمومی تحلیل احساسات و روش‌های سنتی است.
- توانایی بالای مدل در شناسایی ظرافت‌های متنی و ترکیبات زبانی رایج در متون مالی (مانند «کاهش جزئی» یا «چشم‌انداز قوی»).
- پایداری و تعمیم‌پذیری مناسب در چندین مجموعه داده مالی معتبر (از جمله Financial PhraseBank و FiQA).

محدودیت‌ها

- نیازمند دسترسی به پیکره‌های بزرگ و باکیفیت از متون مالی برای آموزش پیش‌زمینه.
- همچنان تحت محدودیت‌های معماری BERT است (مانند حداکثر طول ورودی برابر با ۵۱۲ توکن).
- مشابه سایر مدل‌های مبتنی بر Transformer، فاقد شفافیت و تفسیرپذیری کافی در تصمیم‌گیری است.
- عملکرد مدل در وظایفی که نیازمند استدلال اقتصادی پیچیده یا تحلیل چندمرحله‌ای هستند ممکن است افت کند.

سهم در پروژه من

مدل FinBERT به‌عنوان یکی از ابزارهای اصلی در پژوهش من برای استخراج احساسات از اخبار مرتبط با بازارهای مالی به‌کار گرفته شد. افزون بر این، نتایج حاصل از آن با سایر مدل‌های زبانی و رویکردهای تحلیل احساسات مقایسه گردید تا میزان کارایی نسبی آن مشخص شود. در ادامه، از امتیازهای استخراج‌شده توسط این مدل برای بررسی قابلیت پیش‌بینی تغییرات قیمتی در بازار استفاده شد. این تحلیل‌ها به درک بهتر ارتباط میان احساسات متنی و نوسانات بازار در چارچوب پروژه کمک شایانی کرد.

۳-۲-۳ FinGPT: Open-Source Financial Large Language Models [۳]

تمرکز پژوهش

هدف FinGPT فراهم کردن یک بستر متن‌باز و کم‌هزینه برای استفاده از مدل‌های زبانی در حوزه مالی است. این پروژه تلاش می‌کند تا به جای مدل‌های اختصاصی و بسته، امکان دسترسی همگانی به ابزارهای تحلیلی فراهم شود. کاربردهای اصلی آن شامل تحلیل احساسات اخبار مالی، خلاصه‌سازی گزارش‌ها و پاسخ به پرسش‌های مالی است. بدین ترتیب، FinGPT موانع استفاده از مدل‌های زبانی در دانشگاه و صنعت را کاهش می‌دهد.

روش‌شناسی

FinGPT با تکیه بر مدل‌های زبانی متن‌باز خانواده GPT توسعه یافته و از چندین رویکرد برای سازگاری با وظایف مالی استفاده می‌کند:

- **ستون فقرات مدل:** بهره‌گیری از معماری‌های متن‌باز خانواده GPT.
- **سازگاری با حوزه مالی:** تنظیم مبتنی بر دستورالعمل و ریزتنظیم روی متون مالی برای آموزش وظایف خاص.
- **کارایی محاسباتی:** استفاده از روش‌های سبک مانند LoRA برای کاهش تعداد پارامترهای قابل آموزش و صرفه‌جویی در منابع.
- **هم‌ترازی با نیازهای کاربر:** استفاده از یادگیری تقویتی با بازخورد انسانی (RLHF) برای بهبود کیفیت و اعتمادپذیری پاسخ‌ها.

جدول (۳-۳) نکات کلیدی روش‌شناسی FinGPT

مؤلفه	توضیح
ستون فقرات مدل	مدل‌های زبانی متن‌باز خانواده GPT
سازگاری با حوزه مالی	ریزتنظیم و تنظیم مبتنی بر دستورالعمل روی داده‌های مالی
روش‌های افزایش کارایی	LoRA و بهینه‌سازی سبک برای کاهش هزینه محاسباتی
هم‌ترازی	RLHF برای افزایش دقت و اعتمادپذیری پاسخ‌ها

یافته‌ها

- عملکرد رقابتی در بنچمارک‌های پردازش زبان مالی در مقایسه با مدل‌های اختصاصی نشان داده است.
- توانایی انجام وظایف متنوع مانند تحلیل احساسات، پرسش و پاسخ و خلاصه‌سازی متون.
- چارچوب متن‌باز، شفافیت علمی و امکان سفارشی‌سازی برای پژوهشگران و صنعت را فراهم می‌کند.
- به‌عنوان یک جایگزین کم‌هزینه برای مدل‌های مالی بسته و گران‌قیمت مطرح است.

محدودیت‌ها

- عملکرد آن به کیفیت و پوشش داده‌های مالی آموزشی وابسته است.
- در مقایسه با مدل‌های تجاری بسیار بزرگ ممکن است دقت پایین‌تری داشته باشد.
- در کاربردهای حساس یا دارای الزامات سخت‌گیرانه نظارتی هنوز چالش وجود دارد.
- احتمال تولید خروجی‌های نادرست یا گمراه‌کننده (Hallucination) همچنان وجود دارد که می‌تواند تبعات اخلاقی و حقوقی داشته باشد.

سهام در پروژه من

پروژه FinGPT نیز همچون FinBERT به عنوان یکی از مدل های اصلی در پژوهش من برای استخراج احساسات از اخبار مرتبط با بازارهای مالی مورد استفاده قرار گرفت. در ادامه، آزمون ها و مقایسه های تجربی بر روی این مدل انجام شد تا کارایی آن در کنار سایر رویکردها سنجیده شود. این تحلیل ها امکان ارزیابی دقیق تر ارتباط میان داده های متنی و رفتار بازار را در چارچوب پروژه فراهم ساخت.

۳-۳ کتابخانه ها و چارچوب های یادگیری تقویتی در حوزه مالی

۳-۳-۱ Deep Reinforcement Learning in Quantitative [۴] Algorithmic Trading: A Review

تمرکز پژوهش

این مرور به بررسی استفاده از یادگیری تقویتی عمیق^۶ در معامله گری الگوریتمی کمی با فرکانس پایین می پردازد. در این چارچوب، بازار سهام به عنوان محیطی با مشاهده جزئی و اطلاعات ناقص در نظر گرفته می شود □ مشابه محیط بازی هایی مانند □□ یا شطرنج □ که در آن عامل ها می آموزند راهبردهایی را برای بیشینه سازی بازده تجمعی در عین کنترل ریسک توسعه دهند.

روشناسی

دامنه مرور محدود به عامل های معاملاتی یادگیری تقویتی عمیق خودکار و انتها-به-انتها است که در بازه های زمانی دقیقه ای تا روزانه فعالیت می کنند. در این بررسی، مدل های پیش بینی، رویکردهای ترکیبی یا فراابتکاری و معامله گری با فرکانس بالا کنار گذاشته شده اند. رویکردهای انتخاب شده به سه دسته اصلی طبقه بندی شده اند (جدول (۳-۴)).

جدول (۳-۴) دسته بندی رویکردهای DRL در معامله گری (اقتباس شده از [۴])

دسته	نمونه ها
فقط منتقد (مبتنی بر ارزش) ^۷	شبکه های Q عمیق ^۸ ، DQN دوگانه ^۹
فقط بازیگر (مبتنی بر سیاست) ^{۱۰}	REINFORCE، روش های گرادیان سیاست ^{۱۱}
ترکیبی بازیگر □ منتقد	بازیگر-منتقد مزیت ^{۱۲} ، گرادیان سیاست قطعی عمیق ^{۱۳} ، بهینه سازی سیاست مجانبی ^{۱۴}

یافته ها

□ عامل های معاملاتی مبتنی بر یادگیری تقویتی عمیق در بسیاری از مطالعات شبیه سازی عملکردی بهتر از روش های سنتی پایه دارند.

□ نتایج گزارش شده عمدتاً جنبه آماری دارند و الزاماً به سودآوری عملی منجر نمی شوند.

^۶Deep Reinforcement Learning, DRL

□ بیشتر پژوهش‌ها در سطح اثبات مفهوم باقی مانده‌اند و گرچه نتایج متوسط بوده‌اند، نشان‌دهنده پتانسیل قابل توجه این رویکردها هستند.

محدودیت‌ها

- بیشتر مطالعات به شبیه‌سازی و بک‌تست‌های ساده متکی‌اند و نه محیط‌های واقعی بازار.
- مقایسه‌های نظام‌مند میان الگوریتم‌های مختلف یادگیری تقویتی عمیق محدود بوده و در موارد اندکی با عملکرد معامله‌گران انسانی سنجیده شده‌اند.
- موانع عملی همچون تأخیر اجرایی، هزینه‌های تراکنش و ریزساختار بازار اغلب نادیده گرفته می‌شوند.
- سودآوری پایدار در شرایط واقعی همچنان اثبات‌نشده باقی مانده است.

سهم در پروژه من

این مرور نقش مهمی در شکل‌گیری دیدگاه اولیه من نسبت به کاربردهای یادگیری تقویتی در حوزه مالی ایفا کرد. از یک سو، موجب شد با رویکردها و الگوریتم‌های متنوع یادگیری تقویتی عمیق در معامله‌گری آشنا شوم و از سوی دیگر، نمونه‌هایی از مقالات و پژوهش‌های پیشین را مرور کنم. بررسی ویژگی‌ها و محدودیت‌های هر روش، درک روشن‌تری از چشم‌انداز پژوهش و مسیر توسعه پروژه فراهم ساخت. افزون بر این، این مرور به من کمک کرد تا با چالش‌ها و مشکلات عمده پژوهش‌های موجود در این حوزه آشنا شوم و در نتیجه، تلاش کنم در طراحی مسئله و چارچوب پیشنهادی خودم راهکارهایی برای رفع بخشی از این کاستی‌ها ارائه دهم.

۳-۳-۲ - Stable-Baselines3: Reliable Reinforcement Learning Implementations [۵]

تمرکز پژوهش

Stable-Baselines3 (SB3) یک کتابخانه متن‌باز در پایتون است که پیاده‌سازی‌های استاندارد و آزموده‌شده از الگوریتم‌های یادگیری تقویتی عمیق ارائه می‌دهد. این کتابخانه بر پایه PyTorch ساخته شده و به‌عنوان جانشین Stable-Baselines (مبتنی بر TensorFlow) معرفی گردید. هدف اصلی آن تضمین بازتولیدپذیری، سهولت استفاده و فراهم کردن بستری توسعه‌پذیر برای پژوهش و کاربردهای عملی در یادگیری تقویتی است. با ارائه پیاده‌سازی‌های قابل اعتماد، این کتابخانه هم پژوهشگران و هم متخصصان صنعتی را در آزمایش و توسعه روش‌های نوین پشتیبانی می‌کند.

روش‌شناسی

SB3 بر سه اصل طراحی کلیدی تکیه دارد:

- **قابلیت اعتماد و بازتولیدپذیری:** اجرای آزمون‌های دقیق (واحد، یکپارچه‌سازی، بازگشتی) و تولید نتایج قطعی در صورت امکان.
- **سهولت استفاده:** ارائه رابطی ساده و سطح بالا (مانند `.learn()`) که آموزش و ارزیابی الگوریتم‌ها را یکپارچه می‌سازد. همچنین سازگاری کامل با OpenAI Gym، PyTorch و NumPy دارد.
- **قابلیت توسعه:** معماری ماژولار که امکان سفارشی‌سازی آسان سیاست‌ها، شبکه‌ها، حافظه‌های بازپخش^{۱۵} و توابع

^{۱۵}Replay Buffers

زیان را فراهم کرده و از نمونه‌سازی سریع روش‌های جدید پشتیبانی می‌کند.

یافته‌ها

- SB3 شامل طیف گسترده‌ای از الگوریتم‌های پرکاربرد یادگیری تقویتی است، چه مبتنی بر سیاست جاری^{۱۶} (مانند (TRPO, A2C, PPO) و چه خارج از سیاست^{۱۷} (مانند (SAC, TD3, DDPG, DQN).
- آزمایش‌ها در محیط‌های استاندارد (مانند MuJoCo و Atari) نشان داده‌اند که نتایج SB3 هم‌تراز یا حتی بهتر از گزارش‌های مقالات اصلی الگوریتم‌ها و نسخه پیشین Stable-Baselines است.
- ابرپارامترها^{۱۸} و تنظیمات پیش‌فرض با دقت از مقالات اصلی الگوریتم‌ها استخراج شده‌اند تا نتایج قابل اعتماد و بازتولیدپذیر تضمین شود.

محدودیت‌ها

- تمرکز این کتابخانه بر اجرای تک‌ماشینه است و فاقد مقیاس‌پذیری چارچوب‌های توزیعی مانند RLlib یا Tianshou می‌باشد.
- الگوریتم‌های آزمایشی در ماژول جداگانه SB3-Contrib ارائه می‌شوند که سطح پایداری و آزمون‌پذیری آن‌ها به اندازه هسته اصلی کتابخانه نیست.
- با وجود اولویت‌دهی به بازتولیدپذیری، نتایج می‌توانند بسته به تصادفی بودن محیط‌ها یا تفاوت سخت‌افزاری تغییر کنند.

سهم در پروژه من

کتابخانه Stable-Baselines3 به‌عنوان ابزار اصلی برای توسعه عامل‌های یادگیری تقویتی در این پژوهش مورد استفاده قرار گرفت. سازگاری کامل این کتابخانه با سایر ابزارهای علمی در پایتون فرآیند پیاده‌سازی را ساده‌تر و روان‌تر ساخت. همچنین متن‌باز بودن و وجود مستندات و پیاده‌سازی‌های استاندارد، نقش مهمی در تسریع توسعه و افزایش قابلیت اطمینان آزمایش‌ها ایفا کرد.

FinRL: A Deep Reinforcement Learning Library – ۳-۳-۳ for Automated Stock Trading in Quantitative [۶] Finance

تمرکز پژوهش

FinRL یکی از نخستین کتابخانه‌های متن‌باز یادگیری تقویتی عمیق است که به‌طور خاص برای حوزه مالی کمی طراحی شده است. هدف اصلی آن فراهم کردن یک چارچوب بازتولیدپذیر، قابل گسترش و کاربرپسند است که سد ورود برای پژوهشگران و متخصصان علاقه‌مند به توسعه راهبردهای معامله‌گری خودکار را کاهش دهد.

¹⁶On-policy

¹⁷Off-policy

¹⁸Hyperparameters

روش‌شناسی

این کتابخانه یک معماری سه لایه ماژولار اتخاذ می‌کند که انعطاف‌پذیری و قابلیت توسعه را در کاربردهای مختلف ممکن می‌سازد:

□ **لایه محیط:** شبیه‌سازی بازار با استفاده از داده‌های تاریخی یا بلادرنگ، شامل هزینه‌های معاملاتی، محدودیت‌های نقدشوندگی و ترجیحات ریسک سرمایه‌گذار.

□ **لایه عامل:** پیاده‌سازی الگوریتم‌های پیشرفته یادگیری تقویتی عمیق (مانند DQN, DDPG, PPO, SAC, TD3, A2C) با توابع پاداش قابل سفارشی‌سازی.

□ **لایه کاربرد:** ماژول‌های آماده برای معامله سهام، تخصیص دارایی و معامله رمزارز، همراه با ابزارهای یکپارچه برای Backtesting.

این چارچوب در PyTorch پیاده‌سازی شده، با OpenAI Gym-API سازگار است و مستندات و آموزش‌های گسترده‌ای برای پشتیبانی از یادگیری و بازتولیدپذیری ارائه می‌دهد.

جدول (۳-۵) احزای کلیدی در FinRL

مؤلفه	ویژگی‌های کلیدی
لایه محیط	داده‌های تاریخی/بلادرنگ، هزینه‌های تراکنش، محدودیت‌های نقدشوندگی
لایه عامل	الگوریتم‌های یادگیری تقویتی عمیق DQN, PPO, SAC, TD3, A2C، توابع پاداش قابل سفارشی‌سازی
لایه کاربرد	ماژول‌های معامله سهام و رمزارز، راهبردهای سبد دارایی، ابزارهای Backtesting

یافته‌ها

□ نشان می‌دهد که عامل‌های یادگیری تقویتی عمیق می‌توانند در وظایف متنوع معامله‌گری مالی به‌طور موفق عمل کنند.

□ به‌طور گسترده در پژوهش‌های دانشگاهی و آموزش مورد استفاده قرار گرفته و پلی میان یادگیری ماشین و مالی کمی ایجاد کرده است.

محدودیت‌ها

□ راهبردهای سودآور آماده ارائه نمی‌دهد؛ بیشتر به‌عنوان یک جعبه‌ابزار زیرساختی عمل می‌کند تا یک راه‌حل معاملاتی کامل.

□ برخی انتخاب‌های طراحی محیط (مانند تعریف فضای عمل) ممکن است سوگیری‌های مدل‌سازی ظریفی ایجاد کنند.

□ استقرار در دنیای واقعی نیازمند تخصص بالای حوزه، مهندسی داده و مدیریت ریسک فراتر از خود ابزار است.

سهم در پروژه من

کتابخانه FinRL به دلیل متن‌باز بودن، نقش مهمی در پیشبرد پروژه من ایفا کرد. این امکان را فراهم ساخت تا از محیط‌های پیاده‌سازی شده به‌عنوان پایه استفاده کنم و آن‌ها را مطابق نیازهای پژوهش شخصی‌سازی کرده و بهبودهای مدنظر خود را اعمال نمایم. افزون بر این، FinRL به من اجازه داد عملکرد الگوریتم‌های مختلف را به‌صورت سریع و نظام‌مند بررسی و مقایسه کنم که این موضوع در انتخاب و طراحی چارچوب مناسب برای پروژه بسیار مؤثر بود.

۳-۴- Deep Reinforcement Learning for Automated Stock Trading: An Ensemble Strategy [۷]

تمرکز پژوهش

این مطالعه یک راهبرد تجمیعی^{۱۹} مبتنی بر یادگیری تقویتی عمیق را برای معامله‌گری خودکار سهام پیشنهاد می‌دهد. هدف اصلی، ترکیب نقاط قوت چند الگوریتم یادگیری تقویتی عمیق برای ساخت یک عامل معاملاتی مقاوم‌تر و سازگارتر است که بتواند با رژیم‌های پویا و پرنوسان بازار مقابله کند.

روش‌شناسی

چارچوب تجمیعی چند الگوریتم بازیگر-منتقد^{۲۰} را با یک فرآیند انتخاب سیستماتیک ادغام می‌کند:

□ الگوریتم‌های استفاده‌شده: A2C، PPO و DDPG.

□ تکنیک **Load-on-demand**: روشی برای مدیریت کارآمد داده که در آن داده‌ها تنها در زمان نیاز از حافظه یا دیسک بارگذاری می‌شوند. این رویکرد باعث کاهش سربار حافظه و افزایش کارایی در محیط‌های دارای فضای عمل پیوسته می‌شود.

□ سازوکار تجمیع:

□ عامل‌ها با استفاده از پنجره‌های متحرک داده‌های تاریخی آموزش داده می‌شوند.

□ یک پنجره اعتبارسنجی برای ارزیابی عامل‌ها بر اساس Sharpe Ratio استفاده می‌شود.

□ بهترین عامل برای اجرای معاملات در دوره معاملاتی بعدی انتخاب می‌شود.

□ مجموعه داده: سی سهم از شاخص Dow Jones Industrial Average (DJIA)

یافته‌ها

□ راهبرد تجمیعی به‌طور مداوم عملکردی بهتر از خط‌مبناهای تک‌عاملی DRL دارد.

□ Sharpe Ratio بالاتر و بازده‌های تعدیل‌شده با ریسک پایدارتر تولید می‌کند.

□ با انتخاب عامل مناسب تحت رژیم‌های مختلف بازار، سازگاری بالایی نشان می‌دهد.

¹⁹Ensemble Strategy

²⁰Actor-Critic

جدول (۳-۶) مروری بر راهبرد تجمیعی (Li et al., 2020)

مؤلفه	توضیحات
الگوریتم‌ها	DDPG, A2C, PPO (مدل‌های DRL بازیگر-منتقد)
معیار انتخاب	Sharpe Ratio (تعدیل‌شده با ریسک)
فرآیند	آموزش → اعتبارسنجی → انتخاب بهترین عامل → معامله
مقایسه با مبنا	شاخص DJIA, سبد دارایی حداقل واریانس، و هر یک از الگوریتم‌های A2C, PPO و DDPG به صورت مستقل

محدودیت‌ها

- از نظر محاسباتی پرهزینه است، زیرا نیازمند آموزش و نگهداری چندین عامل به طور همزمان است.
- عملکرد به اندازه پنجره متحرک، ابرپارامترها و شرایط غالب بازار حساس است.
- محدود به سه الگوریتم است؛ گسترش به روش‌های جدیدتر (مانند SAC یا TD3) می‌تواند مقاومت را افزایش دهد.
- ارزیابی تنها به بک‌تست محدود است؛ استقرار در دنیای واقعی همچنان تأیید نشده است.

سهم در پروژه من

این پژوهش الهام‌بخش شکل‌گیری ایده‌های جدیدی در پروژه من شد؛ به‌ویژه آشنایی با روش‌های Ensemble که می‌توانند در صورت نیاز در طراحی و توسعه راهبردهای پیشنهادی به کار گرفته شوند. این آشنایی چشم‌انداز وسیع‌تری برای ترکیب مدل‌ها و بهره‌برداری از نقاط قوت هر رویکرد در اختیارم قرار داد.

A Novel Deep Reinforcement Learning-Based Automated Stock Trading System Using Cascaded LSTM Networks [۸]

تمرکز پژوهش

این مقاله به چالش‌های استفاده از یادگیری تقویتی عمیق در سری‌های زمانی مالی می‌پردازد؛ سری‌هایی که معمولاً دارای نسبت پایین سیگنال به نویز، الگوهای نامنظم و رفتار ناپایدار هستند. نویسندگان یک معماری Cascaded LSTM پیشنهاد می‌کنند تا توانایی عامل‌های یادگیری تقویتی عمیق در ثبت وابستگی‌های زمانی و ساختارهای پنهان در داده‌های روزانه قیمت سهام تقویت شود.

روش‌شناسی

- این چارچوب با یک طراحی دومارحله‌ای Cascaded LSTM، استخراج ویژگی و یادگیری تقویتی را ترکیب می‌کند:
- **مرحله استخراج ویژگی:** نخستین شبکه LSTM الگوهای زمانی را از داده‌های خام روزانه سهام مدل‌سازی می‌کند.
- **مرحله عامل:** ویژگی‌های استخراج‌شده به یک عامل یادگیری تقویتی عمیق مبتنی بر PPO داده می‌شوند. در این مرحله، یک LSTM دیگر درون شبکه‌های بازیگر-منتقد تعبیه شده تا تصمیم‌گیری دنباله‌ای بهبود یابد.

این سیستم بر روی چهار شاخص عمده سهام ارزیابی شده است: Dow Jones Industrial Average (US)، (DJI)، SSE50 (China)، SENSEX (India) و FTSE100 (UK). عملکرد آن در برابر مبناهایی مانند Buy-and-Hold، PPO-MLP، مدل‌های LightGBM، Standalone LSTM/MLP، Gradient Boosting و راهبردهای یادگیری تقویتی تجمیعی مقایسه شده است.

یافته‌ها

- سیستم Cascaded LSTM-PPO بهبودهایی در حدود ۵ تا ۵۲ درصد نسبت به مبنای شاخص‌های کلیدی مالی از جمله بازده تجمعی، بیشینه بازده و میانگین سود هر معامله نشان داد.
- عملکرد آن برتر از مدل‌های یادگیری ماشین سنتی و الگوریتم‌های یادگیری تقویتی بدون ادغام Cascaded LSTM بود.

محدودیت‌ها

- افزایش پیچیدگی و هزینه آموزشی به دلیل معماری دوطرفه‌ای.
- حساسیت بالا به ابرپارامترها، شرایط مختلف بازار و فرکانس داده که می‌تواند مقاومت و پایداری را کاهش دهد.
- ارزیابی صرفاً در قالب آزمایش‌های Backtesting انجام شده و اعتبارسنجی در معاملات زنده صورت نگرفته است.
- خطر بیش‌برازش به دلیل پیچیدگی زیاد شبکه وجود دارد.

سهم در پروژه من

این پژوهش الهام‌بخش شکل‌گیری ایده‌هایی در پروژه من شد که بر ترکیب شبکه‌های بازگشتی با الگوریتم‌های یادگیری تقویتی متمرکز بودند. در ادامه، با جست‌وجو و شناسایی پیاده‌سازی‌های موجود از نسخه‌های بازگشتی الگوریتم PPO، امکان ارزیابی و آزمون این ایده فراهم گردید. این تجربه به من درک عمیق‌تری از ظرفیت شبکه‌های بازگشتی در بهبود تصمیم‌گیری دنباله‌ای در معامله‌گری مالی بخشید.

۳-۶- Commission Fee is not Enough: A Hierarchical Reinforced Framework for Portfolio Management

[۹]

تمرکز پژوهش

این مطالعه به یک محدودیت رایج در مدیریت سبد سهام مبتنی بر یادگیری تقویتی عمیق اشاره می‌کند: اغلب مدل‌های موجود تنها کارمزد کمیسیون را به‌عنوان هزینه معاملاتی لحاظ می‌کنند و اثر مهم لغزش قیمتی را نادیده می‌گیرند. از آنجا که لغزش می‌تواند نتایج واقعی معاملات را به‌شدت تغییر دهد، نویسندگان چارچوب HRPم را پیشنهاد می‌کنند؛ مدلی سلسله‌مراتبی که به‌طور صریح فرآیند تخصیص سبد سهام را از اجرای معاملات جدا می‌سازد.

روش‌شناسی

چارچوب HRPM یک ساختار دوسطحی اتخاذ می‌کند:

- **سیاست سطح بالا:** در بازه‌های زمانی بلندتر وزن‌های سبد سهام را تعیین می‌کند با هدف بیشینه‌سازی بازده.
 - **سیاست سطح پایین:** در بازه‌های کوتاه‌تر معاملات را اجرا می‌کند و به‌طور راهبردی هزینه‌های معاملاتی از جمله لغزش را کاهش می‌دهد.
- راهبرد آموزشی شامل:
- پیش‌آموزش مستقل هر دو سطح برای ایجاد رفتار پایه.
 - آموزش مشترک و تکرارشونده برای هماهنگ‌سازی تصمیم‌گیری در سطح راهبرد و اجرا.
- این چارچوب در بازار سهام ایالات متحده و چین آزمایش شده و با خط‌مبناهای یادگیری تقویتی عمیق و روش‌های سنتی مدیریت سبد سهام مقایسه گردید.

یافته‌ها

- **هزینه‌های معاملاتی:** نتایج نشان داد که کمیسیون تنها سهم کوچکی از هزینه‌هاست، در حالی که لغزش قیمتی بخش عمده را تشکیل می‌دهد، به‌ویژه در معاملات با حجم بالا.
 - **تنظیم آنتروپی:** افزودن پاداش آنتروپی منجر به تنوع‌سازی بهتر شد:
- $$\eta = 0.05 \quad \square \quad \text{بیشترین بازده سالانه}^{21} \text{ را ایجاد کرد.}$$
- $$\eta = 0.1 \quad \square \quad \text{کمترین افت سرمایه بیشینه را حاصل نمود.}$$
- **رفتار اجرا:** سیاست سطح پایین معاملات را به‌صورت مرحله‌ای و راهبردی پخش می‌کند (مانند فروش بخشی از موقعیت پیش از موعد یا هماهنگ کردن خرید/فروش با روند کوتاه‌مدت قیمت)، که این امر هزینه‌های لغزش را کاهش می‌دهد.
 - **عملکرد کلی:** HRPM در هر دو بازار آمریکا و چین نسبت به خط‌مبناهای یادگیری تقویتی عمیق و روش‌های کلاسیک مدیریت سبد سهام برتری نشان داد.

محدودیت‌ها

- معماری سلسله‌مراتبی باعث افزایش پیچیدگی و هزینه آموزشی می‌شود.
- نتایج به ابرپارامترها (مانند وزن آنتروپی η) بسیار حساس است و بر تعادل میان ریسک و بازده تأثیر می‌گذارد.
- ارزیابی تنها از طریق Backtesting انجام شده و هیچ آزمون زنده‌ای در بازار واقعی صورت نگرفته است.
- پایداری رفتار اجرا ممکن است در شرایطی از بازار که در مطالعه پوشش داده نشده‌اند (مانند نقدشوندگی پایین یا نوسانات شدید) کاهش یابد.

²¹Annualized Return, ARR

سهام در پروژه من

این پژوهش باعث شد با چالش‌های عملی در مدیریت سبد سهام مبتنی بر یادگیری تقویتی عمیق آشنایی بیشتری پیدا کنم. همچنین آشنایی با ایده‌های سلسله‌مراتبی در طراحی عامل‌ها الهام‌بخش من شد تا در صورت نیاز از این رویکرد برای بهبود ساختار و کارایی مدل‌های خود بهره بگیرم.

Multi-Type Data Fusion Framework Based on ۷-۳-۳ Deep Reinforcement Learning for Algorithmic [۱۰] Trading

تمرکز پژوهش

این مقاله به محدودیت‌های سامانه‌های معامله‌گری مبتنی بر یادگیری تقویتی عمیق که فقط از یک منبع داده استفاده می‌کنند می‌پردازد. چنین سامانه‌هایی اغلب نمی‌توانند ماهیت چندبُعدی بازارهای مالی را به‌طور کامل ثبت کنند. برای رفع این مشکل، نویسندگان MSF-DRL را پیشنهاد می‌دهند؛ چارچوبی برای ادغام چندنوع داده که داده‌های خام سهام، شاخص‌های فنی^{۲۲} و تصاویر نمودار شمعی^{۲۳} را با هم ترکیب می‌کند تا بازنمایی جامع‌تری از بازار ساخته شود.

روش‌شناسی

چارچوب MSF-DRL از یک فرآیند استخراج ویژگی دوشاخه و سپس ادغام استفاده می‌کند:

□ **شاخه عددی:** قیمت‌های سهام و شاخص‌های فنی با یک شبکه LSTM^{۲۴} پردازش می‌شوند تا وابستگی‌های زمانی استخراج و نویز کاهش یابد.

□ **شاخه دیداری:** نمودارهای شمعی با یک شبکه عصبی پیچشی^{۲۵} همراه با شبکه LSTM دوسویه^{۲۶} کدگذاری می‌شوند تا هم الگوهای فضایی و هم الگوهای توالی‌محور ثبت شوند.

□ **ادغام:** ویژگی‌های استخراج‌شده از دو شاخه ترکیب شده و یک بازنمایی حالت جامع ساخته می‌شود.

بازنمایی حالت ادغام‌شده سپس به یک عامل یادگیری تقویتی عمیق داده می‌شود که خروجی آن تصمیمات گسسته خرید، فروش یا نگهداری است.

یافته‌ها

□ MSF-DRL عملکرد بهتری نسبت به خط‌مبناهای سنتی و مدل‌های یادگیری عمیق تک‌منبعی دارد.

□ سودآوری بالاتر و Sharpe Ratio بهتری ارائه می‌دهد که نشان‌دهنده بازده‌های تعدیل‌شده با ریسک قوی‌تر است.

□ پایداری میان‌بازاری نشان می‌دهد و هم در داده‌های سهام چین و هم در برخی سهام S&P 500 عملکرد مؤثری دارد.

²²Technical Indicators

²³Candlestick Charts

²⁴Long Short-Term Memory

²⁵Convolutional Neural Network (CNN)

²⁶Bidirectional LSTM (BiLSTM)

محدودیت‌ها

- معماری دوشاخه پیچیدگی محاسباتی و هزینه آموزش را افزایش می‌دهد.
- عملکرد به کیفیت تولید نمودارهای شمعی و انتخاب‌های پیش‌پردازش حساس است.
- ارزیابی تنها به Backtesting تاریخی محدود است و هیچ اعتبارسنجی در معاملات زنده انجام نشده است.
- ادغام داده‌ها تنها به سه نوع محدود است و منابع اطلاعاتی دیگر مانند احساسات یا اخبار در نظر گرفته نشده‌اند.

سهم در پروژه من

این پژوهش باعث شد با ایده‌های ترکیب داده‌های چندوجهی^{۲۷} در زمینه یادگیری تقویتی و بازارهای مالی آشنا شوم، هرچند از این ایده به‌طور مستقیم در پروژه خود استفاده نکردم. این آشنایی صرفاً به گسترش دید من نسبت به رویکردهای موجود کمک کرد.

۸-۳-۳ Market Sentiment-Aware Deep Reinforcement Learning Approach for Stock Portfolio Allocation

[۱۱]

تمرکز پژوهش

این مقاله به یکی از محدودیت‌های کلیدی راهبردهای تخصیص سبد سهام مبتنی بر یادگیری تقویتی عمیق می‌پردازد؛ این مدل‌ها معمولاً تنها به اطلاعات قیمتی تاریخی متکی هستند. نویسندگان یک چارچوب یادگیری تقویتی عمیق آگاه از احساسات پیشنهاد می‌دهند که قیمت‌های بازار را با احساسات سرمایه‌گذاران ادغام می‌کند و بدین ترتیب پویایی‌های روانشناختی بازار را که نقشی مهم در بازده سهام دارند، ثبت می‌نماید.

روش‌شناسی

این چارچوب بازنمایی حالت را با ترکیب سیگنال‌های کمی و احساسی غنی‌تر می‌سازد:

□ **ورودی‌های یکپارچه:** ترکیب داده‌های تاریخی سهام با ویژگی‌های احساسی استخراج‌شده از اخبار مالی و رسانه‌های اجتماعی.

□ **استخراج احساسات:** اگرچه جزئیات خط لوله پردازش زبان طبیعی مشخص نشده، امتیازهای احساسی به ویژگی‌های کمی مناسب برای ورودی مدل تبدیل شده‌اند.

□ **چارچوب یادگیری تقویتی عمیق:** بازنمایی حالت غنی‌شده به یک عامل یادگیری تقویتی عمیق داده می‌شود (الگوریتم دقیق مشخص نیست، اما رویکردهایی مانند DQN یا PPO قابل استفاده هستند).

□ **دامنه سبد سهام:** ارزیابی بر روی شرکت‌های شاخص Dow Jones Industrial Average (DJIA) انجام شده است.

²⁷Multi-Modal

یافته‌ها

□ مدل‌های یادگیری تقویتی عمیق آگاه از احساسات عملکرد بهتری نسبت به رویکردهای مبتنی صرف بر داده‌های قیمتی دارند.

□ Sharpe Ratio و بازده‌های سالانه بالاتری به دست آمد.

□ با ادغام سیگنال‌های احساسی، مقاومت بیشتری در تخصیص سبد سهام مشاهده شد.

محدودیت‌ها

□ فرآیند استخراج احساسات شفافیت ندارد، زیرا جزئیات خط لوله پردازش زبان طبیعی مشخص نشده است.

□ عملکرد مدل به کیفیت و قابلیت اعتماد داده‌های احساسی وابسته است که ممکن است پرنویز یا جانبدارانه باشند.

□ مطالعه فقط به سهام Dow Jones محدود شده و تعمیم به سایر بازارها بررسی نشده است.

□ ارزیابی صرفاً به Backtesting تاریخی محدود بوده و هیچ آزمایش زنده یا بلادرنگ انجام نشده است.

سهم در پروژه من

این پژوهش به عنوان یکی از پایه‌ای‌ترین منابع در مسیر پروژه من عمل کرد و مستقیماً با ایده اصلی من یعنی ترکیب احساسات بازار با یادگیری تقویتی همسو بود. بررسی این مطالعه به من کمک کرد تا روش‌های استخراج احساسات را بهبود دهم و در نهایت به نتایج دقیق‌تر و کارآمدتری در مدل‌سازی و ارزیابی دست یابم.

A Multi-Agent Reinforcement Learning Framework for Optimizing Financial Trading Strategies Based on TimesNet [۱۲]

تمرکز پژوهش

این مقاله به محدودیت‌های پایداری مدل‌های یادگیری تقویتی عمیق تک‌عاملی در معامله‌گری مالی می‌پردازد. نویسندگان MADDQN را معرفی می‌کنند؛ یک چارچوب یادگیری تقویتی عمیق چندعاملی^{۲۸} که استخراج‌کننده‌های ویژگی متنوعی TimesNet و Multi-Scale CNN □ را ترکیب می‌کند تا راهبردهای معاملاتی با هدف متعادل‌سازی میان بیشینه‌سازی بازده و کنترل ریسک توسعه یابند.

روش‌شناسی

چارچوب پیشنهادی یک طراحی دوعاملی به کار می‌گیرد که هر عامل در استخراج نوع خاصی از ویژگی‌ها تخصص دارد:

□ **عامل ۱:** از TimesNet استفاده می‌کند که سری‌های زمانی یک‌بعدی را به نمایش‌های دوبعدی تبدیل می‌کند تا وابستگی‌های دوره‌ای و چندمقیاسی ثبت شوند.

□ **عامل ۲:** از Multi-Scale CNN برای استخراج ویژگی‌های زمانی در سطوح مختلف وضوح بهره می‌برد.

²⁸Multi-Agent Deep Reinforcement Learning

هر دو عامل با استفاده از Double DQN (DDQN) آموزش داده می‌شوند تا سوگیری بیش‌برآورد در یادگیری مقادیر Q کاهش یابد. فرآیند آموزشی شامل دو مرحله است:

- **پیش‌آموزش:** روی یک مجموعه داده ترکیبی از شاخص‌های اصلی ایالات متحده برای افزایش قابلیت تعمیم.
- **ریزتنظیم:** روی دارایی‌های منفرد برای انطباق راهبردها با شرایط خاص بازار.

یافته‌ها

- بازده تجمعی میانگین 23.08٪ در پنج شاخص سهامی به دست آمد.
- نسبت به خط‌مبناهای تک‌عاملی، در سودآوری و پایداری عملکردی برتری داشت.
- توانایی تعمیم‌پذیری قوی نشان داد؛ به‌طوری‌که پیش‌آموزش انتقال‌پذیری را افزایش داد و ریزتنظیم موجب تثبیت عملکرد ویژه هر دارایی شد.
- طراحی چندعاملی پروفایل‌های بازده ریسک پایدارتر نسبت به سیستم‌های تک‌عاملی ایجاد کرد.

محدودیت‌ها

- هزینه محاسباتی بالا به دلیل بار آموزشی و هماهنگی چند عامل.
- اتکای زیاد به TimesNet و استخراج‌کننده‌های مبتنی بر CNN که ممکن است در رژیم‌های بازار بسیار متفاوت یا پیش‌بینی‌نشده کارایی را کاهش دهد.
- ارزیابی صرفاً در قالب Backtesting تاریخی انجام شده و هیچ آزمایش معاملات زنده وجود نداشت.
- تمرکز اصلی بر شاخص‌های سهام ایالات متحده بوده و تعمیم به بازارهای دیگر بررسی نشده است.

محدودیت‌ها

- از نظر محاسباتی پرهزینه است به دلیل سربار آموزش و هماهنگ‌سازی چندین عامل.
- اتکا شدید به TimesNet و استخراج‌کننده‌های مبتنی بر CNN ممکن است انطباق‌پذیری را در رژیم‌های بازار کاملاً متفاوت یا پیش‌بینی‌نشده کاهش دهد.
- ارزیابی به Backtest تاریخی محدود بود؛ هیچ آزمایش معاملاتی زنده انجام نشد.
- تمرکز عمدتاً بر شاخص‌های سهام ایالات متحده بوده و تعمیم فرامرزی بررسی نشده است.

سهم در پروژه من

این پژوهش موجب شد با رویکردها و معماری‌های چندعاملی در یادگیری تقویتی آشنا شوم. هرچند از این رویکرد به‌طور مستقیم در پروژه خود استفاده نکردم، اما بررسی آن به گسترش دید من نسبت به ظرفیت‌ها و چالش‌های این حوزه کمک کرد.

۳-۴- رویکردهای ترکیبی: ادغام مدل‌های زبانی بزرگ با یادگیری تقویتی در زمینه مالی

FINCON: A Synthesized LLM Multi-Agent System with Conceptual Verbal Reinforcement for Enhanced Financial Decision Making [۱۳]

تمرکز پژوهش

این پژوهش به پیچیدگی تصمیم‌گیری‌های متوالی مالی با ادغام مدل‌های زبانی بزرگ و یادگیری تقویتی عمیق در یک چارچوب چندعاملی^{۲۹} می‌پردازد. FINCON یک سلسله‌مراتب مدیر^{۳۰} تحلیلگر، تقویت کلامی مفهومی^{۳۱} و کنترل ریسک دوسطحی معرفی می‌کند تا مقاومت، تفسیرپذیری و آگاهی از ریسک در راهبردهای مالی خودکار ارتقا یابد.

روش‌شناسی

چارچوب FINCON شامل اجزای زیر است:

□ معماری چندعاملی:

□ عوامل تحلیلگر بازار: استخراج و خلاصه‌سازی داده‌های کمی بازار (مانند قیمت سهام و متغیرهای بنیادی).

□ عوامل خبر و احساسات: پردازش اخبار مالی، گزارش‌های تحلیلی و شبکه‌های اجتماعی برای تولید بینش‌های احساسی.

□ عوامل راهبردی: تدوین اقدامات معاملاتی و پیشنهاد سبد سهام با ادغام ورودی‌های تحلیلگر و احساسات.

□ عوامل مدیریت ریسک: اعمال محدودیت‌های ریسک در سطح سبد سهام، پایش مواجهه و تضمین ایمنی.

□ عامل مدیر: تجمیع ورودی‌ها، داوری میان راهبردها و نهایی‌سازی تصمیمات معاملاتی.

□ کنترل ریسک:

□ درون‌دوره‌ای: پایش Conditional Value-at-Risk (CVaR) برای محدودکردن ریسک کوتاه‌مدت.

□ میان‌دوره‌ای: به‌روزرسانی باورها و تنظیم راهبردی برای بهبود سازگاری بلندمدت.

□ CVRF: عامل‌ها با خودانتقادی و بیان «باورهای مفهومی» در زبان طبیعی، تصمیم‌گیری‌های آینده را هدایت می‌کنند.

□ فرمول‌بندی POMDP^{۳۱}: معامله و تخصیص سبد سهام به‌عنوان POMDP مدل‌سازی می‌شوند تا عدم قطعیت‌های کلان اقتصادی و بازار لحاظ شوند.

□ بهینه‌سازی پرامپت: گرادیان نزولی متنی پرامپت‌ها را میان دوره‌ها اصلاح می‌کند تا استدلال و هماهنگی میان عامل‌ها پایدارتر شود.

²⁹Multi-Agent Framework

³⁰Conceptual Verbal Reinforcement, CVRF

³¹Partially Observable Markov Decision Process

یافته‌ها

- عملکردی بهتر از عامل‌های یادگیری تقویتی عمیق خط‌مبنا و سایر سیستم‌های مبتنی بر مدل‌های زبانی در تصمیم‌گیری مالی نشان داد.
- بهبود در Cumulative Return (CR)، Sharpe Ratio (SR) و کاهش Maximum Drawdown (MDD) گزارش شد.
- سلسله‌مراتب مدیرتحلیلگر کارایی را با کاهش سرشار ارتباط میان‌عاملی افزایش داد.
- CVRF تفسیرپذیری و تعمیم‌پذیری را در وظایف تک‌سهمی و مدیریت سبد سهام تقویت کرد.

محدودیت‌ها

- به دلیل پیچیدگی هماهنگی چندعاملی و پردازش چندوجهی ورودی‌ها، محاسبات سنگین و پرهزینه است.
- عملکرد به شدت وابسته به مهندسی پرامپت و دسترسی به داده‌های مالی باکیفیت است.
- ارزیابی تنها در قالب Backtesting تاریخی انجام شده و هیچ آزمایش معاملات زنده وجود ندارد.
- مقیاس‌پذیری به شبکه‌های بزرگ‌تر عاملی می‌تواند چالش‌های هماهنگی را تشدید کند.

سهم در پروژه من

این پژوهش ایده‌های ارزشمندی در زمینه به‌کارگیری مدل‌های زبانی بزرگ در حوزه مالی ارائه داد. به‌ویژه معرفی عامل‌های خبری و تحلیلی دید مناسبی برای توسعه اجزای مشابه در پروژه من فراهم ساخت. همچنین با توجه به اینکه FINCON یک چارچوب جامع برای مقایسه روش‌ها با معیارهای متنوع در سطح تک‌سهم و سبد سهام ارائه می‌دهد، مبنای مناسبی برای ارزیابی و مقایسه عملکرد مدل‌ها و ایده‌های پیشنهادی من ایجاد شد.

۳-۵- جمع‌بندی

این فصل پژوهش‌های مربوط به مدل‌های زبانی بزرگ و یادگیری تقویتی در حوزه مالی را مرور کرد که شامل مدل‌های حوزه‌محور پردازش زبان طبیعی مالی، کتابخانه‌های استاندارد یادگیری تقویتی و راهبردهای متنوع مبتنی بر یادگیری تقویتی عمیق در معامله‌گری بود. همچنین به رویکردهای ترکیبی نوظهوری اشاره شد که سیگنال‌های متنی و عددی را با یکدیگر ادغام می‌کنند. اگرچه این مطالعات پتانسیل ترکیب مدل‌های زبانی بزرگ و یادگیری تقویتی را نشان می‌دهند، کاربرد آن‌ها در حوزه مالی همچنان محدود است و فضای قابل توجهی برای کاوش بیشتر باقی مانده است. این بینش‌ها مستقیماً انگیزه و جهت‌گیری این پروژه را شکل می‌دهند.

فصل ۴

شرح پروژه

۴-۱- مقدمه

این فصل به تشریح جزئیات فنی پروژه می‌پردازد و معماری کلی، داده‌های مورد استفاده، محیط معاملاتی و عامل یادگیری تقویتی را معرفی می‌کند. ابتدا ساختار انتهابه‌انتها و تعامل اجزای سیستم توضیح داده می‌شود، سپس بازار هدف و روش گردآوری داده‌های مالی و خبری تشریح می‌گردد. در ادامه، فرآیند استخراج احساسات با استفاده از مدل‌های زبانی مالی، طراحی محیط معاملاتی و تعریف توابع پاداش ارائه می‌شوند. در نهایت، عامل‌های یادگیری تقویتی، روش پایش آموزش و چارچوب استقرار سامانه معرفی خواهند شد تا بستر کامل آزمایش‌ها و تحلیل‌ها فراهم آید.


۴-۲- معماری کلی سیستم

نمای کلی. شکل (۴-۱) معماری انتها به انتها سیستم را نشان می‌دهد. داده‌های بازار (از Google News و Yahoo Finance) گردآوری شده و بر اساس زمان هم‌تراز می‌شوند. اخبار توسط دو مدل احساسی مبتنی بر مدل‌های زبانی بزرگ، یعنی FinGPT و FinBERT، امتیازدهی می‌شوند تا ویژگی‌های احساسی مکمل تولید شود. تمامی ویژگی‌ها (شامل OHLCV، شاخص‌های فنی و احساسات) پس از مرحله‌ی پیش‌پردازش و نرمال‌سازی در نمایش حالت محیط معاملاتی ادغام می‌گردند. یک عامل یادگیری تقویتی (RPPPO / PPO با استفاده از Stable-Baselines3) با محیط تعامل کرده و تحت قوانین صریح ریسک (آستانه‌های نرم/سخت آشفستگی) و هزینه‌های تراکنش، تخصیص‌های هدف را تولید می‌کند. پس از پایان آموزش، بخش ارزیابی معیارهای مالی Sharpe، CAGR و Max Drawdown را بر روی داده‌های خارج از نمونه محاسبه می‌نماید. در نهایت، نتایج و پیش‌بینی‌های زنده از طریق داشبورد Streamlit و سرویس FastAPI در دسترس قرار می‌گیرند.

تعامل اجزا.

۱. گردآوری داده‌ها. مقالات Google News با استفاده از یک خزنده اختصاصی همراه با فیلتر نماد/تاریخ جمع‌آوری می‌شوند؛ داده‌های روزانه OHLCV نیز از طریق API در Yahoo Finance دریافت می‌گردند. تمام داده‌ها در زمان UTC برچسب‌گذاری و به نمادهای مربوطه نگاشت می‌شوند.

۲. احساس مبتنی بر مدل‌های زبانی بزرگ. هر مقاله یا تیتیر به دو مدل ارسال می‌شود: FinGPT یک توزیع احتمالی $P(pos, neg, neu)$ تولید می‌کند؛ FinBERT نیز توزیع مشابهی روی سه برچسب گزارش می‌کند. این سیگنال‌ها برای هر دارایی تجمیع و با داده‌های معاملاتی هم‌تراز می‌شوند.



شکل (۱-۴) معماری کلی سیستم

۳. پیش‌پردازش و ترکیب ویژگی‌ها. داده‌ها یکتاسازی و پاک‌سازی می‌شوند، شاخص‌های فنی (MACD, EMA, Bollinger width, ATR, RSI, OHLCV) و احساس ادغام می‌گردند.

۴. محیط. محیطی مشابه Gym تعریف شده است که حالت ترکیبی شامل وجه نقد، دارایی‌ها، شاخص‌های فنی، احساسات و شاخص‌های ریسک را در اختیار عامل قرار می‌دهد. همچنین محدودیت‌های عمل مانند وزن‌های softmax با سقف تخصیص برای هر دارایی و ممنوعیت فروش استقراری، هزینه‌های تراکنش (۱٪) برای خرید و فروش و قوانین مدیریت ریسک (آشفته‌گی نرم و سخت) در آن اعمال می‌شوند.

۵. عامل یادگیری تقویتی. عامل با استفاده از الگوریتم‌های PPO و RPPO (در بخش contrib از Stable-Baselines3) آموزش داده می‌شود.

۶. مدیریت سبد دارایی. اعمال عامل به سفارش‌های صحیح سهام تبدیل شده، هزینه‌ها لحاظ شده و وضعیت سبد (وجه نقد/دارایی‌ها/سود و زیان) به‌روزرسانی می‌گردد.

۷. ارزیابی. روی مجموعه آزمون مجزا، مازول ارزیابی مجدداً قیمت‌ها را از Yahoo Finance واکشی کرده، معیارهای مالی Sharpe, CAGR و Max Drawdown را محاسبه و با خط‌پایه‌ها (مانند فقط OHLCV بدون احساس) مقایسه می‌کند.

۸. ارائه. نتایج و در صورت نیاز پیش‌بینی زنده از طریق داشبورد Streamlit و سرویس FastAPI در اختیار قرار می‌گیرند.

منطق طراحی. دو کانال احساسی (احتمالات FinGPT و FinBERT) سیگنال‌های مکمل فراهم می‌کنند؛ ادغام آن‌ها با OHLCV و شاخص‌های فنی، فضای حالت را غنی‌تر می‌سازد بدون آن‌که نشت اطلاعات آینده رخ دهد. اعمال کنترل‌های صریح آشفته‌گی و هزینه‌های تراکنش موجب واقع‌گرایی در پویایی آموزش می‌شوند. بخش ارزیابی داده‌های قیمتی را دوباره واکشی می‌کند تا جداسازی شفاف میان داده‌های آموزش و آزمون تضمین گردد. در نهایت، جداسازی بخش ارائه (FastAPI/Streamlit) از آموزش، امکان آزمایش‌های آفلاین بازتولیدپذیر و استقرار مازولار را فراهم می‌سازد.

۴-۳- توصیف بازار انتخاب‌شده

در ابتدا، بازار رمزارزها به‌عنوان محیط هدف انتخاب شد و Bitcoin به‌عنوان دارایی اصلی در نظر گرفته شد. روش‌های پایه‌ی یادگیری تقویتی روی این بازار پیاده‌سازی شدند و حتی تحلیل احساسات با استفاده از مدل‌های زبانی بزرگ نیز به آن اضافه گردید. با این حال، نتایج بهبود معناداری نشان ندادند. با بررسی‌های بیشتر دریافتم که بازار رمزارزها نوسان بسیار بالا و پیچیدگی زیادی دارد که دستیابی به نتایج پایدار و سازگار را دشوار می‌سازد. بنابراین تصمیم گرفتم تمرکز پژوهش را به بازار دیگری تغییر دهم.

پس از انجام تحقیقات بیشتر، بازار سهام ایالات متحده و به‌طور مشخص شاخص Dow Jones Industrial Average (DOW30) انتخاب شد. برای ساده‌سازی دامنه و کاهش پیچیدگی ناشی از کار با تعداد زیاد سهام، یک زیرمجموعه شامل چهار شرکت انتخاب شد: Apple (AAPL), JPMorgan Chase (JPM), Boeing (BA) و Goldman Sachs (GS). این انتخاب به‌طور هدفمند انجام شد تا دو سهم با پوشش خبری فراوان (JPM و AAPL) و دو سهم با دسترسی محدودتر به اخبار (GS و BA) در بر گرفته شوند.

علاوه بر این، تحلیل در این پروژه بر مبنای داده‌های روزانه انجام شد و از داده‌های با فرکانس بالاتر مانند ساعتی یا دقیقه‌ای استفاده نگردید. انتخاب داده‌های روزانه به دلایل زیر صورت گرفت:

۱. پردازش آن ساده‌تر و از نظر محاسباتی کم‌هزینه‌تر است.
 ۲. اثر نویزهای کوتاه‌مدت و نوسانات شدید را کاهش می‌دهد.
 ۳. نسبت به داده‌های با بسامد بالا در دسترس‌تر و قابل‌اعتمادتر است.
 ۴. هم‌سویی بیشتری با منابع اطلاعاتی بیرونی مانند اخبار و تحلیل احساسات دارد که غالباً به‌صورت روزانه منتشر می‌شوند.
 ۵. نتایج پایدارتر و قابل‌تفسیرتری برای ارزیابی راهبردهای معاملاتی فراهم می‌کند.
- مراحل بعدی این پروژه با استفاده از این زیرمجموعه سهام به‌عنوان محیط اصلی انجام گرفت.

۴-۴- جمع‌آوری داده

داده‌های موردنیاز این پروژه به دو دسته اصلی تقسیم می‌شوند:

□ داده‌های فنی بازار

□ داده‌های مرتبط با اخبار

برای داده‌های فنی، شاخص‌های استاندارد مالی مانند Open, Close, Low, High, Volume (OCLHV)، شاخص نوسان (Volatility Index, VIX) و شاخص آشفتگی (Turbulence Index) گردآوری شدند. این مجموعه داده‌ها از Yahoo Finance و با استفاده از کتابخانه‌های پایتون استخراج گردیدند که یک منبع رایگان، معتبر و دارای مستندات کافی برای اطلاعات بازار مالی محسوب می‌شود. بخش چالش‌برانگیزتر جمع‌آوری داده مربوط به اخبار مالی بود. دسترسی به منابع باکیفیت اخبار مالی اغلب مستلزم اشتراک‌های گران‌قیمت است و خزیدن در چنین وبسایت‌هایی معمولاً به دلیل تدابیر امنیتی و ضدبات با محدودیت مواجه می‌شود. در بازار رمزارزها، من از وبسایت <https://cryptoslate.com/> استفاده کردم که امکان فیلترگذاری بر اساس رمزارزهای مختلف را فراهم می‌کرد. از طریق این منبع توانستم اخبار مرتبط با Bitcoin را در بازه‌ای دوساله (از ابتدای ۲۰۲۴ تا ۲۰۲۵) استخراج کنم. این داده‌های استخراج‌شده به‌صورت عمومی در دسترس قرار گرفته‌اند (لینک اضافه خواهد شد).

در مقابل، بازار سهام ایالات متحده چالش بزرگ‌تری ایجاد کرد، چراکه بیشتر رسانه‌های معتبر مالی محدودیت‌های سخت‌گیرانه‌تری داشتند و جمع‌آوری داده به‌صورت نظام‌مند را دشوار می‌ساختند. برای حل این مشکل، از Google News استفاده شد که فیلترهای جست‌وجوی منعطفی برای نماد سهام، بازه زمانی و مرتب‌سازی بر اساس ارتباط یا اعتبار منبع ارائه می‌دهد. با این روش توانستم اخبار مرتبط با چهار شرکت منتخب (AAPL, JPM, BA, GS) را در بازه ۲۰۱۰ تا ۲۰۲۵ جمع‌آوری کنم.

مجموعه داده استخراج‌شده شامل فیلدهای زیر است: عنوان خبر، خلاصه، لینک، تاریخ انتشار، finbert_label، finbert_score، fingpt_label و fingpt_score. جزئیات مربوط به تولید این امتیازهای احساسی در بخش استخراج احساس از اخبار توضیح داده خواهد شد. برای فرآیند web scraping از کتابخانه Selenium در پایتون استفاده شد که امکان مرور خودکار و استخراج داده از هر دو منبع CryptoSlate و Google News را فراهم ساخت. داده‌های پردازش‌شده نهایی ذخیره و به‌اشتراک گذاشته شده‌اند (لینک اضافه خواهد شد).

۴-۵- تحلیل داده

تحلیل اصلی در این پروژه بر بررسی رابطه میان امتیازهای احساسی و تغییرات قیمتی بعدی در طول زمان متمرکز بود. به طور خاص، بررسی شد که آیا احساس استخراج شده از اخبار می تواند به پیش بینی بازدهی های آتی سهام کمک کند یا خیر.

برای این منظور از تحلیل علیت Granger بر پایه مدل Vector Autoregression (VAR) استفاده شد. آزمون Granger causality test یک روش آماری است که تعیین می کند آیا یک سری زمانی می تواند اطلاعات پیش بینانه برای سری زمانی دیگر فراهم کند یا خیر. به عبارت دیگر، اگر وارد کردن مقادیر گذشته ای امتیاز احساس پیش بینی بازدهی سهام را نسبت به حالتی که تنها از بازدهی های گذشته استفاده شود بهبود دهد، آنگاه گفته می شود سری احساسی Granger-cause بازدهی است. این رویکرد امکان آزمون هم زمان قدرت پیش بینی چندین ویژگی احساسی را با در نظر گرفتن وابستگی های با وقفه فراهم می سازد.

پیش از انجام این تحلیل لازم است همه متغیرها ایستا باشند، یعنی خواص آماری آن ها (میانگین، واریانس) در طول زمان تغییر نکنند. برای دستیابی به ایستایی، تحلیل بر روی بازدهی ها (اختلاف لگاریتمی قیمت های پایانی متوالی) به جای قیمت های خام انجام شد. به طور مشابه، امتیازهای احساسی حاصل از FinBERT و FinGPT در سطح روزانه تجمیع شده و با استفاده از میانگین متحرک (با پنجره ۷ روزه و نیمه عمر ۰.۵ روز) هموار شدند تا اثر اخبار طی چند روز بعدی بازتاب داده شود.

ایستایی هر سری زمانی با آزمون Augmented Dickey-Fuller (ADF) بررسی شد. این آزمون فرض صفر مبنی بر وجود ریشه واحد در سری (یعنی نایستایی) را ارزیابی می کند. در صورت رد فرض صفر، سری ایستا محسوب شده و برای مدل سازی VAR مناسب خواهد بود.

با این روش، توانستم عملکرد پیش بینی امتیازهای احساسی FinBERT و FinGPT را در ارتباط با بازدهی های روزانه سهام مقایسه و ارزیابی کنم. روش شناسی دقیق استخراج این امتیازها از اخبار در بخش استخراج احساس از اخبار تشریح خواهد شد. نتایج آزمون ها و ارزیابی های پیش بینانه در فصل آزمایش ها و نتایج ارائه و بحث می شوند.

۴-۶- استخراج احساس از اخبار

در این پروژه از دو مدل زبانی تخصصی در حوزه مالی برای تحلیل احساسات استفاده شده است: **FinBERT** و **FinGPT**. هر دو مدل یک توزیع احتمالی روی برچسب های positive, negative و neutral ارائه می کنند، اما از نظر معماری، تعداد پارامترها، داده های آموزش دیده و پیچیدگی در مرحله استنتاج، تفاوت های قابل توجهی با یکدیگر دارند.

۴-۶-۱- FinBERT

FinBERT یک Transformer از نوع فقط رمزگذار است که بر پایه BERT-base ساخته شده و برای حوزه مالی بازآموزی شده است. این مدل از پیکربندی استاندارد BERT (۱۲ لایه، ۱۲ سر توجه، اندازه بردار پنهان ۷۶۸ و حدود ۱۱۰ میلیون پارامتر) استفاده می کند. FinBERT ابتدا با متون مالی در مقیاس بزرگ پیش تمرین داده شده و سپس روی مجموعه داده های برچسب خورده ای مانند Financial PhraseBank برای طبقه بندی احساس ریز تنظیم شده است. در نسخه عمومی ProsusAI/finbert، لایه نهایی یک توزیع softmax روی سه برچسب positive, negative و neutral تولید می کند [۲].

۴-۶-۲- FinGPT (Llama 3 + LoRA adapters)

FinGPT یک مدل زبانی بزرگ از نوع فقط رمزگذار است که بر پایه meta-llama/Meta-Llama-3-8B ساخته شده و با استفاده از LoRA adapters و ریزتنظیم مبتنی بر دستورالعمل برای حوزه مالی سازگار گردیده است. مدل FinGPT/fingpt-mt_llama3-8b_lora ماژول‌های سبک LoRA را به مدل پایه متصل می‌کند و این امکان را فراهم می‌سازد که تنها با تعداد کمی پارامتر قابل آموزش، انطباق دامنه‌ای انجام شود. ابتکار FinGPT یک رویکرد داده‌محور دارد: گردآوری خودکار داده‌های مالی (مانند اخبار، گزارش‌ها، شبکه‌های اجتماعی و جفت‌های پرسش و پاسخ) و سپس سازگاری مدل‌های بازمتن. برای تحلیل احساس، FinGPT آموزش دیده است که دستورالعمل‌ها را دنبال کند و یکی از برچسب‌های negative, positive یا neutral را تولید نماید [۳].

۴-۶-۳- امتیازدهی عددی احساسات

برای هر دو مدل، خروجی خام یک توزیع احتمالی روی سه کلاس احساسی است. برای تبدیل این توزیع به یک امتیاز عددی منفرد، یک رویکرد ساده و کارآمد به کار گرفته شد: اختلاف میان احتمال پیش‌بینی شده کلاس‌های positive و negative به صورت رسمی:

$$SentimentScore = P(positive) - P(negative).$$

این تعریف تضمین می‌کند که امتیازهای بالاتر نشان‌دهنده احساس مثبت‌تر، امتیازهای پایین‌تر بیانگر احساس منفی‌تر و مقادیر نزدیک به صفر معادل با حالت خنثی خواهند بود.

۴-۷- محیط معاملاتی

۴-۷-۱- محیط معاملاتی سفارشی‌سازی شده

به عنوان نقطه آغاز، از محیط متن‌باز موجود در کتابخانه FinRL^۱ استفاده شد. به دلیل متن‌باز بودن، این محیط به طور گسترده سفارشی‌سازی گردید. اصلاحات اصلی شامل موارد زیر بودند:

- طراحی مجدد فضای حالت با افزودن ویژگی‌های فنی، احساسی و ریسکی.
- بازتعریف تابع پاداش برای بازتاب بهتر عملکرد سبد سهام.
- پیاده‌سازی یک سازوکار کنترل ریسک مبتنی بر آشفتگی بازار.
- پشتیبانی از آموزش چندمحیطی به منظور بهبود پایداری.
- تصادفی‌سازی دوره‌ها با تاریخ‌های شروع و طول‌های متغیر.
- یک سازوکار اجرای عمل جدید بر پایه وزن‌های سبد سهام.

^۱https://github.com/AI4Finance-Foundation/FinRL/blob/master/finrl/meta/env_stock_trading/env_stocktrading.py

۴-۷-۲- فضای حالت

نمایش نهایی حالت شامل ادغام شاخص‌های فنی، معیارهای ریسک، سیگنال‌های احساسی و اطلاعات سبد سهام است. هر ویژگی استانداردسازی می‌شود تا قابلیت مقایسه بین سهام مختلف فراهم گردد. شاخص‌های فنی با استفاده از کتابخانه متن‌باز ^۲ta محاسبه شدند که پیاده‌سازی کارآمدی از شاخص‌های فنی استاندارد بازار ارائه می‌دهد. مجموعه کامل ویژگی‌ها عبارت است از:

□ **20-day momentum (mom_20d)**: تغییر نسبی قیمت طی ۲۰ روز گذشته برای ثبت تکانه کوتاه‌مدت.

□ **Exponential Moving Averages (ema_20, ema_60)**: روندهای قیمتی کوتاه‌مدت و میان‌مدت.

□ **MACD و signal line**: شاخص‌های تکانه برای شناسایی تغییر روند.

□ **Relative Strength Index (RSI, 14-day)**: نوسانگر برای تشخیص شرایط اشباع خرید یا فروش.

□ **Average True Range (ATR, 14-day)**: معیاری از نوسان بازار بر اساس دامنه‌های معاملاتی.

□ **Bollinger Band Width**: شاخص نوسان مبتنی بر فاصله میان باندهای بولینگر.

□ **Normalized closing price (zclose_60)**: قیمت پایانی نرمال‌شده نسبت به پنجره ۶۰ روزه.

□ **Daily return (ret_1d)**: بازدهی یک‌روزه برای سنجش عملکرد کوتاه‌مدت دارایی.

□ **Sentiment scores (finbert_future, fingpt_future)**: امتیازهای احساسی استخراج‌شده از اخبار مالی توسط FinBERT و FinGPT.

□ **On-Balance Volume (OBV)**: شاخص مبتنی بر حجم برای نشان دادن جریان سرمایه.

□ **Normalized VIX**: شاخص نوسان بازار به‌عنوان نماینده ریسک سیستماتیک.

□ **Portfolio state**: تعداد نرمال‌شده سهام هر دارایی و موجودی نقدی نرمال‌شده.

۴-۷-۳- تابع پاداش

در این کار از دو تعریف ساده برای پاداش استفاده شده است:

۱. بازدهی نرمال‌شده سبد سهام در طول دوره (**episode-normalized return**). در این روش تغییر ارزش سبد سهام نسبت به ابتدای دوره محاسبه و متناسب با طول دوره مقیاس‌دهی می‌شود:

$$R^{\square} = \frac{A_{end} - A_{begin}}{A_{begin} + \varepsilon} \times \frac{n_{days}}{L} \times \kappa,$$

^۲<https://github.com/bukosabino/ta>

که در آن A_{begin} و A_{end} به ترتیب ارزش سبد سهام در آغاز و پایان دوره هستند، L طول دوره (به تعداد روز/گام)، n_{days} ضریب نرمال سازی زمانی، κ ثابت reward scaling و ε یک مقدار کوچک برای پایداری عددی است.

۲. **بازدهی لگاریتمی یک گامی (one-step log return).** در این روش پاداش هر گام زمانی بر اساس بازدهی لحظه ای سبد سهام تعریف می شود و برای ریسک گریزی، از لگاریتم استفاده می گردد:

$$r_t = \log(\max(10^{-3}, 1 + \rho_t)) \times \kappa, \quad \rho_t = \frac{A_t - A_{t-1}}{A_{t-1} + \varepsilon},$$

که در آن A_t ارزش سبد سهام در انتهای گام t است. در گام نخست، اگر A_{t-1} در دسترس نباشد، بازدهی یک گام به صورت امن مقداردهی می شود تا از ناپایداری عددی جلوگیری گردد.

۴-۷-۴ کنترل ریسک با استفاده از آشفستگی

برای مدیریت ریسک در دوره های پرنوسان، یک سازوکار مبتنی بر آشفستگی به کار گرفته شد. آشفستگی شرایط غیرعادی بازار را از طریق مقایسه حرکات قیمتی با کوواریانس تاریخی کمی سازی می کند. دو آستانه در نظر گرفته شد:

□ **آستانه نرم** ($\tau_{soft} = 70$): در صورت عبور، هیچ دستور خرید جدیدی اجرا نمی شود.

□ **آستانه سخت** ($\tau_{hard} = 100$): در صورت عبور، همه موقعیت های موجود نقد می شوند و خریدهای بعدی مسدود می گردند.

این سازوکار باعث می شود عامل در شرایط بحرانی رفتار محافظه کارانه تری داشته باشد.

۴-۷-۵ تصادفی سازی دوره

محیط پیش فرض FinRL دوره ها را به صورت بازه های ثابت تعریف می کند که از نخستین روز معاملاتی آغاز شده و در آخرین روز داده ها پایان می یابند. اگرچه این رویکرد یک ساختار آموزشی سازگار فراهم می کند، اما تنوع شرایط بازاری تجربه شده توسط عامل را محدود می سازد. برای رفع این محدودیت، **تصادفی سازی دوره ها** معرفی گردید. به صورت رسمی، فرض کنید T تعداد کل روزهای معاملاتی در مجموعه داده و L_{min} حداقل طول مجاز دوره باشد. در ابتدای هر دوره، یک روز شروع s به صورت تصادفی از توزیع یکنواخت انتخاب می شود:

$$s \sim \text{Uniform}(0, T - L_{min}).$$

سپس طول دوره L از بازه زیر نمونه گیری می شود:

$$L \sim \text{Uniform}(L_{min}, T - s).$$

دور از s تا $s + L$ ادامه می یابد تا قید حداقل طول رعایت شود. با احتمال کم، کل مجموعه داده مورد استفاده قرار می گیرد ($L = T, s = 0$) تا سازگاری با تنظیمات اولیه حفظ شود.

این استراتژی تنوع بیشتری در زیربازه های بازار به عامل معرفی می کند و باعث بهبود تعمیم با:

□ جلوگیری از بیش برآزش روی الگوهای زمانی خاص.

□ شبیه سازی شرایط آموزشی نزدیک تر به معامله گری واقعی، که تاریخ شروع و افق زمانی متغیر هستند.

□ افزایش مقاومت در برابر رژیم های متفاوت نوسان و چرخه های بازار.

۴-۷-۶ سازوکار اجرای عمل

در پیاده‌سازی پیش‌فرض FinRL، عمل برای هر سهم i یک عدد منفرد $a_i \in [-1, 1]$ است که در یک ثابت $h_{\max}$ ضرب می‌شود تا تعداد سهام خریداری یا فروخته‌شده تعیین گردد. این شیوه چند محدودیت جدی دارد:

□ با ارزش کل سبد سهام مقیاس‌پذیر نیست.

□ تفاوت قیمت سهام را در نظر نمی‌گیرد.

□ عامل را به حجم‌های ثابت معامله محدود می‌کند، بدون توجه به شرایط بازار.

برای رفع این محدودیت‌ها، عمل به‌صورت یک مسئله تخصیص سبد سهام بازنویسی شد. بردار اولیه اعمال به‌صورت $\mathbf{z} \in \mathbb{R}^N$ (به‌همراه یک مؤلفه مربوط به وجه نقد) تعریف می‌شود. سپس این مقادیر به وزن‌های نرمال شده $\mathbf{w}$ با استفاده از تبدیل softmax تبدیل می‌گردند:

$$w_i = \frac{\exp(z_i)}{\sum_{j=1}^{N+1} \exp(z_j)}, \quad i = 1, \dots, N+1,$$

به‌طوری که $\sum_{i=1}^{N+1} w_i = 1$.

برای جلوگیری از تمرکز بیش‌ازحد روی یک دارایی خاص، سقف تخصیص اعمال می‌شود:

$$w_i^{\text{capped}} = \min(w_i, c), \quad c = 0.5.$$

بر این اساس، مقدار هدف برای سرمایه‌گذاری در سهم i به‌صورت زیر محاسبه می‌شود:

$$d_{i,t} = w_i^{\text{capped}} \cdot A_t,$$

که در آن A_t ارزش فعلی سبد سهام است. تعداد سهام هدف نیز به‌صورت زیر تعیین می‌گردد:

$$q_{i,t}^{\text{target}} = \left\lfloor \frac{d_{i,t}}{p_{i,t}} \right\rfloor,$$

که در آن $p_{i,t}$ قیمت سهم در زمان t است. اختلاف با وضعیت فعلی حجم معامله لازم را مشخص می‌کند:

$$\Delta q_{i,t} = q_{i,t}^{\text{target}} - q_{i,t}^{\text{current}}.$$

پس از آن، آستانه‌های آشفستگی (بخش ۴-۷-۶) اعمال می‌شوند:

□ اگر آشفستگی $> \tau_{\text{hard}}$ باشد: همه $q_{i,t}$ برابر صفر می‌شوند (تصفیه کامل).

□ اگر $\tau_{\text{soft}} \leq$ آشفستگی $\leq \tau_{\text{hard}}$: هیچ دستور خریدی اجرا نمی‌شود و تنها فروش مجاز است، یعنی $\Delta q_{i,t} = \min(0, \Delta q_{i,t})$.

این بازنویسی چند مزیت کلیدی دارد:

□ اعمال متناسب با ارزش سبد سهام و قیمت دارایی‌ها مقیاس می‌شوند.

□ عامل به‌جای انتخاب تعداد دلخواه سهام، یک راهبرد تخصیص بهینه می‌آموزد.

□ ریسک به‌طور مستقیم با استفاده از سقف تخصیص و کنترل آشفستگی مدیریت می‌شود.

۴-۷-۷- جمع‌بندی

محیط سفارشی‌شده در این پروژه دارای مزایای زیر است:

- نمایش حالت جامع و پر جزئیات با ترکیب داده‌های فنی، احساسی و ریسک.
 - تعریف توابع پاداش که مستقیماً با عملکرد سبد سهام ارتباط دارند.
 - مدیریت ریسک شفاف و مؤثر بر پایه شاخص آشفتگی بازار.
 - افزایش تنوع آموزشی از طریق تصادفی‌سازی دوره‌ها و شرایط شروع.
 - سازوکار اجرای عمل پایدار و انعطاف‌پذیر بر مبنای وزن‌های سبد سهام.
- برای پیاده‌سازی از کتابخانه Gymnasium استفاده شد که یکپارچگی کامل با اغلب عامل‌ها و چارچوب‌های یادگیری تقویتی را امکان‌پذیر می‌سازد و سازگاری کامل با محیط معاملاتی سفارشی تضمین می‌کند.

۴-۸-۱- عامل یادگیری تقویتی

برای پیاده‌سازی عامل یادگیری تقویتی از کتابخانه Stable-Baselines3 (SB3)^۳ و توسعه آن sb3-contrib استفاده شد. این کتابخانه‌ها پیاده‌سازی‌های قابل‌اعتماد از الگوریتم‌های یادگیری تقویتی را ارائه داده و تعامل کامل با چارچوب Gymnasium را فراهم می‌کنند، در نتیجه سازگاری کامل با محیط معاملاتی سفارشی تضمین می‌شود.

۴-۸-۱-۱- چارچوب پیاده‌سازی

برای عامل یک پوسته‌ی نرم‌افزاری (wrapper) اختصاصی طراحی شد تا اجرای آزمایش‌ها با الگوریتم‌های مختلف ساده‌تر شود. این پوسته امکانات اصلی زیر را فراهم می‌کند:

- **مقداردهی مدل:** بارگذاری مدل‌های یادگیری تقویتی با استفاده از ابرپارامترهای پیش‌فرض یا تنظیم‌شده توسط کاربر.
- **آموزش:** اجرای فرآیند آموزش همراه با ثبت گزارش‌ها و استفاده از مکانیزم‌های بازخوانی (callback) برای پایش روند یادگیری.
- **پیش‌بینی:** اجرای مدل روی داده‌های بازار جدید (که در آموزش استفاده نشده‌اند) و ثبت تغییرات سبد سهام و معاملات انجام‌شده.

۴-۸-۲- الگوریتم‌های ارزیابی‌شده

چندین الگوریتم یادگیری تقویتی از SB3 و sb3-contrib روی مجموعه داده اعتبارسنجی ارزیابی شدند، از جمله:

□ TD3, SAC, PPO, A2C (از SB3)

□ TRPO, CrossQ, RecurrentPPO (از sb3-contrib)

^۳<https://github.com/DLR-RM/stable-baselines3>

از میان این الگوریتم‌ها، دو مورد بر اساس عملکرد در اعتبارسنجی برای آزمایش‌های نهایی انتخاب شدند: Proximal Policy Optimization (PPO) و Recurrent Proximal Policy Optimization (RecurrentPPO).

PPO. یک روش مبتنی بر گرادینت سیاست است که با محدودسازی به‌روزرسانی‌های سیاست از طریق تابع هدف برش‌یافته (clipped surrogate objective)، آموزش را پایدار می‌سازد. این امر از به‌روزرسانی‌های بیش‌ازحد بزرگ جلوگیری کرده و تعادلی میان اکتشاف و بهره‌برداری برقرار می‌کند. به دلیل سادگی و پایداری، PPO به یکی از پرکاربردترین الگوریتم‌ها در مسائل کنترل پیوسته از جمله معامله‌گری مالی تبدیل شده است.

RecurrentPPO. چارچوب PPO را با افزودن شبکه‌های عصبی بازگشتی (مانند LSTM) به معماری سیاست گسترش می‌دهد. این ارتقاء به عامل امکان می‌دهد وابستگی‌های زمانی را ثبت کرده و اطلاعات حالت‌های گذشته را حفظ کند، که در بازارهای مالی بسیار سودمند است زیرا زمینه تاریخی و الگوهای سری‌های زمانی در تصمیم‌گیری نقش دارند.

۴-۸-۳ - بهینه‌سازی ابرپارامترها

عملکرد الگوریتم‌های یادگیری تقویتی به شدت به انتخاب ابرپارامترها (مانند نرخ یادگیری، ضریب تنزیل، اندازه دسته و بازه برش) حساس است. برای تنظیم نظام‌مند این پارامترها، از کتابخانه Optuna^۴ استفاده شد. جست‌وجوی ابرپارامترها روی مجموعه اعتبارسنجی انجام گرفت تا پیکربندی‌های مقاوم به‌دست آید و از بیش‌برازش جلوگیری شود. ابرپارامترهای بهینه و نتایج متناظر آن‌ها در فصل آزمایش‌ها و نتایج گزارش خواهند شد.

۴-۹-۹ - پایش

پایش یکی از مؤلفه‌های کلیدی در آموزش و ارزیابی مدل‌های یادگیری تقویتی است، به‌ویژه در حوزه مالی که عملکرد مدل‌ها به شدت به ابرپارامترها و شرایط متغیر بازار وابسته است. برای این منظور، یک چارچوب پایش بهبودیافته طراحی شد که قابلیت‌های پایه موجود در کتابخانه FinRL را گسترش می‌دهد.

۴-۹-۱ - رویکرد

پیشرفت فرایند آموزش با استفاده از مکانیزم‌های **بازخوانی** (callback) دنبال شد. این مکانیزم‌ها سیگنال‌های کلیدی مانند پاداش‌ها، طول دوره‌ها و نرخ‌های یادگیری را ثبت می‌کنند. سپس این داده‌ها با ابزارهای بصری‌سازی مانند TensorBoard و Weights & Biases (W&B) یکپارچه شدند تا امکان بررسی بلادرنگ روند یادگیری فراهم گردد. در مقایسه با پیکربندی پیش‌فرض، این چارچوب پایش بهبودیافته دید دقیق‌تر و قابل‌اعتمادتری از رفتار مدل در طول آموزش ارائه می‌دهد.

۴-۹-۲ - مزایا

این چارچوب پایش امکانات زیر را فراهم کرد:

□ شناسایی زودهنگام بی‌ثباتی یا واگرایی در روند آموزش.

□ مقایسه منظم و دقیق الگوریتم‌ها و پیکربندی‌های مختلف ابرپارامتر.

^۴<https://optuna.org/>

□ ارزیابی شفاف‌تر عملکرد مدل در مراحل گوناگون آموزش و اعتبارسنجی.

۴-۱۰-۱-۰ - ارائه و استقرار

برای استفاده عملی از مدل‌های آموزش‌دیده یادگیری تقویتی، یک پایپلاین ارائه و استقرار طراحی شد. این سیستم از دو بخش اصلی تشکیل شده است:

□ بخش (Backend): پیاده‌سازی‌شده با FastAPI، مسئول اجرای مدل و پاسخ به درخواست‌ها.

□ بخش (Frontend): ساخته‌شده با Streamlit، برای نمایش نتایج و تعامل ساده با کاربر.

۴-۱۰-۱-۱ - بخش Backend

این بخش مدل‌های آموزش‌دیده را بارگذاری کرده و از طریق رابط‌های برنامه‌نویسی کاربردی (API) در دسترس قرار می‌دهد. وظایف اصلی آن عبارت‌اند از:

□ اجرای مدل: دریافت داده ورودی و بازگرداندن تصمیم‌های معاملاتی پیشنهادی.

□ مدیریت سبد سهام: واکنشی و نمایش موقعیت‌های باز و بسته.

□ آماده‌سازی داده: هماهنگ کردن داده‌های ورودی با قالب مورد انتظار مدل.

۴-۱۰-۲-۱ - بخش Frontend

این بخش یک رابط تعاملی و ساده برای کاربران فراهم می‌کند و شامل سه قسمت اصلی است:

۱. نمودار قیمت: نمایش قیمت پایانی هر سهم در بازه انتخاب‌شده.

۲. تحلیل فنی: محاسبه و نمایش شاخص‌ها و ویژگی‌های فنی منتخب.

۳. اقدامات معاملاتی: نمایش خرید و فروش‌های پیشنهادی عامل در بازه انتخاب‌شده.

۴-۱۰-۳-۱ - جمع‌بندی

این چارچوب امکان استفاده کامل از عامل معاملاتی را فراهم می‌کند. بخش پشتی مسئول اجرای مدل و پاسخگویی به درخواست‌هاست، در حالی که بخش کاربری نتایج را به‌صورت تصویری و قابل‌فهم برای کاربر نمایش می‌دهد.

۴-۱۱-۱ - جمع‌بندی

در این فصل، تمامی اجزای اصلی پروژه از گردآوری داده تا استقرار نهایی شرح داده شدند. معماری کلی سیستم، انتخاب بازار و داده‌ها، طراحی محیط و عامل یادگیری تقویتی و همچنین فرآیند پایش و ارائه بررسی شدند. این مجموعه عناصر، چارچوبی منسجم و بازتولیدپذیر برای آزمون و ارزیابی راهبردهای معاملاتی مبتنی بر یادگیری تقویتی فراهم ساختند و زمینه لازم برای ارائه نتایج در فصل بعدی را مهیا کردند.

فصل ۵

پیاده‌سازی

۵-۱- مقدمه

این فصل جزئیات پیاده‌سازی سامانه پیشنهادی را ارائه می‌دهد. ابتدا ابزارها و کتابخانه‌های اصلی معرفی می‌شوند، سپس روش‌های تضمین بازتولیدپذیری نتایج و منابع محاسباتی مورد استفاده تشریح خواهند شد. در پایان نیز پیکربندی محاسباتی و تنظیمات اصلی آموزش بیان می‌شود تا ارتباط میان مباحث نظری و نتایج تجربی برقرار گردد.

۵-۲- ابزارها و چارچوب‌ها

پیاده‌سازی پروژه در Python 3 انجام شد که یک چارچوب غنی برای علم داده، یادگیری تقویتی و استقرار فراهم می‌کند. جدول (۵-۱) ابزارها و کتابخانه‌های اصلی مورد استفاده را نشان می‌دهد که بر اساس کارکرد گروه‌بندی شده‌اند.

دسته‌بندی	ابزارها و کاربرد
گردآوری داده	yfinance □ دریافت داده‌های OHLCV از Yahoo Finance API Selenium □ جمع‌آوری اخبار Google News با فیلتر نماد/تاریخ/ارتباط.
پردازش داده و ویژگی‌ها	pandas, numpy □ پردازش، پاک‌سازی و نرمال‌سازی داده‌ها. ta □ محاسبه شاخص‌های فنی (ATR, RSI, MACD, EMA, Bollinger). json □ ذخیره‌سازی تنظیمات و نتایج.
محیط	gymnasium □ رابط پایه محیط‌های یادگیری تقویتی. FinRL □ نمونه‌سازی سریع و سفارشی‌سازی محیط‌های معاملاتی.
یادگیری تقویتی	stable_baselines3 □ پیاده‌سازی الگوریتم‌هایی مانند PPO, DQN, A2C. sb3-contrib □ توسعه RPPPO. torch □ موتور یادگیری عمیق برای آموزش مدل و ذخیره‌سازی نقاط واریسی.
بهینه‌سازی ابرپارامترها	Optuna □ تنظیم خودکار ابرپارامترها بر داده اعتبارسنجی.
ردیابی آزمایش‌ها	wandb (Weights & Biases) □ ثبت، مصورسازی و مقایسه آزمایش‌ها.
ارزیابی و مقایسه	scipy □ ابزارهای عددی برای ارزیابی. PyPortfolioOpt (pypfopt) □ خط‌مبنای بهینه‌سازی میانگین-واریانس.
مصورسازی	seaborn, matplotlib □ ترسیم نمودارهای ایستا از عملکرد. plotly □ نمودارهای تعاملی از منحنی سرمایه و تخصیص سبد سهام.
استقرار و ارائه	Streamlit □ رابط داشبوردی. FastAPI □ REST API برای ارائه مدل. requests □ ارتباط با API. gdown □ تبادل مدل‌ها/داده‌ها با Google Drive.
ابزار کمکی	Python logging □ ثبت و مدیریت گزارش‌ها برای بازتولیدپذیری.

جدول (۵-۱) خلاصه ابزارها و چارچوب‌های مورد استفاده در پیاده‌سازی.

به طور کلی، این مجموعه ابزارها یک زنجیره کامل برای توسعه، آموزش، ارزیابی و استقرار سامانه معاملاتی فراهم کرده است. ابزار FinRL امکان **نمونه‌سازی سریع** و ایجاد محیط‌های معاملاتی استاندارد را فراهم می‌کند. کتابخانه‌های Stable-Baselines3 و PyTorch ستون اصلی برای آموزش پایدار الگوریتم‌های یادگیری تقویتی هستند که با استفاده از آن‌ها می‌توان مدل‌هایی مانند PPO و RPPPO را به صورت قابل اعتماد پیاده‌سازی و اجرا کرد. برای گردآوری خودکار داده‌ها، از yfinance برای دریافت داده‌های مالی OHLCV و از Selenium برای جمع‌آوری اخبار مالی (مانند Google News) استفاده شد. این داده‌ها سپس توسط کتابخانه‌هایی مانند pandas و numpy پردازش و آماده‌سازی شدند و اندیکاتورهای فنی با کمک ta محاسبه گردیدند. ابزار wandb نقش کلیدی در ردیابی دقیق آزمایش‌ها ایفا کرد و امکان ثبت نمودارها، مقایسه نسخه‌های مختلف مدل و مدیریت سوابق آزمایش‌ها را فراهم آورد. همچنین برای بهینه‌سازی خودکار ابرپارامترها از Optuna استفاده شد تا کارایی مدل‌ها در داده‌های اعتبارسنجی افزایش یابد. در نهایت، برای استقرار عملی، از Streamlit به عنوان رابط کاربری داشبوردی برای نمایش نتایج و از FastAPI به عنوان سرویس پشتی برای ارائه مدل‌ها و پاسخ به درخواست‌ها استفاده شد. ابزارهایی مانند requests و gdown نیز برای برقراری ارتباط با API و تبادل مدل‌ها/داده‌ها با Google Drive به کار گرفته شدند. این ترکیب از ابزارها و چارچوب‌ها باعث شد چرخه کامل از جمع‌آوری داده تا استقرار نهایی عامل معاملاتی به صورت منسجم، بازتولیدپذیر و کارآمد پیاده‌سازی شود.

۵-۳- بازتولیدپذیری و محیط

آزمایش‌ها با استفاده از Python، همراه با PyTorch و Stable-Baselines3 اجرا شدند. محیط محاسباتی از پردازنده گرافیکی (GPU) پشتیبانی می‌کرد. از آن‌جا که seedهای تصادفی در همه کتابخانه‌ها به طور کامل ثابت نشده بودند، نتایج اجرای تکی می‌توانند به دلیل عوامل تصادفی در یادگیری تقویتی (مانند مقداردهی اولیه مدل، فرآیند اکتشاف و تفاوت‌های سخت‌افزاری در GPU) کمی متفاوت باشند. برای کاهش این مشکل، هر آزمایش چند بار تکرار شد و میانگین نتایج در ۱۰ اجرا گزارش شد تا نتایج قابل اعتمادتر باشند. برای تضمین بازتولیدپذیری داده‌ها، تاریخ دقیق دریافت داده‌های Yahoo Finance ثبت شد و زمان جمع‌آوری تمام اخبار Google News ذخیره گردید. همه زمان‌ها به UTC تبدیل شدند و در فرآیند مهندسی ویژگی‌ها از هرگونه نگاه به آینده اجتناب شد.

۵-۴- سخت‌افزار و منابع محاسباتی

آزمایش‌ها با ترکیبی از منابع ابری برای آموزش و استنتاج، و یک لپ‌تاپ محلی برای استقرار و تست سبک انجام شدند. **Kaggle (آموزش)**. بخش اصلی آموزش یادگیری تقویتی در محیط نوت‌بوک Kaggle انجام شد. این محیط مجهز به (16 GB VRAM) NVIDIA Tesla P100 GPU، حداکثر 13 GB RAM و حدود 73 GB فضای دیسک بود. از آنجا که فضای دیسک در Kaggle فقط از طریق Datasets/Notebooks پایدار است، مدل‌ها و گزارش‌ها بعد از هر اجرا به طور خارجی ذخیره می‌شدند.

Google Colab Pro (استنتاج مدل‌های زبانی). Colab Pro فقط برای وظایف پردازش زبان طبیعی استفاده شد، مانند استنتاج با مدل‌های زبانی بزرگ (FinGPT و FinBERT) به منظور استخراج احساس از اخبار Google News. برای این کار به یک محیط با حافظه بالا (52 GB RAM) و یک NVIDIA A100 GPU.

(40 GB VRAM) نیاز بود تا استنتاج دسته‌ای سریع‌تر انجام شود. آموزش عامل‌های $\square\square$ روی Colab Pro انجام نشد.

لپ‌تاپ محلی (استقرار). برای استقرار و تست نسخه نهایی سیستم، از یک لپ‌تاپ شخصی با Ubuntu 22.04، مجهز به پردازنده Intel، 16 GB RAM و یک NVIDIA MX140 GPU (2 GB VRAM) استفاده شد. این سیستم برای اجرای مدل‌های آموزش‌دیده از طریق FastAPI و نمایش نتایج در Streamlit مناسب بود، اما توان کافی برای آموزش در مقیاس بزرگ نداشت.

پیکربندی محاسباتی. در طول آموزش، بین ۱ تا ۴ محیط موازی در Stable-Baselines3 به کار گرفته شد. اندازه دسته‌ها (batch size) بین ۲۵۶ تا ۱۰۲۴ بود و کل گام‌های زمانی بین 400,000 تا 2.5 میلیون بسته به الگوریتم تغییر می‌کرد. هر آزمایش به‌طور مستقل ۳ تا ۱۰ بار تکرار شد تا اثر تصادفی بودن پوشش داده شود. زمان آموزش هر اجرا بسته به پردازنده گرافیکی، الگوریتم و تنظیمات بین حدود ۳۰ دقیقه تا ۳ ساعت متغیر بود.

۵-۵ - جمع‌بندی

در این فصل چارچوب فنی پژوهش توضیح داده شد. ابزارها و محیط‌های محاسباتی معرفی شدند و تدابیری برای بازتولیدپذیری نتایج مورد توجه قرار گرفت. این بستر فنی، زمینه لازم برای اجرای آزمایش‌ها و تحلیل نتایج در فصل‌های بعدی را فراهم می‌سازد.

فصل ۶

آزمایش‌ها و نتایج

۶-۱- تحلیل ایستایی: قیمت‌های پایانی در مقابل بازدهی‌ها

۶-۱-۱- روش‌شناسی

برای بررسی این‌که در مدل‌سازی از سطوح قیمتی یا بازدهی‌ها استفاده شود، آزمون ریشه واحد Augmented Dickey-Fuller (ADF) اعمال شد. فرض صفر H_0 بیان می‌کند که سری شامل ریشه واحد است (یعنی ناپایستا است). این آزمون روی قیمت‌های پایانی تعدیل‌شده روزانه و بازدهی‌های لگاریتمی آن‌ها برای چهار سهم از شاخص Dow Jones (AAPL, BA, GS, JPM) در بازه زمانی 2010-01-01 تا 2025-09-07 اجرا گردید. انتخاب طول وقفه‌ها به‌صورت خودکار بر اساس معیار AIC انجام شد.

۶-۱-۲- نتایج

جدول (۶-۱) نتایج آزمون ADF را خلاصه می‌کند. برای هر چهار سهم، سری قیمت پایانی دارای مقادیر p -value بزرگ‌تر از 0.05 هستند، که نشان می‌دهد نمی‌توان فرض صفر وجود ریشه واحد را رد کرد. این موضوع حاکی از ناپایستگی قیمت‌هاست. در مقابل، سری بازدهی‌های لگاریتمی آماره‌های آزمون به‌شدت منفی و p -value بسیار کوچک‌تر از 0.01 دارند؛ بنابراین فرض صفر رد می‌شود و می‌توان نتیجه گرفت که بازدهی‌ها ایستا هستند.

جدول (۶-۱) نتایج آزمون ADF برای قیمت‌های پایانی و بازدهی‌های لگاریتمی (2010-2025).

	Stationary	Non-stationary	0-0.0000	0.0000.0000	0.000000	0.000000 (%)
AAPL	Stationary	Non-stationary	0.000	0.735	0.991	33
AAPL	Log Return	Close Price	-16.602	0.735	0.991	33
BA	Stationary	Non-stationary	0.000	-1.818	0.371	34
BA	Log Return	Close Price	-12.967	-1.818	0.371	34
GS	Stationary	Non-stationary	0.000	1.895	0.999	31
GS	Log Return	Close Price	-24.675	1.895	0.999	31
JPM	Stationary	Non-stationary	0.000	2.377	0.999	29
JPM	Log Return	Close Price	-17.571	2.377	0.999	29

۶-۱-۳ بحث

یافته‌ها با نتایج شناخته‌شده در اقتصادسنجی مالی هماهنگ هستند: سطوح قیمت دارایی‌ها معمولاً روند تصادفی دارند و ناپایستا هستند، در حالی که بازدهی‌های لگاریتمی رفتار ایستا دارند. بنابراین در این پروژه بازدهی‌ها به جای قیمت‌ها برای نمایش حالت و محاسبه پاداش در یادگیری تقویتی استفاده شدند. در مواردی که نیاز به قیمت باشد (مثل محاسبه ارزش سبد سهام)، از روش‌هایی مانند تفاضل‌گیری یا همسان‌سازی (نرمال‌سازی) استفاده می‌شود تا مشکل ناپایداری کاهش یابد.

۶-۲ تحلیل علیت: مدل‌های احساسی و بازدهی‌های بازار

۶-۲-۱ روش‌شناسی

برای بررسی اینکه آیا اطلاعات احساسی به توضیح پویایی‌های بازار کمک می‌کند، از آزمون Granger Causal-ity Test در چارچوب Vector Autoregression (VAR) استفاده شد. - برای هر سهم (AAPL, BA, GS, JPM)، بازدهی‌های لگاریتمی روزانه به عنوان متغیر وابسته در نظر گرفته شدند. - امتیازهای احساسی FinBERT و FinGPT (با میانگین متحرک نمایی ۷ روزه و نیمه‌عمر ۵.۲ روز) به عنوان متغیرهای پیش‌بین وارد شدند. - طول وقفه بهینه با استفاده از معیارهای اطلاعاتی (AIC, BIC, HQIC) و حداکثر ۱۰ وقفه انتخاب شد. - دو آزمون انجام گرفت: ۱. بررسی اینکه هر کدام از FinBERT یا FinGPT به طور جداگانه بازدهی‌ها را Granger-cause می‌کنند. ۲. بررسی اینکه این دو مدل به طور مشترک بازدهی‌ها را Granger-cause می‌کنند.

۶-۲-۲ نتایج

جدول (۶-۲) آماره‌های F-stat و p-value را نشان می‌دهد. نتایج برای هر سهم متفاوت است: - FinGPT AAPL اثر معناداری دارد ($p = 0.021$)، در حالی که FinBERT ندارد. آزمون مشترک بسیار قوی است ($p < 0.001$) و نشان می‌دهد ترکیب دو منبع احساس پیش‌بینی را بهبود می‌دهد. - BA هیچ کدام از مدل‌ها اثر معناداری به تنهایی ندارند. آزمون مشترک نیز بی‌معناست ($p = 0.333$). - GS هیچ کدام از مدل‌ها اثر معناداری نشان نمی‌دهند؛ همه p-value‌ها بزرگ‌تر از ۱۹.۰ هستند.

- JPM: هر دو مدل نزدیک به معناداری هستند ($0.07 \approx p \leq 0.08$). آزمون مشترک در سطح ۵٪ معنادار است ($p = 0.028$).

جدول (۲-۶) آزمون‌های Granger Causality برای اثر امتیازهای احساسی FinBERT و FinGPT بر بازدهی سهام.

Stock	Predictor	F-stat	p-value
AAPL	FinBERT	1.387	0.197
	FinGPT	2.259	0.021
	Joint	2.812	<0.001
BA	FinBERT	0.865	0.565
	FinGPT	1.791	0.057
	Joint	1.107	0.333
GS	FinBERT	1.307	0.227
	FinGPT	0.668	0.739
	Joint	1.271	0.196
JPM	FinBERT	1.754	0.072
	FinGPT	1.723	0.078
	Joint	1.728	0.028

۳-۲-۶ بحث

در کل، نتایج نشان می‌دهد: - سیگنال‌های احساسی برای سهام مختلف اثر یکسانی ندارند. - FinGPT معمولاً قوی‌تر از FinBERT ظاهر می‌شود (مثلاً برای AAPL و JPM). - اگرچه هر مدل به تنهایی همیشه قوی نیست، ترکیب آن‌ها (آزمون مشترک) می‌تواند قدرت توضیحی بیشتری ایجاد کند.

به عنوان یک فرضیه، می‌توان گفت دلیل عملکرد ضعیف‌تر در مورد BA و GS این است که منابع خبری مرتبط با این شرکت‌ها محدودتر هستند و پوشش خبری آن‌ها تنوع و عمق کافی ندارد. در مقابل، شرکت‌هایی مانند AAPL و JPM بسیار بیشتر و دقیق‌تر در رسانه‌ها پوشش داده می‌شوند؛ به همین دلیل سیگنال‌های احساسی برای آن‌ها واضح‌تر و باکیفیت‌تر بوده و اثر پیش‌بینی‌کننده بهتری ایجاد کرده‌اند.

این موضوع بیانگر آن است که عامل‌های یادگیری تقویتی بهتر است از چند منبع احساس استفاده کنند، نه اینکه تنها به یک مدل متکی باشند.

۳-۶ ارزیابی عامل معاملات: الگوریتم‌ها، محیط‌ها و پیکربندی‌ها

۳-۶-۱ مروری بر ابعاد آزمایش

PPO در مقابل RPPO. الگوریتم Proximal Policy Optimization (PPO) به عنوان روش پایه‌ی on-policy استفاده شد. نسخه‌ی توسعه‌یافته‌ی آن، یعنی Regularized PPO (RPPO)، با افزودن جمله‌های منظم‌ساز طراحی شده است تا پایداری آموزش و توانایی تعمیم مدل به شرایط جدید را بهبود دهد.

بازدهی خام نرمال شده در مقابل پاداش لگاریتمی تعدیل شده. پاداش بازدهی خام نرمال شده بر اساس بازدهی های نرمال شده در سطح سبد سهام محاسبه می شود. در مقابل، پاداش لگاریتمی تعدیل شده از لگاریتم بازدهی های یک مرحله ای استفاده می کند تا زیان های بزرگ جریمه شوند و حساسیت به ریسک بهتر نمایش داده شود.

محیط تک گانه در مقابل محیط های برداری. در پیکربندی تک محیطی، عامل در هر به روز رسانی تنها با یک مسیر بازار آموزش می بیند. اما در پیکربندی برداری (3-env)، سه محیط به طور موازی اجرا می شوند. این کار هم کارایی نمونه گیری را افزایش می دهد و هم باعث می شود عامل با شرایط متنوع تری از بازار روبه رو شود.

دوره های عادی در مقابل دوره های تصادفی. دوره های عادی از تاریخ شروع و طول ثابت پیروی می کنند. در مقابل، در دوره های تصادفی، تاریخ شروع و طول دوره های به طور تصادفی انتخاب می شوند (حداقل 1500 گام). این روش تنوع بیشتری در داده های آموزشی ایجاد می کند و یادگیری را واقع بینانه تر می سازد.

پیش از ارائه نتایج باید اشاره کرد که هر پیکربندی چندین بار (بین 10 تا 15 اجرای مستقل) تکرار شد تا اثر تصادفی بودن در آموزش یادگیری تقویتی کاهش یابد. اعداد گزارش شده به صورت میانگین روی اجراها محاسبه شده اند تا مقایسه ها قابل اعتماد باشند.

آزمون های بازآزمایی (backtest) در بازه ی زمانی 2023-01-03 تا 2025-08-29 انجام شدند. در ادامه، نتایج بر اساس الگوریتم، نوع پاداش، پیکربندی محیط و ساختار دوره های بررسی می شوند.

۶-۳-۲- نتایج آزمایش

در این بخش، جداول مربوط به معیارهای ارزیابی برای هر یک از پیکربندی های آزمایشی ارائه شده اند. تحلیل و تفسیر دقیق تر این نتایج در فصل هشتم (بحث و تحلیل) مورد بررسی قرار خواهد گرفت.

جدول (۶-۳) نتایج PPO پاداش بازدهی خام نرمال شده □ محیط تک گانه □ دوره های عادی

Mean ± Std	Metric
25.65 ± 4.47	Annualized Return [%]
20.46 ± 1.07	Annualized Volatility [%]
-24.78 ± 1.82	Max Drawdown [%]
-5.33 ± 0.57	Average Drawdown [%]
1.22 ± 0.19	Sharpe Ratio
1.58 ± 0.24	Sortino Ratio
1.04 ± 0.19	Calmar Ratio
127.60 ± 19.68	Max Drawdown Duration (days)
122.50 ± 58.41	Number of Trades

جدول (۴-۶) نتایج PPO پاداش بازدهی خام نرمال شده □ محیط تک‌گانه □ دوره‌های تصادفی

Mean ± Std	Metric
21.35 ± 4.97	Annualized Return [%]
19.25 ± 2.13	Annualized Volatility [%]
-23.43 ± 1.94	Max Drawdown [%]
-6.05 ± 1.58	Average Drawdown [%]
1.11 ± 0.22	Sharpe Ratio
1.48 ± 0.29	Sortino Ratio
0.91 ± 0.20	Calmar Ratio
182.70 ± 88.75	Max Drawdown Duration (days)
124.70 ± 47.89	Number of Trades

جدول (۵-۶) نتایج PPO پاداش بازدهی خام نرمال شده □ محیط‌های برداری (۳-محیط) □ دوره‌های عادی

Mean ± Std	Metric
19.10 ± 3.98	Annualized Return [%]
21.25 ± 1.35	Annualized Volatility [%]
-24.33 ± 2.20	Max Drawdown [%]
-7.79 ± 1.21	Average Drawdown [%]
0.93 ± 0.14	Sharpe Ratio
1.24 ± 0.18	Sortino Ratio
0.79 ± 0.18	Calmar Ratio
250.20 ± 108.01	Max Drawdown Duration (days)
139.60 ± 11.89	Number of Trades

جدول (۶-۶) نتایج PPO پاداش‌بازدهی خام نرمال‌شده محیط‌های برداری (۳-محیط) دوره‌های تصادفی

Mean $\pm$ Std	Metric
20.89 $\pm$ 4.75	Annualized Return [%]
19.21 $\pm$ 2.86	Annualized Volatility [%]
-23.24 $\pm$ 2.86	Max Drawdown [%]
-5.62 $\pm$ 1.48	Average Drawdown [%]
1.09 $\pm$ 0.16	Sharpe Ratio
1.45 $\pm$ 0.20	Sortino Ratio
0.90 $\pm$ 0.15	Calmar Ratio
154.25 $\pm$ 69.62	Max Drawdown Duration (days)
154.00 $\pm$ 33.93	Number of Trades

جدول (۷-۶) نتایج PPO پاداش پاداش لگاریتمی تعدیل‌شده محیط تک‌گانه دوره‌های عادی

Mean $\pm$ Std	Metric
24.38 $\pm$ 8.64	Annualized Return [%]
20.52 $\pm$ 1.45	Annualized Volatility [%]
-25.03 $\pm$ 0.82	Max Drawdown [%]
-6.26 $\pm$ 2.13	Average Drawdown [%]
1.16 $\pm$ 0.35	Sharpe Ratio
1.55 $\pm$ 0.47	Sortino Ratio
0.97 $\pm$ 0.33	Calmar Ratio
192.00 $\pm$ 113.68	Max Drawdown Duration (days)
127.80 $\pm$ 47.99	Number of Trades

جدول (۸-۶) نتایج PPO پاداش پاداش لگاریتمی تعدیل شده محیط‌های برداری (۳-محیط) دوره‌های عادی

Mean $\pm$ Std	Metric
21.97 $\pm$ 8.12	Annualized Return [%]
20.84 $\pm$ 1.39	Annualized Volatility [%]
-25.33 $\pm$ 0.92	Max Drawdown [%]
-6.44 $\pm$ 2.55	Average Drawdown [%]
1.05 $\pm$ 0.31	Sharpe Ratio
1.40 $\pm$ 0.40	Sortino Ratio
0.86 $\pm$ 0.30	Calmar Ratio
214.50 $\pm$ 134.69	Max Drawdown Duration (days)
135.75 $\pm$ 38.51	Number of Trades

جدول (۹-۶) نتایج RPPO پاداش بازدهی خام نرمال شده محیط تک‌گانه دوره‌های عادی

Mean $\pm$ Std	Metric
22.67 $\pm$ 5.21	Annualized Return [%]
19.68 $\pm$ 1.73	Annualized Volatility [%]
-24.53 $\pm$ 1.58	Max Drawdown [%]
-5.85 $\pm$ 1.62	Average Drawdown [%]
1.14 $\pm$ 0.23	Sharpe Ratio
1.53 $\pm$ 0.31	Sortino Ratio
0.93 $\pm$ 0.21	Calmar Ratio
175.00 $\pm$ 99.07	Max Drawdown Duration (days)
85.30 $\pm$ 30.01	Number of Trades

جدول (۶-۱۰) نتایج RPPO پاداش بازدهی خام نرمال شده □ محیط تک گانه □ دوره های تصادفی

Mean ± Std	Metric
22.05 ± 3.40	Annualized Return [%]
19.05 ± 1.94	Annualized Volatility [%]
-24.13 ± 1.45	Max Drawdown [%]
-5.57 ± 1.36	Average Drawdown [%]
1.16 ± 0.20	Sharpe Ratio
1.56 ± 0.26	Sortino Ratio
0.92 ± 0.16	Calmar Ratio
142.33 ± 58.01	Max Drawdown Duration (days)
112.17 ± 35.53	Number of Trades

جدول (۶-۱۱) نتایج RPPO پاداش بازدهی خام نرمال شده □ محیط های برداری (۳-محیط) □ دوره های عادی

Mean ± Std	Metric
28.62 ± 2.23	Annualized Return [%]
19.60 ± 1.69	Annualized Volatility [%]
-25.11 ± 2.97	Max Drawdown [%]
-4.48 ± 0.40	Average Drawdown [%]
1.39 ± 0.04	Sharpe Ratio
1.83 ± 0.11	Sortino Ratio
1.14 ± 0.06	Calmar Ratio
99.80 ± 8.84	Max Drawdown Duration (days)
89.80 ± 36.19	Number of Trades

جدول (۱۲-۶) نتایج RPPO پاداش بازدهی خام نرمال شده □ محیط‌های برداری (۳-محیط) □ دوره‌های تصادفی

Mean ± Std	Metric
25.26 ± 6.75	Annualized Return [%]
19.52 ± 1.06	Annualized Volatility [%]
-24.32 ± 1.56	Max Drawdown [%]
-5.24 ± 1.89	Average Drawdown [%]
1.26 ± 0.33	Sharpe Ratio
1.71 ± 0.46	Sortino Ratio
1.04 ± 0.31	Calmar Ratio
146.00 ± 94.41	Max Drawdown Duration (days)
75.00 ± 65.87	Number of Trades

جدول (۱۳-۶) نتایج RPPO پاداش پاداش لگاریتمی تعدیل شده □ محیط تک‌گانه □ دوره‌های عادی

Mean ± Std	Metric
25.47 ± 4.32	Annualized Return [%]
20.18 ± 1.94	Annualized Volatility [%]
-25.33 ± 2.01	Max Drawdown [%]
-5.21 ± 0.72	Average Drawdown [%]
1.23 ± 0.17	Sharpe Ratio
1.64 ± 0.26	Sortino Ratio
1.00 ± 0.11	Calmar Ratio
120.60 ± 24.14	Max Drawdown Duration (days)
85.80 ± 39.42	Number of Trades

جدول (۱۴-۶) نتایج RPPO پاداش پاداش لگاریتمی تعدیل شده □ محیط‌های برداری (۳-محیط) □ دوره‌های عادی

Mean ± Std	Metric
27.01 ± 3.13	Annualized Return [%]
19.48 ± 1.33	Annualized Volatility [%]
-25.46 ± 2.07	Max Drawdown [%]
-4.90 ± 0.68	Average Drawdown [%]
1.33 ± 0.12	Sharpe Ratio
1.79 ± 0.18	Sortino Ratio
1.06 ± 0.04	Calmar Ratio
117.25 ± 15.95	Max Drawdown Duration (days)
119.25 ± 31.69	Number of Trades

۴-۶ جمع‌بندی

در این بخش، جداول مقایسه‌ای کلی از حالت‌های مختلف ارائه شدند. تفسیر و تحلیل عمیق‌تر نتایج به فصل هشتم (بحث و تحلیل) موکول می‌شود.

جدول (۱۵-۶) مقایسه کلی عملکرد PPO و RPPO در سناریوهای مختلف

Max Drawdown [%]	Calmar	Sortino	Sharpe	Volatility [%]	Annualized Return [%]	Condition
-24.78 ± 1.82	1.04 ± 0.19	1.58 ± 0.24	1.22 ± 0.19	20.46 ± 1.07	25.65 ± 4.47	PPO - Raw - 1env - Normal
-23.43 ± 1.94	0.91 ± 0.20	1.48 ± 0.29	1.11 ± 0.22	19.25 ± 2.13	21.35 ± 4.97	PPO - Raw - 1env - Random
-24.33 ± 2.20	0.79 ± 0.18	1.24 ± 0.18	0.93 ± 0.14	21.25 ± 1.35	19.10 ± 3.98	PPO - Raw - 3env - Normal
-23.24 ± 2.86	0.90 ± 0.15	1.45 ± 0.20	1.09 ± 0.16	19.21 ± 2.86	20.89 ± 4.75	PPO - Raw - 3env - Random
-25.03 ± 0.82	0.97 ± 0.33	1.55 ± 0.47	1.16 ± 0.35	20.52 ± 1.45	24.38 ± 8.64	PPO - Log - 1env - Normal
-25.33 ± 0.92	0.86 ± 0.30	1.40 ± 0.40	1.05 ± 0.31	20.84 ± 1.39	21.97 ± 8.12	PPO - Log - 3env - Normal
-24.53 ± 1.58	0.93 ± 0.21	1.53 ± 0.31	1.14 ± 0.23	19.68 ± 1.73	22.67 ± 5.21	RPPO - Raw - 1env - Normal
-24.13 ± 1.45	0.92 ± 0.16	1.56 ± 0.26	1.16 ± 0.20	19.05 ± 1.94	22.05 ± 3.40	RPPO - Raw - 1env - Random
-25.11 ± 2.97	1.14 ± 0.06	1.83 ± 0.11	1.39 ± 0.04	19.60 ± 1.69	28.62 ± 2.23	RPPO - Raw - 3env - Normal
-24.32 ± 1.56	1.04 ± 0.31	1.71 ± 0.46	1.26 ± 0.33	19.52 ± 1.06	25.26 ± 6.75	RPPO - Raw - 3env - Random
-25.33 ± 2.01	1.00 ± 0.11	1.64 ± 0.26	1.23 ± 0.17	20.18 ± 1.94	25.47 ± 4.32	RPPO - Log - 1env - Normal
-24.90 ± 2.07	1.06 ± 0.04	1.79 ± 0.18	1.33 ± 0.12	19.48 ± 1.33	27.01 ± 3.13	RPPO - Log - 3env - Normal

جدول (۱۶-۶) مقایسه میانگین عملکرد PPO و RPPO

Max Drawdown [%]	Calmar	Sortino	Sharpe	Volatility [%]	Annualized Return [%]	Algorithm
-24.36 ± 0.80	0.91 ± 0.09	1.45 ± 0.12	1.09 ± 0.10	20.26 ± 0.57	22.22 ± 2.39	PPO (avg)
-24.81 ± 0.44	1.01 ± 0.08	1.68 ± 0.13	1.25 ± 0.09	19.58 ± 0.28	25.18 ± 2.33	RPPO (avg)

جدول (۱۷-۶) مقایسه میانگین عملکرد Raw در برابر پاداش لگاریتمی تعدیل شده

Max Drawdown [%]	Calmar	Sortino	Sharpe	Volatility [%]	Annualized Return [%]	Reward Type
-24.23 ± 0.56	0.96 ± 0.11	1.55 ± 0.17	1.16 ± 0.15	19.75 ± 0.82	23.20 ± 3.08	Raw (avg)
-25.29 ± 0.14	0.97 ± 0.06	1.60 ± 0.12	1.19 ± 0.09	20.26 ± 0.29	24.71 ± 2.12	Log (avg)

جدول (۱۸-۶) مقایسه میانگین عملکرد محیط تک‌گانه در برابر محیط‌های برداری (۳-محیط)

Max Drawdown [%]	Calmar	Sortino	Sharpe	Volatility [%]	Annualized Return [%]	Env
-24.54 ± 0.42	0.96 ± 0.06	1.56 ± 0.10	1.17 ± 0.07	19.86 ± 0.62	23.60 ± 1.77	1env (avg)
-24.63 ± 0.79	0.96 ± 0.12	1.57 ± 0.16	1.18 ± 0.13	19.98 ± 0.90	23.81 ± 2.74	3env (avg)

جدول (۱۹-۶) مقایسه میانگین عملکرد دوره‌های عادی در برابر دوره‌های تصادفی

Max Drawdown [%]	Calmar	Sortino	Sharpe	Volatility [%]	Annualized Return [%]	Regime
-24.99 ± 0.44	0.97 ± 0.09	1.57 ± 0.16	1.18 ± 0.13	20.25 ± 0.57	24.36 ± 2.94	Normal (avg)
-23.78 ± 0.41	0.94 ± 0.06	1.55 ± 0.10	1.16 ± 0.07	19.26 ± 0.21	22.39 ± 1.77	Random (avg)

فصل ۷

بحث و تحلیل

۷-۱- مقدمه

۷-۲- تحلیل نقش منبع احساسات

نتایج آزمون‌های Granger Causality نشان می‌دهد که اثر سیگنال‌های احساسی بسته به نوع سهام و منبع استخراج احساسات متفاوت است. به‌طور کلی، FinGPT در مقایسه با FinBERT عملکرد قوی‌تری داشته است؛ برای نمونه، در سهام AAPL و به‌ویژه BA توان پیش‌بینی FinGPT به‌مراتب بهتر بوده و در حالی که FinBERT عملکرد ضعیفی داشته، FinGPT توانسته است نتایج معناداری ارائه دهد. در سهام JPM عملکرد هر دو مدل تقریباً مشابه بوده و تفاوت معناداری مشاهده نشده است. در مقابل، در سهام GS که از نظر حجم و کیفیت پوشش خبری ضعیف‌تر است، هر دو مدل عملکرد پایینی داشته‌اند و حتی FinGPT نیز نتوانسته بهبود چشمگیری ایجاد کند. همچنین نتایج ترکیب ویژگی‌های دو مدل نشان می‌دهد که در اغلب موارد، استفاده از ترکیب FinBERT و FinGPT قدرت توضیحی بیشتری ایجاد می‌کند و نتوانسته است در مقایسه با هر یک از مدل‌ها به‌تنهایی، روابط معنادارتری را آشکار سازد. تنها در مورد سهام BA این ترکیب نسبت به FinGPT بهبود محسوس‌تری نداشته است. در مجموع می‌توان گفت:

- سیگنال‌های احساسی در سهام مختلف اثر یکسانی ندارند و کیفیت و حجم داده‌های خبری نقش کلیدی ایفا می‌کند.
- FinGPT معمولاً کارآمدتر از FinBERT است، به‌ویژه در سهامی با پوشش خبری گسترده مانند AAPL یا در مواردی که FinBERT ضعیف عمل می‌کند (مانند BA).
- ترکیب منابع مختلف احساس به‌طور معمول نتایج بهتری به همراه دارد و نشان می‌دهد که عامل‌های یادگیری تقویتی بهتر است به جای تکیه بر یک منبع منفرد، از چندین منبع احساسات به صورت هم‌زمان استفاده کنند.

۷-۳- مقایسه با مدل‌های سنتی

- پیش از تحلیل نتایج، به‌طور خلاصه روش‌های سنتی مورد استفاده به‌عنوان خط مبنا معرفی می‌شوند:
- Buy & Hold (BH): خرید و نگهداری دارایی در کل بازه بدون تغییر سبد سهام.
 - Equal-Weight (EW): تخصیص مساوی سرمایه به تمام دارایی‌ها، بدون توجه به ریسک یا بازده تاریخی.

□ DIJA: شاخص Dow Jones Industrial Average به عنوان نماینده ای از عملکرد کلی بازار.
 □ Mean-Variance Optimization (MVO): بهینه سازی سبد سهام بر اساس میانگین و واریانس بازده تاریخی برای بیشینه سازی نسبت بازده به ریسک.

جدول (۷-۱) مقایسه عملکرد مدل پیشنهادی با روش های سنتی

مقیاس	میانگین بازده	واریانس	نسبت بازده به ریسک	میانگین بازده	واریانس	نسبت بازده به ریسک	میانگین بازده	واریانس	نسبت بازده به ریسک
۳۹.۱	۹۹.۱	۵۳.۱	۱۰.۳	۳۵.۲۵	۲۱.۲۱	۱۷.۲۵	۴۴.۱۲۲	۴۵.۳۷	۳۰.۱۰۹
۷۸.۰	۳۴.۱	۹۵.۰	۱۷۷	۳۷.۱۶	۶۸.۱۳	۷۴.۱۲	۴۵.۳۷	۴۵.۳۷	۳۰.۱۰۹
۲۳.۱	۰.۲۰۲	۴۸.۱	۱۲۱	۰.۳۲۶	۲۳.۲۰	۱۰.۳۲	۳۰.۱۰۹	۳۰.۱۰۹	۳۰.۱۰۹
۹۳.۰	۵۲.۱	۱۶.۱	۱۳۲	۹۱.۲۶	۰.۱۲۱	۹۵.۲۴	۵۷.۸۰	۵۷.۸۰	۵۷.۸۰
۰.۶۱	۷۳.۱	۲۳.۱	۹۹	۹۷.۲۶	۴۷.۲۰	۵۲.۲۸	۵۸.۹۴	۵۸.۹۴	۵۸.۹۴

جدول (۷-۱) عملکرد بهترین مدل پیشنهادی را در مقایسه با روش های سنتی شامل Buy & Hold (BH)، سبد سهام هم وزن (EW)، شاخص DIJA و بهینه سازی میانگین-واریانس (MVO) نشان می دهد. به طور کلی، مدل پیشنهادی در مقایسه با سه رویکرد نخست (BH، EW و DIJA) بهبود قابل توجهی در معیارهای بازده، نسبت های ریسک-بازده و کنترل افت سرمایه ارائه می دهد. این امر نشان می دهد که عامل مبتنی بر یادگیری تقویتی قادر است با بهره گیری از سیگنال های غنی تر و پویاتر، محدودیت های روش های ساده را برطرف سازد.

در مقابل، مقایسه با MVO نتایج متفاوتی به همراه داشته است. در بازه ی زمانی 2023-2025، این روش در برخی معیارها مانند بازده سالانه و نسبت شارپ عملکردی هم تراز یا حتی بهتر از مدل پیشنهادی نشان داده است. دلیل اصلی این موضوع به ماهیت MVO بازمی گردد: این روش به طور خاص برای بیشینه سازی نسبت بازده به ریسک طراحی شده و هنگامی که بازار روندی نسبتاً پایدار و صعودی داشته باشد (مانند رالی سهام آمریکا در سال های 2023 و 2024)، نتایج آن بسیار مطلوب ظاهر می شود.

با این حال، نقاط ضعف بنیادین MVO نباید نادیده گرفته شود. این روش بر تخمین های تاریخی میانگین و کوواریانس متکی است که به شدت پرنویز بوده و پایداری اندکی دارند؛ در نتیجه، تغییر کوچک در بازه ی داده می تواند به سبد سهام کاملاً متفاوتی منجر شود. علاوه بر این، MVO یک رویکرد ایستا محسوب می شود و توانایی سازگاری با تغییر رژیم های بازار را ندارد. در مقابل، عامل یادگیری تقویتی قابلیت به روزرسانی و انطباق پویاتر را داراست و می تواند در بازه های طولانی تر یا شرایط پرنوسان برتری خود را نشان دهد.

به بیان دیگر، هرچند MVO در این بازه ی خاص نتایج چشمگیری به دست آورده است، اما این امر بیشتر بازتابی از شرایط بازار و مفروضات خوش بینانه ی آن است. نقطه قوت اصلی مدل پیشنهادی در پایداری و انعطاف پذیری بلندمدت آن نهفته است، نه الزاماً در بیشینه سازی بازده در یک بازه ی محدود.

۷-۴ - مقایسه روش پیشنهادی با سایر پژوهش ها

از آن جا که بازه ی معاملاتی این پژوهش 2023-2025 انتخاب شده، یافتن مطالعاتی با شرایط آزمایشی کاملاً یکسان دشوار است. با این حال، نتایج روش پیشنهادی با پژوهش [۱۱] مقایسه می شود.

این پژوهش مشابه کار حاضر از سیگنال های احساسی استفاده کرده است، اما تفاوت اصلی در آن بهره گیری از روش های لغوی برای استخراج احساسات بوده، در حالی که در این تحقیق از مدل های زبانی بزرگ مانند FinBERT و FinGPT استفاده شده است. همچنین، تعریف فضای اکشن جدید، اعمال کنترل های ریسک و استفاده از الگوریتم های پیشرفته تر مانند RPPO از دیگر نوآوری های این پژوهش محسوب می شوند.

جدول (۲-۷) مقایسه نتایج روش پیشنهادی و پژوهش مرجع بر اساس بازده سالانه و نسبت شارپ

Sharpe Ratio	Annualized Return [%]	Approach
1.39	28.62	Proposed Method (Best RPPO Config.)
2.07	22.05	Sentiment-Aware ADDPG (Reference)

بر اساس جدول (۲-۷)، بازده سالانه‌ی روش پیشنهادی (28.62%) بالاتر از پژوهش مرجع (22.05%) است. از سوی دیگر، نسبت شارپ در پژوهش مرجع مقدار 2.07 گزارش شده که بالاتر از مقدار متناظر در این پژوهش (1.39) است.

به طور کلی، روش پیشنهادی توانسته بازدهی بیشتری نسبت به کار مرجع به دست آورد، هرچند نسبت‌های ریسک-بازده در پژوهش مرجع در سطح بالاتری قرار داشته است. یکی دیگر از پژوهش‌های بسیار مشابه با کار حاضر، مطالعه‌ی [۳۰] است. این تحقیق با هدف بهبود عملکرد شبکه‌های بازگشتی، از xLSTM به جای LSTM برای طراحی سیاست‌ها استفاده کرده است. بازه‌ی آزمایشی در این پژوهش 2022-2024 بوده که از نظر زمانی نزدیک به بازه‌ی تحقیق حاضر است و امکان مقایسه نسبی مناسبی فراهم می‌کند.

جدول (۳-۷) مقایسه روش پیشنهادی با پژوهش مبتنی بر xLSTM

Sharpe Ratio	Annualized Return [%]	Approach
1.39	28.62	Proposed Method (Best RPPO Config.)
1.65	26.50	xLSTM-based DRL (Reference)

بر اساس جدول (۳-۷)، بازده سالانه‌ی روش پیشنهادی (28.62%) اندکی بالاتر از پژوهش مبتنی بر xLSTM (26.50%) است. این امر نشان می‌دهد که روش حاضر از نظر سودآوری نسبی عملکرد بهتری داشته است. از سوی دیگر، نسبت شارپ در مطالعه‌ی مرجع (1.65) کمی بالاتر از روش پیشنهادی (1.39) گزارش شده است که بیانگر پایداری نسبی بیشتر بازده در آن روش است.

بهبود اصلی پژوهش مبتنی بر xLSTM جایگزینی این شبکه با LSTM بوده که منجر به افزایش نسبت شارپ و بهبود کنترل ریسک شده است، هرچند از نظر سودآوری همچنان پایین‌تر از روش حاضر باقی مانده است. در مجموع، روش پیشنهادی این تحقیق با بهره‌گیری از مدل‌های زبانی بزرگ و طراحی اجزای جدید توانسته است بازدهی بهتری ارائه دهد و از نظر ریسک نیز رقابتی ظاهر شود.

۵-۷- تحلیل پیکربندی‌ها

بررسی میانگین نتایج نشان می‌دهد که الگوریتم RPPO به‌طور کلی عملکرد بهتری نسبت به PPO دارد. این برتری هم در معیار بازده سالانه و هم در شاخص‌های ریسک-بازده مانند نسبت شارپ و سورتیو مشاهده می‌شود، در حالی که میزان بیشینه افت سرمایه در هر دو الگوریتم تقریباً مشابه باقی مانده است. به بیان دیگر، استفاده از RPPO منجر به سودآوری بالاتر و پایداری بیشتر نسبت به نسخه‌ی استاندارد PPO شده است.

مقایسه میان انواع تابع پاداش نشان می‌دهد که استفاده از پاداش خام (Raw) نسبت به نسخه‌ی لگاریتمی (Log-Risk Adjusted) نتایج متعادلی ارائه می‌دهد. اگرچه پاداش لگاریتمی در برخی شاخص‌ها اندکی بهبود ایجاد کرده است، اما تفاوت‌ها معنادار نبوده و در مجموع نمی‌توان گفت که این تغییر به بهبود پایدار معیارهای ریسک منجر شده است.

در زمینه‌ی طراحی محیط، استفاده از محیط‌های برداری (سه‌محیط) در مقایسه با محیط تک‌گانه باعث بهبود جزئی در معیارهای بازده و نسبت‌های ریسک‌بازده شده است. این تفاوت در برخی پیکربندی‌ها مشهودتر بوده و نشان می‌دهد که بهره‌گیری از چند محیط موازی می‌تواند فرایند یادگیری عامل را تقویت کند.

بررسی دوره‌های آموزشی نشان داد که استفاده از دوره‌های تصادفی در مقایسه با دوره‌های عادی به بهبود معناداری در معیارهای کلیدی منجر نشد. اگرچه انتظار می‌رفت افزایش تنوع سناریوهای بازار در فرایند آموزش بتواند قابلیت تعمیم عامل را تقویت کند، اما در نتایج به‌دست‌آمده تفاوت چشمگیری میان دو رویکرد مشاهده نشد. این موضوع بیانگر آن است که در چارچوب آزمایش‌های حاضر، عامل به اندازه‌ی کافی توانسته است با شرایط بازار سازگار شود و تصادفی‌سازی دوره‌ها اثر قابل‌توجهی بر عملکرد نهایی نداشته است.

در نهایت باید تأکید کرد که این مقایسه‌ها بر اساس کل بازه‌ی داده انجام شده‌اند. برای دستیابی به نتایج دقیق‌تر و تحلیل‌های عمیق‌تر، بررسی این پیکربندی‌ها بر روی بازه‌های زمانی متفاوت ضروری خواهد بود.

۷-۶- روش‌های ارزیابی

یکی از چالش‌های اساسی در پژوهش‌های حوزه معامله‌گری مبتنی بر یادگیری تقویتی، نحوه ارزیابی عملکرد مدل هاست. رایج‌ترین رویکرد، اجرای backtest روی یک بازه زمانی ثابت از داده‌های تاریخی است. هرچند این روش ساده، قابل‌اجرا و مقایسه‌پذیر است، اما محدودیت‌های جدی دارد که می‌تواند نتایج پژوهش را گمراه‌کننده سازد:

❑ **وابستگی به بازه انتخابی.** نتایج بک‌تست به‌شدت به بازه زمانی انتخاب‌شده وابسته‌اند. یک مدل ممکن است در یک دوره خاص عملکردی عالی نشان دهد، اما در بازه‌ی دیگر با ساختار متفاوت بازار (مانند دوره‌های صعودی یا نزولی شدید) عملکرد ضعیفی داشته باشد.

❑ **عدم پوشش تغییر رژیم‌ها.** بازارهای مالی ماهیتی پویا دارند و اغلب وارد رژیم‌های متفاوت می‌شوند (مثلاً بحران‌های مالی، رکود، رونق، یا دوره‌های کم‌نوسان). ارزیابی در یک بازه ثابت نمی‌تواند تاب‌آوری مدل در برابر چنین تغییراتی را نشان دهد.

❑ **ریسک بیش‌برازش.** وقتی مدل تنها روی یک بازه مشخص اعتبارسنجی یا آزمون می‌شود، خطر بیش‌برازش به همان دوره افزایش می‌یابد. در نتیجه مدلی که در بک‌تست نتایج عالی دارد، ممکن است در شرایط واقعی کارایی خود را از دست بدهد.

❑ **نبود دیدگاه آینده‌نگر.** بازدهی پایدار در بازار نیازمند ارزیابی‌های پویاتر است. صرفاً اتکا به یک بک‌تست ایستا نمی‌تواند نشان دهد که آیا مدل در مواجهه با داده‌های برخط یا در شرایط غیرمنتظره نیز کارآمد خواهد بود.

بنابراین، استفاده از روش‌های ارزیابی پیشرفته‌تر ضرورت دارد. برخی مسیرهای پیشنهادی عبارت‌اند از:

❑ **بک‌تست متحرک (Rolling/Walk-forward analysis):** تقسیم داده‌ها به چندین پنجره زمانی و اجرای ارزیابی در طول دوره‌های پشت‌سرهم برای بررسی پایداری عملکرد.

❑ **تحلیل رژیم‌های بازار:** آزمون مدل در شرایط متفاوت بازار (مانند بحران‌ها یا رونق‌های قیمتی) برای سنجش تاب‌آوری.

❑ **Paper trading** یا داده‌های زنده: اجرای مدل در محیط‌های برخط (بدون ریسک واقعی) برای مشاهده عملکرد در شرایط واقعی و جاری بازار.

به طور خلاصه، تکیه بر یک بک تست ایستا نه تنها محدودکننده است بلکه می تواند تصویری بیش از حد خوش بینانه از عملکرد مدل ارائه دهد. برای رسیدن به نتایج معتبر و کاربردی، ضروری است از رویکردهای متنوع و پویا در ارزیابی استفاده شود که قابلیت تعمیم مدل به شرایط متغیر بازار را بسنجند.

۷-۷- جمع بندی

در این فصل نتایج حاصل از آزمایش ها و مقایسه های مختلف ارائه و تحلیل شد. ابتدا عملکرد روش پیشنهادی در مقایسه با مدل های سنتی بررسی گردید که نشان داد عامل مبتنی بر یادگیری تقویتی توانسته است نسبت به روش هایی همچون Buy & Hold، سبد سهام هم وزن و شاخص DIJA برتری معناداری داشته باشد، هرچند در مقایسه با MVO نتایج بسته به بازه ی زمانی متفاوت بوده است. سپس نقش استفاده از داده های احساسی تحلیل شد که بیانگر برتری نسبی FinGPT نسبت به FinBERT و همچنین کارایی بالاتر ترکیب این دو منبع در بیشتر موارد بود.

در ادامه، مقایسه روش پیشنهادی با پژوهش های مشابه نشان داد که این روش از نظر بازدهی توانسته است عملکرد رقابتی و حتی برتر ارائه دهد، هرچند در برخی مطالعات نسبت شارپ بالاتری گزارش شده است. همچنین بررسی پیکربندی های مختلف نشان داد که به کارگیری RPPO نسبت به PPO برتری محسوسی داشته است، در حالی که تغییر نوع تابع پاداش یا تعداد محیط ها تنها اثرات جزئی ایجاد کرده اند و استفاده از دوره های تصادفی نیز بهبود چشمگیری به همراه نداشته است. به طور کلی، یافته ها حاکی از آن است که روش پیشنهادی با ترکیب مدل های زبانی بزرگ برای استخراج احساسات، تعریف فضای اکشن جدید، کنترل های ریسک و بهره گیری از الگوریتم های پیشرفته توانسته است سودآوری بالاتر و پایداری نسبت به اغلب رویکردهای مقایسه ای ارائه دهد. این امر نشان می دهد که استفاده از یادگیری تقویتی تقویت شده با داده های احساسی می تواند مسیری مؤثر برای توسعه سامانه های معاملاتی هوشمند در شرایط واقعی بازار باشد.

فصل ۸

نتیجه‌گیری و کارهای آینده

تمامی نتایج، داده‌ها و کدهای این پژوهش به صورت متن‌باز در مخزن زیر در دسترس قرار دارند: <https://github.com/InFluX-M/FinLLMRL>

هدف اصلی این پژوهش بررسی نقش مدل‌های زبانی بزرگ در طراحی عامل‌های یادگیری تقویتی و به کارگیری آن‌ها در بازارهای مالی بود. در این راستا، علاوه بر استفاده از سیگنال‌های متنی مبتنی بر FinBERT و FinGPT، تعریف دقیق فضای حالت، عمل و پاداش و همچنین اعمال کنترل‌های ریسک و بهبود در معماری الگوریتم‌ها (مانند RPPO) مد نظر قرار گرفت. این ترکیب باعث شد چارچوبی نسبتاً کامل برای ارزیابی عملکرد عامل‌های معاملاتی در شرایط مختلف بازار طراحی شود.

نتایج به دست آمده نشان داد که روش پیشنهادی از نظر بازدهی نسبت به بسیاری از پژوهش‌های مشابه عملکرد بهتری داشته است. در عین حال، در برخی معیارهای ریسک‌بازده مانند نسبت شارپ و کنترل افت سرمایه، روش‌های مرجع بهبود نسبی بیشتری نشان دادند. یکی از یافته‌های مهم، برتری نسبی FinGPT نسبت به FinBERT در استخراج سیگنال‌های احساسی بود که اهمیت انتخاب منبع داده‌ی متنی را برجسته می‌کند. همچنین، آزمایش بر روی پیکربندی‌های مختلف (مانند نوع پاداش، تعداد محیط‌های برداری و تصادفی‌سازی دوره‌ها) نشان داد که هرچند تغییرات می‌تواند اثرات جزئی بر نتایج داشته باشد، اما انتخاب الگوریتم مناسب (مانند RPPO) و بهره‌گیری از سیگنال‌های متنی باکیفیت، اثرگذاری بیشتری بر عملکرد کلی دارند.

با این حال، یکی از محدودیت‌های اساسی این پژوهش — و بسیاری از مطالعات مشابه — اتکا به بک‌تست در یک بازه‌ی زمانی ثابت است. اگرچه این روش رایج‌ترین شیوه‌ی ارزیابی در حوزه‌ی معاملات الگوریتمی محسوب می‌شود، اما لزوماً نمی‌تواند بازتاب‌دهنده‌ی پایداری روش در شرایط واقعی بازار یا تغییر رژیم‌های قیمتی باشد. از این رو، نیاز به طراحی روش‌های ارزیابی جامع‌تر و پویا همچنان احساس می‌شود.

کارهای آینده

در ادامه مسیر این پژوهش، می‌توان به چند جهت‌گیری مهم اشاره کرد:

□ طراحی و ارائه‌ی یک چارچوب سیستماتیک برای مقایسه‌ی مدل‌های معاملاتی که بتواند فراتر از بک‌تست ایستا عمل کند و شرایط متنوع بازار (مانند بحران‌ها و تغییر رژیم‌ها) را نیز در نظر بگیرد.

□ بهبود الگوریتم‌های مبتنی بر PPO و استفاده از معماری‌های پیشرفته‌تر، از جمله مدل‌های مبتنی بر Transformer و شبکه‌های بازگشتی عمیق‌تر (xLSTM/LSTM/RNN) برای درک وابستگی‌های زمانی و استخراج نمایش‌های غنی‌تر از حالت.

- بهره‌گیری از الگوریتم‌های یادگیری تقویتی پیشرفته‌تر مانند SAC، DDPG یا رویکردهای هیبریدی که قابلیت مدل‌سازی عدم قطعیت و کنترل ریسک را به‌طور مستقیم در فرایند تصمیم‌گیری وارد می‌کنند.
 - گسترش استفاده از مدل‌های زبانی بزرگ برای کنترل ریسک و نه صرفاً استخراج احساسات؛ برای مثال، استفاده از عامل‌های متنی به‌عنوان ناظر ریسک یا تحلیل‌گر ثانویه در کنار عامل اصلی.
 - ارتقای کیفیت داده‌های متنی از طریق استفاده از منابع خبری معتبرتر و کامل‌تر، و نیز تحلیل محتوای کامل خبر (نه صرفاً تیتر یا خلاصه) برای افزایش دقت سیگنال‌های احساسی.
 - آزمایش چارچوب پیشنهادی بر روی بازارها و دارایی‌های متنوع‌تر، از جمله شاخص‌های بین‌المللی، اوراق قرضه، ارزهای دیجیتال و کالاها، برای بررسی قابلیت تعمیم روش در محیط‌های گوناگون.
 - حرکت به سمت تست‌های نزدیک‌تر به شرایط واقعی بازار از طریق paper trading یا داده‌های برخت، به‌منظور سنجش پایداری و کارایی عملی روش پیشنهادی.
- به‌طور کلی، این پژوهش نشان داد که ترکیب یادگیری تقویتی با مدل‌های زبانی بزرگ ظرفیت بالایی برای بهبود سامانه‌های معاملاتی هوشمند دارد. گام‌های بعدی می‌تواند بر روی تقویت پایداری، افزایش دقت سیگنال‌ها و تعمیم‌پذیری روش در سناریوهای مختلف بازار متمرکز شود.

کتاب نامہ

00 0000000 “0 0000000, 0. 000 000, 0. 00000, 0. 0. 0000000, 0. 0. 00000, 0. 00000, 0. 000, 0. [\]
000 0000000000 000000000, 00000000000000: 0000000000 000 000000 000000000 00000
0. 2. 24 000000: 24. 8. 119. 3, 0000000000 00000 000000000000.”

00000000 000-0000000 0000 00000000 000000000 000000000 “0000000: 000000. 0. 0. [۲]
۰۲۰۱۹ 000000:۱۹۰۸.۱۰۰۶۳, 000000000 00000 0000000.”

[illegible]

0000- 00000000000 00000000000 00 00000000 00000000000000 “0000 0000000, 0-0. [۴]
 .۲۰۲۱ 00000:۲۱.۰۶.۰۰۱۲۳, 000000000 000000 0000000,” 0 000:

[illegible]

0000 0 “00000: 0000, 0. 0. 000 0000, 0. 0000, 0. 00000, 0. 0000, 0. 0000, 0. 000, 0.-0. [6]
000000000000 00 000000 00000 0000000000 000 0000000 00000000 00000000000000
5.2. 00000:5.11.96.7, 00000000 00000 0000000.”

0000- 000 000000000 00000000000000 “0000 00000, 0. 000 00000, 0. 000, 0.-0. 0000, 0. [v]
00000000- 000 000 00 00000000000 00000000.” 00000000 00 0000000: 00000 00000
Y.Y. (00000), 0000000 00 00 00 0000000000 000000

000000 0000000000 000000000000 0000 000000 “0 000, 0. 000 0000, 0. 000, 0. 000, 0. [A]
00000000 00000 00000000.” 0000 00000000 00000 000000 00000000 00000 0000000000
.5.22 00000:22)2.:272),

0000- 0 000000: 000 00 000 “00000000000 000, 0. 000 0000, 0. 00, 0. 000, 0. 0000, 0. [9]
000 00 00000000000 0000000000.” 0000000000 000 0000000000 0000000000 0000000000
.5.2) 000000), 0000000000 (0000-2) 000000000000 0000000000 00 0000000000 0000

“reinforcement-learning” (Sutton and Barto, 2018). [10]
 “reinforcement-learning” (Sutton and Barto, 2018). [10]
 .2022 Reinforcement Learning.

“reinforcement-learning” (Sutton and Barto, 2018). [11]
 “reinforcement-learning” (Sutton and Barto, 2018). [11]
 .2021 Reinforcement Learning, Sutton and Barto.

“reinforcement-learning” (Sutton and Barto, 2018). [12]
 “reinforcement-learning” (Sutton and Barto, 2018). [12]
 .2023 Reinforcement Learning, Sutton and Barto.

“reinforcement-learning” (Sutton and Barto, 2018). [13]
 “reinforcement-learning” (Sutton and Barto, 2018). [13]
 .2024 Reinforcement Learning, Sutton and Barto.

https://www.mathworks.com/help/reinforcement-learning/ug/reinforcement_
 .2025 .learning_diagram.png

“reinforcement-learning” (Sutton and Barto, 2018). [14]
 https://huggingface.co/datasets/huggingface-deep-rl-course/
 .2025 .course-images/resolve/main/en/unit1/exp_2.jpg

“reinforcement-learning” (Sutton and Barto, 2018). [15]
 .2018

“reinforcement-learning” (Sutton and Barto, 2018). [16]
 .1989 Reinforcement Learning, Sutton and Barto.

“reinforcement-learning” (Sutton and Barto, 2018). [17]
 “reinforcement-learning” (Sutton and Barto, 2018). [17]
 .2015 Reinforcement Learning, Sutton and Barto.

“reinforcement-learning” (Sutton and Barto, 2018). [18]
 “reinforcement-learning” (Sutton and Barto, 2018). [18]
 .1999 Reinforcement Learning, Sutton and Barto.

“reinforcement-learning” (Sutton and Barto, 2018). [19]
 .1992 Reinforcement Learning, Sutton and Barto.

